

Universidad Complutense de Madrid
Facultad de Ciencias Matemáticas

Trabajo de Fin de Grado
Doble Grado en Matemáticas y Ciencia de Datos

STRATA: supervisión estadística en tiempo real de un agente de trading basado en LLMs

Autora: Raquel García

Tutor/es: [pendiente]

Curso académico [pendiente] — [fecha pendiente]

Índice general

1. Introducción	3
2. Estado del arte	4
2.1. Agentes LLM para decisiones financieras	4
2.2. Supervisión en tiempo de ejecución de sistemas ML y agentes	5
2.3. Régimen de mercado y gestión de riesgo como capa de control	5
El hueco que llena STRATA	6
3. Marco teórico	7
3.1. Preliminares y notación	7
3.2. STRATA a nivel técnico	8
3.3. Modelos de cambio de régimen: HMM gaussiano	9
3.3.1. Cambio de régimen en series financieras	9
3.3.2. Definición del HMM gaussiano	10
3.3.3. Algoritmo forward	11
3.3.4. Posterior filtrado frente a posterior suavizado	12
3.3.5. Estimación: el algoritmo de Baum-Welch (EM)	13
3.3.6. El algoritmo de Viterbi	14
3.3.7. Selección del número de estados	15
3.4. Volatilidad condicional: ARCH y GARCH(1,1)-t	15
3.4.1. Series temporales y heterocedasticidad condicional	15
3.4.2. De ARCH a GARCH	16
3.4.3. Estacionariedad y varianza incondicional	17
3.4.4. Innovaciones Student-t	19
3.4.5. Estimación por máxima verosimilitud	20
3.5. Detección bayesiana de puntos de cambio (BOCPD)	20
3.5.1. Run-length y detección online	20
3.5.2. Recursión de la distribución de run-length	21
3.5.3. Función de hazard y predictiva conjugada	23
3.6. STRATA aplicado: construcción, calibración y umbrales	23
3.6.1. Datos y calibración	24
3.6.2. RAM: desajuste entre régimen y acción	24
3.6.3. GSO: tamaño compatible con la volatilidad	25
3.6.4. PSA: coherencia temporal del agente	25

3.6.5.	La capa de intervención	26
3.7.	Estrategias supervisadas: aprendizaje sobre las señales	26
3.7.1.	El problema de aprendizaje supervisado	26
3.7.2.	Árboles de decisión	27
3.7.3.	Gradient boosting	27
3.7.4.	XGBoost y el meta-learner M10	28
3.7.5.	Apilamiento y super learner	30
3.7.6.	Búsqueda automatizada: H2O AutoML	30
3.7.7.	Catálogo de estrategias	30
3.8.	Métricas de evaluación	31
3.8.1.	El ratio de Sharpe	31
3.8.2.	Sortino, drawdown máximo y Calmar	31
3.9.	Validación	31
3.9.1.	Causalidad: la regla signal_lag=1	31
3.9.2.	Validación walk-forward (rolling-origin)	32
3.9.3.	Purga y embargo	32
3.9.4.	Por qué no validación cruzada convencional. CPCV	32
3.10.	Contraste de hipótesis	32
3.10.1.	Test del signo binomial	32
3.10.2.	Test de McNemar pareado	32
3.10.3.	Test de Diebold-Mariano	32
3.10.4.	Contrastes de equivalencia	32
3.10.5.	Bootstrap estacionario	32
3.10.6.	Deflated Sharpe Ratio	32
4.	Marco práctico: ¿aporta valor supervisar a un agente LLM?	33
4.1.	Datos, universo y protocolo	33
4.2.	Mecánica ex ante: los tres detectores	34
4.3.	Caso de estudio: SPY	34
4.4.	Generalización y universalidad (panel de quince activos)	36
4.5.	Patrón entre activos: ¿qué estrategia conviene a cada tipo?	37
4.6.	Robustez y honestidad	38
4.7.	Conclusiones del marco práctico	38
5.	Conclusiones	40
5.1.	Límites y trabajo futuro	40
	Bibliografía	41

Capítulo 1

Introducción

Capítulo 2

Estado del arte

2.1. Agentes LLM para decisiones financieras

En pocos años, los grandes modelos de lenguaje han reorganizado campos enteros, de la programación a la medicina, al convertirse en sistemas capaces de razonar sobre texto especializado y no solo de procesarlo. Las finanzas no han sido una excepción. Los modelos de lenguaje empezaron a usarse como motor de decisión financiera cuando se comprobó que un modelo adaptado al dominio podía sostener un razonamiento económico sobre texto, y no limitarse a clasificar el sentimiento de una noticia [1]. El interés se desplazó pronto de si un modelo entiende los mercados a cómo coordinar varios para que decidan en conjunto. La respuesta dominante ha sido la arquitectura multiagente, en la que distintas personalidades inversoras deliberan y un gestor de riesgo modera la posición resultante [2]. Ese gestor de riesgo es interno al agente y heurístico. Vive dentro del mismo sistema que produce la decisión, compartiendo su información y por tanto sus sesgos. La evaluación rigurosa de estos agentes, en cambio, es reciente y todavía escasa. Los trabajos de *benchmarking* sistemático muestran que el rendimiento reportado depende en gran medida del protocolo de medición, y que numerosos resultados optimistas no resisten una validación temporal honesta [3]. Marcos de evaluación como DeepFund miden la decisión del agente sesión a sesión sobre retornos reales y evitan que el modelo se beneficie de haber visto antes esos datos; de ahí se concluye que muchos rendimientos aparentes se desvanecen al aplicar un corte temporal limpio. Validar honestamente en el tiempo exige que el periodo de prueba sea posterior a todo aquello que el modelo pudo haber visto, lo que se conoce como cut off. A esa fragilidad metodológica se añade un sesgo característico de estos modelos, el look-ahead. Cuando el periodo evaluado está dentro del preentrenamiento, el modelo no infiere sino que reproduce lo memorizado, y eso infla las métricas [4]. Para que la evaluación signifique algo, la ventana fuera de muestra (OOS) debe arrancar después del corte de entrenamiento del modelo empleado, decisión de diseño que se retomará en el capítulo 3.

El agente concreto que se estudia, una réplica de AI Hedge Fund con cinco personalidades inversoras, reproduce estos problemas cuando opera sin supervisión externa. Sobre SMCI, el activo del caso de estudio, y en la ventana OOS pierde dinero: su acierto direccional (la fracción de días en que predice correctamente el signo del retorno siguiente) es de 0,484, por debajo del nivel que daría una moneda, y una inversión inicial de €1000 termina en €978.

A este agente sin supervisar lo llamaremos M5 a lo largo de la memoria. Lo más informativo es la estructura de la pérdida, no su magnitud: el agente mantiene posición corta el 95 % de los días, un sesgo direccional casi constante. Que el fallo sea sistemático, y no fruto del azar, es lo que lo hace corregible desde fuera: una posición rígida que apenas atiende a la señal diaria deja margen a una capa que reintroduzca esa información. Ese patrón estructural en las decisiones del agente es el síntoma sobre el que se construye nuestra capa de supervisión.

2.2. Supervisión en tiempo de ejecución de sistemas ML y agentes

Vigilar un sistema mientras decide, y no solo medirlo una vez ha decidido, enlaza con la tradición de la detección de anomalías, cuyo problema central es declarar qué cuenta como comportamiento normal y cuantificar lo que se aparta de él [5]. Esa tradición es necesaria pero no suficiente para el caso que nos ocupa. Detectar una anomalía es señalarla; lo que se busca aquí es además actuar sobre ella en el mismo paso en que se produce. Esa segunda exigencia define la familia del control en tiempo de ejecución (*runtime enforcement*), que impone durante la ejecución un conjunto de restricciones que el agente no puede violar: se especifican condiciones que deben cumplirse y se intercepta cada acción antes de ejecutarla, bloqueando las que las incumplen. Existen ya métodos de este tipo, e incluso marcos de fiabilidad pensados para la IA agéntica que tratan la supervisión como una propiedad del sistema desde su diseño. La comparación con este trabajo es imperfecta, porque parten de objetos de control distintos: las reglas declarativas codifican qué está prohibido, mientras que aquí se modela cómo de coherente es una posición dado el estado del mercado.

Frente a los enfoques basados en reglas, nuestra capa de supervisión recurre a detectores estadísticos clásicos e interpretables que comparan la decisión del agente contra un modelo explícito del mercado. Son tres. RAM (*Regime-Action Mismatch*) juzga la coherencia entre la acción y el régimen de mercado mediante un modelo de Markov oculto; PSA (*Position Sizing Anomaly*) vigila la coherencia temporal del agente con un detector bayesiano de puntos de cambio; y GSO (*GARCH-bounded Sizing Override*) acota la exposición en función de la volatilidad estimada por un GARCH. La definición formal de los tres se tratará en el capítulo 3.

2.3. Régimen de mercado y gestión de riesgo como capa de control

Hamilton introduce la idea de que la serie no responde a un único mecanismo: hay estados con propiedades estadísticas distintas y la serie cambia de estado sin que lo observemos. La distribución de cada retorno depende del estado vigente, que permanece latente [6]. Su utilidad no es meramente descriptiva. Condicionar la asignación de la cartera al régimen estimado mejora las decisiones de forma económicamente apreciable, según una literatura ya consolidada en torno a la persistencia de estos estados y a su efecto sobre la composición óptima del riesgo [7, 8]. Sobre el eje continuo de la volatilidad opera una idea complementaria: dimensionar la posición para alcanzar una volatilidad objetivo (el *volatility targeting*) mejora las propiedades

de la serie de retornos y constituye el ancla teórica del detector GSO [9]. No hay consenso sobre el número de estados: los trabajos previos oscilan entre dos [7] y cuatro [8]. Se adopta una partición de tres regímenes (calma, estrés y crisis): la verosimilitud fuera de muestra descarta con holgura dos estados (Sección 3.3.7), y por encima de tres la ganancia no compensa la pérdida de interpretabilidad de estados nombrables y con lectura económica directa.

El régimen funciona como proxy direccional únicamente de forma condicional, y esa condicionalidad sostiene buena parte de la tesis a la vez que la limita. La condición es el *leverage effect* de los índices agregados: en activos como SPY los estados de alta volatilidad coinciden con tramos bajistas, de modo que conocer el régimen informa también sobre el signo probable del retorno [10, 11]. Esto no convierte al régimen en un predictor del retorno. El régimen no predice; el régimen ordena las decisiones del agente. La coincidencia entre volatilidad alta y caída no se da por igual en valores individuales con apalancamiento financiero débil, donde el efecto se diluye y el régimen pierde poder direccional, lo que delimita el alcance de la técnica y se documenta como limitación del trabajo. De esa tensión entre el estado del mercado, los cambios de opinión del agente y la volatilidad nace el diseño de los detectores que se desarrollan en el capítulo 3.

El hueco que llena STRATA

Estas tres líneas de investigación se han tocado, por separado, nuestra motivación es crear un sistema que las una y supervise en tiempo de ejecución las decisiones de un agente LLM con detectores estadísticos clásicos e interpretables, que lo compare mediante tests pareados contra el mismo agente sin supervisar y que atribuya el efecto a cada detector por separado. Una capa de auditoría que corregirá al agente cuando su decisión contradice un modelo explícito del mercado, cambiando la posición hacia la dirección del régimen y que monitoriza cada corrección. Los tres detectores miden ejes distintos (régimen discreto, coherencia temporal y volatilidad continua) para buscar la ortogonalidad.

Capítulo 3

Marco teórico

Este capítulo reúne la base matemática sobre la que se construye STRATA y fija la notación que usa el resto de la memoria. Tras unos preliminares que establecen la notación el desarrollo se organiza en cuatro bloques. El primero presenta STRATA a nivel técnico: qué supervisa, con qué tres detectores y de qué forma interviene (Sección 3.2). El segundo desarrolla la teoría matemática que sostiene cada detector: el modelo oculto de Markov del régimen (Sección 3.3), el modelo GARCH de la volatilidad (Sección 3.4) y la detección bayesiana de puntos de cambio (Sección 3.5). El tercero construye STRATA sobre esa teoría y fija sus calibraciones y umbrales (Sección 3.6). El cuarto reúne las herramientas de validación: las métricas de evaluación, la ausencia de fuga temporal y los contrastes de hipótesis (Secciones 3.8, 3.9 y 3.10).

3.1. Preliminares y notación

Trabajamos con una serie de precios diarios de un activo. Denotamos por $P_t > 0$ el precio de cierre del día t , con $t \in \{0, 1, \dots, T\}$. La cantidad relevante no es el precio en sí, sino su variación relativa de un día al siguiente. Definimos el *log-retorno*

$$r_t^{\log} = \log\left(\frac{P_t}{P_{t-1}}\right) = \log P_t - \log P_{t-1}, \quad t \geq 1,$$

El log-retorno mide el crecimiento del precio en escala logarítmica; es positivo cuando el precio sube y negativo cuando baja.

Conviene compararlo con el *retorno simple* $R_t = (P_t - P_{t-1})/P_{t-1} = P_t/P_{t-1} - 1$, que es la definición intuitiva, la fracción ganada o perdida. Ambos se relacionan por $r_t^{\log} = \log(1 + R_t)$. La razón de preferir el log-retorno es su aditividad temporal. Consideremos el retorno acumulado entre los días t_0 y $t_0 + n$. En escala logarítmica,

$$\log\left(\frac{P_{t_0+n}}{P_{t_0}}\right) = \log\left(\prod_{j=1}^n \frac{P_{t_0+j}}{P_{t_0+j-1}}\right) = \sum_{j=1}^n \log\left(\frac{P_{t_0+j}}{P_{t_0+j-1}}\right) = \sum_{j=1}^n r_{t_0+j}^{\log}.$$

El log-retorno de varios días es la suma de los log-retornos diarios. El retorno simple, en cambio, se compone de forma multiplicativa, $1 + R_{[t_0, t_0+n]} = \prod_{j=1}^n (1 + R_{t_0+j})$, lo que complica cualquier análisis que sume o promedie a lo largo del tiempo. Esta aditividad es la que justifica modelar

$r_t^{\log}$ en lo que sigue: las sumas de variables aleatorias son más tratables que los productos, y los modelos lineales en el tiempo se expresan de forma natural.

Fijamos también la convención temporal que gobierna toda la validación y todo el back-test. La decisión de cartera tomada con la información disponible hasta el día t no puede recompensarse con el movimiento de ese mismo día, que ya ha ocurrido. Por eso, para evitar el *look-ahead*, el retorno que se contabiliza frente a una posición tomada en t es el del día siguiente,

$$r_{t+1} = \log\left(\frac{P_{t+1}}{P_t}\right).$$

Y así nos aseguramos la ausencia de fuga temporal: de aquí en adelante, todo producto entre una posición y un retorno usará r_{t+1} .

Por último, una medida de cuánto se mueve el activo en un tramo de tiempo. Dada una ventana de h días que termina en t , definimos la *volatilidad realizada*

$$RV_t = \sqrt{\sum_{j=0}^{h-1} (r_{t-j}^{\log})^2},$$

esto es, la raíz de la suma de cuadrados de los log-retornos de la ventana. RV_t es un estimador no paramétrico de la dispersión local de los retornos: crece cuando el activo encadena días de movimientos grandes y se reduce en los tramos planos. A diferencia de la volatilidad condicional σ_t que se introduce en la Sección 3.4, RV_t no presupone ningún modelo; es una lectura directa de los datos.

Las series de retornos financieros no se comportan como ruido blanco gaussiano. Tres regularidades empíricas, documentadas de forma sistemática en la literatura [12], motivan los modelos del resto del capítulo. La primera es que la distribución de los retornos tiene *colas pesadas*: los movimientos extremos son mucho más frecuentes de lo que predice una normal, lo que lleva a sustituir la gaussiana por una distribución de colas anchas como la t de Student en el modelo de volatilidad. El *agrupamiento de volatilidad* es la segunda: los días de gran movimiento tienden a seguirse unos a otros, así que la magnitud de los retornos sí está correlada en el tiempo aunque su signo apenas lo esté, y eso es lo que captura un modelo GARCH. Queda la tercera, la *poca autocorrelación* de los retornos en niveles: casi nula a partir del primer rezago, mientras que sus cuadrados o sus valores absolutos sí la presentan. La combinación de las tres sugiere que el comportamiento del activo alterna entre estados o regímenes con dinámicas distintas, idea que formaliza el modelo de cambio de régimen de la siguiente sección.

3.2. STRATA a nivel técnico

Cada día, el agente de trading toma una decisión sobre el activo. Lo resumimos en una terna: un *signo* (comprar o vender), un *tamaño* y una *confianza*. Esa terna determina una *posición* $w_t \in [-1, +1]$, donde el signo marca la dirección (larga si $w_t > 0$, corta si $w_t < 0$) y el módulo $|w_t|$ es la fracción de capital expuesta; la posición tomada en t se evalúa contra el retorno del día siguiente, $w_t \cdot r_{t+1}$. STRATA no decide por el agente: *supervisa* esa decisión.

Formalmente, si llamamos $\mathcal{A}$ al espacio de decisiones del agente y $\mathcal{M}_t$ a la información de mercado disponible hasta el día t (resumida en $x_{1:t}$), STRATA es la aplicación

$$\text{STRATA}: \mathcal{A} \times \mathcal{M}_t \longrightarrow [0, 1]^3, \quad (w_t, x_{1:t}) \longmapsto (\text{RAM}_t, \text{PSA}_t, \text{GSO}_t),$$

que a partir de la decisión del agente y de una lectura estadística del mercado produce tres *señales* sobre esa decisión, cada una en $[0, 1]$. STRATA no predice el retorno: mide en qué grado la decisión del agente es coherente con el estado del mercado.

Las señales provienen de tres detectores, cada uno a cargo de un eje distinto. **RAM** se centra en el régimen: comprueba si la dirección de la apuesta encaja con el estado de mercado que el modelo oculto de Markov de la Sección 3.3 considera vigente. **PSA** atiende al propio agente; con la detección bayesiana de puntos de cambio vigila si éste cambia de criterio de forma estructural, no por una simple fluctuación. **GSO** se ocupa del tamaño de la apuesta: contrasta el módulo de la posición con la volatilidad que estima el GARCH de la Sección 3.4, y salta cuando la apuesta es grande para lo agitado que está el mercado. Esta ortogonalidad de los tres ejes permite que cada detector vea algo que los otros dos no pueden ver.

La intervención puede ir desde solo registrar la señal hasta encoger la posición o sustituirla por completo. En este trabajo trataremos y analizaremos únicamente la variante más fuerte, que reorienta el signo de w_t hacia el régimen cuando la incoherencia es alta; los modos intermedios quedan sujetos a un posible trabajo futuro. La Sección 3.6 detalla cómo se construye cada señal a partir de su detector y cuándo actúa esta intervención.

Hay que distinguir desde el principio entre la capa de señales y las reglas que las consumen. Cuando escribimos STRATA nos referimos siempre a la capa que produce las señales, mientras que cuando hablamos de M8 o M10 estamos haciendo referencia a las estrategias que la utilizan. **M8** es una regla determinista de umbrales fijos, la capa de intervención que se detalla en la Sección 3.6.5, y la usamos como referencia interpretable. **M10**, en cambio, no aplica umbrales fijos sino que es un modelo de segundo nivel (un *meta-learner*) que toma como entradas las salidas del agente y de los detectores de STRATA, aprende a combinar esas mismas señales para decidir la dirección del día siguiente. Se entrena solo con el pasado y es el objeto central del caso de estudio, que se desarrollará en el capítulo 4.

3.3. Modelos de cambio de régimen: HMM gaussiano

3.3.1. Cambio de régimen en series financieras

Un único modelo con parámetros constantes describe mal una serie financiera larga. Un mercado en tendencia alcista tranquila y un mercado en plena caída no comparten ni media ni volatilidad de los retornos, y forzar un solo conjunto de parámetros para ambos promedia dos comportamientos que conviene separar. La alternativa clásica es admitir que la serie atraviesa distintos *regímenes*, cada uno con su propia ley de probabilidad, y que el régimen vigente cambia en el tiempo de forma no observable directamente. Hamilton formalizó esta idea para series económicas mediante un proceso de Markov sobre los estados no observados [6]: el régimen sigue una cadena de Markov y, condicionado a él, la serie observada se distribuye

según los parámetros de ese régimen.

En el caso que nos ocupa interpretamos los regímenes como estados de mercado: un régimen de *Calma*, con retornos de media ligeramente positiva y volatilidad baja; un régimen de *Estrés*, intermedio; y un régimen de *Crisis*, con volatilidad alta y retorno medio negativo. Esta lectura puede cambiar según el activo, como se discute en la Sección 3.3.7. El instrumento concreto es el modelo oculto de Markov gaussiano, que se define a continuación.

3.3.2. Definición del HMM gaussiano

Un *modelo oculto de Markov* (HMM) consta de una secuencia de estados ocultos y una secuencia de observaciones generadas por esos estados [13, 14]. Sea $z_t \in \{1, \dots, K\}$ el estado oculto (el régimen) en el día t , con K el número de regímenes. La sucesión $\{z_t\}$ es una cadena de Markov homogénea de primer orden: dado el estado en t , el estado en $t + 1$ no depende del pasado anterior,

$$\mathbb{P}(z_{t+1} = j \mid z_t = i, z_{t-1}, \dots, z_1) = \mathbb{P}(z_{t+1} = j \mid z_t = i).$$

Recogemos estas probabilidades en la *matriz de transición* $A \in \mathbb{R}^{K \times K}$, de entradas

$$A_{ij} = \mathbb{P}(z_{t+1} = j \mid z_t = i), \quad A_{ij} \geq 0, \quad \sum_{j=1}^K A_{ij} = 1 \quad \forall i,$$

y la ley del estado inicial en la *distribución inicial* $\pi = (\pi_1, \dots, \pi_K)$ con $\pi_k = \mathbb{P}(z_1 = k)$ y $\sum_k \pi_k = 1$.

El estado no se observa; lo que se observa es x_t , el vector de características del día t (en nuestro caso, el log-retorno y la volatilidad realizada RV_t con ventana de 21 días). Suponemos *emisiones gaussianas*: condicionada al régimen k , la observación es normal multivariante,

$$x_t \mid z_t = k \sim \mathcal{N}(\mu_k, \Sigma_k),$$

con μ_k el vector de medias del régimen k y Σ_k su matriz de covarianzas. Escribimos la densidad de emisión como

$$b_k(x) = \mathcal{N}(x \mid \mu_k, \Sigma_k).$$

El modelo asume dos hipótesis de independencia condicional, palanca de toda derivación posterior. La observación de cada día depende solo del estado de ese día,

$$\mathbb{P}(x_t \mid z_t, z_{t-1}, \dots, z_1, x_{t-1}, \dots, x_1) = \mathbb{P}(x_t \mid z_t) = b_{z_t}(x_t), \quad (*)$$

y la dinámica de los estados es markoviana de primer orden.

El conjunto de parámetros es $\lambda = (A, \pi, \{\mu_k, \Sigma_k\}_{k=1}^K)$. Para una secuencia observada $x_{1:T} = (x_1, \dots, x_T)$ y una trayectoria oculta $z_{1:T}$, la probabilidad conjunta se factoriza según el grafo del modelo:

$$\mathbb{P}(x_{1:T}, z_{1:T} \mid \lambda) = \pi_{z_1} b_{z_1}(x_1) \prod_{t=2}^T A_{z_{t-1}z_t} b_{z_t}(x_t).$$

La verosimilitud de los datos observados se obtiene marginalizando sobre todas las trayectorias ocultas posibles,

$$\mathbb{P}(x_{1:T} \mid \lambda) = \sum_{z_{1:T}} \mathbb{P}(x_{1:T}, z_{1:T} \mid \lambda).$$

Esta suma recorre K^T trayectorias, así que evaluarla término a término es inviable salvo para T minúsculos. El algoritmo *forward* la calcula en tiempo lineal en T .

3.3.3. Algoritmo forward

Definimos la *variable forward*

$$\alpha_t(k) = \mathbb{P}(x_{1:t}, z_t = k \mid \lambda),$$

la masa de probabilidad conjunta que el modelo asigna a la trayectoria de observaciones hasta t y al hecho de estar en el régimen k precisamente en ese instante. La verosimilitud completa se recupera de ella sin más que marginalizar el último estado: $\mathbb{P}(x_{1:T} \mid \lambda) = \sum_k \alpha_T(k)$. El resultado central, clásico en el tratamiento del HMM [13, 15], es que α_t admite una recursión.

Proposición 3.1 (Recursión forward). *Para $t \geq 1$ se tiene la inicialización $\alpha_1(k) = \pi_k b_k(x_1)$ y, para todo $j \in \{1, \dots, K\}$,*

$$\alpha_{t+1}(j) = b_j(x_{t+1}) \sum_{k=1}^K \alpha_t(k) A_{kj}.$$

Demostración. La inicialización es inmediata: $\alpha_1(k) = \mathbb{P}(x_1, z_1 = k) = \mathbb{P}(z_1 = k) \mathbb{P}(x_1 \mid z_1 = k) = \pi_k b_k(x_1)$, usando $(*)$ en el segundo factor.

Para el paso recursivo partimos de la definición e introducimos el estado anterior z_t marginalizando sobre sus K valores posibles:

$$\alpha_{t+1}(j) = \mathbb{P}(x_{1:t+1}, z_{t+1} = j) = \sum_{k=1}^K \mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j).$$

Descomponemos cada sumando separando la última observación x_{t+1} del resto mediante la regla del producto,

$$\mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j) = \mathbb{P}(x_{t+1} \mid x_{1:t}, z_t = k, z_{t+1} = j) \mathbb{P}(x_{1:t}, z_t = k, z_{t+1} = j).$$

Por la independencia condicional de las emisiones $(*)$, la observación x_{t+1} depende solo de su propio estado $z_{t+1} = j$, de modo que el primer factor es

$$\mathbb{P}(x_{t+1} \mid x_{1:t}, z_t = k, z_{t+1} = j) = \mathbb{P}(x_{t+1} \mid z_{t+1} = j) = b_j(x_{t+1}).$$

El segundo factor se descompone a su vez aislando la transición $z_t = k \rightarrow z_{t+1} = j$:

$$\mathbb{P}(x_{1:t}, z_t = k, z_{t+1} = j) = \mathbb{P}(z_{t+1} = j \mid x_{1:t}, z_t = k) \mathbb{P}(x_{1:t}, z_t = k).$$

La Markovianidad de la cadena, junto con la independencia condicional de las emisiones (*), hace que, fijado z_t , el estado z_{t+1} sea independiente de $x_{1:t}$ y de los estados anteriores (es la d-separación en el grafo del modelo); por tanto $\mathbb{P}(z_{t+1} = j \mid x_{1:t}, z_t = k) = A_{kj}$. El factor restante es, por definición, $\alpha_t(k)$. Reuniendo los tres trozos,

$$\mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j) = b_j(x_{t+1}) A_{kj} \alpha_t(k),$$

y al sumar en k el factor $b_j(x_{t+1})$ no depende del índice de la suma y sale fuera:

$$\alpha_{t+1}(j) = b_j(x_{t+1}) \sum_{k=1}^K \alpha_t(k) A_{kj},$$

que es lo que se quería probar. $\square$

La recursión reduce el coste de K^T a $\mathcal{O}(TK^2)$ operaciones: en cada paso se actualizan K variables y cada una suma sobre K términos. En la práctica los $\alpha_t(k)$ decaen exponencialmente con t y se trabaja con su logaritmo o con una normalización por paso para evitar el desbordamiento numérico, pero la estructura de la recursión es la enunciada.

3.3.4. Posterior filtrado frente a posterior suavizado

La variable forward responde a una probabilidad conjunta, pero lo que interesa para decidir es la probabilidad del régimen *dado* lo observado. Definimos el *posterior filtrado*

$$\gamma_t^f(k) = \mathbb{P}(z_t = k \mid x_{1:t}),$$

la probabilidad de estar en el régimen k en el instante t condicionada únicamente a las observaciones disponibles hasta ese instante. Se obtiene normalizando la variable forward sobre los estados [13, 15].

Proposición 3.2 (Filtrado a partir del forward). *Para todo $t \geq 1$ y todo k ,*

$$\gamma_t^f(k) = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)}.$$

Demostración. Por la definición de probabilidad condicional y la de α_t ,

$$\gamma_t^f(k) = \mathbb{P}(z_t = k \mid x_{1:t}) = \frac{\mathbb{P}(x_{1:t}, z_t = k)}{\mathbb{P}(x_{1:t})} = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)},$$

donde en el denominador se ha usado $\mathbb{P}(x_{1:t}) = \sum_j \mathbb{P}(x_{1:t}, z_t = j) = \sum_j \alpha_t(j)$. $\square$

El adjetivo *filtrado* es preciso, y su consecuencia es el eje de toda la memoria.

Corolario 3.3 (Causalidad del filtrado). *Para cada t , el posterior filtrado γ_t^f es función únicamente de las observaciones $x_{1:t}$. En particular, puede calcularse en tiempo real el día t sin recurrir a ninguna observación posterior.*

Demostración. Por la Proposición 3.2, γ_t^f se expresa a través de $\{\alpha_t(j)\}_{j=1}^K$. La inicialización $\alpha_1(k) = \pi_k b_k(x_1)$ depende solo de x_1 y, por la recursión de la Proposición 3.1, cada $\alpha_t(j)$ se obtiene de $\alpha_{t-1}(\cdot)$ y de x_t . Por inducción sobre t , $\alpha_t(j)$ es función de $x_{1:t}$, luego también lo es γ_t^f . $\square$

Así, la estimación del régimen en t condiciona solo sobre el pasado y el presente, nunca sobre el futuro: es *causal* y podría calcularse el mismo día t con la información que existe ese día.

Esto contrasta con el *posterior suavizado*

$$\mathbb{P}(z_t = k \mid x_{1:T}),$$

que condiciona sobre la secuencia completa hasta el final T , incluyendo $x_{t+1:T}$. El suavizado es una estimación mejor del régimen pasado precisamente porque incorpora lo que ocurrió después: el conocimiento del futuro afina el juicio sobre el presente. Se calcula con el algoritmo forward-backward, que combina la variable forward con una variable backward que recorre la secuencia en sentido inverso [16, 13]. Esa misma virtud lo descalifica para nuestro uso. Emplear el suavizado dentro de un sistema de decisión introduciría *look-ahead*: la decisión del día t quedaría contaminada por información de días posteriores que en operativa real no se conocen. Por esta razón, **STRATA usa exclusivamente el posterior filtrado** γ_t^f , nunca el suavizado: solo así, por el Corolario 3.3, el sistema es reproducible en tiempo real.

3.3.5. Estimación: el algoritmo de Baum-Welch (EM)

Hasta aquí se ha supuesto conocido el conjunto de parámetros λ . En la práctica λ debe estimarse a partir de los datos, y como los estados $z_{1:T}$ no se observan no puede maximizarse la verosimilitud directamente. El algoritmo de Baum-Welch resuelve esto como una instancia del esquema de esperanza-maximización (EM): alterna una estimación de los estados ocultos con una reestimación de los parámetros, de forma que la verosimilitud observada no decrece en cada iteración [16, 17].

En el *paso E* (esperanza) se calculan, con los parámetros actuales, los posteriores de los estados y de las transiciones. Se necesitan el posterior suavizado puntual $\mathbb{P}(z_t = k \mid x_{1:T})$ y el posterior suavizado de pares $\mathbb{P}(z_t = i, z_{t+1} = j \mid x_{1:T})$, ambos obtenidos con el algoritmo forward-backward. Aquí sí se emplea el suavizado, y es legítimo: el ajuste del modelo se hace una sola vez, fuera de línea, sobre el periodo de calibración completo, no como parte de una decisión en tiempo real. La causalidad solo se exige en la fase de explotación, donde rige el filtrado.

En el *paso M* (maximización) se reestiman los parámetros maximizando la esperanza calculada en el paso E, lo que da fórmulas cerradas. La distribución inicial y la matriz de transición se actualizan como frecuencias esperadas,

$$\hat{\pi}_k = \mathbb{P}(z_1 = k \mid x_{1:T}), \quad \hat{A}_{ij} = \frac{\sum_{t=1}^{T-1} \mathbb{P}(z_t = i, z_{t+1} = j \mid x_{1:T})}{\sum_{t=1}^{T-1} \mathbb{P}(z_t = i \mid x_{1:T})},$$

y las medias y covarianzas de cada régimen, como promedios ponderados por el posterior del

estado,

$$\hat{\mu}_k = \frac{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T}) x_t}{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T})}, \quad \hat{\Sigma}_k = \frac{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T}) (x_t - \hat{\mu}_k)(x_t - \hat{\mu}_k)^\top}{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T})},$$

donde la media $\hat{\mu}_k$ que interviene en $\hat{\Sigma}_k$ es la ya reestimada en esa misma iteración. Lo que justifica el procedimiento es que ningún paso empeora el ajuste.

Lema 3.4 (Monotonía de EM). *Sea λ' el conjunto de parámetros que produce un paso de EM a partir de λ . Entonces la verosimilitud observada no decrece:*

$$\mathbb{P}(x_{1:T} \mid \lambda') \geq \mathbb{P}(x_{1:T} \mid \lambda).$$

Demostración. Para cualquier parámetro θ descomponemos la log-verosimilitud observada tomando esperanza sobre $z_{1:T}$ con la ley del paso E, $\mathbb{P}(\cdot \mid x_{1:T}, \lambda)$, en la identidad $\log \mathbb{P}(x_{1:T} \mid \theta) = \log \mathbb{P}(x_{1:T}, z_{1:T} \mid \theta) - \log \mathbb{P}(z_{1:T} \mid x_{1:T}, \theta)$, cuyo miembro izquierdo no depende de $z_{1:T}$:

$$\log \mathbb{P}(x_{1:T} \mid \theta) = Q(\theta \mid \lambda) - H(\theta \mid \lambda),$$

con $Q(\theta \mid \lambda) = \mathbb{E}_{z|x,\lambda}[\log \mathbb{P}(x_{1:T}, z_{1:T} \mid \theta)]$ y $H(\theta \mid \lambda) = \mathbb{E}_{z|x,\lambda}[\log \mathbb{P}(z_{1:T} \mid x_{1:T}, \theta)]$. El paso M elige $\lambda' = \arg \max_{\theta} Q(\theta \mid \lambda)$, luego $Q(\lambda' \mid \lambda) \geq Q(\lambda \mid \lambda)$. Por la desigualdad de Gibbs (un caso de la de Jensen),

$$H(\lambda \mid \lambda) - H(\lambda' \mid \lambda) = \text{KL}(\mathbb{P}(\cdot \mid x_{1:T}, \lambda) \parallel \mathbb{P}(\cdot \mid x_{1:T}, \lambda')) \geq 0.$$

Restando ambas descomposiciones,

$$\log \mathbb{P}(x_{1:T} \mid \lambda') - \log \mathbb{P}(x_{1:T} \mid \lambda) = \underbrace{Q(\lambda' \mid \lambda) - Q(\lambda \mid \lambda)}_{\geq 0} + \underbrace{H(\lambda \mid \lambda) - H(\lambda' \mid \lambda)}_{\geq 0} \geq 0. \quad \square$$

El algoritmo itera los pasos E y M hasta que la verosimilitud se estabiliza. Su convergencia a un punto estacionario de la verosimilitud, bajo condiciones de regularidad, es un resultado clásico de la teoría de EM [17]. El óptimo alcanzado es local y depende de la inicialización, de ahí la importancia de fijar la semilla y de partir de una inicialización razonable, como se documenta en el capítulo de metodología.

3.3.6. El algoritmo de Viterbi

El filtrado y el suavizado responden a una pregunta puntual: cuál es la probabilidad del régimen *en un instante dado*. Una pregunta distinta es cuál es la *trayectoria* de estados más probable en su conjunto, esto es, la secuencia $z_{1:T}^*$ que maximiza la probabilidad conjunta a posteriori,

$$z_{1:T}^* = \arg \max_{z_{1:T}} \mathbb{P}(z_{1:T} \mid x_{1:T}, \lambda).$$

Esto es el estimador MAP de la trayectoria completa, y lo resuelve el algoritmo de Viterbi mediante programación dinámica, con una recursión análoga a la del forward que sustituye la suma sobre estados por un máximo [18]. Si $\delta_t(j) = \max_{z_{1:t-1}} \mathbb{P}(z_{1:t-1}, z_t = j, x_{1:t} \mid \lambda)$ es la

probabilidad de la mejor trayectoria que termina en el estado j en el instante t , la recursión es

$$\delta_{t+1}(j) = b_j(x_{t+1}) \max_{1 \leq k \leq K} \delta_t(k) A_{kj}, \quad \delta_1(k) = \pi_k b_k(x_1),$$

y la trayectoria óptima se recupera memorizando en cada paso el estado k que alcanza el máximo y recorriéndolos hacia atrás desde T . La distinción es importante y no anecdótica: encadenar los modos del filtrado instante a instante, $\arg \max_k \gamma_t^f(k)$ para cada t , no produce en general la misma secuencia que Viterbi, porque la concatenación de óptimos puntuales puede dar una trayectoria que la matriz de transición considera improbable o incluso imposible. Viterbi optimiza la trayectoria como un todo y respeta las transiciones. En esta memoria el detector de régimen se apoya en el filtrado puntual por la exigencia de causalidad de la Sección 3.3.4; Viterbi se usa de forma auxiliar para la lectura interpretativa de la secuencia de regímenes sobre el periodo de calibración, donde la trayectoria global es lo que se quiere visualizar.

3.3.7. Selección del número de estados

Queda fijar K , el número de regímenes. Un valor demasiado pequeño no distingue estados de mercado realmente diferentes; uno demasiado grande sobreajusta y fragmenta la serie en regímenes sin contenido interpretable, además de multiplicar los parámetros a estimar. El criterio que seguimos combina dos exigencias. La primera es estadística: para cada candidato de K se ajusta el HMM sobre el tramo de entrenamiento y se evalúa la *log-verosimilitud held-out*

$$\ell_{\text{val}}(K) = \sum_{t \in \text{val}} \log \mathbb{P}(x_t \mid x_{1:t-1}, \hat{\lambda}_K),$$

con $\hat{\lambda}_K$ el modelo de K estados ajustado en el entrenamiento, sobre un tramo de validación posterior en el tiempo, nunca solapado con el de entrenamiento, de modo que la comparación respeta el orden temporal de la serie y no premia el sobreajuste [13]. La segunda es de interpretabilidad: los regímenes resultantes deben admitir una lectura económica clara y estable. Esta decisión se desarrolla en el capítulo siguiente; podemos anticipar que la combinación de ambos criterios fija $K = 3$ como la calibración de referencia del método, con los tres estados ya descritos: calma, estrés y crisis.

3.4. Volatilidad condicional: ARCH y GARCH(1,1)-t

3.4.1. Series temporales y heterocedasticidad condicional

Una serie de retornos financieros es una realización de un *proceso estocástico* en tiempo discreto: una sucesión de variables aleatorias $\{r_t^{\log}\}_{t \geq 1}$ indexada por el tiempo. Modelarla es describir su ley conjunta, que la regla de la cadena factoriza en un producto de distribuciones condicionales,

$$\mathbb{P}(r_{1:T}^{\log}) = \prod_{t=1}^T \mathbb{P}(r_t^{\log} \mid \mathcal{F}_{t-1}),$$

donde $\mathcal{F}_{t-1}$ es la *filtración*, la σ -álgebra generada por el pasado hasta $t - 1$. Modelar las distribuciones condicionales es, por tanto, modelar la conjunta, y es lo que da pie a la verosimilitud condicional de la Sección 3.4.5. El objeto central son su media y su varianza condicionales, $\mathbb{E}[r_t^{\log} | \mathcal{F}_{t-1}]$ y $\text{Var}(r_t^{\log} | \mathcal{F}_{t-1})$, frente a sus versiones *incondicionales* $\mathbb{E}[r_t^{\log}]$ y $\text{Var}(r_t^{\log})$, que no dependen del instante t y nos dan información del comportamiento de la serie [19, 20].

El punto de partida más simple es el *ruido blanco*: una sucesión de media cero, varianza constante e incorrelada a todo rezago. No tiene estructura explotable en sus dos primeros momentos, y un modelo de varianza condicional constante homocedástico hereda esa rigidez. Pero incorrelación no es independencia: un proceso puede ser ruido blanco y, aun así, guardar estructura temporal en momentos de orden superior. Es lo que muestran las regularidades empíricas de la Sección 3.1: el signo de los retornos es casi impredecible (poca autocorrelación en niveles), mientras que su *magnitud* se agrupa en el tiempo, de modo que la varianza condicional depende del pasado. Esta *heterocedasticidad condicional* es la diferencia entre incorrelación e independencia que los modelos ARCH explotan [12].

Modelaremos el retorno como $r_t^{\log} = \mu + \epsilon_t$, separando la media de la *innovación* $\epsilon_t = \sigma_t \eta_t$, con η_t un ruido i.i.d. y toda la dinámica de interés en la varianza condicional $\text{Var}(\epsilon_t | \mathcal{F}_{t-1}) = \sigma_t^2$. Como en niveles los retornos son prácticamente incorrelados, no imponemos dinámica autorregresiva en la media y la tomamos constante; la riqueza del modelo vive en σ_t^2 . La innovación resultante es una *diferencia de martingala*, $\mathbb{E}[\epsilon_t | \mathcal{F}_{t-1}] = 0$: incorrelada, pero no independiente.

Dos nociones de estacionariedad recorren el capítulo. Un proceso con segundo momento finito es *estacionario en covarianza* (o débilmente estacionario) si su media es constante y su autocovarianza $\text{Cov}(r_t^{\log}, r_{t+h}^{\log})$ depende solo del desfase h y no de t ; es *estrictamente estacionario* si la ley conjunta de cualquier bloque $(r_{t_1}^{\log}, \dots, r_{t_k}^{\log})$ es invariante frente a una traslación común de los índices [21]. Bajo segundo momento finito la estricta implica la débil. La estacionariedad en covarianza es la que caracteriza el Teorema 3.5: modelar la varianza condicional como variable en el tiempo es compatible con que el proceso siga siendo estacionario en covarianza, pues su varianza *incondicional* se mantiene constante siempre que los parámetros cumplan la condición $\alpha + \beta < 1$ de ese teorema, aunque la *condicional* fluctúe día a día.

3.4.2. De ARCH a GARCH

El HMM reparte la volatilidad entre unos pocos estados discretos, cada uno con su covarianza Σ_k constante. Esa descripción es útil para clasificar el mercado en regímenes, pero es gruesa: dentro de un mismo régimen la dispersión de los retornos no es fija, sino que sube y baja de forma continua. El agrupamiento de volatilidad descrito entre las regularidades empíricas de la Sección 3.1 pide un modelo en el que la varianza de hoy dependa explícitamente de lo agitado que haya estado el pasado reciente. Ese es el cometido de la familia ARCH/GARCH.

Engle introdujo el modelo *ARCH* (heterocedasticidad condicional autorregresiva) para capturar precisamente este fenómeno [22]. La idea es hacer que la varianza de la innovación $\epsilon_t = r_t^{\log} - \mu$ de la subsección anterior sea función de los errores recientes al cuadrado. En un ARCH de orden q , $\text{ARCH}(q)$, la varianza condicional de la innovación, que denotamos σ_t^2 , se

escribe

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2, \quad \omega > 0, \quad \alpha_i \geq 0,$$

con la convención $\epsilon_t = \sigma_t \eta_t$, donde η_t es un ruido i.i.d. de media 0 y varianza 1 que se especifica más abajo. Denotamos por $\mathcal{F}_t = \sigma(\epsilon_s : s \leq t)$ la filtración generada por las innovaciones hasta t . Que σ_t^2 sea *condicional* significa que es la varianza de ϵ_t dada $\mathcal{F}_{t-1}$: es $\mathcal{F}_{t-1}$ -medible, depende solo del pasado y no del propio ϵ_t . Un error grande en cualquiera de los q días anteriores eleva σ_t^2 , lo que reproduce el agrupamiento: tras un golpe, la volatilidad esperada sube.

La limitación práctica de ARCH es que reproducir la persistencia observada en los datos exige un orden q alto, y con él muchos parámetros α_i que estimar, lo que vuelve el modelo inestable y propenso a violar las restricciones de no negatividad. Bollerslev resolvió esta cuestión generalizando el modelo: el *GARCH* (ARCH generalizado) añade a la recursión términos de la propia varianza condicional pasada, de modo que la persistencia se consigue con pocos parámetros [23]. El modelo elegido será el GARCH(1, 1), la versión más sencilla, la que consigue esa persistencia con menos parámetros, y la más extendida en finanzas. Definimos

$$\epsilon_t = \sigma_t \eta_t, \quad \eta_t \text{ i.i.d.}, \quad \mathbb{E}[\eta_t] = 0, \quad \text{Var}(\eta_t) = 1,$$

y la recursión de la varianza condicional

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \omega > 0, \quad \alpha \geq 0, \quad \beta \geq 0. \quad (3.1)$$

La varianza de hoy combina tres ingredientes: un suelo constante ω , la sorpresa del día anterior ϵ_{t-1}^2 (término ARCH, peso α) y la propia varianza del día anterior σ_{t-1}^2 (término GARCH, peso β). El último es el que aporta memoria larga con un solo parámetro: σ_{t-1}^2 ya resume todo el pasado, así que arrastrarla evita tener que sumar muchos rezagos de ϵ^2 . La cantidad $\sigma_t = \sqrt{\sigma_t^2}$ es la *volatilidad condicional*, la desviación típica de la innovación dada la información hasta $t-1$, y es la que utiliza el detector GSO de la Parte B. Las cifras de volatilidad se reportan *anualizadas*. Una volatilidad diaria es un número pequeño y poco intuitivo; la escala anual es la que se usa en finanzas para comparar activos y leer el riesgo de manera más intuitiva. Para pasar de la diaria a la anual multiplicamos σ_t por $\sqrt{252}$: como las varianzas de días aproximadamente independientes se suman, la desviación típica crece con la raíz del número de días, y el año bursátil tiene unos 252.

3.4.3. Estacionariedad y varianza incondicional

La recursión (3.1) solo define un proceso bien comportado bajo una condición sobre los parámetros. El siguiente resultado la caracteriza y, de paso, da la varianza a largo plazo del proceso.

Teorema 3.5 (Estacionariedad en covarianza del GARCH(1, 1)). *Sea $\{\epsilon_t\}$ el proceso definido por $\epsilon_t = \sigma_t \eta_t$ con $\{\eta_t\}$ i.i.d. de media 0 y varianza 1 y la recursión (3.1), con $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$. Entonces $\{\epsilon_t\}$ admite una solución estacionaria en covarianza con varianza incondicional finita si y solo si*

$$\alpha + \beta < 1,$$

y en ese caso la varianza incondicional vale

$$\text{Var}(\epsilon_t) = \frac{\omega}{1 - \alpha - \beta}.$$

Demostración. Supongamos primero que existe una solución estacionaria en covarianza, lo que significa, en particular, que $\text{Var}(\epsilon_t)$ es finita y no depende de t ; la llamamos $\bar{\sigma}^2 := \text{Var}(\epsilon_t)$. Calculamos la varianza incondicional de ϵ_t por la ley de la varianza total, usando que $\mathbb{E}[\epsilon_t] = 0$ (pues $\mathbb{E}[\epsilon_t] = \mathbb{E}[\sigma_t] \mathbb{E}[\eta_t] = 0$, al ser σ_t función del pasado e independiente de η_t , y $\mathbb{E}[\eta_t] = 0$):

$$\text{Var}(\epsilon_t) = \mathbb{E}[\epsilon_t^2] = \mathbb{E}[\mathbb{E}[\epsilon_t^2 \mid \mathcal{F}_{t-1}]],$$

donde $\mathcal{F}_{t-1}$ es la información hasta $t-1$. Como σ_t es función de $\mathcal{F}_{t-1}$ y η_t es independiente de $\mathcal{F}_{t-1}$ con $\mathbb{E}[\eta_t^2] = \text{Var}(\eta_t) = 1$,

$$\mathbb{E}[\epsilon_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2 \mathbb{E}[\eta_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2,$$

de donde $\mathbb{E}[\epsilon_t^2] = \mathbb{E}[\sigma_t^2]$. La misma identidad aplicada en $t-1$ da $\mathbb{E}[\epsilon_{t-1}^2] = \mathbb{E}[\sigma_{t-1}^2]$. Tomamos ahora esperanzas en la recursión (3.1):

$$\mathbb{E}[\sigma_t^2] = \omega + \alpha \mathbb{E}[\epsilon_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2] = \omega + \alpha \mathbb{E}[\sigma_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2].$$

Por estacionariedad, $\mathbb{E}[\sigma_t^2] = \mathbb{E}[\sigma_{t-1}^2] =: m$, constante en el tiempo. Sustituyendo,

$$m = \omega + (\alpha + \beta) m \iff m(1 - \alpha - \beta) = \omega.$$

Como $\omega > 0$ y $m = \mathbb{E}[\sigma_t^2] = \text{Var}(\epsilon_t) > 0$ es finita, el factor $1 - \alpha - \beta$ ha de ser estrictamente positivo, es decir, $\alpha + \beta < 1$, y entonces

$$\text{Var}(\epsilon_t) = m = \frac{\omega}{1 - \alpha - \beta}.$$

Esto prueba la necesidad de la condición y la fórmula de la varianza.

Recíprocamente, supongamos $\alpha + \beta < 1$ y construyamos una solución estacionaria. Re-escribiendo $\alpha \epsilon_{s-1}^2 + \beta \sigma_{s-1}^2 = (\alpha \eta_{s-1}^2 + \beta) \sigma_{s-1}^2$ e iterando la recursión (3.1) hacia atrás n pasos,

$$\sigma_t^2 = \omega \sum_{i=0}^{n-1} \prod_{l=1}^i (\alpha \eta_{t-l}^2 + \beta) + \left(\prod_{l=1}^n (\alpha \eta_{t-l}^2 + \beta) \right) \sigma_{t-n}^2.$$

En lugar de suponer la solución dada, la *construimos* como la serie

$$\sigma_t^2 := \omega \sum_{i=0}^{\infty} \prod_{l=1}^i (\alpha \eta_{t-l}^2 + \beta),$$

y comprobamos que está bien definida. Los η_{t-l} son i.i.d. con $\mathbb{E}[\alpha \eta_{t-l}^2 + \beta] = \alpha + \beta$ y los factores de cada producto son independientes, de modo que el término i -ésimo tiene esperanza $\omega (\alpha + \beta)^i$. Como todos los sumandos son no negativos, el teorema de convergencia monótona

permite intercambiar esperanza y suma:

$$\mathbb{E}[\sigma_t^2] = \omega \sum_{i=0}^{\infty} (\alpha + \beta)^i = \frac{\omega}{1 - \alpha - \beta} < \infty,$$

y la serie geométrica converge por ser $\alpha + \beta < 1$. La serie que define σ_t^2 converge así en L^1 (y casi seguramente), tiene esperanza finita y constante, y por construirse con las mismas variables i.i.d. desplazadas en el tiempo su ley no depende de t ; además satisface la recursión (3.1). El término residual de la iteración finita, $(\prod_{l=1}^n (\alpha \eta_{t-l}^2 + \beta)) \sigma_{t-n}^2$, tiene esperanza $(\alpha + \beta)^n \mathbb{E}[\sigma_{t-n}^2] \rightarrow 0$, lo que confirma que la serie es el límite de las iteraciones.

Queda ver que $\epsilon_t = \sigma_t \eta_t$ es estacionario en covarianza, esto es, que su media, su varianza y sus autocovarianzas no dependen de t . La media es $\mathbb{E}[\epsilon_t] = \mathbb{E}[\sigma_t] \mathbb{E}[\eta_t] = 0$, y la varianza, $\mathbb{E}[\epsilon_t^2] = \mathbb{E}[\sigma_t^2] = \omega/(1 - \alpha - \beta)$, es finita y constante. Para las autocovarianzas, fijado $h \geq 1$, como η_t es independiente de $\mathcal{F}_{t-1}$ con $\mathbb{E}[\eta_t] = 0$ y ϵ_{t-h} es $\mathcal{F}_{t-1}$ -medible,

$$\mathbb{E}[\epsilon_t \epsilon_{t-h}] = \mathbb{E}[\epsilon_{t-h} \mathbb{E}[\epsilon_t | \mathcal{F}_{t-1}]] = 0, \quad \text{ya que } \mathbb{E}[\epsilon_t | \mathcal{F}_{t-1}] = \sigma_t \mathbb{E}[\eta_t] = 0.$$

Media nula, varianza finita constante y autocovarianzas nulas: el proceso es estacionario en covarianza, lo que cierra la equivalencia [24, 25]. $\square$

La suma $\alpha + \beta$ mide la *persistencia* de la volatilidad: cuán despacio se reabsorbe un golpe. Cuando $\alpha + \beta$ está cerca de 1, la varianza incondicional $\omega/(1 - \alpha - \beta)$ explota y los choques tardan muchísimo en disiparse; en series financieras diarias es habitual estimar valores muy próximos a la unidad, signo de volatilidad muy persistente. El caso límite $\alpha + \beta = 1$ define el modelo *IGARCH* (GARCH integrado) [26], en el que la varianza incondicional ya no es finita y un choque tiene efecto permanente sobre la volatilidad esperada, de forma análoga a una raíz unitaria en la media. En esa frontera el Teorema 3.5 deja de garantizar estacionariedad en covarianza, y la interpretación de σ_t como fluctuación alrededor de un nivel de largo plazo se pierde. Conviene distinguir esta estacionariedad en covarianza, que exige $\alpha + \beta < 1$, de la estacionariedad estricta, que se cumple bajo la condición más débil $\mathbb{E}[\log(\alpha \eta_t^2 + \beta)] < 0$ [24].

3.4.4. Innovaciones Student-t

Falta especificar la ley del ruido η_t . La elección más simple, $\eta_t \sim \mathcal{N}(0, 1)$, reproduce el agrupamiento de volatilidad pero subestima la frecuencia de los movimientos extremos: incluso con varianza variable, un GARCH gaussiano genera colas demasiado finas frente a las que muestran los retornos reales. Como las colas pesadas eran una de las regularidades empíricas de la Sección 3.1, conviene un ruido con colas más anchas. Bollerslev propuso sustituir la normal por una t de Student estandarizada [27].

Tomamos entonces η_t i.i.d. con distribución t de Student de ν grados de libertad, reescalada para tener varianza unidad,

$$\eta_t \sim t_\nu \text{ estandarizada}, \quad \mathbb{E}[\eta_t] = 0, \quad \text{Var}(\eta_t) = 1, \quad \nu > 2.$$

El parámetro ν , los *grados de libertad*, controla el grosor de las colas: cuanto menor es ν , más

probabilidad acumula la distribución en los extremos y más frecuentes son los retornos atípicos. La restricción $\nu > 2$ es necesaria para que la varianza exista y el reescalado a varianza unidad tenga sentido. En el límite $\nu \rightarrow \infty$ la t de Student converge a la normal estándar, de modo que el GARCH(1, 1) gaussiano queda como caso particular del GARCH(1, 1)- t ; estimar ν finito y pequeño indica, dentro del modelo, que las innovaciones estandarizadas tienen colas más pesadas que la gaussiana. Esta es la especificación que se usa en la memoria y la que abrevia el rótulo GARCH(1, 1)- t .

3.4.5. Estimación por máxima verosimilitud

Los parámetros $\theta = (\omega, \alpha, \beta, \nu)$ se estiman por máxima verosimilitud condicional. Sea f_ν la densidad de la t de Student estandarizada de ν grados de libertad. Condicionada a la información hasta $t-1$, la innovación $\epsilon_t = \sigma_t \eta_t$ tiene densidad $\frac{1}{\sigma_t} f_\nu(\epsilon_t / \sigma_t)$, ya que es un cambio de escala de η_t por el factor σ_t , que es conocido en $t-1$. La log-verosimilitud condicional de la muestra $\epsilon_{1:T}$, dado un valor inicial σ_1^2 , es la suma de las contribuciones diarias

$$\ell(\theta) = \sum_{t=1}^T \left[\log f_\nu \left(\frac{\epsilon_t}{\sigma_t} \right) - \log \sigma_t \right],$$

donde cada σ_t se obtiene recorriendo la recursión (3.1) con los parámetros θ en evaluación. El término $-\log \sigma_t$ es el jacobiano del cambio de variable de η_t a ϵ_t . No existe solución cerrada para el máximo, así que se maximiza $\ell(\theta)$ numéricamente sobre la región admisible $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$, $\nu > 2$.

El estimador resultante hereda las buenas propiedades de la máxima verosimilitud bajo condiciones de regularidad. Bajo el modelo correctamente especificado, la condición de estacionariedad del Teorema 3.5 y condiciones adicionales de regularidad (en particular, momentos suficientes de las innovaciones, $\nu > 4$ para el cuarto momento, y un óptimo interior a la región admisible), el estimador máximo-verosímil $\hat{\theta}$ es consistente y asintóticamente normal, con matriz de covarianzas el inverso de la información de Fisher. La prueba de estas propiedades para el GARCH no figura en los trabajos que introducen el modelo, sino en su tratamiento posterior, al que se remite [25]. Conviene una cautela: la normalidad asintótica de $\hat{\alpha}$ y $\hat{\beta}$ se degrada cuando $\alpha + \beta$ se aproxima a la frontera 1, justo el régimen IGARCH discutido arriba, lo que se tiene presente al interpretar los intervalos de confianza de los parámetros estimados en el capítulo de resultados.

3.5. Detección bayesiana de puntos de cambio (BOCPD)

3.5.1. Run-length y detección online

Los dos modelos anteriores miran el mercado. El detector que ahora se introduce mira al *agente*: vigila si la serie de decisiones (en concreto, el tamaño de las posiciones que va tomando) sufre una ruptura estructural, un cambio de comportamiento que no se explica como fluctuación dentro del mismo patrón. El instrumento es la detección bayesiana de puntos de cambio online de Adams y MacKay [28].

Sea $x_{1:t}$ la secuencia observada hasta el día t , donde aquí x_t es la magnitud que se vigila (el tamaño de la posición del agente). Un *punto de cambio* es un instante en el que los parámetros que generan la serie cambian; entre dos puntos de cambio consecutivos la serie se considera generada por un mismo modelo con parámetros fijos. Adoptamos el *modelo de particiones por producto* [28]: los segmentos que delimitan los puntos de cambio son independientes entre sí y, dentro de cada uno, las observaciones son i.i.d. según el modelo del segmento. Esta hipótesis, análoga a la independencia condicional (*) del HMM, es la que sostiene la recursión que sigue. La variable central es la *run-length* r_t , el número de pasos transcurridos desde el último punto de cambio:

$$r_t \in \{0, 1, 2, \dots\}, \quad r_t = 0 \Leftrightarrow \text{hay un punto de cambio en } t,$$

y $r_t = r$ indica que el día actual y los r días previos se atribuyen al mismo segmento, todavía sin ruptura. La run-length crece de uno en uno mientras no hay cambio ($r_t = r_{t-1} + 1$) y se reinicia a 0 cuando lo hay.

La distinción entre detección *online* y *offline* es decisiva para esta memoria. Un detector *offline* dispone de toda la serie $x_{1:T}$ y localiza los cambios mirando hacia delante y hacia atrás; es más preciso, pero no es causal. Un detector *online* estima la run-length usando únicamente $x_{1:t}$, la información disponible en el instante t , sin asomarse al futuro. El método de Adams y MacKay es online por construcción: en cada día actualiza la distribución de r_t a partir de la del día anterior y de la nueva observación. Esta causalidad es exactamente la que exige el detector PSA, igual que el filtrado del HMM frente al suavizado (Sección 3.3.4): una alarma de cambio de comportamiento del agente solo es legítima si pudo emitirse el mismo día, sin conocer lo que el agente hizo después.

3.5.2. Recursión de la distribución de run-length

El objetivo es calcular, de forma online, la distribución posterior de la run-length, $\mathbb{P}(r_t \mid x_{1:t})$. Se obtiene normalizando la conjunta $\mathbb{P}(r_t, x_{1:t})$, que admite una recursión. Necesitamos dos ingredientes. El primero es la *función de hazard* $H(r)$, la probabilidad de que se produzca un cambio dado que el tramo actual lleva ya r pasos sin él,

$$H(r) = \mathbb{P}(r_t = 0 \mid r_{t-1} = r - 1),$$

que gobierna la frecuencia a priori de los puntos de cambio. El segundo es la *predictiva posterior* del modelo de observación dentro de un tramo: dado que la run-length actual es $r_{t-1} = r$, la densidad del nuevo dato condicionada a las observaciones de ese mismo tramo,

$$\pi_{\text{pred}}^{(r)} = \mathbb{P}(x_t \mid r_{t-1} = r, x_{1:t-1}),$$

que se calcula con las observaciones acumuladas desde el último reinicio. Con estos dos elementos derivamos la recursión [28].

Proposición 3.6 (Recursión de Adams–MacKay). *La distribución conjunta de la run-length y los datos satisface, partiendo de $\mathbb{P}(r_{t-1}, x_{1:t-1})$, los dos mensajes siguientes. El mensaje de*

crecimiento (*no hay cambio*, $r_t = r_{t-1} + 1$):

$$\mathbb{P}(r_t = r_{t-1} + 1, x_{1:t}) = \mathbb{P}(r_{t-1}, x_{1:t-1}) (1 - H(r_{t-1} + 1)) \pi_{\text{pred}}^{(r_{t-1})},$$

y el mensaje de reinicio (*hay cambio*, $r_t = 0$):

$$\mathbb{P}(r_t = 0, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_{t-1}, x_{1:t-1}) H(r_{t-1} + 1) \pi_{\text{pred}}^{(r_{t-1})}.$$

La posterior de la run-length se recupera normalizando,

$$\mathbb{P}(r_t \mid x_{1:t}) = \frac{\mathbb{P}(r_t, x_{1:t})}{\sum_r \mathbb{P}(r_t = r, x_{1:t})}.$$

Demostración. Partimos de la conjunta del instante t e introducimos la run-length anterior marginalizando sobre sus valores posibles:

$$\mathbb{P}(r_t, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_t, r_{t-1}, x_{1:t}).$$

Cada sumando se descompone separando la nueva observación x_t del pasado $x_{1:t-1}$ mediante la regla del producto,

$$\mathbb{P}(r_t, r_{t-1}, x_{1:t}) = \mathbb{P}(r_t \mid r_{t-1}, x_{1:t-1}) \mathbb{P}(x_t \mid r_t, r_{t-1}, x_{1:t-1}) \mathbb{P}(r_{t-1}, x_{1:t-1}).$$

El primer factor es la dinámica de la run-length, que por construcción del modelo solo depende de r_{t-1} : dado un tramo de longitud r_{t-1} , en el paso siguiente o bien hay cambio, y entonces $r_t = 0$ con probabilidad $H(r_{t-1} + 1)$, o bien no lo hay, y entonces $r_t = r_{t-1} + 1$ con probabilidad $1 - H(r_{t-1} + 1)$. Es decir,

$$\mathbb{P}(r_t \mid r_{t-1}, x_{1:t-1}) = \begin{cases} H(r_{t-1} + 1), & r_t = 0, \\ 1 - H(r_{t-1} + 1), & r_t = r_{t-1} + 1, \\ 0, & \text{en otro caso.} \end{cases}$$

El segundo factor es la predictiva del dato nuevo dentro del tramo: condicionada a r_{t-1} , y por la independencia entre segmentos, la observación x_t depende solo de las r_{t-1} observaciones del tramo en curso, lo que da $\pi_{\text{pred}}^{(r_{t-1})}$. El tercer factor es la conjunta del paso anterior, ya disponible. En ambos mensajes interviene esta misma predictiva $\pi_{\text{pred}}^{(r_{t-1})}$ porque x_t se evalúa contra el segmento en curso, de longitud r_{t-1} : el reinicio se materializa en la run-length siguiente, $r_t = 0$, no en la pertenencia de x_t , que todavía corresponde a ese segmento.

Como la transición de la run-length concentra toda su masa en dos destinos, la marginalización sobre r_{t-1} se reparte en dos casos. Si $r_t = r_{t-1} + 1 > 0$, solo contribuye el valor concreto $r_{t-1} = r_t - 1$ (no hay otra forma de llegar a esa run-length sin reinicio), de donde

$$\mathbb{P}(r_t = r_{t-1} + 1, x_{1:t}) = \mathbb{P}(r_{t-1}, x_{1:t-1}) (1 - H(r_{t-1} + 1)) \pi_{\text{pred}}^{(r_{t-1})},$$

que es el mensaje de crecimiento. Si $r_t = 0$, contribuyen *todos* los valores de r_{t-1} , pues desde cualquier longitud puede producirse un reinicio, y la suma da

$$\mathbb{P}(r_t = 0, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_{t-1}, x_{1:t-1}) H(r_{t-1} + 1) \pi_{\text{pred}}^{(r_{t-1})},$$

que es el mensaje de reinicio. Finalmente, la posterior se obtiene de la conjunta dividiendo por la verosimilitud marginal del dato, $\mathbb{P}(x_{1:t}) = \sum_r \mathbb{P}(r_t = r, x_{1:t})$, lo que da la normalización del enunciado. $\square$

La recursión es enteramente causal: $\mathbb{P}(r_t, x_{1:t})$ se construye a partir de $\mathbb{P}(r_{t-1}, x_{1:t-1})$ y de la observación x_t , sin recurrir a ningún dato posterior. Por eso sirve para PSA. El soporte de r_t crece un paso en cada iteración, así que en la práctica se trunca la distribución descartando las run-lengths cuya probabilidad cae por debajo de un umbral, lo que mantiene el coste acotado sin alterar de forma apreciable la inferencia.

3.5.3. Función de hazard y predictiva conjugada

Para cerrar el modelo hay que fijar la función de hazard y la predictiva. La elección estándar para la hazard es la *constante*,

$$H(r) = \frac{1}{\lambda}, \quad \lambda > 0,$$

independiente de r . Bajo esta elección la dinámica de la run-length carece de memoria: la probabilidad de que el segmento actual termine en el paso siguiente es siempre $1/\lambda$, sea cual sea el tiempo que lleve vigente. La longitud de cada segmento queda entonces distribuida como una geométrica de parámetro $1/\lambda$ y media λ pasos. El parámetro λ codifica, por tanto, la escala temporal esperada entre rupturas y es el único hiperparámetro de la dinámica.

La predictiva $\pi_{\text{pred}}^{(r)}$ se calcula de forma cerrada eligiendo el modelo de observación dentro de un tramo en una familia exponencial con su *previa conjugada*: la posterior de los parámetros del tramo pertenece entonces a la misma familia que la previa, y la predictiva del dato nuevo tiene expresión analítica que se actualiza de forma incremental al llegar cada observación. Esta conjugación es lo que hace que la recursión de la Proposición 3.6 sea barata de evaluar día a día. La especificación concreta del modelo de observación de PSA se detalla en el capítulo de metodología. Como contexto, el trabajo de Fearnhead sobre inferencia exacta para modelos multipunto desarrolla los métodos de cálculo de estas distribuciones predictivas y de la partición en tramos sobre los que se apoya el enfoque online [29].

3.6. STRATA aplicado: construcción, calibración y umbrales

Cada detector produce una señal numérica que mide un tipo de incoherencia entre la decisión del agente y el estado del mercado; cuando esa señal supera un umbral, STRATA interviene.

3.6.1. Datos y calibración

Los tres modelos se estiman una sola vez, sobre un periodo de calibración fijo y anterior al periodo de evaluación, y no se reentrenan después. Esta separación entre la fase de calibración y producción impide que cualquier parámetro de STRATA haya visto los datos futuros. Fijar un único periodo de calibración presupone que la estructura de la serie es razonablemente estable dentro de él, hipótesis que se puede contrastar con el test de cambios estructurales múltiples de Bai y Perron [30, 31], que localiza el número y la posición de las rupturas en los parámetros de un modelo.

3.6.2. RAM: desajuste entre régimen y acción

El detector RAM mide si la dirección de la apuesta del agente es coherente con el régimen de mercado. Toma como entrada el posterior filtrado γ_t^f de la Sección 3.3.4: para cada día, una distribución de probabilidad sobre los tres regímenes. Lo que falta es asociar esos regímenes a direcciones de mercado, y ahí entra el único ingrediente económico del detector.

En los índices bursátiles agregados, el retorno y la volatilidad están correlados negativamente: los tramos de alta volatilidad coinciden con caídas y los de baja volatilidad con subidas. Black documentó este fenómeno y lo llamó *leverage effect* [10]; Christie lo estudió de forma sistemática [11]. En un índice, por tanto, el régimen de alta volatilidad que identifica el HMM adquiere una lectura direccional: alta volatilidad tiende a significar mercado a la baja. Esa correspondencia es una propiedad de los índices, no una ley universal; en una acción individual el leverage effect es débil y la asociación entre nivel de volatilidad y dirección se diluye. Por eso STRATA no fija la dirección de cada régimen a mano, sino que la aprende del dato: para cada régimen k se toma el signo de su media de log-retorno, esto es, la componente de retorno del vector μ_k estimado en la calibración, de modo que el régimen de media más negativa se asocia a la dirección bajista y el de media más positiva a la alcista. Este prior por activo es lo que permite aplicar RAM a cualquier serie sin suponer que se comporta como un índice.

Con el prior fijado, formalizamos el detector. Para cada régimen k , sea $d_k = \text{sign}((\mu_k)_{\text{ret}}) \in \{-1, 0, +1\}$ su dirección aprendida (el signo de la componente de retorno de μ_k), y sea w_t la posición del agente.

Definición 3.7 (RAM score). El *RAM score* es la masa filtrada sobre los regímenes cuya dirección aprendida contradice la apuesta del agente,

$$\text{RAM}_t = \sum_{k=1}^K \gamma_t^f(k) \mathbf{1}\{\text{sign}(w_t) d_k < 0\} = \mathbb{P}(\text{sign}(w_t) d_{z_t} < 0 \mid x_{1:t}) \in [0, 1].$$

En los tres regímenes de la calibración (Calma alcista, $d = +1$; Crisis bajista, $d = -1$; Estrés neutro, $d = 0$) esto es $\text{RAM}_t = \gamma_t^f(\text{Crisis})$ si el agente va largo y $\text{RAM}_t = \gamma_t^f(\text{Calma})$ si va corto; el Estrés, sin dirección, nunca penaliza. El score vive en $[0, 1]$: cuanto más alto, más probabilidad pone el HMM en que el agente apuesta contra el régimen. El detector se activa con tres umbrales fijados ex ante, 0,25, $\tau = 0,50$ y 0,70, que marcan severidad baja, media y alta. El umbral operativo es el central, $\tau = 0,50$: equivale a intervenir cuando la dirección contraria a la apuesta acumula más de la mitad de la probabilidad de régimen, esto es, a la

regla de mayoría. Además, veremos que en nuestro caso de estudio el score tiende a concentrar su masa cerca de 0 o de 1, de modo que el acierto del detector apenas cambia para umbrales en un entorno de 0,5.

3.6.3. GSO: tamaño compatible con la volatilidad

GSO se ocupa del tamaño de la apuesta: comprueba si es compatible con la volatilidad vigente. Su referencia teórica es el *volatility targeting*, que dimensiona la posición de forma inversamente proporcional a la volatilidad estimada ($\propto 1/\sigma$) para mantener el riesgo aproximadamente constante; Moreira y Muir documentan que una variante de este principio, el escalado por la inversa de la *varianza* ($1/\sigma^2$), mejora el rendimiento ajustado por riesgo [9]. GSO toma la volatilidad condicional σ_t del GARCH(1,1)- t de la Sección 3.4, calculada con información hasta $t - 1$, y la traduce en una banda de tamaño admisible.

Definición 3.8 (Banda de volatilidad y GSO score). Dada una volatilidad objetivo anualizada v^* ($v^* = 0,10$ en la memoria), la *banda* admisible y el *GSO score* son

$$b_t = \min\left(1, \frac{v^*}{\sigma_t}\right), \quad \text{GSO}_t = \frac{\max(0, |w_t| - b_t)}{b_t}.$$

El score mide la sobreexposición relativa: es nulo mientras el tamaño cabe en la banda y crece cuando la supera. GSO emite señal cuando GSO_t rebasa los percentiles 95 y 99 de su distribución sobre el periodo de calibración, y en la intervención recorta el tamaño a $\text{sign}(w_t) \min(|w_t|, b_t)$.

Sobre los datos estudiados, GSO rara vez supera la severidad media: el tamaño que toma el agente casi nunca viola la banda de forma marcada. Es una limitación del detector sobre este activo, que recojo en los resultados.

3.6.4. PSA: coherencia temporal del agente

PSA vigila la coherencia temporal del agente: detecta si cambia de criterio de forma estructural, no como fluctuación dentro de un mismo patrón. Aplica la detección bayesiana de puntos de cambio de la Sección 3.5 a la serie de tamaños de posición del agente, con una función de hazard constante $H = 1/\lambda$, $\lambda = 250$, que fija a priori la escala temporal entre rupturas en un año bursátil, unos 250 días de mercado (la media de la geométrica de la Sección 3.5.3); no es un valor optimizado contra el periodo de evaluación, sino una escala interpretable, fijada como un cambio esperado al año.

Definición 3.9 (PSA score). El *PSA score* es la masa posterior de la run-length sobre las rachas cortas, esto es, la probabilidad de que se haya producido un cambio reciente,

$$\text{PSA}_t = \sum_{r=0}^w \mathbb{P}(r_t = r \mid x_{1:t}),$$

con $w = 5$ la ventana de racha corta (en días de mercado). Crece cuando el *sizing* del agente acaba de romper con su patrón previo.

Los umbrales operativos siguen el mismo criterio que GSO: los percentiles 95 y 99 sobre el periodo de calibración. En la intervención, necesitamos un índice muy alto de PSA para frenar la posición resultante.

3.6.5. La capa de intervención

Las tres señales alimentan la capa de intervención, que transforma la posición w_t en una posición supervisada w_t^* por composición de tres operadores. Sea $\rho_t = +1$ si $\gamma_t^f(\text{Calma}) \geq \gamma_t^f(\text{Crisis})$ y $\rho_t = -1$ en otro caso, la dirección del régimen dominante.

Definición 3.10 (Capa de intervención M8). La posición supervisada es $w_t^* = (C_{\text{PSA}} \circ R_{\text{RAM}} \circ G_{\text{GSO}})(w_t)$, donde cada operador actúa solo si su detector dispara y es la identidad en caso contrario:

$$G_{\text{GSO}}(w) = \text{sign}(w) \min(|w|, b_t), \quad R_{\text{RAM}}(w) = \rho_t b_t, \quad C_{\text{PSA}}(w) = \frac{1}{2} w.$$

El disparo se produce con severidad *medium* o superior para GSO y RAM (es decir, $\text{RAM}_t \geq \tau$) y *high* para PSA.

El GSO acota la magnitud a la banda de volatilidad; el RAM, cuando $\text{RAM}_t \geq \tau$ con $\tau = 0,50$, reorienta la posición al signo del régimen con esa banda (el único paso que cambia la dirección); el PSA frena a la mitad ante un cambio brusco de *sizing*. La intervención trabaja solo con el posterior filtrado del régimen. La regla de referencia M8 es exactamente esta configuración, con `signal_lag = 1`.

3.7. Estrategias supervisadas: aprendizaje sobre las señales

La regla M8 combina las tres señales con umbrales fijos, elegidos de antemano. La pregunta natural es si una combinación *aprendida* de esas mismas señales lo haría mejor: en lugar de fijar los umbrales a mano, un modelo puede estimar de los datos cómo pesar la información del agente y de STRATA para anticipar la dirección del día siguiente. Esa es la estrategia M10, y su generalización mediante búsqueda automatizada de modelos es la estrategia AutoML. Ambas se apoyan en el aprendizaje supervisado por árboles potenciados, que esta sección desarrolla con el mismo nivel de detalle que los modelos de los detectores, porque son el objeto central del capítulo de resultados y porque la objeción natural del tribunal (¿el modelo supervisado bate a STRATA o solo la redescubre?) exige tenerlos bien especificados.

3.7.1. El problema de aprendizaje supervisado

Cada día disponemos de un vector de características $\mathbf{x}_t \in \mathbb{R}^d$ con $d = 22$, que reúne toda la información del día: las ternas de las cinco personalidades del agente (Buffett, Wood, Druckenmiller, Burry y Ackman), cada una con su *signo*, *tamaño* y *confianza*, lo que aporta quince componentes, y las siete lecturas estadísticas de STRATA, a saber las tres señales RAM_t , PSA_t , GSO_t , las tres probabilidades de régimen filtradas $\gamma_t^f(\text{Calma})$, $\gamma_t^f(\text{Estrés})$, $\gamma_t^f(\text{Crisis})$ y la volatilidad

condicional σ_t del GARCH. La etiqueta es la dirección realizada del día siguiente,

$$y_t = \mathbf{1}\{r_{t+1} > 0\} \in \{0, 1\},$$

de modo que el problema es de clasificación binaria causal: a partir de $\mathbf{x}_t$, conocido en t , predecir el signo de r_{t+1} . Un modelo produce una probabilidad estimada $p(\mathbf{x}_t) = \widehat{\mathbb{P}}(y_t = 1 \mid \mathbf{x}_t)$, y la posición asociada es

$$w_t = \text{sign}(p(\mathbf{x}_t) - \frac{1}{2}),$$

larga si el modelo da más de un medio a la subida y corta en caso contrario. Esta capa de segundo nivel, que aprende sobre las salidas de un primer nivel (el agente) en lugar de sobre los precios crudos, es un *meta-learner* en el sentido del *meta-labeling* de López de Prado [32].

El ajuste minimiza la entropía cruzada (o *pérdida logística*) sobre el conjunto de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$,

$$L = - \sum_{i=1}^n [y_i \log p(\mathbf{x}_i) + (1 - y_i) \log (1 - p(\mathbf{x}_i))],$$

que es la verosimilitud negativa del modelo de Bernoulli y penaliza con dureza la confianza mal puesta. La familia de funciones $p(\cdot)$ que adoptamos es la de los árboles de decisión potenciados, que describimos a continuación de lo simple a lo compuesto.

3.7.2. Árboles de decisión

La pieza elemental es el árbol de decisión, una función constante a trozos sobre una partición del espacio de características en regiones rectangulares [33]. Un árbol con T hojas que inducen una partición $\{R_1, \dots, R_T\}$ de $\mathbb{R}^d$ se escribe

$$h(\mathbf{x}) = \sum_{j=1}^T w_j \mathbf{1}\{\mathbf{x} \in R_j\},$$

donde w_j es el valor asignado a la hoja j . Las regiones se construyen de forma recursiva y voraz: en cada nodo se elige la variable y el punto de corte que más reducen una medida de impureza, y se repite sobre los dos hijos hasta un criterio de parada. Un árbol aislado tiene poco sesgo pero mucha varianza, y su frontera escalonada rara vez generaliza bien por sí sola; la potencia aparece al combinar muchos árboles, que es lo que hacen el *boosting* y el apilamiento de las secciones siguientes.

3.7.3. Gradient boosting

El *gradient boosting* construye un predictor aditivo como suma de árboles ajustados en etapas [34]. Partiendo de un valor inicial F_0 , en la etapa m se añade un árbol h_m y se actualiza

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu \gamma_m h_m(\mathbf{x}),$$

con $\nu \in (0, 1]$ la tasa de aprendizaje (*shrinkage*). La idea de Friedman es interpretar el ajuste como un descenso de gradiente en el espacio de funciones: el árbol h_m se ajusta a los *pseudo-residuos*, el gradiente negativo de la pérdida evaluado en el modelo actual,

$$r_{im} = - \left[\frac{\partial L(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)} \right]_{F=F_{m-1}},$$

y el paso γ_m se fija por minimización unidimensional de la pérdida en esa dirección. La siguiente proposición especializa los pseudo-residuos al caso logístico, que es el que usamos, y conecta el boosting con la verosimilitud de Bernoulli.

Proposición 3.11 (Pseudo-residuos del boosting logístico). *Si F es el logaritmo de la razón de momios y $p = \sigma(F) = (1 + e^{-F})^{-1}$ la probabilidad asociada, el pseudo-residuo de la pérdida logística es la diferencia entre la etiqueta y la probabilidad predicha,*

$$r_i = - \frac{\partial L}{\partial F} \Big|_{F(\mathbf{x}_i)} = y_i - p(\mathbf{x}_i).$$

Demostración. Con $p = \sigma(F)$ se tiene $dp/dF = p(1-p)$. La contribución de un dato a la pérdida es $L = -y \log p - (1-y) \log(1-p)$, de donde

$$\frac{\partial L}{\partial p} = -\frac{y}{p} + \frac{1-y}{1-p} = \frac{p-y}{p(1-p)}.$$

Por la regla de la cadena, $\partial L / \partial F = (\partial L / \partial p) p(1-p) = p - y$, y el pseudo-residuo es su opuesto, $y - p$ [34]. $\square$

Así, cada árbol corrige el error de probabilidad acumulado por los anteriores. El *shrinkage* ν y el submuestreo de filas y columnas en cada etapa (*stochastic gradient boosting*) regularizan el ajuste y reducen el sobreajuste [34, 33].

3.7.4. XGBoost y el meta-learner M10

XGBoost es una realización de gradient boosting que añade una regularización explícita sobre la complejidad de cada árbol y usa la curvatura de la pérdida, no solo su gradiente [35]. El objetivo de la etapa t , al incorporar el árbol $f_t(\mathbf{x}) = w_{q(\mathbf{x})}$ definido por su estructura q y sus pesos de hoja w , es

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t), \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2,$$

donde γ penaliza el número de hojas y λ la magnitud de los pesos. Desarrollando la pérdida hasta segundo orden en torno a la predicción acumulada, con gradiente $g_i = \partial_{\hat{y}} l(y_i, \hat{y}_i^{(t-1)})$ y hessiana $h_i = \partial_{\hat{y}}^2 l(y_i, \hat{y}_i^{(t-1)})$, el problema por hoja se vuelve cuadrático y admite solución cerrada.

Proposición 3.12 (Pesos óptimos y ganancia de una división). *Fijada la estructura q , con conjuntos de instancias por hoja $I_j = \{i : q(\mathbf{x}_i) = j\}$ y sumas $G_j = \sum_{i \in I_j} g_i$, $H_j =$*

$\sum_{i \in I_j} h_i$, el peso que minimiza la aproximación de segundo orden del objetivo y el valor óptimo correspondiente son

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \quad \tilde{\mathcal{L}}^*(q) = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T.$$

En consecuencia, dividir una hoja en dos descendientes L y R reduce el objetivo en

$$\text{Gan} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma,$$

que es el criterio con el que se eligen los cortes.

Demostración. La expansión de Taylor de segundo orden de la pérdida y el descarte del término constante $l(y_i, \hat{y}_i^{(t-1)})$ dan

$$\tilde{\mathcal{L}}^{(t)} = \sum_{i=1}^n \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t(\mathbf{x}_i)^2 \right] + \Omega(f_t).$$

Como $f_t(\mathbf{x}_i) = w_j$ para todo $i \in I_j$, se agrupa por hoja,

$$\tilde{\mathcal{L}}^{(t)} = \sum_{j=1}^T \left[G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2 \right] + \gamma T.$$

Para la pérdida logística, la Proposición 3.11 da $g_i = p_i - y_i$ y un cálculo análogo $h_i = p_i(1 - p_i) \geq 0$, luego $H_j + \lambda > 0$ y cada sumando es una parábola convexa en w_j . Su mínimo está en $w_j^* = -G_j/(H_j + \lambda)$, con valor $-\frac{1}{2}G_j^2/(H_j + \lambda)$; sumando sobre las hojas se obtiene $\tilde{\mathcal{L}}^*(q)$. La ganancia de una división es la diferencia entre el objetivo de la hoja madre y el de los dos hijos, que arroja la expresión del enunciado [35]. $\square$

El *meta-learner* M10 del trabajo es XGBoost con esta especificación y los hiperparámetros fijados en la calibración: trescientos árboles de profundidad cuatro, tasa de aprendizaje $\nu = 0,05$, submuestreo de filas y columnas al ochenta por ciento, regularización $\lambda = 1$ y pérdida logística. Para rebajar la varianza del estimador, M10 promedia diez ajustes que solo difieren en la semilla de aleatorización,

$$\bar{p}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B p^{(b)}(\mathbf{x}), \quad B = 10,$$

una forma de agregación cuya reducción de varianza es la del promediado de predictores [36, 33]: si los B ajustes tienen varianza τ^2 y correlación media ϱ , la varianza del promedio es $\varrho \tau^2 + (1 - \varrho) \tau^2/B$, menor que τ^2 siempre que la correlación no sea perfecta. La posición de M10 es $w_t = \text{sign}(\bar{p}(\mathbf{x}_t) - \frac{1}{2})$. El entrenamiento sigue el protocolo *walk-forward* de la Sección 3.9.2, con ventana expandible y embargo 1: cada modelo aprende solo del pasado y predice el tramo siguiente.

3.7.5. Apilamiento y super learner

El apilamiento (*stacking*) combina varios modelos base entrenando un segundo modelo, el *metalearner*, sobre las predicciones que aquellos hacen fuera de muestra por validación cruzada [37]. Entrenar el *metalearner* sobre predicciones *out-of-fold*, y no sobre las del propio ajuste, evita que un modelo base que sobreajusta arrastre al combinador. El *super learner* es la formalización de esta idea por van der Laan, Polley y Hubbard [38]. El *metalearner* busca la combinación convexa de los modelos base que minimiza el riesgo de validación cruzada, y goza de una propiedad oráculo: asintóticamente, su riesgo es tan bueno como el del mejor de los modelos base, o el de su mejor combinación, sin conocerlo de antemano. Esta es exactamente la pieza *StackedEnsemble* que la búsqueda automatizada de la siguiente sección apila sobre sus modelos base.

3.7.6. Búsqueda automatizada: H2O AutoML

La estrategia AutoML relaja la elección de la familia del modelo: en vez de fijar XGBoost de antemano, deja que una búsqueda automatizada entrene y compare modelos de varias familias y devuelva el mejor. Usamos H2O AutoML [39], restringido a tres familias por activo: árboles potenciados (GBM), XGBoost y el apilamiento (StackedEnsemble) sobre los anteriores. Cada modelo se evalúa por validación cruzada purgada (la *K-fold* con *fold_column* y embargo de la Sección 3.9, no la convencional), y el *leader* es el de mayor AUC. La posición de AutoML es, igual que la de M10, $w_t = \text{sign}(p_1(\mathbf{x}_t) - \frac{1}{2})$, con p_1 la probabilidad del *leader*, y se reentrena con el mismo *walk-forward* causal.

La búsqueda se acota por número fijo de modelos y semilla fija, no por presupuesto de tiempo, y esa elección es la que hace el resultado reproducible y defendible: con un límite temporal, el conjunto de modelos explorado depende de la carga de la máquina y el *leader* cambia entre ejecuciones con la misma semilla, lo que invalidaría cualquier cifra reportada; con número fijo de modelos y semilla, la búsqueda es determinista. El papel metodológico de AutoML es servir de control de universalidad (Capítulo 4): si ni siquiera una búsqueda sobre varias familias bate de forma robusta a las referencias triviales, se refuerza la conclusión de que la señal aprovechable ya está capturada con independencia de la familia de modelos elegida.

3.7.7. Catálogo de estrategias

Todas las estrategias evaluadas son funciones que devuelven una posición w_t contra r_{t+1} con *signal_lag* = 1; la probabilidad p_1 de los modelos supervisados es un paso intermedio.

Definición 3.13 (Estrategias evaluadas). Sobre el mismo periodo de prueba y con causalidad *signal_lag* = 1:

- **M5** (agente): la posición cruda del agente, $w_t = \text{sign}(\text{tamaño}_t)$, sin supervisión.
- **M8** (intervención): la regla determinista de umbrales fijos de la Definición 3.10, $w_t = w_t^*$.
- **M10** (meta-learner): el promedio de diez XGBoost sobre las 22 características, $w_t = \text{sign}(\bar{p}(\mathbf{x}_t) - \frac{1}{2})$.

- **AutoML**: el *leader* de la búsqueda H2O sobre GBM/XGBoost/StackedEnsemble, $w_t = \text{sign}(p_1(\mathbf{x}_t) - \frac{1}{2})$.
- **ZeroR**: la referencia trivial sin habilidad, que predice la clase mayoritaria del pasado estricto, $w_t = \text{sign}(\frac{1}{t-1} \sum_{s < t} y_s - \frac{1}{2})$, calculada de forma causal.
- **B&H** (*buy and hold*): comprar y mantener, $w_t \equiv 1$.

Las dos últimas son las referencias frente a las que cualquier estrategia con pretensión de habilidad debe demostrar valor: ZeroR fija el techo direccional que se alcanza sin información alguna, y B&H, la exposición pasiva al activo. El capítulo de resultados contrasta M5, M8, M10 y AutoML contra ambas y entre sí.

3.8. Métricas de evaluación

Para juzgar si una estrategia lo hace bien no basta con mirar cuánto gana: hay que poner el rendimiento en relación con el riesgo asumido. A continuación describiremos unas métricas que enriquezcan nuestros resultados aunque es importante entender que ninguna prueba nada por sí sola y la prueba estadística del trabajo descansa en los contrastes de la Sección 3.10.

3.8.1. El ratio de Sharpe

3.8.2. Sortino, drawdown máximo y Calmar

3.9. Validación

Un backtest sobre datos pasados no vale nada si su evaluación usó, aunque sea de forma sutil, información que no estaba disponible al decidir. Esa contaminación se conoce como *look-ahead*; las salvaguardas que la impiden son necesarias para que las cifras del capítulo de resultados sean fiables. La regla es la misma siempre: solo se usa información del pasado y del presente, nunca del futuro.

3.9.1. Causalidad: la regla `signal_lag=1`

La Sección 3.1 fijó esta regla; aquí vemos por qué es condición de ausencia de fuga. La posición w_t se decide con la información disponible hasta el cierre del día t . El retorno de ese mismo día, r_t , ya se ha producido cuando se decide: forma parte de la información que entra en la decisión. Contabilizar la ganancia como $w_t \cdot r_t$ sería, por tanto, estimar la posición con un movimiento que ya se conocía al tomarla, permitiendo que la decisión mire su propio resultado. Es *look-ahead* y produce backtests artificialmente buenos que se desploman en operativa real.

La regla correcta, que en el código lleva el nombre `signal_lag=1`, es contabilizar la posición de t contra el retorno del día siguiente:

$$\text{resultado del día} = w_t \cdot r_{t+1}.$$

La posición se fija en t y se evalúa con el primer retorno que aún no se conocía, el de $t + 1$. Encaja con el filtrado causal de la Sección 3.3.4: el régimen γ_t^f que alimenta la decisión en

t se calcula solo con $x_{1:t}$, y la decisión resultante se enfrenta a r_{t+1} . Esta construcción es la recomendada en la literatura sobre evaluación de estrategias financieras, que insiste en alinear el etiquetado de cada decisión con el horizonte en el que se materializa su resultado [32].

3.9.2. Validación walk-forward (rolling-origin)

La convención `signal_lag=1` asegura la causalidad de una decisión aislada, pero el meta-learner del caso de estudio *aprende* de los datos, y validar un modelo que aprende necesita un protocolo que reproduzca cómo se usaría si queremos llevarlo a producción. El que adoptamos es el *walk-forward* de origen rodante (*rolling-origin*), el estándar para evaluar predicción sobre series temporales [40, 41]: el modelo se entrena solo con el pasado, predice un tramo futuro, y la ventana de entrenamiento avanza en el tiempo repitiendo el ciclo.

Se reserva un *periodo de arranque* (*burn-in*) inicial, que sirve para el primer entrenamiento y no se puntúa. A partir de ahí, cada cierto número de días el modelo se reentrena con *toda* la información disponible hasta esa fecha y predice el bloque siguiente, estrictamente futuro respecto al entrenamiento. Como la ventana se expande y nunca retrocede, ninguna predicción usa datos posteriores al día en que se emite: el protocolo es causal por construcción y *desplegable*: reproduce lo que se haría en la realidad, reentrenando de forma periódica y operando hacia delante. Los valores concretos del burn-in y de la frecuencia de reentrenamiento se fijarán en el capítulo 4.

3.9.3. Purga y embargo

3.9.4. Por qué no validación cruzada convencional. CPCV

3.10. Contraste de hipótesis

3.10.1. Test del signo binomial

3.10.2. Test de McNemar pareado

3.10.3. Test de Diebold-Mariano

3.10.4. Contrastes de equivalencia

3.10.5. Bootstrap estacionario

3.10.6. Deflated Sharpe Ratio

Capítulo 4

Marco práctico: ¿aporta valor supervisar a un agente LLM?

Este trabajo pregunta si una capa de supervisión estadística clásica logra rescatar a un agente de trading cuando falla, y si ese rescate puede probarse. El agente que estudiamos, cinco personalidades sobre un modelo de lenguaje, decide cada día una dirección y un tamaño de posición. Sobre el periodo de evaluación pierde dinero y acierta la dirección menos de la mitad de las veces. STRATA observa cada decisión con tres detectores de series temporales, régimen, cambio de opinión y volatilidad, y produce señales que tres estrategias derivadas explotan: la regla a mano M8, el meta-learner XGBoost M10 y una búsqueda automática de modelo con AutoML.

El capítulo sostiene que supervisar al agente añade valor medible, y lo contrasta por partes. Las estrategias supervisadas baten al agente en acierto direccional con significancia y le recortan el riesgo. Un aprendizaje potente, libre de elegir entre muchas familias de modelos, reencuentra las señales de STRATA antes que inventar otras. Y al agrupar los activos por su naturaleza asoma qué estrategia conviene a cada tipo. El límite va por delante: batir a las estrategias triviales en accuracy es nominal con esta muestra. STRATA no promete alfa; rescata al perdedor y acota dónde funciona.

4.1. Datos, universo y protocolo

El caso central es **SPY**, el ETF del S&P 500, acompañado de un panel de robustez de quince activos que abarca índices amplios, sectoriales, acciones individuales, un proxy de criptomoneda y una materia prima. La elección de SPY como escaparate descansa en el *leverage effect* (Black 1976 [10]; Christie 1982 [11]): en un índice amplio la volatilidad alta coincide con las caídas *de forma contemporánea*, de modo que el régimen de volatilidad del HMM adquiere contenido de riesgo sobre el que la supervisión puede actuar. Conviene acotar el alcance desde el principio: esa coincidencia es del mismo día y no convierte al régimen en un predictor de la dirección del día siguiente. La asunción se debilita además en valores individuales con apalancamiento flojo, y esa frontera la documentamos más adelante.

Los tres detectores se calibran una sola vez sobre el periodo 2000-01-01 a 2024-09-30 (veinticuatro años) y sus umbrales quedan fijados *ex ante*, nunca sobre los datos de evaluación

(Sección 3.6.1). La evaluación es fuera de muestra desde 2024-10-01 hasta el cierre del trabajo, con inicio posterior al corte de conocimiento del modelo de lenguaje que mueve al agente, lo que descarta que esas decisiones se memorizaran en su entrenamiento. Tras el arranque del walk-forward quedan en torno a doscientos cincuenta días de evaluación por activo.

El protocolo desplegable es un walk-forward expandible con arranque de ciento cincuenta días, reentrenamiento cada veintiuno y embargo de un día, justificado por el horizonte de la etiqueta en un esquema de origen rodante (Tashman 2000 [40]; López de Prado 2018 [32]). La convención causal es la de la Sección 3.9.1: la posición del día t multiplica al retorno del día $t + 1$, con `signal_lag = 1`.

4.2. Mecánica ex ante: los tres detectores

STRATA combina tres detectores ortogonales, todos calibrados antes de mirar la evaluación. RAM lee el régimen con un HMM gaussiano de tres estados (Hamilton 1989 [6]) sobre el log-retorno y la volatilidad realizada a veintiún días, y mide si la dirección del agente concuerda con el régimen; su prior régimen-a-signo se calibra por activo a partir de las medias del periodo de ajuste. GSO aplica un GARCH(1,1) de innovaciones Student-t (Bollerslev 1986 [23]) y juzga si el tamaño es compatible con la volatilidad prevista. PSA, más sutil, detecta con el algoritmo bayesiano de Adams y MacKay cuándo el agente cambia de opinión de forma estructural. Las definiciones formales y los umbrales de los tres están en las Secciones 3.6.2, 3.6.3 y 3.6.4.

La Figura 4.1 muestra el régimen filtrado del HMM sobre la curva de SPY en el periodo de evaluación: los tramos de Crisis se concentran en las caídas, manifestación contemporánea del *leverage effect*. La precisión importa para no prometer de más. En la calibración el retorno del mismo día baja de forma monótona con el régimen (+0,00054 en Calma, +0,00017 en Estrés, −0,000002 en Crisis), pero el retorno del día siguiente es positivo en los tres regímenes y la fracción de días al alza ronda el azar (en torno a 0,52 en Crisis): el régimen separa por volatilidad y coincide con las caídas el mismo día, no anticipa el signo de mañana. Su valor para la supervisión está en disciplinar el riesgo, no en predecir la dirección.

*Régimen HMM filtrado sobre la curva de SPY (OOS), exportar desde el notebook
STRATA_marco_practico.ipynb §4.2.*

Figura 4.1: Régimen del HMM (Calma, Estrés, Crisis) sobre el nivel de SPY en el periodo de evaluación. Las fases de Crisis coinciden con las caídas, condición del *leverage effect*.

4.3. Caso de estudio: SPY

SPY es el escaparate del mecanismo. El agente solo, que denotamos M5, acierta el 36,6% de las direcciones, muy por debajo del azar, con un Sharpe de −3,07 y un capital final del

0,70 del inicial. El sign test contra 0,5 rechaza la hipótesis de no-habilidad con $p < 0,001$: el agente es un perdedor direccional claro, que es el punto de partida del problema.

La Tabla 4.1 recoge las seis estrategias sobre SPY. La regla M8 sube la accuracy a 0,442 y recorta el daño en riesgo (Sharpe $-0,46$, máxima caída del 15,2 % frente al 30,2 % del agente). El meta-learner M10 alcanza 0,494. La búsqueda automática AutoML llega a 0,574 y gana en punto a todas las estrategias, incluidas las triviales, con un Sharpe de $+2,68$. Las triviales comprar-y-mantener y clase mayoritaria coinciden aquí en 0,566, porque SPY fue alcista en la ventana y la clase dominante es estar largo.

Tabla 4.1: SPY, periodo de evaluación walk-forward (config. mm25, embargo = 1). Accuracy direccional, Sharpe, máxima caída, Calmar y capital final. Fuente: `panel_mm25_..._seed42.json`.

Estrategia	Accuracy	Sharpe	Máx. caída	Calmar	Capital
AutoML (búsqueda H2O)	0,574	+2,68	$-5,5\%$	6,93	$1,38\times$
ZeroR (clase mayoritaria)	0,566	$+2,21$	$-9,8\%$	3,10	$1,30\times$
B&H (comprar y mantener)	0,566	$+2,21$	$-9,8\%$	3,10	$1,30\times$
M10 (meta-learner XGBoost)	0,494	$-0,60$	$-16,1\%$	$-0,50$	$0,92\times$
M8 (regla STRATA)	0,442	$-0,46$	$-15,2\%$	$-0,39$	$0,94\times$
M5 (agente solo)	0,366	$-3,07$	$-30,2\%$	$-1,00$	$0,70\times$

Ese “gana a todo” de AutoML admite dos lecturas, y las dos son ciertas. El McNemar pareado sobre los aciertos diarios da $p = 0,007$ para M10 frente a M5 y $p = 0,0002$ para AutoML frente a M5: STRATA rescata al agente con significancia. El mismo test de AutoML frente a ZeroR da $p = 0,90$, sin potencia para separarlos. La ventaja en accuracy sobre el mercado pasivo es nominal, fruto de una ventana de evaluación corta, y así la reportamos.

El rescate también se ve en el riesgo. Las curvas de capital de la Figura 4.2 muestran al agente hundiéndose mientras M8 y M10 controlan la caída. A nivel de un solo activo el intervalo de confianza del bootstrap estacionario (Politis y Romano 1994 [42]) sobre la diferencia de Sharpe todavía cruza el cero, porque doscientos cincuenta días dan poca potencia; la significancia del rescate de riesgo aparece al agrupar el panel (Sección 4.4).




Figura 4.2: Capital acumulado de las estrategias sobre SPY en el periodo de evaluación. El agente solo se hunde; M8 y M10 contienen la caída.

La importancia por valores de Shapley sobre el mejor árbol del leaderboard de AutoML y la importancia por permutación del ensemble coinciden en colocar las señales de STRATA por delante de las del agente, primer indicio de la universalidad que el panel confirma.

4.4. Generalización y universalidad (panel de quince activos)

Para distinguir el efecto de la suerte llevamos el análisis a los quince activos. La Tabla 4.2 reúne la accuracy de cada estrategia por activo, y su lectura conjunta es matizada. En los índices amplios (SPY, QQQ, DIA, IWM, XLK) las triviales suelen ganar en accuracy, porque fueron mercados alcistas y la clase mayoritaria cuesta de batir. Donde el activo es volátil o de apalancamiento débil, en cambio, asoma una derivada de STRATA que supera a las dos triviales a la vez: M8 en MSTR, M10 en SMCi y en UNG, AutoML en MARA. El rescate del agente es, con todo, transversal: alguna derivada de STRATA mejora a M5 en casi todo el panel.

Tabla 4.2: Accuracy direccional por activo y estrategia (panel de quince, walk-forward, embargo = 1). En negrita, por activo, la mejor derivada de STRATA cuando supera a las dos triviales. El ganador por activo individual no es robusto: un bootstrap estacionario por bloques solo halla un margen al segundo significativo en SPY y XLK, de modo que el patrón se lee a nivel de grupo (Sección 4.5), no celda a celda. El número de días de evaluación varía por activo (246 a 259) según la fecha de arranque del walk-forward. Fuente: `panel_mm25_..._seed42.json`.

Activo	M5	M8	M10	AutoML	ZeroR	B&H
SPY	0,366	0,442	0,494	0,574	0,566	0,566
QQQ	0,418	0,486	0,522	0,534	0,590	0,590
DIA	0,440	0,484	0,468	0,520	0,552	0,556
IWM	0,450	0,470	0,458	0,482	0,554	0,574
XLE	0,448	0,528	0,508	0,532	0,565	0,565
XLFX	0,429	0,502	0,526	0,510	0,538	0,538
XLK	0,510	0,470	0,542	0,590	0,641	0,641
NVDA	0,467	0,521	0,483	0,517	0,552	0,552
BAC	0,451	0,516	0,419	0,488	0,561	0,561
TSLA	0,474	0,478	0,522	0,454	0,458	0,530
MSTR	0,554	0,558	0,534	0,498	0,530	0,450
SMCI	0,484	0,496	0,552	0,472	0,516	0,484
ROKU	0,444	0,528	0,508	0,544	0,548	0,548
MARA	0,528	0,528	0,532	0,544	0,532	0,468
UNG	0,510	0,502	0,518	0,482	0,449	0,486

La aportación dura del trabajo está en el riesgo agregado. Agrupando los retornos diarios de los quince activos (tres mil setecientos cincuenta y un días) y aplicando un bootstrap estacionario pareado por bloques (Politis y Romano 1994 [42]), el rescate de riesgo de la regla frente al agente es significativo: M8 mejora el Sharpe de M5 en +0,66 con intervalo de confianza al 95 % de [0,23, 1,16], y reduce la máxima caída en +0,24 con intervalo [0,02, 0,44]; ambos excluyen el cero (Tabla 4.3). El mismo contraste para M10 frente a M5 queda en el límite, con el intervalo del Sharpe rozando el cero. La supervisión disciplina el riesgo del agente con evidencia que sobrevive a un test.

La universalidad se mide con la importancia por características y con una ablación. Repartiendo la importancia por valores de Shapley (Lundberg y Lee 2017 [43]) en bloques, las características de STRATA concentran de media el 66 % del total (régimen 0,38, volatilidad 0,15 y cambio de opinión 0,14, frente a 0,34 del agente), y la cuota de STRATA supera la mitad en los quince activos. El aprendiz potente, lejos de descartar las señales de STRATA, se apoya en ellas. La ablación añade un matiz honesto: sumar las siete señales de STRATA al vector de

Tabla 4.3: Rescate de riesgo agregado (bootstrap estacionario pareado por bloques, $n = 3751$ días, quince activos). Diferencias frente al agente M5 con intervalo al 95 %. Fuente: `decision_automl_prep.json`, bloque `pooled`.

Comparación	ΔSharpe	IC_{95}	¿excluye 0?
M8 vs M5	+0,66	[0,23, 1,16]	sí
M10 vs M5	+0,61	[-0,04, 1,25]	no
	$\Delta\text{Máx. caída}$	IC_{95}	¿excluye 0?
M8 vs M5	+0,24	[0,02, 0,44]	sí
M10 vs M5	+0,23	[-0,02, 0,45]	no

quince características del agente no eleva la accuracy del meta-learner de media ($-0,05$ en SPY, $+0,08$ en SMCI). El valor de STRATA está en el rescate y en la interpretabilidad.




Figura 4.3: Izquierda: accuracy por activo y estrategia centrada en el azar. Derecha: importancia media por bloque de características, con STRATA por delante del agente.

4.5. Patrón entre activos: ¿qué estrategia conviene a cada tipo?

No todos los activos son iguales: cambian el *leverage effect*, la volatilidad y el sesgo del agente. Agrupamos los quince por su naturaleza, con características de mercado y no de rendimiento para no contaminar la lectura, mediante cuatro métodos adecuados a una muestra pequeña: KMeans, Ward, mezcla gaussiana y agrupamiento espectral. La calidad de la partición favorece tres grupos: la silueta es máxima en $k = 3$ para los tres métodos concordantes (0,485 en KMeans, Ward y la mezcla gaussiana) y el criterio BIC de la mezcla gaussiana cae con holgura al pasar de dos a tres grupos. El método espectral discrepa, y lo recogemos como tal.

Los tres grupos admiten lectura económica. El primero reúne los índices y sectoriales de *leverage* fuerte (SPY, QQQ, DIA, IWM, XLE, XLF, XLK, BAC), con correlación retorno-volatilidad media de $-0,09$. El segundo agrupa los volátiles de apalancamiento débil (NVDA, TSLA, ROKU, MARA). El tercero recoge tres activos atípicos (MSTR, SMCI, UNG). Cruzando los grupos con la Tabla 4.2 emerge una hipótesis: en los índices de *leverage* fuerte el valor está en el canal de régimen, que rescata al agente y disciplina su riesgo aunque no bata a las triviales; en los volátiles y atípicos el valor está en el meta-learner y en AutoML, que sí superan a las triviales. La conclusión es exploratoria, a una muestra de quince activos, y la presentamos como material para futuras líneas (Figura 4.4).

Proyección PCA 2D de la naturaleza de los activos por grupo ($k = 3$), exportar desde el notebook §4.5.

Figura 4.4: Agrupamiento de los quince activos por naturaleza de mercado (proyección a dos componentes principales). Los índices de *leverage* fuerte, los volátiles y los atípicos se separan.

4.6. Robustez y honestidad

Conviene poner la señal de STRATA a prueba contra una alternativa exigente. Sobre SPY, partiendo de un modelo con solo características de momento, añadir las siete señales de STRATA sube la accuracy de 0,521 a 0,582, una mejora de +0,06 que se repite en los cinco bloques de semillas y resulta significativa en el McNemar de tres. La señal de STRATA aporta información que el momento no captura.

El cuadro cambia en SMCI, una acción de apalancamiento débil. Ahí el régimen de Crisis tiene media positiva, el HMM pierde su contenido direccional y el margen de rescate se estrecha. El M10 desplegable acierta el 55,2 % y gana a todas las referencias, pero de forma nominal: el binomial frente a la clase mayoritaria da $p = 0,14$. El límite estaba previsto en el diseño, ya que la supervisión rescata con fuerza cuando el agente discrepa de un régimen que acierta, y SMCI cumple poco esa condición.

Queda claro qué sobrevive a un test y qué no. El rescate del agente en accuracy es significativo (McNemar de M10 y AutoML frente a M5 sobre SPY, $p = 0,007$ y $p = 0,0002$). El rescate en riesgo lo es en el agregado del panel (Sharpe y máxima caída de M8 frente a M5, con intervalos que excluyen el cero). Batir a las triviales en accuracy no alcanza significancia, sin potencia a doscientos cincuenta días. La señal informativa reside en STRATA, con una cuota de importancia media del 66 %. Todo se mide con `signal_lag = 1`, embargo de un día, modelos fijados *ex ante* y contrastes con cita, y el notebook cierra con un auto-test que cruza cada cifra de cabecera con su fichero de origen.

4.7. Conclusiones del marco práctico

Cada afirmación del capítulo queda sostenida por la evidencia que admite. El agente solo pierde y acierta menos de la mitad (SPY: accuracy 0,366, Sharpe muy negativo, sign test que rechaza el azar). STRATA lo rescata, y el rescate se prueba: en accuracy con el McNemar frente al agente, y en riesgo con el bootstrap agregado del panel, donde la regla M8 mejora el Sharpe en +0,66 y la máxima caída en +0,24 con intervalos que excluyen el cero. Un aprendiz potente reencuentra la señal de STRATA y se apoya en ella, con una cuota de importancia media de dos tercios, y sobre un modelo de momento esas señales añaden acierto. El agrupamiento por naturaleza sugiere un patrón entre el tipo de activo y la estrategia que le conviene, que dejamos como hipótesis exploratoria. El límite se dice con la misma claridad: ninguna estrategia bate a las triviales en accuracy con significancia a esta muestra, y donde el apalancamiento es débil

el margen de rescate se estrecha.

La aportación es un protocolo de supervisión estadística interpretable que recupera a un agente perdedor en acierto y en riesgo, que un meta-learner potente confirma al apoyarse en sus señales, y que delimita con honestidad dónde funciona. La significancia plena de la ventaja en accuracy y la generalización a otros agentes y activos quedan como las líneas inmediatas del Capítulo 5.

Capítulo 5

Conclusiones

5.1. Límites y trabajo futuro

La limitación principal es el tamaño de la muestra. El agente solo existe sobre el periodo posterior al corte del modelo de lenguaje, lo que acota la evaluación a unos 250 días y deja la significancia plena fuera de alcance frente a un benchmark justo. La convergencia de las cuatro evidencias (dominancia 2×2 , invarianza a la partición, consistencia en ventanas rodantes y mecanismo identificado por ablación y SHAP) sostiene la conclusión a este tamaño, pero un periodo más largo es la vía natural para llevar la ventaja nominal a significancia plena.

Quedan tres extensiones. La generalización a otros agentes y a otros activos, costosa en inferencia y en tiempo por las razones que cuantificamos en el Capítulo 5. El despliegue en vivo, con su coste operativo. Y, sobre todo, SPY como activo donde el mecanismo de STRATA debería ser significativo: en un índice el *leverage effect* es fuerte, el régimen de alta volatilidad coincide con el bajista y el HMM actúa como proxy direccional, justo la condición que SMCI no satisface. Sobre este activo, en cambio, el protocolo es desplegable: en un benchmark honesto recupera la dirección del agente y supera a la regla a mano y a lo trivial.

Bibliografía

- [1] Hongyang Yang, Xiao-Yang Liu y Christina Dan Wang. «FinGPT: Open-Source Financial Large Language Models». En: *arXiv preprint arXiv:2306.06031* (2023). FinLLM Workshop @ IJCAI 2023. DOI: 10.48550/arXiv.2306.06031.
- [2] Yijia Xiao et al. «TradingAgents: Multi-Agents LLM Financial Trading Framework». En: *arXiv preprint arXiv:2412.20138* (2024). DOI: 10.48550/arXiv.2412.20138.
- [3] Changlun Li et al. «Will LLMs be Professional at Fund Investment? DeepFund: A Live Arena Perspective». En: *arXiv preprint arXiv:2503.18313* (2025). NeurIPS 2025 (poster). DOI: 10.48550/arXiv.2503.18313.
- [4] Mostapha Benhenda. «Look-Ahead-Bench: a Standardized Benchmark of Look-ahead Bias in Point-in-Time LLMs for Finance». En: *arXiv preprint arXiv:2601.13770* (2026). DOI: 10.48550/arXiv.2601.13770.
- [5] Varun Chandola, Arindam Banerjee y Vipin Kumar. «Anomaly detection: A survey». En: *ACM Computing Surveys* 41.3 (2009), págs. 1-58. DOI: 10.1145/1541880.1541882.
- [6] James D. Hamilton. «A new approach to the economic analysis of nonstationary time series and the business cycle». En: *Econometrica* 57.2 (1989), págs. 357-384.
- [7] Andrew Ang y Geert Bekaert. «International asset allocation with regime shifts». En: *The Review of Financial Studies* 15.4 (2002), págs. 1137-1187. DOI: 10.1093/rfs/15.4.1137.
- [8] Massimo Guidolin y Allan Timmermann. «Asset allocation under multivariate regime switching». En: *Journal of Economic Dynamics and Control* 31.11 (2007), págs. 3503-3544.
- [9] Alan Moreira y Tyler Muir. «Volatility-managed portfolios». En: *The Journal of Finance* 72.4 (2017), págs. 1611-1644.
- [10] Fischer Black. «Studies of stock price volatility changes». En: *Proceedings of the 1976 Meetings of the American Statistical Association, Business and Economic Statistics Section*. 1976, págs. 177-181.
- [11] Andrew A. Christie. «The stochastic behavior of common stock variances: Value, leverage and interest rate effects». En: *Journal of Financial Economics* 10.4 (1982), págs. 407-432.
- [12] Rama Cont. «Empirical properties of asset returns: stylized facts and statistical issues». En: *Quantitative Finance* 1.2 (2001), págs. 223-236. DOI: 10.1080/713665670.
- [13] Lawrence R. Rabiner. «A tutorial on hidden Markov models and selected applications in speech recognition». En: *Proceedings of the IEEE* 77.2 (1989), págs. 257-286.

- [14] Olivier Cappé, Eric Moulines y Tobias Rydén. *Inference in Hidden Markov Models*. Springer Series in Statistics. New York: Springer, 2005. ISBN: 9780387402642. DOI: 10.1007/0-387-28982-8.
- [15] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006. ISBN: 9780387310732.
- [16] Leonard E. Baum et al. «A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains». En: *The Annals of Mathematical Statistics* 41.1 (1970), págs. 164-171.
- [17] Arthur P. Dempster, Nan M. Laird y Donald B. Rubin. «Maximum likelihood from incomplete data via the EM algorithm». En: *Journal of the Royal Statistical Society: Series B* 39.1 (1977), págs. 1-38. DOI: 10.1111/j.2517-6161.1977.tb01600.x.
- [18] Andrew J. Viterbi. «Error bounds for convolutional codes and an asymptotically optimum decoding algorithm». En: *IEEE Transactions on Information Theory* 13.2 (1967), págs. 260-269.
- [19] James D. Hamilton. *Time Series Analysis*. Princeton, NJ: Princeton University Press, 1994. ISBN: 9780691042893.
- [20] Ruey S. Tsay. *Analysis of Financial Time Series*. 3.^a ed. Wiley Series in Probability and Statistics. Hoboken, NJ: Wiley, 2010. ISBN: 9780470414354. DOI: 10.1002/9780470644560.
- [21] Peter J. Brockwell y Richard A. Davis. *Time Series: Theory and Methods*. 2.^a ed. Springer Series in Statistics. New York: Springer-Verlag, 1991. ISBN: 9780387974293.
- [22] Robert F. Engle. «Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation». En: *Econometrica* 50.4 (1982), págs. 987-1007.
- [23] Tim Bollerslev. «Generalized autoregressive conditional heteroskedasticity». En: *Journal of Econometrics* 31.3 (1986), págs. 307-327.
- [24] Daniel B. Nelson. «Stationarity and persistence in the GARCH(1,1) model». En: *Econometric Theory* 6.3 (1990), págs. 318-334. DOI: 10.1017/S0266466600005296.
- [25] Christian Francq y Jean-Michel Zakoïan. *GARCH Models: Structure, Statistical Inference and Financial Applications*. 2.^a ed. Chichester: Wiley, 2019. ISBN: 9781119313571. DOI: 10.1002/9781119313472.
- [26] Robert F. Engle y Tim Bollerslev. «Modelling the persistence of conditional variances». En: *Econometric Reviews* 5.1 (1986), págs. 1-50. DOI: 10.1080/07474938608800095.
- [27] Tim Bollerslev. «A conditionally heteroskedastic time series model for speculative prices and rates of return». En: *The Review of Economics and Statistics* 69.3 (1987), págs. 542-547.
- [28] Ryan P. Adams y David J. C. MacKay. «Bayesian online changepoint detection». En: *arXiv preprint arXiv:0710.3742* (2007).
- [29] Paul Fearnhead. «Exact and efficient Bayesian inference for multiple changepoint problems». En: *Statistics and Computing* 16.2 (2006), págs. 203-213.

- [30] Jushan Bai y Pierre Perron. «Estimating and testing linear models with multiple structural changes». En: *Econometrica* 66.1 (1998), págs. 47-78. DOI: 10.2307/2998540.
- [31] Jushan Bai y Pierre Perron. «Computation and analysis of multiple structural change models». En: *Journal of Applied Econometrics* 18.1 (2003), págs. 1-22. DOI: 10.1002/jae.659.
- [32] Marcos López de Prado. *Advances in Financial Machine Learning*. Hoboken, NJ: Wiley, 2018.
- [33] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2.^a ed. Springer Series in Statistics. New York: Springer, 2009. ISBN: 9780387848570. DOI: 10.1007/978-0-387-84858-7.
- [34] Jerome H. Friedman. «Greedy function approximation: A gradient boosting machine». En: *The Annals of Statistics* 29.5 (2001), págs. 1189-1232. DOI: 10.1214/aos/1013203451.
- [35] Tianqi Chen y Carlos Guestrin. «XGBoost: A scalable tree boosting system». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, págs. 785-794. DOI: 10.1145/2939672.2939785.
- [36] Leo Breiman. «Bagging predictors». En: *Machine Learning* 24.2 (1996), págs. 123-140. DOI: 10.1007/BF00058655.
- [37] David H. Wolpert. «Stacked generalization». En: *Neural Networks* 5.2 (1992), págs. 241-259. DOI: 10.1016/S0893-6080(05)80023-1.
- [38] Mark J. van der Laan, Eric C. Polley y Alan E. Hubbard. «Super Learner». En: *Statistical Applications in Genetics and Molecular Biology* 6.1 (2007), Article 25. DOI: 10.2202/1544-6115.1309.
- [39] Erin LeDell y Sebastien Poirier. «H2O AutoML: Scalable Automatic Machine Learning». En: *Proceedings of the 7th ICML Workshop on Automated Machine Learning (AutoML)*. 2020. URL: https://www.automl.org/wp-content/uploads/2020/07/AutoML_2020_paper_61.pdf.
- [40] Leonard J. Tashman. «Out-of-sample tests of forecasting accuracy: an analysis and review». En: *International Journal of Forecasting* 16.4 (2000), págs. 437-450. DOI: 10.1016/S0169-2070(00)00065-0.
- [41] Christoph Bergmeir, Rob J. Hyndman y Bonsoo Koo. «A note on the validity of cross-validation for evaluating autoregressive time series prediction». En: *Computational Statistics & Data Analysis* 120 (2018), págs. 70-83. DOI: 10.1016/j.csda.2017.11.003.
- [42] Dimitris N. Politis y Joseph P. Romano. «The stationary bootstrap». En: *Journal of the American Statistical Association* 89.428 (1994), págs. 1303-1313.
- [43] Scott M. Lundberg y Su-In Lee. «A unified approach to interpreting model predictions». En: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. Curran Associates, Inc., 2017, págs. 4766-4777. URL: <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.