

UNIVERSIDAD COMPLUTENSE DE MADRID
FACULTAD DE CIENCIAS MATEMÁTICAS



UNIVERSIDAD COMPLUTENSE
MADRID

TRABAJO DE FIN DE GRADO

STRATA: capa de supervisión estadística en tiempo real
de un agente de trading basado en LLMs

Tutor: Daniel Vélez Serrano

Raquel García Hernández

Grado en Matemáticas y Ciencia de Datos

Curso académico 2025-2026

Abstract

Large language model agents already make investment decisions, and they are not deterministic: faced with the same question they can answer differently, and they fail without warning. When real money is at stake, that is a problem. This work studies one such agent, a replica of AI Hedge Fund with five investor personalities that chooses a direction and a size for each asset and each day. Out of sample it loses: on SPY it gets the next day’s direction right on only 36,6 % of the days, below a coin toss, and an initial €1000 ends at €700.

We design STRATA, a statistical layer that supervises the agent in runtime. STRATA audits every decision with three orthogonal classical detectors, a hidden Markov regime model, a Bayesian change-point detector and a GARCH volatility band, and overrides the decision when it contradicts an explicit model of the market. We test the supervision with paired statistics on three questions: whether it rescues the agent in directional accuracy and in risk, which detector drives the effect, and whether a free meta-learner rediscovers STRATA’s signals instead of discarding them.

The rescue is statistically significant and its mechanics are interpretable. Across a panel of ten assets we find a pattern that maps where the approach is worth applying: the stronger an asset’s leverage effect, the more the supervision rescues, and the regime rule leads on broad indices while the meta-learner leads on the rest. Its scope is supervision, not alpha, and that boundary is left as future work.

Keywords: runtime supervision, LLM trading agent, hidden Markov model, GARCH, change-point detection, meta-labeling, leverage effect.

Índice general

1. Introducción	3
1.1. Problema. Motivación	3
1.2. Propuesta: supervisión estadística externa	3
2. Objetivos	5
2.1. Hipótesis	5
2.2. Objetivo general	5
2.3. Objetivos específicos	5
2.4. Plan de trabajo	6
3. Estado del arte	7
3.1. Agentes LLM en finanzas	7
3.2. Supervisión en tiempo de ejecución	8
3.3. Régimen de mercado y leverage effect	8
4. Fundamentos teóricos y diseño de STRATA	9
4.1. Los detectores: RAM, PSA y GSO	9
4.1.1. Preliminares y notación	9
4.1.2. La salida del agente	10
4.1.3. STRATA a nivel técnico	11
4.1.4. Modelos de cambio de régimen: HMM gaussiano	12
4.1.5. Volatilidad condicional: ARCH y GARCH(1,1)-t	14
4.1.6. Detección bayesiana de puntos de cambio (BOCPD)	15
4.1.7. STRATA aplicado: construcción, calibración y umbrales	16
4.2. Estrategias supervisadas: M8, M10 y AutoML	20
4.2.1. El problema de aprendizaje supervisado	20
4.2.2. De los árboles al meta-learner M10	20
4.2.3. Apilamiento y búsqueda automatizada AutoML	21
4.2.4. Estrategias	21
4.3. Protocolo de evaluación	22
4.3.1. Métricas de evaluación	22
4.3.2. Validación	22
4.3.3. Contraste de hipótesis	23

5. Aplicación a SPY	25
5.1. La intervención en detalle	25
5.2. Comparación de las seis estrategias	27
5.3. El rescate sobre SPY	28
6. Validación sobre el panel de diez activos	30
6.1. El rescate en el panel	30
6.1.1. La compuerta de régimen y la activación de detectores	30
6.1.2. Accuracy por activo: dónde se supera a la trivial	30
6.1.3. Pooled: el rescate en riesgo	32
6.1.4. Equivalencia: el aprendiz recupera STRATA y supera a la regla	33
6.1.5. Complementariedad por régimen	34
6.2. El patrón: ley del leverage y clustering	35
6.2.1. La ley del <i>leverage</i>	35
6.2.2. Clustering: la naturaleza separa los grupos	36
6.3. Robustez	37
6.4. Alcance y limitaciones	37
7. Conclusiones y trabajo futuro	39
7.1. Revisión de los objetivos	39
7.2. Aportaciones	39
7.3. Limitaciones	40
7.4. Trabajo futuro	40
7.5. Conclusión	41
Bibliografía	42
A. Demostraciones	47
A.1. Recursión forward del HMM	47
A.2. Filtrado y causalidad del HMM	48
A.3. Fórmulas de actualización del paso M de Baum-Welch	48
A.4. Recursión de Viterbi	49
A.5. Monotonía del algoritmo EM	49
A.6. Estacionariedad y varianza incondicional del GARCH(1,1)	49
A.7. Verosimilitud condicional del GARCH(1,1)- t	51
A.8. Recursión de Adams–MacKay del BOCPD	51
A.9. Pseudo-residuos del boosting logístico	52
A.10. Pesos óptimos y ganancia de una división en XGBoost	52
B. Figuras complementarias	54
B.1. Mecanismo sobre SPY	54
B.2. Panel de diez activos	54

Capítulo 1

Introducción

1.1. Problema. Motivación

Los agentes basados en grandes modelos de lenguaje ya toman decisiones de inversión. Con ese despliegue ha crecido una demanda concreta: supervisar de forma continua y trazable lo que la IA agéntica decide. A medida que estos sistemas ganan autonomía, sus decisiones se vuelven difíciles de seguir para un humano, y crece el interés en los *guardrails*: una supervisión automática que acote lo que el agente puede hacer.

Muchas personas ya confían su dinero a estos agentes. Un agente LLM no es determinista: ante la misma pregunta puede responder de forma distinta, y no señala cuándo acierta o falla. En la gestión de capital, donde un solo error tiene coste elevado, esa indeterminación es crítica.

Los agentes LLM ejecutan las instrucciones con fidelidad antes que maximizar el beneficio [1], su confianza declarada está mal calibrada y son manipulables. Entre la supervisión que se reclama y una herramienta falsable que la ofrezca hay una distancia que este trabajo aborda.

El agente estudiado es una réplica de AI Hedge Fund: cinco personalidades inversoras sobre un mismo modelo de lenguaje que deciden, para cada activo y cada día, una dirección y un tamaño. Sin supervisión pierde dinero. Sobre SPY acierta la dirección el 0,366 de los días, por debajo de lo que daría una moneda, y una inversión inicial de €1000 termina en €700. El fenómeno no es propio de SPY: el agente acierta por debajo del medio punto en siete de los diez activos del panel.

La pérdida tiene estructura. El agente mantiene una posición casi rígida que apenas atiende a la señal del día. Un fallo sistemático se puede corregir desde fuera; ese es el problema que aborda este trabajo.

1.2. Propuesta: supervisión estadística externa

STRATA es la solución a este problema: un supervisor estadístico exógeno que audita cada decisión en tiempo de ejecución y la rectifica cuando contradice el comportamiento del mercado. Se apoya en tres detectores ortogonales, cada uno sobre un modelo estadístico clásico que el capítulo 4 formaliza: RAM mira la coherencia de la apuesta con el régimen de mercado, PSA la coherencia temporal de las decisiones del agente y GSO la compatibilidad del tamaño con la volatilidad. Cuando uno se dispara, STRATA actúa sobre la decisión: la registra, atenúa

su tamaño o la sustituye. La corrección se contrasta de forma pareada contra el mismo agente sin supervisar, decisión a decisión.

La idea de una etapa secundaria que vigila a un modelo primario no es nueva: el *meta-labeling* de López de Prado [2] añade un segundo modelo que decide si actuar sobre la señal del primero. STRATA recoge esa lógica y la lleva más lejos. Aquí el primario es el agente LLM, y el supervisor son tres detectores estadísticos clásicos que juzgan su decisión desde ejes independientes. La intervención es exógena: depende de lo que los detectores leen del mercado, no de lo que el agente declare. Eso la separa del equipo de riesgo de TradingAgents [3], un agente deliberativo interno que comparte la información y los sesgos del sistema.

Capítulo 2

Objetivos

Este capítulo formula la hipótesis del trabajo y la descompone en objetivos contrastables.

2.1. Hipótesis

La hipótesis del trabajo es una afirmación refutable sobre si una capa de supervisión estadística externa rescata a un agente LLM cuando pierde:

Filtrar o atenuar las decisiones de un agente LLM de trading con detectores estadísticos clásicos rescata al agente de forma significativa cuando este pierde dinero y acierta la dirección menos de la mitad de las veces.

La hipótesis nula es que la supervisión no cambia nada: las decisiones supervisadas no se distinguen de las del agente solo, ni en acierto direccional ni en riesgo. Para rechazarla se fija de antemano el contraste de cada nivel y un criterio de fracaso, de modo que un resultado contrario refute la hipótesis en lugar de maquillarla.

2.2. Objetivo general

Demostrar que supervisar en tiempo de ejecución las decisiones de un agente LLM de trading con detectores estadísticos clásicos rescata al agente cuando pierde, y caracterizar cuándo y por qué funciona.

2.3. Objetivos específicos

1. Formalizar los tres detectores clásicos sobre los que se apoya STRATA, el régimen con un HMM, el cambio estructural con BOCPD y la volatilidad con un GARCH, junto con el protocolo de medición causal y sin fuga que los evalúa. El capítulo 4 se ocupa de ello.
2. Probar si esa supervisión rescata al agente cuando pierde. Se mide con contrastes pareados, en acierto direccional (McNemar y *sign test*) y en riesgo (Δ Sharpe con *bootstrap*), primero sobre SPY y después sobre el panel de diez activos.

3. Atribuir el efecto a cada detector y entender en qué activos funciona la supervisión, desde la anatomía de una intervención hasta el patrón que liga la naturaleza del activo con el canal que lo rescata.
4. Comprobar si un meta-learner libre recupera las señales de STRATA en lugar de prescindir de ellas. Se contrasta por dos vías: la atribución, con valores de Shapley y ablación, y la equivalencia frente a la regla.
5. Ver si alguna estrategia derivada de STRATA bate en acierto direccional a la referencia trivial, comprar y mantener o la clase mayoritaria del pasado.
6. Delimitar con honestidad el alcance de la técnica, declarando con el mismo rigor lo que aporta y lo que no: ni gana a una referencia trivial ni mantiene su mecanismo en los activos de apalancamiento débil.

2.4. Plan de trabajo

La memoria sigue este orden. El capítulo 3 sitúa el trabajo entre los agentes LLM de trading, la supervisión en tiempo de ejecución y los modelos clásicos de régimen y volatilidad. El capítulo 4 formaliza los tres detectores, las estrategias que derivan de ellos y el protocolo de medición fuera de muestra. El capítulo 5 lleva STRATA al caso de SPY, paso a paso. El capítulo 6 prueba el rescate sobre el panel de diez activos y busca el patrón que esconde la naturaleza de los mismos. Cierran las conclusiones y el trabajo futuro (capítulo 7).

Capítulo 3

Estado del arte

3.1. Agentes LLM en finanzas

Un LLM es una red que predice la siguiente palabra a partir del contexto, mediante un mecanismo de atención [4]. Por sí solo escribe; se vuelve un *agente* al envolverlo en un bucle que razona, llama a herramientas y actúa sobre un entorno [5, 6]. De ahí salieron sistemas que deciden inversiones en lugar de redactar [7]. Hoy domina la arquitectura multiagente: varias personalidades inversoras deliberan y un gestor modera la posición final [3, 8]. El control de riesgo que incorporan opera dentro del propio sistema y comparte sus sesgos: el equipo de riesgo de TradingAgents razona en lenguaje natural [3] y AlphaAgents ajusta la cartera a la tolerancia del inversor [8], pero ninguno audita con un modelo estadístico externo si cada decisión es coherente con el mercado observado.

Los agentes LLM ejecutan las instrucciones con fidelidad antes que maximizar beneficio, aun cuando eso les hace perder [1], y su confianza declarada está peor calibrada que la de un humano: se muestran sobreconfiados justo cuando fallan [9, 10]. Cambian de estilo inversor sin que el cambio responda a su propio criterio [11] y resultan manipulables ante datos diseñados para engañarlos [12]. La evaluación, además, es frágil: muchos resultados optimistas no aguantan una validación temporal honesta [13], y el *look-ahead* infla las métricas cuando el periodo de prueba cae dentro del preentrenamiento [14]; por eso la ventana fuera de muestra de este trabajo empieza tras el corte de entrenamiento del modelo.

El agente estudiado es una réplica de AI Hedge Fund [15], un sistema de cinco personalidades que emulan a inversores reconocidos (Buffett, Wood, Druckenmiller, Burry y Ackman) sobre un mismo modelo de lenguaje. Para cada activo y día cada personalidad emite una señal direccional con un grado de confianza; un agente de riesgo fija el límite de posición según la volatilidad, y un gestor integra las cinco señales y ese límite en una sola decisión, dirección y tamaño, por criterio propio y no por voto. Esa decisión diaria es lo que STRATA supervisa. El agente sin supervisar se denota M5, el punto de partida que el resto de la memoria rescata (Sección 1.1).

3.2. Supervisión en tiempo de ejecución

La industria ya pide vigilar a estos agentes mientras operan. El discurso profesional lo resume en una consigna, *guardrails, but no handcuffs*: barreras que acoten al agente sin maniatarlo, con monitorización continua, trazas de auditoría y salidas que escalen a un humano [16]. Entre los controles aparece, casi de pasada, la *validación estadística*: que las salidas se alineen con normas estadísticas realistas [16]. La demanda queda en eslogan, sin decir qué norma, qué contraste ni cómo se mide que la corrección funcione. STRATA lo convierte en detectores falsables con contraste pareado.

La supervisión en tiempo de ejecución se relaciona con la detección de anomalías [17] y con el control en tiempo de ejecución (*runtime enforcement*), que intercepta cada acción y bloquea la que incumple una condición [18, 19]. Una regla declarativa codifica qué está prohibido; STRATA modela la coherencia de una posición con el estado del mercado, con tres detectores estadísticos clásicos e interpretables: RAM mira la coherencia con el régimen (modelo de Markov oculto), PSA la coherencia temporal del agente (puntos de cambio bayesianos) y GSO la compatibilidad del tamaño con la volatilidad (GARCH). Los tres se apoyan en la descripción estadística del régimen de mercado y su riesgo.

3.3. Régimen de mercado y leverage effect

La idea de fondo de RAM viene de Hamilton: una serie financiera no responde a un único mecanismo, sino que atraviesa estados latentes con propiedades estadísticas distintas y cambia de estado sin que lo veamos [20]. Condicionar la cartera al régimen mejora las decisiones [21, 22]. Sobre el eje continuo de la volatilidad opera la idea que ancla a GSO: dimensionar la posición para alcanzar una volatilidad objetivo (el *volatility targeting*) mejora las propiedades de la serie de retornos [23]. La literatura usa de dos [21] a cuatro [22] estados; este trabajo usa tres (calma, estrés y crisis): la verosimilitud fuera de muestra descarta dos, y por encima de tres se pierde interpretabilidad.

El régimen funciona como proxy direccional solo de forma condicional, y esa condición sostiene y limita la tesis: el *leverage effect*. En los mercados bursátiles el retorno y la volatilidad están correlados negativamente, de modo que los tramos de alta volatilidad coinciden con las caídas. Lo documentó Black [24] y Christie lo estudió de forma sistemática [25]. Una caída del precio eleva el peso de la deuda sobre el del patrimonio y deja a la empresa más apalancada, y por tanto más volátil; para el uso aquí basta el signo de la correlación, no su causa. Su magnitud no es uniforme: fuerte en los índices agregados y mucho más débil en una acción individual [26]. En un activo con poder direccional, alta volatilidad tiende a significar mercado a la baja; en un valor aislado esa asociación se diluye. El régimen no predice el retorno: ordena las decisiones del agente.

Capítulo 4

Fundamentos teóricos y diseño de STRATA

Las tres líneas del capítulo anterior —agentes LLM de trading, supervisión en tiempo de ejecución y modelos clásicos de régimen y volatilidad— no se habían combinado sobre un mismo agente. Este capítulo reúne la base matemática de esa combinación y fija la notación del resto de la memoria: los tres detectores y la capa que convierte sus señales en intervención, las estrategias que aprenden sobre esas señales y el protocolo de medición del rescate. El caso de SPY, donde el sistema se pone a prueba, queda para el capítulo 5.

4.1. Los detectores: RAM, PSA y GSO

4.1.1. Preliminares y notación

Sea $P_t > 0$ el precio de cierre del día t , con $t \in \{0, 1, \dots, T\}$. La cantidad relevante es su variación relativa de un día al siguiente, el *log-retorno*

$$r_t^{\log} = \log\left(\frac{P_t}{P_{t-1}}\right) = \log P_t - \log P_{t-1}, \quad t \geq 1,$$

positivo cuando el precio sube y negativo cuando baja.

El *retorno simple* $R_t = (P_t - P_{t-1})/P_{t-1}$ se relaciona con él por $r_t^{\log} = \log(1 + R_t)$. La ventaja del log-retorno es su aditividad temporal: el retorno acumulado entre los días t_0 y $t_0 + n$, en escala logarítmica, es la suma de los log-retornos diarios,

$$\log\left(\frac{P_{t_0+n}}{P_{t_0}}\right) = \log\left(\prod_{j=1}^n \frac{P_{t_0+j}}{P_{t_0+j-1}}\right) = \sum_{j=1}^n \log\left(\frac{P_{t_0+j}}{P_{t_0+j-1}}\right) = \sum_{j=1}^n r_{t_0+j}^{\log}.$$

El retorno simple, en cambio, se compone de forma multiplicativa, $1 + R_{[t_0, t_0+n]} = \prod_{j=1}^n (1 + R_{t_0+j})$, lo que complica sumar o promediar a lo largo del tiempo. Esa aditividad justifica modelar $r_t^{\log}$.

Se fija también la convención temporal que gobierna toda la validación. La decisión tomada con la información hasta el día t no puede recompensarse con el movimiento de ese mismo

día, que ya ha ocurrido. Para evitar el *look-ahead*, el retorno que se contabiliza frente a una posición tomada en t es el del día siguiente,

$$r_{t+1} = \log\left(\frac{P_{t+1}}{P_t}\right).$$

En adelante, todo producto entre una posición y un retorno usa r_{t+1} .

Por último, una medida de cuánto se mueve el activo. Dada una ventana de h días que termina en t , la *volatilidad realizada* es

$$RV_t = \sqrt{\sum_{j=0}^{h-1} (r_{t-j}^{\log})^2},$$

la raíz de la suma de cuadrados de los log-retornos de la ventana. RV_t es un estimador no paramétrico de la dispersión local: crece cuando el activo encadena movimientos grandes y se reduce en los tramos planos. A diferencia de la volatilidad condicional σ_t de la Sección 4.1.5, no presupone ningún modelo.

Las series de retornos financieros no son ruido blanco gaussiano. Tres regularidades empíricas [27] motivan los modelos del resto del capítulo. Primera, *colas pesadas*: los movimientos extremos son mucho más frecuentes de lo que predice una normal, lo que lleva a sustituirla por una t de Student en el modelo de volatilidad. Segunda, *agrupamiento de volatilidad*: los días de gran movimiento tienden a seguirse, de modo que la magnitud de los retornos está correlada en el tiempo aunque su signo apenas lo esté, y eso captura un GARCH. Tercera, *poca autocorrelación* de los retornos en niveles, casi nula a partir del primer rezago, mientras que sus cuadrados o valores absolutos sí la presentan. Las tres juntas sugieren que el activo alterna entre regímenes de dinámica distinta, idea que el modelo de cambio de régimen formaliza.

4.1.2. La salida del agente

El objeto que STRATA supervisa es la decisión diaria de un agente de trading construido sobre un modelo de lenguaje. Las cinco personalidades y la arquitectura multiagente se describieron en la Sección 3.1; para la capa de supervisión importa la salida: cada día, y para cada activo, el agente emite una dirección, un tamaño y la confianza con que los emite. La Sección 4.1.3 la formaliza como una posición $w_t \in [-1, +1]$, el objeto sobre el que actúan los detectores. Las señales de las cinco personalidades reaparecen como variables de entrada del meta-learner de la Sección 4.2.1.

STRATA trata al agente como una caja negra: supervisa su decisión sin abrir el modelo ni reconstruir su razonamiento. El modelo es opaco, su salida no tiene forma cerrada y su entrenamiento pudo ver parte del periodo de prueba; frente a eso, una capa externa que contrasta la decisión con un modelo explícito del mercado es más fiable que confiar en la coherencia interna del agente. El capítulo 5 documenta que esa decisión acierta la dirección menos de la mitad de los días, con un fallo sistemático y por tanto corregible desde fuera.

4.1.3. STRATA a nivel técnico

La Figura 4.1 da la visión global. El agente emite una decisión diaria; los tres detectores la contrastan con un modelo estadístico del mercado; y dos capas la convierten en una posición supervisada, la regla determinista M8 y el meta-learner M10. El resto del capítulo desarrolla esa arquitectura pieza a pieza: primero los detectores, después las capas que consumen sus señales.




Figura 4.1: Arquitectura de STRATA. La decisión del agente (cinco personalidades) pasa por los tres detectores ortogonales (RAM sobre el régimen del HMM, PSA sobre el cambio estructural del BOCPD, GSO sobre la volatilidad del GARCH); sus señales alimentan la capa de intervención M8 o el meta-learner M10, que devuelven la posición supervisada.

Cada día, el agente toma una decisión sobre el activo, resumida en una terna: un *signo* (comprar o vender), un *tamaño* y una *confianza*. Esa terna determina una *posición* $w_t \in [-1, +1]$, donde el signo marca la dirección (larga si $w_t > 0$, corta si $w_t < 0$) y el módulo $|w_t|$ es la fracción de capital expuesta; la posición tomada en t se evalúa contra $w_t \cdot r_{t+1}$. STRATA no decide por el agente: *supervisa* esa decisión. Con $\mathcal{A}$ el espacio de decisiones del agente y $\mathcal{M}_t$ la información de mercado hasta el día t (resumida en $x_{1:t}$), STRATA es la aplicación

$$\text{STRATA}: \mathcal{A} \times \mathcal{M}_t \longrightarrow [0, 1]^3, \quad (w_t, x_{1:t}) \longmapsto (\text{RAM}_t, \text{PSA}_t, \text{GSO}_t),$$

que a partir de la decisión del agente y de una lectura estadística del mercado produce tres *señales*, cada una en $[0, 1]$. STRATA no predice el retorno: mide en qué grado la decisión del agente es coherente con el estado del mercado.

Cada detector cubre un eje distinto. **RAM** se centra en el régimen: comprueba si la dirección de la apuesta encaja con el estado de mercado que el modelo oculto de Markov de la Sección 4.1.4 considera vigente. **PSA** atiende al propio agente; con la detección bayesiana de puntos de cambio vigila si cambia de criterio de forma estructural, no por una fluctuación. **GSO** se ocupa del tamaño: contrasta el módulo de la posición con la volatilidad del GARCH de la Sección 4.1.5, y salta cuando la apuesta es grande para la volatilidad del mercado. La ortogonalidad de los tres ejes hace que cada detector capte algo que los otros no.

La intervención puede ir de solo registrar la señal a reducir la posición o sustituirla. Solo se analiza la variante más fuerte, que reorienta el signo de w_t hacia el régimen cuando la incoherencia es alta; los modos intermedios quedan como trabajo futuro. La Sección 4.1.7 detalla cómo se construye cada señal y cuándo actúa.

Conviene distinguir la capa de señales de las reglas que las consumen. STRATA designa siempre la capa que produce las señales; M8 y M10 son estrategias que la utilizan. **M8** es una regla determinista de umbrales fijos (Sección 4.1.7), referencia interpretable. **M10** no aplica umbrales fijos: es un modelo de segundo nivel (un *meta-learner*) que toma como entradas las salidas del agente y de los detectores y aprende a combinarlas para decidir la dirección del día siguiente. Se entrena solo con el pasado y es el objeto central del caso de estudio (capítulo 5).

4.1.4. Modelos de cambio de régimen: HMM gaussiano

RAM necesita una lectura del estado de mercado. El mercado atraviesa fases distintas —calma, estrés, crisis— que no se observan pero se infieren de los retornos. Hamilton formalizó esta idea con un proceso de Markov sobre estados no observados [20]: el régimen sigue una cadena de Markov y, condicionado a él, la serie observada se distribuye según los parámetros de ese régimen. Los tres regímenes se interpretan como *Calma* (media ligeramente positiva, volatilidad baja), *Estrés* (intermedio) y *Crisis* (volatilidad alta, media negativa).

Definición del HMM gaussiano

Un *modelo oculto de Markov* (HMM) consta de una cadena de estados ocultos y una secuencia de observaciones que esos estados generan [28, 29]. Sea $z_t \in \{1, \dots, K\}$ el estado oculto (el régimen) en el día t . La sucesión $\{z_t\}$ es una cadena de Markov homogénea de primer orden, con *matriz de transición* $A_{ij} = \mathbb{P}(z_{t+1} = j \mid z_t = i)$ ($A_{ij} \geq 0$, $\sum_j A_{ij} = 1$) y *distribución inicial* $\pi_k = \mathbb{P}(z_1 = k)$. El estado no se observa; lo observado es x_t , el vector de características del día t (el log-retorno y la volatilidad realizada RV_t con ventana de 21 días). Suponemos *emisiones gaussianas*,

$$x_t \mid z_t = k \sim \mathcal{N}(\mu_k, \Sigma_k), \quad b_k(x) = \mathcal{N}(x \mid \mu_k, \Sigma_k),$$

y dos hipótesis de independencia condicional, palanca de toda derivación posterior: la observación de cada día depende solo del estado de ese día,

$$\mathbb{P}(x_t \mid z_t, z_{t-1}, \dots, z_1, x_{t-1}, \dots, x_1) = \mathbb{P}(x_t \mid z_t) = b_{z_t}(x_t), \quad (*)$$

y la dinámica de los estados es markoviana de primer orden. El conjunto de parámetros es $\lambda = (A, \pi, \{\mu_k, \Sigma_k\}_{k=1}^K)$, y la verosimilitud observada marginaliza sobre las trayectorias ocultas, $\mathbb{P}(x_{1:T} \mid \lambda) = \sum_{z_{1:T}} \mathbb{P}(x_{1:T}, z_{1:T} \mid \lambda)$. Esta suma recorre K^T trayectorias; el algoritmo *forward* la calcula en tiempo lineal en T .

Algoritmo forward y filtrado causal

La *variable forward* $\alpha_t(k) = \mathbb{P}(x_{1:t}, z_t = k \mid \lambda)$ recupera la verosimilitud completa por marginalización, $\mathbb{P}(x_{1:T} \mid \lambda) = \sum_k \alpha_T(k)$, y admite una recursión que evita la suma exponencial [28, 30].

Proposición 4.1 (Recursión forward). *Para $t \geq 1$ se tiene la inicialización $\alpha_1(k) = \pi_k b_k(x_1)$ y, para todo $j \in \{1, \dots, K\}$,*

$$\alpha_{t+1}(j) = b_j(x_{t+1}) \sum_{k=1}^K \alpha_t(k) A_{kj}.$$

La demostración está en el Anexo A.1. La recursión reduce el coste de K^T a $\mathcal{O}(TK^2)$; en la práctica se trabaja en escala logarítmica para evitar el desbordamiento.

Para decidir interesa la probabilidad del régimen *dado* lo observado, el *posterior filtrado* $\gamma_t^f(k) = \mathbb{P}(z_t = k \mid x_{1:t})$, que normaliza la variable forward [28, 30].

Proposición 4.2 (Filtrado a partir del forward). *Para todo $t \geq 1$ y todo k ,*

$$\gamma_t^f(k) = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)}.$$

Corolario 4.3 (Causalidad del filtrado). *Para cada t , el posterior filtrado γ_t^f es función únicamente de las observaciones $x_{1:t}$. En particular, puede calcularse en tiempo real el día t sin recurrir a ninguna observación posterior.*

La demostración de ambos está en el Anexo A.2. Esa causalidad permite usar el filtrado en producción. Contrasta con el *posterior suavizado* $\mathbb{P}(z_t = k \mid x_{1:T})$, que condiciona sobre la secuencia completa con el algoritmo forward-backward [31, 28]: estima mejor el régimen pasado porque incorpora lo ocurrido después, pero por eso mismo introduciría *look-ahead*. Por el Corolario 4.3, **STRATA usa exclusivamente el posterior filtrado** γ_t^f , nunca el suavizado.

Estimación, trayectoria óptima y número de estados

Los parámetros λ se estiman por el algoritmo de Baum-Welch, instancia del esquema esperanza-maximización (EM) [31, 32]. El paso E calcula los posteriores suavizados de estados y transiciones con el forward-backward —legítimo aquí, porque el ajuste se hace una sola vez fuera de línea sobre la calibración—, y el paso M reestima los parámetros con fórmulas cerradas (Anexo A.3): la distribución inicial y la matriz de transición como frecuencias esperadas, medias y covarianzas como promedios ponderados por el posterior del estado.

Lema 4.4 (Monotonía de EM). *Sea λ' el conjunto de parámetros que produce un paso de EM a partir de λ . Entonces la verosimilitud observada no decrece, $\mathbb{P}(x_{1:T} \mid \lambda') \geq \mathbb{P}(x_{1:T} \mid \lambda)$.*

La demostración está en el Anexo A.5. El óptimo es local y depende de la inicialización, de ahí la importancia de fijar la semilla. Una pregunta distinta al filtrado puntual es la *trayectoria*

de estados más probable, $z_{1:T}^* = \arg \max_{z_{1:T}} \mathbb{P}(z_{1:T} \mid x_{1:T}, \lambda)$, que resuelve el algoritmo de Viterbi por programación dinámica, con una recursión análoga a la del forward que sustituye la suma por un máximo [33] (Anexo A.4). Encadenar los modos del filtrado, $\arg \max_k \gamma_t^f(k)$, no da en general la misma secuencia que Viterbi, que respeta las transiciones de A . El detector de régimen se apoya en el filtrado puntual por causalidad; Viterbi se usa de forma auxiliar para la lectura interpretativa sobre la calibración. El número de estados se fija combinando la log-verosimilitud held-out sobre un tramo de validación posterior [28] con la interpretabilidad económica; ambos fijan $K = 3$ (calma, estrés y crisis), como se desarrolla en el capítulo siguiente.

4.1.5. Volatilidad condicional: ARCH y GARCH(1,1)-t

GSO se ocupa del tamaño de la apuesta, y para juzgarlo necesita una medida de cuánto se mueve el mercado ahora mismo. El HMM reparte la volatilidad en unos pocos estados discretos, lectura útil pero gruesa: dentro de un mismo régimen, la dispersión sube y baja de forma continua. El GARCH captura esa volatilidad que cambia día a día, y es el que alimenta a GSO.

Heterocedasticidad condicional y modelo GARCH(1,1)-t

Una serie de retornos es una realización de un proceso estocástico cuya ley conjunta factoriza en distribuciones condicionales sobre la filtración $\mathcal{F}_{t-1}$ [34, 35]. Las regularidades de la Sección 4.1.1 muestran que el signo de los retornos es casi impredecible mientras su magnitud se agrupa: la varianza condicional depende del pasado. Esta *heterocedasticidad condicional* —la diferencia entre incorrelación e independencia— es lo que explotan los modelos ARCH [27]. El retorno se modela como $r_t^{\log} = \mu + \epsilon_t$ con innovación $\epsilon_t = \sigma_t \eta_t$, η_t i.i.d. de media 0 y varianza 1; μ se toma constante porque en niveles los retornos son incorrelados, y toda la dinámica queda en $\sigma_t^2 = \text{Var}(\epsilon_t \mid \mathcal{F}_{t-1})$. Se distinguen dos nociones de estacionariedad: la *estacionariedad en covarianza*, que exige media y autocovarianzas invariantes, y la *estricta*, invariancia de la ley conjunta de cualquier bloque frente a traslación [36].

Engle introdujo el *ARCH* haciendo la varianza función de los errores recientes al cuadrado [37], pero reproducir la persistencia observada exigía orden alto. Bollerslev lo generalizó al *GARCH*, que añade la varianza pasada y logra esa persistencia con pocos parámetros [38]. Se adopta el GARCH(1,1),

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \omega > 0, \quad \alpha \geq 0, \quad \beta \geq 0, \quad (4.1)$$

suma de un suelo ω , la sorpresa del día anterior (término ARCH, peso α) y la varianza del día anterior (término GARCH, peso β), que aporta memoria larga con un solo parámetro. La *volatilidad condicional* $\sigma_t = \sqrt{\sigma_t^2}$ alimenta a GSO. Las cifras se reportan *anualizadas*, multiplicando σ_t por $\sqrt{252}$.

Como un GARCH gaussiano genera colas demasiado finas para las colas pesadas observadas, η_t se toma con distribución t de Student estandarizada de ν grados de libertad ($\nu > 2$ para que exista la varianza), siguiendo a Bollerslev [39]. Cuanto menor es ν , más pesadas son las colas;

en el límite $\nu \rightarrow \infty$ se recupera el caso gaussiano. Esta es la especificación GARCH(1, 1)- t que emplea la memoria.

Estacionariedad y estimación

La recursión (4.1) solo define un proceso bien comportado bajo una condición sobre los parámetros, que el siguiente resultado caracteriza dando además la varianza a largo plazo.

Teorema 4.5 (Estacionariedad en covarianza del GARCH(1, 1)). *Sea $\{\epsilon_t\}$ el proceso definido por $\epsilon_t = \sigma_t \eta_t$ con $\{\eta_t\}$ i.i.d. de media 0 y varianza 1 y la recursión (4.1), con $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$. Entonces $\{\epsilon_t\}$ admite una solución estacionaria en covarianza con varianza incondicional finita si y solo si $\alpha + \beta < 1$, y en ese caso*

$$\text{Var}(\epsilon_t) = \frac{\omega}{1 - \alpha - \beta}.$$

La demostración está en el Anexo A.6. La suma $\alpha + \beta$ mide la *persistencia* de la volatilidad; en series diarias se estima cerca de 1. El caso límite $\alpha + \beta = 1$ define el *IGARCH* [40], de varianza incondicional infinita y choque permanente, en cuya frontera el Teorema 4.5 deja de garantizar estacionariedad en covarianza. Esta se distingue de la estricta, que se cumple bajo la condición más débil $\mathbb{E}[\log(\alpha \eta_t^2 + \beta)] < 0$ [41].

Los parámetros $\theta = (\omega, \alpha, \beta, \nu)$ se estiman por máxima verosimilitud condicional, maximizando numéricamente sobre $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$, $\nu > 2$ la log-verosimilitud

$$\ell(\theta) = \sum_{t=1}^T \left[\log f_\nu \left(\frac{\epsilon_t}{\sigma_t} \right) - \log \sigma_t \right],$$

con f_ν la densidad de la t estandarizada, cada σ_t de la recursión (4.1) y $-\log \sigma_t$ el jacobiano del cambio $\eta_t \mapsto \epsilon_t$ (Anexo A.7). Bajo especificación correcta y regularidad, $\hat{\theta}$ es consistente y asintóticamente normal, con covarianza el inverso de la información de Fisher [42]; esa normalidad se degrada cuando $\alpha + \beta \rightarrow 1$, lo que se tiene presente al interpretar los intervalos de $\hat{\alpha}$ y $\hat{\beta}$.

4.1.6. Detección bayesiana de puntos de cambio (BOCPD)

PSA mira al agente en lugar de al mercado. Su pregunta es si el agente ha roto con su manera habitual de operar, y la responde estimando día a día cuánto tiempo lleva bajo el mismo patrón; cuando esa cuenta se reinicia, ha habido una ruptura.

Run-length y recursión de Adams–MacKay

El instrumento es la detección bayesiana de puntos de cambio online de Adams y MacKay [43], aplicada a la serie del tamaño de las posiciones del agente. Un *punto de cambio* marca el instante en que cambian los parámetros que generan la serie. Se adopta el *modelo de particiones por producto* [43]: los segmentos entre puntos de cambio son independientes y, dentro de cada uno, las observaciones son i.i.d. —hipótesis análoga a la independencia condicional (*) del HMM—. La variable central es la *run-length* $r_t \in \{0, 1, 2, \dots\}$, los días que el segmento actual

lleva sin ruptura: crece de uno en uno mientras no hay cambio ($r_t = r_{t-1} + 1$) y se reinicia a 0 cuando lo hay. El método es *online*: estima r_t usando solo $x_{1:t}$, la causalidad que exige PSA, igual que el filtrado frente al suavizado en el HMM.

El objetivo es la posterior $\mathbb{P}(r_t \mid x_{1:t})$, que normaliza una conjunta con recursión. Necesita dos ingredientes: la *función de hazard* $H(r) = \mathbb{P}(r_t = 0 \mid r_{t-1} = r - 1)$, frecuencia a priori de los cambios, y la *predictiva posterior* $\pi_{\text{pred}}^{(r)} = \mathbb{P}(x_t \mid r_{t-1} = r, x_{1:t-1})$ del dato nuevo dentro del tramo en curso.

Proposición 4.6 (Recursión de Adams–MacKay). *La distribución conjunta de la run-length y los datos satisface, partiendo de $\mathbb{P}(r_{t-1}, x_{1:t-1})$, los dos mensajes siguientes. El mensaje de crecimiento (no hay cambio, $r_t = r_{t-1} + 1$):*

$$\mathbb{P}(r_t = r_{t-1} + 1, x_{1:t}) = \mathbb{P}(r_{t-1}, x_{1:t-1}) (1 - H(r_{t-1} + 1)) \pi_{\text{pred}}^{(r_{t-1})},$$

y el mensaje de reinicio (hay cambio, $r_t = 0$):

$$\mathbb{P}(r_t = 0, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_{t-1}, x_{1:t-1}) H(r_{t-1} + 1) \pi_{\text{pred}}^{(r_{t-1})}.$$

La posterior de la run-length se recupera normalizando,

$$\mathbb{P}(r_t \mid x_{1:t}) = \frac{\mathbb{P}(r_t, x_{1:t})}{\sum_r \mathbb{P}(r_t = r, x_{1:t})}.$$

La demostración está en el Anexo A.8. La recursión es enteramente causal — $\mathbb{P}(r_t, x_{1:t})$ se construye desde $\mathbb{P}(r_{t-1}, x_{1:t-1})$ y x_t —, por lo que sirve para PSA; en la práctica se trunca el soporte de r_t descartando las run-lengths despreciables, lo que acota el coste sin alterar la inferencia.

Para cerrar el modelo se fija la hazard *constante* $H(r) = 1/\lambda$: la run-length carece de memoria y la longitud de cada segmento es geométrica de media λ pasos, único hiperparámetro de la dinámica. La predictiva $\pi_{\text{pred}}^{(r)}$ se calcula de forma cerrada eligiendo el modelo de observación en una familia exponencial con su *previa conjugada*, lo que da una predictiva analítica que se actualiza de forma incremental [44].

4.1.7. STRATA aplicado: construcción, calibración y umbrales

Cada detector produce una señal numérica que mide un tipo de incoherencia entre la decisión del agente y el estado del mercado; cuando esa señal supera un umbral, STRATA interviene.

Datos y calibración

Los tres modelos se estiman una sola vez, sobre un periodo de calibración fijo y anterior a la evaluación, y no se reentrenan. La Figura 4.2 resume el *protocolo de evaluación causal* que sigue toda la memoria: la calibración (2000 a 2024-09) cierra parámetros y umbrales antes de ver la evaluación (2024-10 en adelante), cuyo arranque queda tras el corte de conocimiento del modelo de lenguaje, de modo que ningún parámetro de STRATA ve los datos futuros. El

protocolo distingue dos ventanas de evaluación: las estrategias que no entrenan (el agente, la regla y las triviales) se miden sobre el OOS completo; las que reentrenan a diario reservan un *burn-in* y se miden sobre la *ventana desplegable* restante, con *walk-forward* rodante y embargo 1 (Sección 4.3.2). Fijar un único periodo de calibración presupone que la estructura de la serie es razonablemente estable dentro de él, hipótesis contrastable con el test de cambios estructurales múltiples de Bai y Perron [45, 46].



Figura 4.2: Protocolo causal en el tiempo. Los detectores se calibran una sola vez sobre 2000 a 2024-09 y sus umbrales se cierran ahí; la evaluación arranca en 2024-10, ya pasado el corte de conocimiento del modelo de lenguaje. Las estrategias que aprenden reservan un *burn-in* de 150 días y se reentrenan con *walk-forward* rodante y embargo 1.

RAM: desajuste entre régimen y acción

El detector RAM mide si la dirección de la apuesta del agente es coherente con el régimen de mercado. Toma como entrada el posterior filtrado γ_t^f de la Sección 4.1.4: para cada día, una distribución de probabilidad sobre los tres regímenes. Lo que falta es asociar esos regímenes a direcciones de mercado, y ahí entra el único ingrediente económico del detector.

En los índices bursátiles agregados, el retorno y la volatilidad están correlados negativamente: los tramos de alta volatilidad coinciden con caídas. Black documentó este fenómeno y lo llamó *leverage effect* [24]; Christie lo estudió de forma sistemática [25]. En un índice, por tanto, el régimen de alta volatilidad adquiere lectura direccional: alta volatilidad tiende a significar mercado a la baja. Esa correspondencia es propia de los índices: en una acción individual el leverage effect es débil y la asociación entre volatilidad y dirección se diluye. La Figura 4.3 contrasta los dos casos: en SPY el retorno de hoy y el cambio de volatilidad de mañana caen sobre una recta de pendiente clara, mientras que en una acción débil la nube es plana. Donde la pendiente se aplanan, RAM pierde su asidero económico. Por eso STRATA no fija la dirección de cada régimen a mano, sino que la aprende del dato: para cada régimen k toma el signo de su media de log-retorno, la componente de retorno del vector μ_k estimado en la calibración, de modo que el régimen de media más negativa se asocia a la dirección bajista y el de media más positiva a la alcista. Este prior por activo permite aplicar RAM a cualquier serie sin suponer que se comporta como un índice.

Con el prior fijado, se formaliza el detector. Para cada régimen k , sea $d_k = \text{sign}((\mu_k)_{\text{ret}}) \in \{-1, 0, +1\}$ su dirección aprendida (el signo de la componente de retorno de μ_k), y sea w_t la posición del agente.

Definición 4.7 (RAM score). El *RAM score* es la masa filtrada sobre los regímenes cuya




Figura 4.3: *Leverage effect* en un índice frente a una acción individual: retorno del día t contra el cambio de la volatilidad realizada del día siguiente, $RV_{t+1} - RV_t$. En SPY (izquierda) la correlación es marcadamente negativa y el régimen de alta volatilidad adquiere lectura direccional; en la acción débil (derecha) la nube es plana y esa lectura se pierde.

dirección aprendida contradice la apuesta del agente,

$$RAM_t = \sum_{k=1}^K \gamma_t^f(k) \mathbf{1}\{\text{sign}(w_t) d_k < 0\} = \mathbb{P}(\text{sign}(w_t) d_{z_t} < 0 \mid x_{1:t}) \in [0, 1].$$

En los tres regímenes de la calibración (Calma alcista, $d = +1$; Crisis bajista, $d = -1$; Estrés neutro, $d = 0$) esto es $RAM_t = \gamma_t^f(\text{Crisis})$ si el agente va largo y $RAM_t = \gamma_t^f(\text{Calma})$ si va corto; el Estrés, sin dirección, nunca penaliza. El score, en $[0, 1]$, crece con la probabilidad que el HMM pone en que el agente apuesta contra el régimen. El detector se activa con tres umbrales ex ante, 0,25, $\tau = 0,50$ y 0,70, de severidad baja, media y alta. El operativo es el central, $\tau = 0,50$: interviene cuando la dirección contraria a la apuesta acumula más de la mitad de la probabilidad de régimen, la regla de mayoría. En el caso de estudio el score concentra su masa cerca de 0 o de 1, de modo que el acierto apenas cambia para umbrales en un entorno de 0,5.

GSO: tamaño compatible con la volatilidad

GSO comprueba si el tamaño de la apuesta es compatible con la volatilidad vigente. Su referencia teórica es el *volatility targeting*, que dimensiona la posición de forma inversamente proporcional a la volatilidad estimada ($\propto 1/\sigma$) para mantener el riesgo constante; Moreira y Muir documentan que una variante, el escalado por la inversa de la *varianza* ($1/\sigma^2$), mejora el rendimiento ajustado por riesgo [23]. GSO toma la volatilidad condicional σ_t del GARCH(1,1)- t de la Sección 4.1.5, calculada con información hasta $t-1$, y la traduce en una banda de tamaño admisible.

Definición 4.8 (Banda de volatilidad y GSO score). Dada una volatilidad objetivo anualizada v^* ($v^* = 0,10$ en la memoria), la *banda* admisible y el *GSO score* son

$$b_t = \min\left(1, \frac{v^*}{\sigma_t}\right), \quad GSO_t = \frac{\max(0, |w_t| - b_t)}{b_t}.$$

El score mide la sobreexposición relativa: nulo mientras el tamaño cabe en la banda y creciente cuando la supera. GSO emite señal cuando GSO_t rebasa los percentiles 95 y 99 de la calibración, y en la intervención recorta el tamaño a $\text{sign}(w_t) \min(|w_t|, b_t)$.

Sobre los datos estudiados, GSO rara vez supera la severidad media: el tamaño del agente casi nunca viola la banda. Es una limitación del detector sobre este activo, recogida en los resultados.

PSA: coherencia temporal del agente

PSA vigila la coherencia temporal del agente: detecta si cambia de criterio de forma estructural, no como fluctuación dentro de un mismo patrón. Aplica la detección bayesiana de puntos de cambio de la Sección 4.1.6 a la serie de tamaños de posición, con hazard constante $H = 1/\lambda$, $\lambda = 250$, que fija a priori la escala entre rupturas en un año bursátil (la media de la geométrica de la Sección 4.1.6): un cambio esperado al año, fijado a mano y sin optimizar contra el periodo de evaluación.

Definición 4.9 (PSA score). El *PSA score* es la masa posterior de la run-length sobre las rachas cortas, esto es, la probabilidad de que se haya producido un cambio reciente,

$$\text{PSA}_t = \sum_{r=0}^w \mathbb{P}(r_t = r \mid x_{1:t}),$$

con $w = 5$ la ventana de racha corta (en días de mercado). Crece cuando el *sizing* del agente acaba de romper con su patrón previo.

Los umbrales operativos siguen el mismo criterio que GSO: los percentiles 95 y 99 sobre el periodo de calibración. En la intervención, se exige un índice muy alto de PSA para frenar la posición resultante.

La capa de intervención

Las tres señales alimentan la capa de intervención, que transforma la posición w_t en una posición supervisada w_t^* por composición de tres operadores. Sea $\rho_t = +1$ si $\gamma_t^f(\text{Calma}) \geq \gamma_t^f(\text{Crisis})$ y $\rho_t = -1$ en otro caso, la dirección del régimen dominante.

Definición 4.10 (Capa de intervención M8). La posición supervisada es $w_t^* = (C_{\text{PSA}} \circ R_{\text{RAM}} \circ G_{\text{GSO}})(w_t)$, donde cada operador actúa solo si su detector dispara y es la identidad en caso contrario:

$$G_{\text{GSO}}(w) = \text{sign}(w) \min(|w|, b_t), \quad R_{\text{RAM}}(w) = \rho_t b_t, \quad C_{\text{PSA}}(w) = \frac{1}{2} w.$$

El disparo se produce con severidad *medium* o superior para GSO y RAM (es decir, $\text{RAM}_t \geq \tau$) y *high* para PSA.

El GSO acota la magnitud a la banda de volatilidad; el RAM, cuando $\text{RAM}_t \geq \tau$ con $\tau = 0,50$, reorienta la posición al signo del régimen con esa banda (el único paso que cambia la dirección); el PSA frena a la mitad ante un cambio brusco de *sizing*. La regla de referencia M8 es esta configuración, con $\text{signal_lag} = 1$.

4.2. Estrategias supervisadas: M8, M10 y AutoML

La regla M8 combina las tres señales con umbrales fijos. La pregunta natural es si una combinación *aprendida* lo haría mejor: en lugar de fijar los umbrales a mano, un modelo puede estimar de los datos cómo pesar la información del agente y de STRATA para anticipar la dirección del día siguiente. Esa es la estrategia M10, y su generalización mediante búsqueda automatizada de modelos es AutoML.

4.2.1. El problema de aprendizaje supervisado

Cada día se dispone de un vector de características $\mathbf{x}_t \in \mathbb{R}^d$ con $d = 22$: las ternas de las cinco personalidades del agente (Buffett, Wood, Druckenmiller, Burry y Ackman), cada una con su *signo*, *tamaño* y *confianza* (quince componentes), y las siete lecturas estadísticas de STRATA —las tres señales $\text{RAM}_t, \text{PSA}_t, \text{GSO}_t$, las tres probabilidades de régimen filtradas γ_t^f (Calma), γ_t^f (Estrés), γ_t^f (Crisis) y la volatilidad condicional σ_t del GARCH. La etiqueta es la dirección realizada del día siguiente,

$$y_t = \mathbf{1}\{r_{t+1} > 0\} \in \{0, 1\},$$

de modo que el problema es de clasificación binaria causal: a partir de $\mathbf{x}_t$, conocido en t , predecir el signo de r_{t+1} . Un modelo produce una probabilidad estimada $p(\mathbf{x}_t) = \hat{\mathbb{P}}(y_t = 1 \mid \mathbf{x}_t)$, y la posición asociada es

$$w_t = \text{sign}(p(\mathbf{x}_t) - \frac{1}{2}),$$

larga si el modelo da más de un medio a la subida y corta en caso contrario. Esta capa de segundo nivel, que aprende sobre las salidas del primer nivel (el agente) en lugar de sobre los precios crudos, es un *meta-learner* en el sentido de López de Prado [2]. El ajuste minimiza la entropía cruzada (*pérdida logística*), verosimilitud negativa del modelo de Bernoulli. La familia $p(\cdot)$ que se adopta es la de los árboles de decisión potenciados.

4.2.2. De los árboles al meta-learner M10

La pieza elemental es el *árbol de decisión*, función constante a trozos sobre una partición rectangular del espacio de características [47]; aislado tiene poco sesgo pero mucha varianza. El *gradient boosting* construye un predictor aditivo como suma de árboles ajustados en etapas, cada uno al gradiente negativo de la pérdida (los *pseudo-residuos*) sobre el modelo acumulado [48]; para la pérdida logística esos residuos tienen forma cerrada (Anexo A.9). *XGBoost* es la realización que añade regularización explícita sobre la complejidad de cada árbol y usa la curvatura de la pérdida, lo que da solución cerrada para los pesos de hoja y para la ganancia de cada división, criterio con el que se eligen los cortes [49] (Anexo A.10).

El *meta-learner* M10 es XGBoost con hiperparámetros fijados en la calibración (trescientos árboles de profundidad cuatro, tasa de aprendizaje $\nu = 0,05$, submuestreo de filas y columnas al ochenta por ciento, regularización $\lambda = 1$, pérdida logística). Para rebajar la varianza promedia $B = 10$ ajustes que solo difieren en la semilla, $\bar{p}(\mathbf{x}) = \frac{1}{B} \sum_b p^{(b)}(\mathbf{x})$ [50, 47]. Su posición es $w_t = \text{sign}(\bar{p}(\mathbf{x}_t) - \frac{1}{2})$, y se entrena con el *walk-forward* de la Sección 4.3.2, con ventana

expandible y embargo 1.

4.2.3. Apilamiento y búsqueda automatizada AutoML

El *apilamiento* (*stacking*) combina varios modelos base entrenando un segundo modelo sobre sus predicciones fuera de muestra [51]; el *super learner* de van der Laan, Polley y Hubbard formaliza la idea y goza de una propiedad oráculo asintótica [52]. Es la pieza *StackedEnsemble* de la búsqueda automatizada. La estrategia AutoML relaja la elección de familia: en vez de fijar XGBoost, una búsqueda entrena y compara modelos de varias familias y devuelve el mejor. Se usa H2O AutoML, restringido por activo a GBM, XGBoost y StackedEnsemble, evaluando cada modelo por validación cruzada purgada (la K -fold con embargo de la Sección 4.3.2) y eligiendo el *leader* por AUC; su posición es $w_t = \text{sign}(p_1(\mathbf{x}_t) - \frac{1}{2})$, reentrenada con el mismo walk-forward causal. La búsqueda se acota por número fijo de modelos y semilla fija, no por presupuesto de tiempo, para que sea reproducible. Su papel es servir de control de universalidad (Capítulo 6): si ni una búsqueda sobre varias familias bate de forma robusta a las referencias triviales, la señal aprovechable ya está capturada con independencia de la familia.

4.2.4. Estrategias

Todas las estrategias devuelven una posición w_t contra r_{t+1} con `signal_lag = 1`; la probabilidad p_1 de los modelos supervisados es un paso intermedio.

Definición 4.11 (Estrategias evaluadas). Sobre el mismo periodo de prueba y con causalidad `signal_lag = 1`:

- **M5** (agente): la posición cruda del agente, $w_t = \text{sign}(\text{tamaño}_t)$, sin supervisión.
- **M8** (intervención): la regla determinista de umbrales fijos de la Definición 4.10, $w_t = w_t^*$.
- **M10** (meta-learner): el promedio de diez XGBoost sobre las 22 características, $w_t = \text{sign}(\bar{p}(\mathbf{x}_t) - \frac{1}{2})$.
- **AutoML**: el *leader* de la búsqueda H2O sobre GBM/XGBoost/StackedEnsemble, $w_t = \text{sign}(p_1(\mathbf{x}_t) - \frac{1}{2})$.
- **ZeroR**: la referencia trivial sin habilidad, que predice la clase mayoritaria del pasado estricto, $w_t = \text{sign}(\frac{1}{t-1} \sum_{s < t} y_s - \frac{1}{2})$, calculada de forma causal.
- **B&H** (*buy and hold*): comprar y mantener, $w_t \equiv 1$.

Las dos últimas son las referencias frente a las que toda estrategia con pretensión de habilidad debe demostrar valor: ZeroR fija el techo direccional sin información, y B&H la exposición pasiva. El capítulo de resultados contrasta M5, M8, M10 y AutoML contra ambas y entre sí.

4.3. Protocolo de evaluación

4.3.1. Métricas de evaluación

Las métricas enriquecen la lectura, pero ninguna prueba nada por sí sola: la prueba descansa en los contrastes de la Sección 4.3.3. La métrica primaria es el *acierto direccional*: w_t acierta cuando su signo coincide con el de r_{t+1} , y la *accuracy* es la fracción de días en que concuerdan, $\text{Acc} = \frac{1}{n} \sum_t \mathbf{1}\{\text{sign}(w_t) = \text{sign}(r_{t+1})\}$. El acierto diario se ordena en una *matriz de confusión* 2×2 , de la que se leen también la *precisión* y el *recall*. El objeto de los contrastes es más fino: el *vector diario* $a_t = \mathbf{1}\{\text{sign}(w_t) = \text{sign}(r_{t+1})\} \in \{0, 1\}$, que alineado entre dos estrategias da los pares del sign test y McNemar. Cuando hay probabilidad $p_1(\mathbf{x}_t)$ antes de umbralizar, el *AUC* —área bajo la curva ROC [53, 54]— mide, sin depender del umbral, con qué frecuencia el modelo da mayor p_1 a un día de subida que a uno de bajada; la búsqueda automatizada elige su *leader* por este criterio. Dos referencias triviales fijan el listón (Definición 4.11): *ZeroR*, la frecuencia de la dirección dominante, y *B&H*, la exposición pasiva.

Las métricas de riesgo trabajan sobre los retornos diarios causales $g_t = w_t \cdot r_{t+1}$. El *ratio de Sharpe* [55, 56] es el cociente $\text{SR} = \bar{g}/\hat{\sigma}_g$ entre retorno medio y desviación típica, anualizado por $\sqrt{252}$, y penaliza por igual la volatilidad al alza y a la baja. La *máxima caída* (*maximum drawdown*) capta las rachas malas, la mayor pérdida relativa desde un máximo previo sobre la curva de capital $V_t = \prod_{s \leq t} (1 + g_s)$ [57], y es la medida de riesgo que más pesa en el panel. El *ratio de Calmar* relaciona el rendimiento anualizado con esa peor caída [58].

4.3.2. Validación

Un backtest no vale si su evaluación usa información no disponible al decidir (*look-ahead*): solo pasado y presente, nunca futuro. La posición w_t se decide con la información hasta el cierre de t , cuando r_t ya se conoce; contabilizar $w_t \cdot r_t$ dejaría a la decisión mirar su propio resultado. La regla correcta, `signal_lag=1` en el código, contabiliza la posición de t contra el retorno del día siguiente, $w_t \cdot r_{t+1}$ [2]. Encaja con el filtrado causal de la Sección 4.1.4: el régimen γ_t^f que alimenta la decisión en t se calcula solo con $x_{1:t}$.

La convención asegura la causalidad de una decisión aislada, pero el meta-learner *aprende* y validarlo exige un protocolo desplegable. Se adopta el *walk-forward* de origen rodante (*rolling-origin*), estándar para series temporales [59, 60]: tras un *burn-in* que no se puntúa, cada cierto número de días el modelo se reentrena con toda la información hasta la fecha y predice el bloque siguiente, estrictamente futuro. La ventana se expande y nunca retrocede, causal por construcción. Cuando la etiqueta se solapa con el bloque de evaluación, la *purga* retira las observaciones cuyo horizonte cae en él, y el *embargo* descarta los h días posteriores para cortar la autocorrelación de retornos contiguos [2]. Como el horizonte es de un solo día, se fija $h = 1$: elimina el único solape posible, y un embargo mayor descartaría información válida. La Figura 4.4 muestra el esquema.

Barajar los pliegues al azar rompe el orden del tiempo: la K -fold convencional puede meter en entrenamiento días posteriores al test, fuga que infla las métricas. Ningún resultado descansa sobre ella. La forma correcta es la *validación cruzada combinatoria purgada* (CPCV), que combina los pliegues con purga y embargo [2, sec. 7.4]; de ella se toma el walk-forward




Figura 4.4: Validación *walk-forward* de origen rodante con purga y embargo. La ventana de entrenamiento se expande y nunca retrocede; el bloque de test es estrictamente futuro; la purga retira las observaciones cuyo horizonte de etiqueta cae en el test y el embargo 1 descarta el día contiguo para cortar la autocorrelación.

desplegable para el meta-learner y una *K-fold purgada* (partida por columna temporal con embargo) para la validación interna de la búsqueda. La *K-fold* sin purgar aparece una sola vez, deliberadamente, como contraejemplo del sesgo que introduce.

Finalmente, el contraste decisivo del rescate de riesgo necesita más muestra que la de un activo. La *agregación pooled* apila las series diarias pareadas de los diez activos en una serie de $n \approx 2493$ días, sobre la que se calcula un único estadístico con su intervalo: multiplica la potencia para distinguir del cero un efecto que en un activo aislado queda dentro del ruido. Es el *pooled-10*. El precio es que los diez activos no son del todo independientes, de modo que el intervalo pide cautela; se discute al interpretar el panel (Capítulo 6).

4.3.3. Contraste de hipótesis

La economía ilustra; la prueba está aquí. Cada pregunta tiene su contraste, con su hipótesis nula y su estadístico (Tabla 4.1). El acierto direccional se contrasta contra el azar con el *sign test* sobre el vector diario a_t (con *intervalo de Wilson*) y, entre dos estrategias, con el *test de McNemar* sobre los días discordantes, $\chi^2 = (b - c)^2 / (b + c)$, en su versión binomial exacta cuando son pocos; la *permutación por bloques* respeta la autocorrelación. El rescate de riesgo se mide sobre la diferencia de Sharpe pareada ΔSR : sin fórmula cerrada fiable bajo dependencia temporal, su intervalo sale del *bootstrap estacionario* en bloques de media $\sqrt{n}$, y el *Deflated Sharpe Ratio* lo depura por número de configuraciones y colas anchas. La multiplicidad se controla con *Holm*; la equivalencia, con el *TOST*, que solo concluye si el intervalo de la diferencia cae entero en $[-\delta, +\delta]$. La asociación de la ley del leverage se mide con *Pearson* y *Spearman* al nivel pre-registrado $\alpha = 0,10$, y la complementariedad por régimen con un *diferencia en diferencias*, $\Delta \Delta SR = (SR_{\text{alza}}^A - SR_{\text{alza}}^B) - (SR_{\text{baja}}^A - SR_{\text{baja}}^B)$. La interpretabilidad atribuye la predicción a cada feature con los *valores de Shapley* (TreeSHAP) y define la *cuota STRATA* = $(\sum_{j \in \text{STRATA}} |\text{SHAP}_j|) / (\sum_j |\text{SHAP}_j|)$, confirmada con la *importancia por permutación*. El agrupamiento del panel usa cuatro algoritmos de familias distintas y juzga la partición con *silueta*, *índice de Rand ajustado* y *PCA* (*BIC* fijando las componentes).

El capítulo siguiente lleva STRATA a SPY y mide si rescata al agente.

Tabla 4.1: Contrastes y herramientas del trabajo, por la pregunta que responden.

Pregunta	Test / herramienta	Referencia
Dirección	Sign test (e intervalo de Wilson); McNemar pareado; permutación por bloques	[61, 62]
Riesgo	Bootstrap estacionario sobre Δ SR; Deflated Sharpe Ratio	[63, 64]
Multiplicidad	Corrección de Holm	[65]
Equivalencia	TOST (<i>two one-sided tests</i>)	[66]
Asociación	Pearson (lineal) y Spearman (monótona)	
Complementariedad	Diferencia en diferencias ($\Delta\Delta$ SR)	
Interpretabilidad	Valores de Shapley (TreeSHAP); importan- cia por permutación	[67, 68, 69]
Agrupamiento	Silueta; índice de Rand ajustado; PCA (k - medias, Ward, mezclas gaussianas, espec- tral; BIC)	[70, 71, 32, 72, 73, 74, 75]

Capítulo 5

Aplicación a SPY

El agente solo (M5) acierta sobre SPY el 0,366 de las direcciones y pierde dinero: ese es el punto de partida. SPY, el ETF que replica el S&P 500, tiene un *leverage effect* de índice amplio que da al régimen contenido direccional (Sección 4.1.7), lo que lo hace un buen caso para mostrar el sistema. Sobre él se construye la cadena entera: la intervención y su anatomía, las seis estrategias y la atribución de lo que STRATA rescata.

5.1. La intervención en detalle

El caso de SPY aplica el protocolo de evaluación causal del Capítulo 4 (Sección 4.3): calibración cerrada hasta 2024-09, evaluación OOS desde 2024-10 y `signal_lag = 1`. Sobre SPY, la ventana OOS completa tiene $n = 401$ días y la desplegable, tras el *burn-in*, $n = 251$.

El régimen de SPY tiene contenido direccional por el *leverage effect* del índice (Sección 4.1.7). La Figura 5.1 lo representa sobre el precio; es descriptiva, decodificada con el camino de Viterbi (Anexo A.4), mientras que RAM usa el filtrado causal. Con un matiz: el régimen coincide con la caída del mismo día pero no anticipa el signo del siguiente, la fracción de días al alza ronda 0,5 incluso en Crisis.



Figura 5.1: Regímenes del HMM ($K = 3$) sobre el precio de SPY en el periodo de evaluación. Calma (volatilidad baja, retorno medio positivo), Estrés (intermedio) y Crisis (volatilidad alta, retorno medio negativo) ordenan por la firma del *leverage effect*. El sombreado marca el régimen vigente cada día; la coincidencia régimen↔caída es contemporánea, no predictiva.

Esa coincidencia contemporánea se ve en la matriz régimen×dirección (Figura B.1 del Anexo B): el régimen acierta el signo del mismo día, pero la fracción de días al alza del siguiente ronda 0,5 en todos los regímenes, también en Crisis. RAM explota una asociación contemporánea, no una capacidad de anticipar el signo de mañana.

Los tres detectores miran dimensiones ortogonales de la decisión del agente. RAM comprueba si la dirección de la apuesta concuerda con el régimen vigente: su *score* es la probabilidad que el HMM pone en que el agente apuesta contra el régimen, y dispara cuando $\text{RAM}_t \geq \tau = 0,50$. PSA vigila con BOCPD si el agente cambia de criterio de forma estructural [43]. GSO contrasta el tamaño de la posición con la volatilidad del GARCH [38]. Cuando RAM dispara, la intervención reorienta la posición al signo del régimen, fijado por un prior calibrado por activo a partir de la media del retorno de cada estado, nunca por una regla del tipo “Crisis implica corto” escrita a mano. La Figura 5.2 sigue ese flujo en un día.




Figura 5.2: Anatomía de un día de intervención sobre SPY: la decisión del agente entra en RAM, que la compara con el régimen filtrado; si choca y el *score* supera $\tau = 0,50$, la intervención la reorienta y el resultado se evalúa contra el retorno del día siguiente.

Sobre SPY actúa una sola supervisión (Tabla 5.1). RAM dispara casi un tercio de los días y acierta más al intervenir que el agente al que corrige; PSA dispara dos días y GSO ninguno, porque el agente mantiene una posición casi constante y sus *scores* de cambio y de tamaño quedan por debajo de los umbrales. PSA y GSO son detectores inertes como reglas sobre este activo. Todo el rescate acumulado sale de los días en que RAM dispara.

Tabla 5.1: Actividad de los tres detectores sobre el OOS completo de SPY ($n = 401$ días). “Acierto” es la fracción de direcciones correctas en los días en que el detector dispara; el P&L de rescate es el acumulado de la intervención en esos días. PSA y GSO apenas disparan: su columna de acierto no aplica.

Detector	Tasa de disparo	Acierto M8	Acierto M5	P&L de rescate
RAM (régimen)	30,2 %	0,587	0,413	+0,312
PSA (cambio estructural)	0,5 %	—	—	0,000
GSO (volatilidad)	0,0 %	—	—	0,000

Cuando RAM está alto, seguir el régimen supera en acierto a seguir al agente; cuando está bajo, la ventaja se diluye y la intervención no se activa (Figura 5.3a). El detector actúa como una compuerta de régimen: deja pasar la decisión del agente salvo cuando choca con el régimen, y solo entonces la corrige. En SPY esa compuerta es todo el mecanismo de la regla.

La intervención admite tres modos: abstenerse cerrando la posición, reducir el tamaño a la mitad o reorientar la dirección al signo del régimen (*override*). La Tabla 5.2 los compara sobre los días en mercado ($n = 232$): el *override*, el modo canónico, gana en acierto y en Sharpe, mientras abstenerse y reducir apenas se distinguen del agente sin tocar. El valor está en corregir activamente la dirección, no en limitarse a evitar el riesgo.

La anatomía de esas intervenciones (Figura 5.3b) separa dos efectos: unas corrigen al




Figura 5.3: Disparo de los detectores y anatomía de la intervención sobre SPY.

Tabla 5.2: Modos de intervención de M8 sobre SPY (días en mercado, $n = 232$). El modo canónico (*override*) reorienta la posición al signo del régimen; las alternativas se abstienen o reducen el tamaño. En negrita, el modo adoptado.

Modo	Accuracy	Sharpe	Capital
Override (canónico)	0,478	-0,46	0,94×
Abstención	0,401	-2,10	0,81×
Reducir a la mitad	0,397	-2,75	0,75×
M5 (agente sin tocar)	0,397	-3,07	0,70×

agente cuando apostaba contra el régimen (71 aciertos), otras añaden ruido cuando el agente tenía razón (50). El saldo neto es positivo: los días de discrepancia grande, los más frecuentes, aportan el grueso del rescate.

5.2. Comparación de las seis estrategias

Las seis estrategias del capítulo anterior se comparan sobre la ventana desplegable: M5 (agente sin supervisar), M8 (regla determinista), M10 (meta-learner, un *ensemble* de diez XGBoost sobre las veintidós características del agente y de STRATA), AutoML (búsqueda de H2O entre GBM, XGBoost y su apilamiento) y las dos referencias triviales, comprar y mantener (B&H) y la clase mayoritaria del pasado (ZeroR). La Tabla 5.3 las reúne.

Leída de abajo arriba, cada capa rescata a la anterior: la regla recupera al agente y le recorta a la mitad la máxima caída, el meta-learner sube otro escalón en accuracy, y AutoML gana en todas las columnas, también a las dos triviales. El rescate es significativo en los tres casos, contrastado con el McNemar pareado sobre los aciertos diarios frente al agente [62]. Las matrices de confusión abren ese acierto (Figura B.7 del Anexo B): no es lo mismo acertar repartido que acertar siempre la misma clase.

Tabla 5.3: Las seis estrategias sobre SPY, ventana desplegable ($n = 251$, `signal_lag = 1`). Accuracy direccional, Sharpe anualizado, máxima caída, ratio de Calmar [58] y capital final por euro invertido. En negrita, la mejor en cada columna.

Estrategia	Accuracy	Sharpe	Máx. caída	Calmar	Capital
AutoML (búsqueda H2O)	0,574	+2,68	−5,5 %	6,93	1,38×
ZeroR (clase mayoritaria)	0,566	+2,21	−9,8 %	3,10	1,30×
B&H (comprar y mantener)	0,566	+2,21	−9,8 %	3,10	1,30×
M10 (meta-learner XGBoost)	0,494	−0,60	−16,1 %	−0,50	0,92×
M8 (regla STRATA)	0,442	−0,46	−15,2 %	−0,39	0,94×
M5 (agente solo)	0,366	−3,07	−30,2 %	−1,00	0,70×

La ventaja sobre la trivial es nominal: el McNemar de AutoML frente a ZeroR no las separa, sin potencia en una ventana de doscientos cincuenta días. La ventaja de AutoML sobre el mercado pasivo sí es real en punto, con explicación económica: SPY es mayormente beta de mercado, el periodo fue alcista e ir largo capturó esa subida (Figura 5.4). El Sharpe deflactado [2, 64] lo confirma: solo el DSR de AutoML se acerca a uno, mientras los de M10 y el agente quedan pegados a cero. AutoML es el único cuyo Sharpe sobrevive al ajuste por número de pruebas.




Figura 5.4: Curvas de capital de las seis estrategias sobre SPY (ventana desplegable, $n = 251$ días, un euro inicial). AutoML (línea destacada) supera a las dos referencias triviales en Sharpe (+2,68 frente a +2,21), en máxima caída (−5,5 % frente a −9,8 %) y en capital final (1,38× frente a 1,30×); el agente solo (M5) termina en 0,70×. La ventaja sobre la trivial es nominal (McNemar AutoML vs ZeroR $p = 0,902$).

Sobre un único activo, el intervalo de confianza del Δ Sharpe de la regla frente al agente cruza el cero. Ese resultado en riesgo, que sobre un activo no alcanza significancia, se comprueba sobre una muestra mayor de activos en el capítulo siguiente.

5.3. El rescate sobre SPY

Sobre SPY el régimen (Sección 5.1) es el único canal que rescata, y el aprendiz no gana por otra vía. La ablación lo confirma: al quitar PSA y GSO y reentrenar, la accuracy de AutoML baja (Tabla 5.4). Aunque esos dos detectores casi nunca disparen como reglas, sus *scores* continuos llevan información que el modelo aprovecha (PSA y GSO permanecen inactivos porque el agente apenas cambia de posición, Figura B.4; el régimen de RAM es contemporáneo, no predictivo, Figura B.1 del Anexo B).

Los valores de Shapley [67] lo confirman: STRATA aporta solo siete de las veintidós características y se lleva más de la mitad del peso. La cuota va etiquetada con su modelo y

ventana, porque no son el mismo objeto: sobre el ensemble M10 ($n = 251$) vale 0,71; sobre el *leader* de AutoML ($n = 401$), 0,565 por árbol y 0,564 por permutación. En todos supera la mitad: el aprendiz coloca los detectores por delante de las características del agente. Cómo usa cada señal y la estabilidad de ese apoyo están en las Figuras B.5 y B.6 del Anexo B. El aprendiz corrige justo donde el agente más falla (Figura B.2 del Anexo B).

Tabla 5.4: Ablación de detectores sobre SPY (ventana desplegable, $n = 251$). El conjunto canónico usa las veintidós características; “sin PSA+GSO” deja solo el canal de régimen entre los detectores. AutoML degrada al quitar PSA+GSO, prueba de que usa sus *scores*.

Conjunto de características	Accuracy AutoML	Accuracy M10
ALL22 (canónico)	0,574	0,494
sin PSA+GSO	0,550	0,514

Las dos capas no rescatan por el mismo eje (Figura 5.5). Todo el P&L de rescate de la regla se concentra en el canal de régimen: RAM aporta el 100 %, PSA y GSO cero. La regla rescata por riesgo y el aprendiz por accuracy, cada uno por un eje distinto.




Figura 5.5: Reparto de funciones entre las dos capas. A la izquierda, atribución del P&L de rescate por detector sobre SPY: el canal de régimen (RAM) concentra el 100 %, PSA y GSO aportan cero. A la derecha, evolución diaria del rescate de la regla (riesgo, Δ Sharpe acumulado) frente al del aprendiz (accuracy, aciertos acumulados sobre el agente): cada serie sube por un eje distinto.

La objeción más natural es que los umbrales se eligieran para que el resultado saliera bien. El barrido completo lo descarta (Figura B.8 del Anexo B): la accuracy apenas se mueve alrededor del valor canónico, ni al variar el umbral τ de RAM en M8 ni el de decisión del meta-learner. El resultado descansa sobre una meseta estable, no sobre un punto afortunado.

La robustez alcanza también a la ventana con que se calibran los detectores: al desplazar el periodo de calibración, el rescate se mantiene (Figura B.3 del Anexo B).

Sobre SPY el mecanismo es transparente: el agente sin supervisión pierde con holgura, la intervención por régimen lo corrige de forma significativa, la derivada aprendida supera a la trivial en este punto apoyándose en STRATA, y todo descansa sobre una meseta robusta de umbrales. A nivel de un único activo, la corrección de riesgo no alcanza significancia y la ventaja sobre la trivial es nominal. El rescate fuera de SPY se prueba sobre el panel de diez activos.

Capítulo 6

Validación sobre el panel de diez activos

El rescate de SPY no se separaba del cero en solitario: el intervalo del Δ Sharpe cruzaba el cero. El contraste decisivo es el panel: diez activos (SPY, QQQ, XLF, DIA, XLK, XLE, ROKU, SMCI, MARA, UNG), elegidos para cubrir distintos grados de *leverage effect*. Sobre ellos se repite la cadena de SPY y se agregan los resultados. Al apilar el panel, el rescate de riesgo que en un activo no alcanzaba significancia la alcanza.

6.1. El rescate en el panel

El fallo del agente es general, no propio de SPY: sobre el panel acierta menos de la mitad de las direcciones en siete de los diez activos, y donde lo supera lo hace por poco y con un Sharpe pobre. Ese es el punto de partida que STRATA corrige.

6.1.1. La compuerta de régimen y la activación de detectores


Los tres detectores no se activan por igual: RAM domina en todo el panel y PSA y GSO apenas disparan, porque el agente mantiene posiciones casi constantes (Figura 6.1a). La supervisión recae, como en SPY, sobre el canal del régimen.

La intervención de RAM no es arbitraria: su frecuencia crece casi linealmente con la discrepancia entre la apuesta del agente y el signo del régimen (Figura 6.1b). Donde RAM dispara, seguir el régimen supera en acierto a seguir al agente en **seis de los diez** activos.


6.1.2. Accuracy por activo: dónde se supera a la trivial

El mapa de calor de la Figura 6.2 cruza los diez activos con las seis estrategias en accuracy. La mejor derivada de STRATA mejora al agente en los **diez de diez** activos, con una mejora media de +0,086, y supera a las dos referencias triviales en cuatro: SPY y MARA por AutoML, SMCI y UNG por M10. En los seis restantes la trivial aguanta; en índices muy direccionales como XLK la clase mayoritaria del pasado supera 0,64 y ninguna derivada se le acerca.

Esas ventajas son reales en punto pero nominales: con unos doscientos cincuenta días por activo y una ganadora que cambia de activo en activo, se seleccionan a posteriori y ninguna



(a) Tasa de disparo de RAM, PSA y GSO y de intervención de la regla, activo a activo. RAM domina en todo el panel y los otros dos apenas se encienden.



(b) Tasa de intervención de RAM frente a la discrepancia media agente↔régimen, un punto por activo. La relación es casi recta (Pearson $r = 0,93$, $p < 0,001$).

Figura 6.1: La compuerta de régimen sobre el panel: activación de los detectores (izquierda) y dependencia de la intervención con la discrepancia (derecha).




Figura 6.2: Mapa de calor de la accuracy direccional por activo (filas) y estrategia (columnas), centrado en 0,5: el color mide la distancia a una referencia trivial. Verde marca accuracy por encima de la trivial del activo, rojo por debajo. La mejor derivada de STRATA supera a las dos triviales solo en SPY, SMC, MARA y UNG; en los demás la trivial aguanta. Victorias nominales ($n \approx 250$, a posteriori).

supera a ZeroR con significancia (McNemar AutoML vs ZeroR sobre SPY, $p = 0,90$). El reparto de aciertos y fallos por activo está en la Figura 6.3: el agente concentra el fallo en una clase y las derivadas lo reparten mejor. El resultado que sí supera un test está en el riesgo, no en el acierto frente a la trivial.




Figura 6.3: Matrices de confusión de la mejor derivada de STRATA en cada activo: el reparto de aciertos y fallos detrás de cada accuracy del panel.

6.1.3. Pooled: el rescate en riesgo

El intervalo del ΔSharpe sobre SPY no se separaba del cero por falta de potencia, no de señal. La agregación lo resuelve: si la supervisión rescata por el mismo mecanismo en activos distintos, apilar sus días multiplica la muestra. Se apilan los días de los diez activos (*pooled-10*, $n = 2493$ días) y se mide el ΔSharpe pareado frente a M5, cada comparación sobre el mismo día y el mismo activo.

La validez del agregado depende del remuestreo. Extraer días sueltos trataría la serie como independiente, y no lo es: los retornos de días vecinos se parecen y el intervalo se estrecharía de forma artificial. Por eso se emplea el *bootstrap* estacionario [63], que toma tramos con inicio al azar y longitud variable de media $\sqrt{n}$, de modo que los días vecinos se remuestrean juntos y el intervalo recoge la dependencia temporal real.

El resultado lo reúne la Figura 6.4: las tres estrategias supervisadas dejan un ΔSharpe positivo (M8 +0,60, M10 +1,12, AutoML +1,08) cuyo intervalo al 95 % excluye el cero, la afirmación que SPY no sostenía en solitario. Hay además un orden: la regla queda con el límite inferior pegado al borde mientras los dos aprendices guardan holgura, de modo que el rescate de riesgo es más firme en los aprendices.

El agregado tiene un matiz: el *pooled* apila los días de los diez activos como si fueran independientes, y no lo son. La correlación cruzada entre índices es alta (SPY y QQQ por encima de 0,9), lo que reduce el tamaño de muestra efectivo y deja el intervalo algo optimista; el bloque medio $\sqrt{n}$ del *bootstrap* amortigua parte del efecto al remuestrear bloques contiguos.

En términos económicos, una derivada de STRATA supera al pasivo en Sharpe en cuatro activos: SPY, SMCI, MARA y UNG (Figura 6.5). En SMCI, MARA y UNG el pasivo pierde o ronda el cero y la derivada obtiene un Sharpe positivo al posicionarse de forma defensiva. En SPY el periodo fue alcista y el activo es mayormente beta de mercado, de modo que el Sharpe positivo refleja sobre todo la exposición al índice.




Figura 6.4: Diagrama de bosque del ΔSharpe *pooled-10* ($n = 2493$ días) frente al agente M5, con intervalo al 95 % (*bootstrap* estacionario de bloque medio $\sqrt{n}$, Politis y Romano 1994). La línea vertical marca el cero. Los tres intervalos excluyen el cero: M8 +0,60 [0,05, 1,22], M10 +1,12 [0,39, 1,84], AutoML +1,08 [0,40, 1,85]; la regla M8 con el límite inferior más cerca del borde y los aprendices con más holgura.




Figura 6.5: Curvas de capital por activo (un euro inicial), con la mejor derivada de STRATA destacada frente a las referencias. En SPY, SMC, MARA y UNG una derivada supera al pasivo en Sharpe.

6.1.4. Equivalencia: el aprendiz recupera STRATA y supera a la regla

El aprendiz se apoya en los detectores de STRATA. Las cuotas de Shapley [67] miden cuánto de su juicio descansa en cada bloque de características; la de las *features* de STRATA supera la mitad en los **diez de diez** activos, con media 0,66. El aprendiz no genera una señal nueva: recupera los detectores definidos a mano y los pondera por encima de las características del agente.

Apoyarse en STRATA no implica replicar la regla. El contraste lo da el TOST de Schuirmann [66]: a diferencia de un test de superioridad, parte de que las dos estrategias son distintas y solo concede equivalencia si la evidencia de parecido es fuerte. La Tabla 6.1 lo aplica al aprendiz frente a la regla M8. En accuracy no hay equivalencia y el aprendiz domina: M10 y AutoML superan a la regla con intervalo al 90 % por encima de cero. En Sharpe el test es no concluyente: las estrategias son indistinguibles en riesgo. La causa está en la forma de cada una: la regla M8 es una compuerta fija sobre el régimen, mientras el aprendiz modela interacciones no lineales entre régimen y agente que la regla no alcanza, y de ahí saca el punto extra de accuracy.

El aprendiz queda caracterizado por dos hechos: se apoya en STRATA, con cuota SHAP mayoritaria en los diez activos, y supera ligeramente a la regla en accuracy sin distinguirse en riesgo (Figura B.11 del Anexo B). La Tabla 6.2 resume el reparto sobre el panel (su lectura por detector, en la Figura 5.5 del capítulo 5).

Tabla 6.1: TOST del aprendiz frente a la regla M8 (Schuirmann 1987) y cuota de Shapley de las features de STRATA por activo (Lundberg y Lee 2017). En accuracy el aprendiz supera a la regla (intervalo al 90 % por encima de cero); en Sharpe el test es no concluyente (indistinguibles). La cuota SHAP de STRATA supera 0,5 en los diez activos.

Comparación	Δ accuracy (IC ₉₀)	TOST Sharpe	Cuota SHAP STRATA
M10 vs M8	+0,021 [+0,001, +0,039]	no concluyente	> 0,5 en 10/10 (media 0,66)
AutoML vs M8	+0,034 [+0,010, +0,056]	no concluyente	

Tabla 6.2: Atribución por capa sobre el panel de diez activos. La regla (M8) aporta el rescate de riesgo, con todo su P&L de intervención concentrado en el canal de régimen (RAM, Figura 5.5); nunca lidera en accuracy. El aprendiz (M10/AutoML) aporta el rescate de accuracy y no lidera el riesgo en exclusiva. El capital final es sobre la ventana desplegable de SPY partiendo de un euro; el agente solo termina en 0,70×. Δ Sharpe pooled frente al agente, IC₉₅ por bootstrap estacionario.

	Regla (M8)	Aprendiz (M10/AutoML)
Eje que rescata	riesgo	accuracy
Δ Sharpe pooled vs M5	+ 0,60 [0,05, 1,22]	+1,12 / +1,08
Capital final sobre SPY	0,94×	0,92× / 1,38×
Lidera en accuracy	0/10	10/10
Significancia accuracy (McNemar)	al borde	significativa

6.1.5. Complementariedad por régimen

El rescate aparece en los dos regímenes, también en el bajista, que es el peligroso. Se parte el panel por régimen y se mide en cada mitad con el McNemar *pooled* de la estrategia superior frente al agente, con corrección de Holm [65]. En alcista los dos aprendices rescatan de forma significativa y la regla M8 queda al borde; en bajista los tres pasan, con la regla holgadamente dentro (Tabla 6.3).

Tabla 6.3: Rescate por régimen (McNemar pooled de la estrategia superior frente a M5, p corregido por Holm 1979) y complementariedad de los aprendices (DiD). El rescate es significativo en alcista y en bajista. El DiD contrasta el $\Delta\Delta$ Sharpe entre aprendices y regímenes: M10 rescata más en alcista, AutoML más en bajista.

	M8	M10	AutoML
McNemar alcista (Holm p)	0,099	0,0076	0,0092
McNemar bajista (Holm p)	0,0092	0,0268	0,0017
DiD complementariedad: $\Delta\Delta$ Sharpe pooled = +1,37, IC ₉₅ [0,20, 2,60], $p = 0,008$			

Los dos aprendices no rescatan igual en cada régimen: M10 protege más en alcista, AutoML más en bajista (Figura 6.6). Un test de diferencia en diferencias, pre-registrado, contrasta si ese reparto es real: el $\Delta\Delta$ Sharpe *pooled* entre los dos aprendices y los dos regímenes vale +1,37 (IC₉₅ [0,20, 2,60], $p = 0,008$) y excluye el cero, de modo que la complementariedad por régimen es significativa sobre el panel (Tabla 6.3). El rescate en acierto es significativo en los dos regímenes, alcista y bajista (Figura B.9 del Anexo B).




Figura 6.6: Complementariedad de los supervisores por régimen: Δ Sharpe de M8, M10 y AutoML frente al agente, en mercado alcista y bajista. M10 rescata más en alcista, AutoML más en bajista; el contraste formal de ese reparto es la diferencia en diferencias ($\Delta\Delta$ Sharpe = +1,37, $p = 0,008$).

La falsación pre-registrada se resuelve en el panel. Sobre SPY aislado, en régimen bajista la regla M8 se invierte: en sus cincuenta días bajistas el Δ Sharpe es $-1,49$, la regla daña en vez de rescatar. Sobre los diez activos el rescate por régimen es significativo en bajista, y la complementariedad DiD lo es en *pooled* aunque no en SPY: el fenómeno es de panel. Resta explicar el reparto por activo, que depende de su naturaleza.

6.2. El patrón: ley del leverage y clustering


El canal que rescata cada activo cambia de uno a otro. La propiedad que ordena el rescate del aprendiz es el *leverage effect*, y un *clustering* sin etiquetas recupera los mismos grupos que esa propiedad define. Con diez activos es una regularidad empírica, no un teorema. El panel se separa en bloques de naturaleza distinta (Figura 6.7a), materia prima de la ley y del agrupamiento que siguen.

6.2.1. La ley del *leverage*


El rescate del aprendiz en accuracy escala con el *leverage effect* del activo. El rescate se define como $\max(\text{M10}, \text{AutoML}) - \text{M5}$ en accuracy y la naturaleza del activo como la correlación de Black, $\text{leverage_corr} = \text{corr}(r_t, \text{RV}_{t+1}^{21} - \text{RV}_t^{21})$, negativa cuando una caída eleva la volatilidad del día siguiente ([24]; [25]).

Las dos magnitudes covarían: cuanto más negativo es el *leverage*, mayor es el rescate del aprendiz en accuracy (Figura 6.7b). Nueve de los diez activos la siguen; ROKU es la excepción, con *leverage* casi nulo y rescate alto. El mecanismo es el de la Sección 6.1.3: cuando el régimen es direccional, la regla disciplina el riesgo y el aprendiz afina la dirección; cuando el régimen no informa el signo, el aprendiz rescata por otra vía y la ganancia se estrecha.

Con diez activos el contraste tiene poca potencia, de modo que el resultado se presenta como tendencia significativa al $\alpha = 0,10$ fijado por adelantado, no como ley exacta (Pearson $r = -0,56$, $p = 0,093$). Su alcance es acotado: ordena el rescate del *aprendiz*, no el de la regla, que no se deja predecir por la naturaleza del activo.



(a) Naturaleza de los diez activos por bloques (índices de *leverage* fuerte, *leverage* invertido y volátiles), con sus rasgos de *leverage*, fracción en Crisis y sesgo del agente. Esa heterogeneidad es la que ordena el rescate.




(b) Rescate del aprendiz (máx(M10, AutoML) – M5) frente al *leverage* de Black, un punto por activo. La recta baja: a más *leverage* negativo, más rescate (Pearson $r = -0,56$, $p = 0,093$). Nueve de los diez la siguen; ROKU es la excepción.

Figura 6.7: La ley del *leverage*: la naturaleza por bloques del panel (izquierda) ordena el rescate del aprendiz en accuracy (derecha).


6.2.2. Clustering: la naturaleza separa los grupos

La misma estructura aparece sin etiquetas. Cada activo se describe por cinco rasgos de naturaleza (*leverage*, retorno medio en Crisis, fracción de días en Crisis, volatilidad OOS y sesgo direccional del agente) y se agrupa con cuatro métodos —*k*-medias [70, 76], enlace de Ward [71], mezcla gaussiana [32] y *clustering* espectral [72]— sin emplear ninguna métrica de rescate.

Los cuatro coinciden en una partición unánime y bien separada (Tabla 6.4): con tres grupos, el índice de Rand ajustado entre cualquier par de métodos vale uno [74]. Cada grupo trae asociado un canal de rescate distinto: los índices de *leverage* fuerte y los volátiles, por AutoML, y los de *leverage* invertido, por M10. Los perfiles de accuracy y Sharpe por grupo (Figura 6.8a) confirman que cada bloque se rescata por su canal, coherente con su naturaleza.



(a) Accuracy y Sharpe medios por estrategia dentro de cada grupo. Cada grupo se rescata por un canal distinto, coherente con su naturaleza.



(b) Proyección sobre las dos primeras componentes principales (partición unánime, Rand = 1,0). El primer eje recupera el *leverage* ($r = 0,84$ entre PC1 y *leverage_corr*).

Figura 6.8: Agrupamiento de la naturaleza de los diez activos: pago del *clustering* (izquierda) y geometría que recupera el *leverage* (derecha).

La geometría lo confirma. Al proyectar la naturaleza de los diez sobre sus dos primeras componentes principales, el primer eje recupera casi exactamente el *leverage* ($r = 0,84$ entre PC1 y *leverage_corr*, Figura 6.8b): sin etiquetas de rescate, el *clustering* ordena los activos

por el mismo eje que la ley de la Sección 6.2.1. La Figura B.10 del Anexo B ilustra dos casos, XLE y MARA.

Con diez activos esto es exploratorio: el clustering describe, no confirma. Predice el *tipo* de canal que rescata cada grupo, no el modelo exacto que ganará por activo, que puede cambiar dentro de un grupo. Se deja para líneas futuras.

Tabla 6.4: Perfil de los tres grupos del *clustering* de la naturaleza de los diez activos (cinco rasgos: *leverage*, retorno medio en Crisis, fracción en Crisis, volatilidad OOS, sesgo del agente): *leverage* medio de cada grupo y su mejor canal de rescate. Los cuatro métodos coinciden en esta misma partición (Rand = 1,0, silueta 0,55).

Cluster	<i>leverage</i> medio	Mejor canal
C0 índices (SPY, QQQ, XLF, DIA, XLK, XLE)	−0,097	AutoML
C1 <i>leverage</i> invertido (SMCI, UNG)	+0,018	M10
C2 volátiles (ROKU, MARA)	−0,028	AutoML

6.3. Robustez

El rescate no depende de una elección afortunada. Se mantiene al mover la ventana de calibración (Figura B.3) y aguanta en el panel por tres vías a la vez (Figura 6.9): la importancia de STRATA es estable en el tiempo, el rescate sobrevive a distintas particiones y se sostiene partido por régimen.




Figura 6.9: Robustez del rescate en el panel por tres vías: cuota de importancia rodante en el tiempo, fracción de ventanas con rescate por activo y McNemar partido por régimen. El rescate aguanta en las tres, no es un artefacto de una ventana ni de un régimen.

6.4. Alcance y limitaciones

Cuatro resultados del capítulo quedan por debajo del umbral de significancia (Tabla 6.5). El de mayor peso: la ventaja sobre la trivial es nominal. La regla, además, se invierte en SPY-bajista, una falsación pre-registrada que la agregación del panel resuelve.

El límite común es la ventana corta: con $n \approx 250$ días, la significancia plena frente a la trivial está fuera de alcance por potencia, no por ausencia de señal. La pregunta inicial queda respondida: lo que en SPY no alcanzaba significancia en solitario la alcanza al agregar.

Tabla 6.5: Resumen de los resultados que no alcanzan significancia plena, con su contraste y su veredicto. La columna de veredicto distingue lo nominal de lo falsado y de lo exploratorio.

Afirmación	Test y cifra	Veredicto
Una derivada supera a la trivial en accuracy	McNemar AutoML vs ZeroR sobre SPY, $p = 0,902$	Nominal ($n \approx 250$, a posteriori)
El rescate en accuracy escala con el <i>leverage</i>	Pearson $r = -0,56$, $p = 0,093$; Spearman $\rho = -0,59$, $p = 0,074$ (diez activos)	Tendencia al $\alpha = 0,10$; no $p < 0,05$
La regla M8 rescata el riesgo en SPY-bajista	$\Delta\text{Sharpe} = -1,49$ ($n = 50$)	Falsación pre-registrada, resuelta por el panel
La naturaleza define grupos de activos	Consenso de cuatro métodos, Rand = 1,0 (diez activos)	Exploratorio, no predictivo por activo

Capítulo 7

Conclusiones y trabajo futuro

Un agente LLM de trading decide dirección y tamaño de cada posición y, sin supervisión, pierde dinero y acierta menos de la mitad de las veces. Este trabajo demuestra que una capa de supervisión estadística externa, con modelos clásicos, corrige ese fallo en tiempo de ejecución.

7.1. Revisión de los objetivos

Los seis objetivos del Capítulo 2 quedan resueltos.

1. **Formalizar los detectores y su protocolo.** El Capítulo 4 define RAM, PSA y GSO sobre un HMM, un BOCPD y un GARCH, con la intervención y el protocolo de medición causal sin fuga.
2. **Probar el rescate.** Se confirma en acierto direccional (McNemar pareado frente al agente) y en riesgo (Δ Sharpe agregado cuyo intervalo excluye el cero, Sección 6.1.3). La hipótesis nula se rechaza.
3. **Atribuir el efecto.** Sobre SPY el rescate se concentra en el canal de régimen (Sección 5.3); sobre el panel, la naturaleza del activo determina qué capa rescata (Sección 6.2).
4. **Comprobar si el aprendiz recupera STRATA.** El meta-learner se apoya en los detectores, con cuota de Shapley mayoritaria, y supera marginalmente a la regla en acierto sin distinguirse en riesgo (Sección 6.1.4); el fracaso no se cumple.
5. **Comparar con la referencia trivial.** Ninguna estrategia la supera con significancia: la ventaja en acierto es nominal por potencia (Sección 6.1.2).
6. **Delimitar el alcance.** El rescate se debilita en los activos de *leverage* débil, donde el régimen pierde contenido direccional; esa propiedad ordena dónde la supervisión rinde más (Sección 6.2).

7.2. Aportaciones

El trabajo deja tres aportaciones. La primera es metodológica: un protocolo para supervisar a un agente opaco con estadística clásica, interpretable y falsable, con tres detectores ortogonales

(HMM, GARCH, BOCPD), calibración cerrada antes de ver la evaluación, dos ventanas sin solape con `signal_lag` contra el *look-ahead* y un contraste pareado que no descansa en un solo test; es aplicable a otros agentes, modelos y mercados. La segunda es empírica: una capa de supervisión clásica rescata a un agente perdedor en acierto y en riesgo. La tercera es un hallazgo, la *ley del leverage*: el apalancamiento del activo ordena la intensidad del rescate del aprendiz y acota dónde la supervisión aporta más.

7.3. Limitaciones

La limitación principal es el tamaño de la muestra. El agente solo existe tras el corte de conocimiento del modelo de lenguaje, de modo que la evaluación se reduce a unos doscientos cincuenta días por activo: la significancia plena frente a una referencia trivial queda fuera por potencia, la ventaja en acierto es nominal y el rescate de riesgo se sostiene en el agregado, no en cada activo. Las dos regularidades de patrón, la ley del *leverage* y el agrupamiento por naturaleza, se contrastan sobre diez puntos, y el estudio emplea un único agente y una única ventana fuera de muestra.

El panel es la segunda limitación: con diez activos los contrastes entre activos tienen poca potencia. Ampliarlo la reforzaría, pero cada activo nuevo exige generar las decisiones del agente con modelos de pago y reentrenar el esquema, un coste que fijó el panel en diez.

7.4. Trabajo futuro

Cada límite abre una continuación.

1. **Más potencia.** Una muestra mayor llevaría la ventaja en acierto a significancia plena y la ley del *leverage* de tendencia a ley.
2. **Ensemble enrutado por régimen.** El aprendiz que protege mejor cambia con el régimen; un supervisor elegido según el estado del mercado es la continuación natural.
3. **Otros agentes, modelos y mercados.** Repetir el esquema separaría lo propio de STRATA de lo de este agente y probaría la ley del *leverage* fuera del panel.
4. **Intervención graduada.** Entre registrar y sustituir queda atenuar la posición de forma continua.
5. **Detectores más ricos.** Calibrar la confianza declarada del agente, o añadir detectores sobre otras dimensiones, ampliaría la cobertura.
6. **Validación prospectiva.** Dejar correr la supervisión en sombra, sin capital real, y comprobar si se sostiene fuera del *backtest*.
7. **De la supervisión al alfa.** En algunos activos una derivada de STRATA supera al pasivo en Sharpe yendo defensiva a tiempo (Sección 6.4): base para una estrategia de alfa direccional con contraste pre-registrado.

7.5. Conclusión

Los agentes LLM ya deciden sobre capital real sin señalar cuándo fallan. Este trabajo no propone un modelo más potente, sino una capa que lo supervisa: tres detectores estadísticos clásicos, calibrados de antemano y contrastados con tests pareados, corrigen al agente cuando contradice al mercado y exponen por qué. Dentro de los límites de la muestra no bate al mercado de forma significativa, pero convierte en fiable a un agente que por sí solo no lo era, y una sola propiedad del activo, su apalancamiento, anticipa cuándo y cómo.

Bibliografía

- [1] Alejandro Lopez-Lira. «Can Large Language Models Trade? Testing Financial Theories with LLM Agents in Market Simulations». En: *arXiv preprint arXiv:2504.10789* (2025).
- [2] Marcos López de Prado. *Advances in Financial Machine Learning*. Hoboken, NJ: Wiley, 2018.
- [3] Yijia Xiao et al. «TradingAgents: Multi-Agents LLM Financial Trading Framework». En: *arXiv preprint arXiv:2412.20138* (2024). DOI: 10.48550/arXiv.2412.20138.
- [4] Ashish Vaswani et al. «Attention Is All You Need». En: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017, págs. 5998-6008.
- [5] Shunyu Yao et al. «ReAct: Synergizing Reasoning and Acting in Language Models». En: *International Conference on Learning Representations (ICLR)*. arXiv:2210.03629. 2023.
- [6] Lei Wang et al. «A Survey on Large Language Model Based Autonomous Agents». En: *Frontiers of Computer Science* 18.6 (2024), pág. 186345. DOI: 10.1007/s11704-024-40231-1.
- [7] Hongyang Yang, Xiao-Yang Liu y Christina Dan Wang. «FinGPT: Open-Source Financial Large Language Models». En: *arXiv preprint arXiv:2306.06031* (2023). FinLLM Workshop @ IJCAI 2023. DOI: 10.48550/arXiv.2306.06031.
- [8] Tianjiao Zhao et al. «AlphaAgents: Large Language Model based Multi-Agents for Equity Portfolio Constructions». En: *arXiv preprint arXiv:2508.11152* (2025).
- [9] Yoo Yeon Sung et al. «GRACE: A Granular Benchmark for Evaluating Model Calibration against Human Calibration». En: *arXiv preprint arXiv:2502.19684* (2025).
- [10] Mehul Damani et al. «Beyond Binary Rewards: Training LMs to Reason About Their Uncertainty». En: *arXiv preprint arXiv:2507.16806* (2025).
- [11] Zeping Li et al. «Behavioral Consistency Validation for LLM Agents: An Analysis of Trading-Style Switching through Stock-Market Simulation». En: *arXiv preprint arXiv:2602.07023* (2026). DOI: 10.48550/arXiv.2602.07023.
- [12] Lewen Yan et al. «TradeTrap: Are LLM-based Trading Agents Truly Reliable and Faithful?» En: *arXiv preprint arXiv:2512.02261* (2025). DOI: 10.48550/arXiv.2512.02261.
- [13] Changlun Li et al. «Will LLMs be Professional at Fund Investment? DeepFund: A Live Arena Perspective». En: *arXiv preprint arXiv:2503.18313* (2025). NeurIPS 2025 (poster). DOI: 10.48550/arXiv.2503.18313.

- [14] Mostapha Benhenda. «Look-Ahead-Bench: a Standardized Benchmark of Look-ahead Bias in Point-in-Time LLMs for Finance». En: *arXiv preprint arXiv:2601.13770* (2026). DOI: 10.48550/arXiv.2601.13770.
- [15] Virat Singh. *AI Hedge Fund: An AI-powered hedge fund team*. Repositorio de software, GitHub. <https://github.com/virattt/ai-hedge-fund>. 2024.
- [16] Alan Milligan. *Navigating the New Frontier: Effective Guardrail Implementations for LLMs in Financial Services*. LinkedIn. Literatura gris; recuperado en junio de 2026. 2024. URL: <https://www.linkedin.com/pulse/navigating-new-frontier-effective-guardrail-llms-alan-milligan-vdqre>.
- [17] Varun Chandola, Arindam Banerjee y Vipin Kumar. «Anomaly detection: A survey». En: *ACM Computing Surveys* 41.3 (2009), págs. 1-58. DOI: 10.1145/1541880.1541882.
- [18] Haoyu Wang, Christopher M. Poskitt y Jun Sun. «AgentSpec: Customizable Runtime Enforcement for Safe and Reliable LLM Agents». En: *Proceedings of the IEEE/ACM International Conference on Software Engineering (ICSE)*. arXiv:2503.18666. 2026. DOI: 10.48550/arXiv.2503.18666.
- [19] Niclas Flehmig, Mary Ann Lundteigen y Shen Yin. «Perspectives on a Reliability Monitoring Framework for Agentic AI Systems». En: *arXiv preprint arXiv:2511.09178* (2025). DOI: 10.48550/arXiv.2511.09178.
- [20] James D. Hamilton. «A new approach to the economic analysis of nonstationary time series and the business cycle». En: *Econometrica* 57.2 (1989), págs. 357-384.
- [21] Andrew Ang y Geert Bekaert. «International asset allocation with regime shifts». En: *The Review of Financial Studies* 15.4 (2002), págs. 1137-1187. DOI: 10.1093/rfs/15.4.1137.
- [22] Massimo Guidolin y Allan Timmermann. «Asset allocation under multivariate regime switching». En: *Journal of Economic Dynamics and Control* 31.11 (2007), págs. 3503-3544.
- [23] Alan Moreira y Tyler Muir. «Volatility-managed portfolios». En: *The Journal of Finance* 72.4 (2017), págs. 1611-1644.
- [24] Fischer Black. «Studies of stock price volatility changes». En: *Proceedings of the 1976 Meetings of the American Statistical Association, Business and Economic Statistics Section*. 1976, págs. 177-181.
- [25] Andrew A. Christie. «The stochastic behavior of common stock variances: Value, leverage and interest rate effects». En: *Journal of Financial Economics* 10.4 (1982), págs. 407-432.
- [26] Jean-Philippe Bouchaud, Andrew Matacz y Marc Potters. «Leverage effect in financial markets: The retarded volatility model». En: *Physical Review Letters* 87.22 (2001), pág. 228701. DOI: 10.1103/PhysRevLett.87.228701.
- [27] Rama Cont. «Empirical properties of asset returns: stylized facts and statistical issues». En: *Quantitative Finance* 1.2 (2001), págs. 223-236. DOI: 10.1080/713665670.
- [28] Lawrence R. Rabiner. «A tutorial on hidden Markov models and selected applications in speech recognition». En: *Proceedings of the IEEE* 77.2 (1989), págs. 257-286.

- [29] Olivier Cappé, Eric Moulines y Tobias Rydén. *Inference in Hidden Markov Models*. Springer Series in Statistics. New York: Springer, 2005. ISBN: 9780387402642. DOI: 10.1007/0-387-28982-8.
- [30] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006. ISBN: 9780387310732.
- [31] Leonard E. Baum et al. «A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains». En: *The Annals of Mathematical Statistics* 41.1 (1970), págs. 164-171.
- [32] Arthur P. Dempster, Nan M. Laird y Donald B. Rubin. «Maximum likelihood from incomplete data via the EM algorithm». En: *Journal of the Royal Statistical Society: Series B* 39.1 (1977), págs. 1-38. DOI: 10.1111/j.2517-6161.1977.tb01600.x.
- [33] Andrew J. Viterbi. «Error bounds for convolutional codes and an asymptotically optimum decoding algorithm». En: *IEEE Transactions on Information Theory* 13.2 (1967), págs. 260-269.
- [34] James D. Hamilton. *Time Series Analysis*. Princeton, NJ: Princeton University Press, 1994. ISBN: 9780691042893.
- [35] Ruey S. Tsay. *Analysis of Financial Time Series*. 3.^a ed. Wiley Series in Probability and Statistics. Hoboken, NJ: Wiley, 2010. ISBN: 9780470414354. DOI: 10.1002/9780470644560.
- [36] Peter J. Brockwell y Richard A. Davis. *Time Series: Theory and Methods*. 2.^a ed. Springer Series in Statistics. New York: Springer-Verlag, 1991. ISBN: 9780387974293.
- [37] Robert F. Engle. «Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation». En: *Econometrica* 50.4 (1982), págs. 987-1007.
- [38] Tim Bollerslev. «Generalized autoregressive conditional heteroskedasticity». En: *Journal of Econometrics* 31.3 (1986), págs. 307-327.
- [39] Tim Bollerslev. «A conditionally heteroskedastic time series model for speculative prices and rates of return». En: *The Review of Economics and Statistics* 69.3 (1987), págs. 542-547.
- [40] Robert F. Engle y Tim Bollerslev. «Modelling the persistence of conditional variances». En: *Econometric Reviews* 5.1 (1986), págs. 1-50. DOI: 10.1080/07474938608800095.
- [41] Daniel B. Nelson. «Stationarity and persistence in the GARCH(1,1) model». En: *Econometric Theory* 6.3 (1990), págs. 318-334. DOI: 10.1017/S0266466600005296.
- [42] Christian Francq y Jean-Michel Zakoïan. *GARCH Models: Structure, Statistical Inference and Financial Applications*. 2.^a ed. Chichester: Wiley, 2019. ISBN: 9781119313571. DOI: 10.1002/9781119313472.
- [43] Ryan P. Adams y David J. C. MacKay. «Bayesian online changepoint detection». En: *arXiv preprint arXiv:0710.3742* (2007).
- [44] Paul Fearnhead. «Exact and efficient Bayesian inference for multiple changepoint problems». En: *Statistics and Computing* 16.2 (2006), págs. 203-213.

- [45] Jushan Bai y Pierre Perron. «Estimating and testing linear models with multiple structural changes». En: *Econometrica* 66.1 (1998), págs. 47-78. DOI: 10.2307/2998540.
- [46] Jushan Bai y Pierre Perron. «Computation and analysis of multiple structural change models». En: *Journal of Applied Econometrics* 18.1 (2003), págs. 1-22. DOI: 10.1002/jae.659.
- [47] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2.^a ed. Springer Series in Statistics. New York: Springer, 2009. ISBN: 9780387848570. DOI: 10.1007/978-0-387-84858-7.
- [48] Jerome H. Friedman. «Greedy function approximation: A gradient boosting machine». En: *The Annals of Statistics* 29.5 (2001), págs. 1189-1232. DOI: 10.1214/aos/1013203451.
- [49] Tianqi Chen y Carlos Guestrin. «XGBoost: A scalable tree boosting system». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, págs. 785-794. DOI: 10.1145/2939672.2939785.
- [50] Leo Breiman. «Bagging predictors». En: *Machine Learning* 24.2 (1996), págs. 123-140. DOI: 10.1007/BF00058655.
- [51] David H. Wolpert. «Stacked generalization». En: *Neural Networks* 5.2 (1992), págs. 241-259. DOI: 10.1016/S0893-6080(05)80023-1.
- [52] Mark J. van der Laan, Eric C. Polley y Alan E. Hubbard. «Super Learner». En: *Statistical Applications in Genetics and Molecular Biology* 6.1 (2007), Article 25. DOI: 10.2202/1544-6115.1309.
- [53] James A. Hanley y Barbara J. McNeil. «The meaning and use of the area under a receiver operating characteristic (ROC) curve». En: *Radiology* 143.1 (1982), págs. 29-36. DOI: 10.1148/radiology.143.1.7063747.
- [54] Tom Fawcett. «An introduction to ROC analysis». En: *Pattern Recognition Letters* 27.8 (2006), págs. 861-874. DOI: 10.1016/j.patrec.2005.10.010.
- [55] William F. Sharpe. «Mutual fund performance». En: *The Journal of Business* 39.1 (1966), págs. 119-138. DOI: 10.1086/294846.
- [56] William F. Sharpe. «The Sharpe ratio». En: *The Journal of Portfolio Management* 21.1 (1994), págs. 49-58.
- [57] Malik Magdon-Ismail et al. «On the maximum drawdown of a Brownian motion». En: *Journal of Applied Probability* 41.1 (2004), págs. 147-161. DOI: 10.1239/jap/1077134674.
- [58] Terry W. Young. *Calmar ratio: A smoother tool*. *Futures*, vol. 20, no. 12, p. 40. Revista profesional sin revisión por pares; sin DOI. 1991.
- [59] Leonard J. Tashman. «Out-of-sample tests of forecasting accuracy: an analysis and review». En: *International Journal of Forecasting* 16.4 (2000), págs. 437-450. DOI: 10.1016/S0169-2070(00)00065-0.
- [60] Christoph Bergmeir, Rob J. Hyndman y Bonsoo Koo. «A note on the validity of cross-validation for evaluating autoregressive time series prediction». En: *Computational Statistics & Data Analysis* 120 (2018), págs. 70-83. DOI: 10.1016/j.csda.2017.11.003.

- [61] William J. Conover. *Practical Nonparametric Statistics*. 3.^a ed. New York: Wiley, 1999.
- [62] Quinn McNemar. «Note on the sampling error of the difference between correlated proportions or percentages». En: *Psychometrika* 12.2 (1947), págs. 153-157.
- [63] Dimitris N. Politis y Joseph P. Romano. «The stationary bootstrap». En: *Journal of the American Statistical Association* 89.428 (1994), págs. 1303-1313.
- [64] David H. Bailey y Marcos López de Prado. «The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality». En: *The Journal of Portfolio Management* 40.5 (2014), págs. 94-107.
- [65] Sture Holm. «A simple sequentially rejective multiple test procedure». En: *Scandinavian Journal of Statistics* 6.2 (1979), págs. 65-70.
- [66] Donald J. Schuirmann. «A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability». En: *Journal of Pharmacokinetics and Biopharmaceutics* 15.6 (1987), págs. 657-680.
- [67] Scott M. Lundberg y Su-In Lee. «A unified approach to interpreting model predictions». En: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. Curran Associates, Inc., 2017, págs. 4766-4777. URL: <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.
- [68] Scott M. Lundberg et al. «From local explanations to global understanding with explainable AI for trees». En: *Nature Machine Intelligence* 2.1 (2020), págs. 56-67. DOI: 10.1038/s42256-019-0138-9.
- [69] Leo Breiman. «Random forests». En: *Machine Learning* 45.1 (2001), págs. 5-32. DOI: 10.1023/A:1010933404324.
- [70] James B. MacQueen. «Some methods for classification and analysis of multivariate observations». En: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Vol. 1. Berkeley, CA: University of California Press, 1967, págs. 281-297.
- [71] Joe H. Ward. «Hierarchical grouping to optimize an objective function». En: *Journal of the American Statistical Association* 58.301 (1963), págs. 236-244. DOI: 10.1080/01621459.1963.10500845.
- [72] Andrew Y. Ng, Michael I. Jordan y Yair Weiss. «On spectral clustering: Analysis and an algorithm». En: *Advances in Neural Information Processing Systems 14 (NIPS 2001)*. MIT Press, 2002, págs. 849-856.
- [73] Gideon Schwarz. «Estimating the dimension of a model». En: *The Annals of Statistics* 6.2 (1978), págs. 461-464. DOI: 10.1214/aos/1176344136.
- [74] Lawrence Hubert y Phipps Arabie. «Comparing partitions». En: *Journal of Classification* 2.1 (1985), págs. 193-218. DOI: 10.1007/BF01908075.
- [75] Ian T. Jolliffe. *Principal Component Analysis*. 2.^a ed. Springer Series in Statistics. New York: Springer, 2002. ISBN: 9780387954424.
- [76] Stuart P. Lloyd. «Least squares quantization in PCM». En: *IEEE Transactions on Information Theory* 28.2 (1982), págs. 129-137. DOI: 10.1109/TIT.1982.1056489.

Apéndice A

Demostraciones

Este anexo reúne las demostraciones y los desarrollos de los resultados enunciados en el capítulo 4. Cada sección recoge la prueba o la derivación de un resultado, indicado al comienzo por su enunciado y su label en el cuerpo de la memoria.

A.1. Recursión forward del HMM

Desarrollo de la Proposición 4.1 (Recursión forward), Sección 4.1.4.

Demostración. La inicialización es inmediata: $\alpha_1(k) = \mathbb{P}(x_1, z_1 = k) = \mathbb{P}(z_1 = k) \mathbb{P}(x_1 | z_1 = k) = \pi_k b_k(x_1)$, usando (*) en el segundo factor.

Para el paso recursivo partimos de la definición e introducimos el estado anterior z_t marginalizando sobre sus K valores posibles:

$$\alpha_{t+1}(j) = \mathbb{P}(x_{1:t+1}, z_{t+1} = j) = \sum_{k=1}^K \mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j).$$

Descomponemos cada sumando separando la última observación x_{t+1} del resto mediante la regla del producto,

$$\mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j) = \mathbb{P}(x_{t+1} | x_{1:t}, z_t = k, z_{t+1} = j) \mathbb{P}(x_{1:t}, z_t = k, z_{t+1} = j).$$

Por la independencia condicional de las emisiones (*), la observación x_{t+1} depende solo de su propio estado $z_{t+1} = j$, de modo que el primer factor es

$$\mathbb{P}(x_{t+1} | x_{1:t}, z_t = k, z_{t+1} = j) = \mathbb{P}(x_{t+1} | z_{t+1} = j) = b_j(x_{t+1}).$$

El segundo factor se descompone a su vez aislando la transición $z_t = k \rightarrow z_{t+1} = j$:

$$\mathbb{P}(x_{1:t}, z_t = k, z_{t+1} = j) = \mathbb{P}(z_{t+1} = j | x_{1:t}, z_t = k) \mathbb{P}(x_{1:t}, z_t = k).$$

La Markovianidad de la cadena, junto con la independencia condicional de las emisiones (*), hace que, fijado z_t , el estado z_{t+1} sea independiente de $x_{1:t}$ y de los estados anteriores (es la d-separación en el grafo del modelo); por tanto $\mathbb{P}(z_{t+1} = j | x_{1:t}, z_t = k) = A_{kj}$. El factor

restante es, por definición, $\alpha_t(k)$. Reuniendo los tres trozos,

$$\mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j) = b_j(x_{t+1}) A_{kj} \alpha_t(k),$$

y al sumar en k el factor $b_j(x_{t+1})$ no depende del índice de la suma y sale fuera:

$$\alpha_{t+1}(j) = b_j(x_{t+1}) \sum_{k=1}^K \alpha_t(k) A_{kj},$$

que es lo que se quería probar. $\square$

A.2. Filtrado y causalidad del HMM

Desarrollo de la Proposición 4.2 (Filtrado a partir del forward) y del Corolario 4.3 (Causalidad del filtrado), Sección 4.1.4.

Filtrado. Por la definición de probabilidad condicional y la de α_t ,

$$\gamma_t^f(k) = \mathbb{P}(z_t = k \mid x_{1:t}) = \frac{\mathbb{P}(x_{1:t}, z_t = k)}{\mathbb{P}(x_{1:t})} = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)},$$

donde en el denominador se ha usado $\mathbb{P}(x_{1:t}) = \sum_j \mathbb{P}(x_{1:t}, z_t = j) = \sum_j \alpha_t(j)$. $\square$

Causalidad. Por la Proposición 4.2, γ_t^f se expresa a través de $\{\alpha_t(j)\}_{j=1}^K$. La inicialización $\alpha_1(k) = \pi_k b_k(x_1)$ depende solo de x_1 y, por la recursión de la Proposición 4.1, cada $\alpha_t(j)$ se obtiene de $\alpha_{t-1}(\cdot)$ y de x_t . Por inducción sobre t , $\alpha_t(j)$ es función de $x_{1:t}$, luego también lo es γ_t^f . $\square$

A.3. Fórmulas de actualización del paso M de Baum-Welch

Desarrollo de las reestimaciones del paso M del algoritmo de Baum-Welch, Sección 4.1.4. La distribución inicial y la matriz de transición se actualizan como frecuencias esperadas,

$$\hat{\pi}_k = \mathbb{P}(z_1 = k \mid x_{1:T}), \quad \hat{A}_{ij} = \frac{\sum_{t=1}^{T-1} \mathbb{P}(z_t = i, z_{t+1} = j \mid x_{1:T})}{\sum_{t=1}^{T-1} \mathbb{P}(z_t = i \mid x_{1:T})},$$

y las medias y covarianzas de cada régimen, como promedios ponderados por el posterior del estado,

$$\hat{\mu}_k = \frac{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T}) x_t}{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T})}, \quad \hat{\Sigma}_k = \frac{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T}) (x_t - \hat{\mu}_k)(x_t - \hat{\mu}_k)^\top}{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T})},$$

donde la media $\hat{\mu}_k$ que interviene en $\hat{\Sigma}_k$ es la ya reestimada en esa misma iteración.

A.4. Recursión de Viterbi

Desarrollo del algoritmo de Viterbi, Sección 4.1.4. Si $\delta_t(j) = \max_{z_{1:t-1}} \mathbb{P}(z_{1:t-1}, z_t = j, x_{1:t} \mid \lambda)$ es la probabilidad de la mejor trayectoria que termina en el estado j en el instante t , la recursión es

$$\delta_{t+1}(j) = b_j(x_{t+1}) \max_{1 \leq k \leq K} \delta_t(k) A_{kj}, \quad \delta_1(k) = \pi_k b_k(x_1),$$

y la trayectoria óptima se recupera memorizando en cada paso el estado k que alcanza el máximo y recorriéndolos hacia atrás desde T .

A.5. Monotonía del algoritmo EM

Demostración del Lema 4.4 (Monotonía de EM), Sección 4.1.4.

Demostración. Para cualquier parámetro θ descomponemos la log-verosimilitud observada tomando esperanza sobre $z_{1:T}$ con la ley del paso E, $\mathbb{P}(\cdot \mid x_{1:T}, \lambda)$, en la identidad $\log \mathbb{P}(x_{1:T} \mid \theta) = \log \mathbb{P}(x_{1:T}, z_{1:T} \mid \theta) - \log \mathbb{P}(z_{1:T} \mid x_{1:T}, \theta)$, cuyo miembro izquierdo no depende de $z_{1:T}$:

$$\log \mathbb{P}(x_{1:T} \mid \theta) = Q(\theta \mid \lambda) - H(\theta \mid \lambda),$$

con $Q(\theta \mid \lambda) = \mathbb{E}_{z|x,\lambda}[\log \mathbb{P}(x_{1:T}, z_{1:T} \mid \theta)]$ y $H(\theta \mid \lambda) = \mathbb{E}_{z|x,\lambda}[\log \mathbb{P}(z_{1:T} \mid x_{1:T}, \theta)]$. El paso M elige $\lambda' = \arg \max_{\theta} Q(\theta \mid \lambda)$, luego $Q(\lambda' \mid \lambda) \geq Q(\lambda \mid \lambda)$. Por la desigualdad de Gibbs (un caso de la de Jensen),

$$H(\lambda \mid \lambda) - H(\lambda' \mid \lambda) = \text{KL}(\mathbb{P}(\cdot \mid x_{1:T}, \lambda) \parallel \mathbb{P}(\cdot \mid x_{1:T}, \lambda')) \geq 0.$$

Restando ambas descomposiciones,

$$\log \mathbb{P}(x_{1:T} \mid \lambda') - \log \mathbb{P}(x_{1:T} \mid \lambda) = \underbrace{Q(\lambda' \mid \lambda) - Q(\lambda \mid \lambda)}_{\geq 0} + \underbrace{H(\lambda \mid \lambda) - H(\lambda' \mid \lambda)}_{\geq 0} \geq 0. \quad \square$$

A.6. Estacionariedad y varianza incondicional del GARCH(1, 1)

Demostración del Teorema 4.5 (Estacionariedad en covarianza del GARCH(1, 1)), Sección 4.1.5.

Demostración. Supongamos primero que existe una solución estacionaria en covarianza, lo que significa, en particular, que $\text{Var}(\epsilon_t)$ es finita y no depende de t ; la llamamos $\bar{\sigma}^2 := \text{Var}(\epsilon_t)$. Calculamos la varianza incondicional de ϵ_t por la ley de la varianza total, usando que $\mathbb{E}[\epsilon_t] = 0$ (pues $\mathbb{E}[\epsilon_t] = \mathbb{E}[\sigma_t] \mathbb{E}[\eta_t] = 0$, al ser σ_t función del pasado e independiente de η_t , y $\mathbb{E}[\eta_t] = 0$):

$$\text{Var}(\epsilon_t) = \mathbb{E}[\epsilon_t^2] = \mathbb{E}[\mathbb{E}[\epsilon_t^2 \mid \mathcal{F}_{t-1}]],$$

donde $\mathcal{F}_{t-1}$ es la información hasta $t - 1$. Como σ_t es función de $\mathcal{F}_{t-1}$ y η_t es independiente

de $\mathcal{F}_{t-1}$ con $\mathbb{E}[\eta_t^2] = \text{Var}(\eta_t) = 1$,

$$\mathbb{E}[\epsilon_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2 \mathbb{E}[\eta_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2,$$

de donde $\mathbb{E}[\epsilon_t^2] = \mathbb{E}[\sigma_t^2]$. La misma identidad aplicada en $t-1$ da $\mathbb{E}[\epsilon_{t-1}^2] = \mathbb{E}[\sigma_{t-1}^2]$. Tomamos ahora esperanzas en la recursión (4.1):

$$\mathbb{E}[\sigma_t^2] = \omega + \alpha \mathbb{E}[\epsilon_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2] = \omega + \alpha \mathbb{E}[\sigma_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2].$$

Por estacionariedad, $\mathbb{E}[\sigma_t^2] = \mathbb{E}[\sigma_{t-1}^2] =: m$, constante en el tiempo. Sustituyendo,

$$m = \omega + (\alpha + \beta) m \iff m(1 - \alpha - \beta) = \omega.$$

Como $\omega > 0$ y $m = \mathbb{E}[\sigma_t^2] = \text{Var}(\epsilon_t) > 0$ es finita, el factor $1 - \alpha - \beta$ ha de ser estrictamente positivo, es decir, $\alpha + \beta < 1$, y entonces

$$\text{Var}(\epsilon_t) = m = \frac{\omega}{1 - \alpha - \beta}.$$

Esto prueba la necesidad de la condición y la fórmula de la varianza.

Recíprocamente, supongamos $\alpha + \beta < 1$ y construyamos una solución estacionaria. Reescribiendo $\alpha \epsilon_{s-1}^2 + \beta \sigma_{s-1}^2 = (\alpha \eta_{s-1}^2 + \beta) \sigma_{s-1}^2$ e iterando la recursión (4.1) hacia atrás n pasos,

$$\sigma_t^2 = \omega \sum_{i=0}^{n-1} \prod_{l=1}^i (\alpha \eta_{t-l}^2 + \beta) + \left(\prod_{l=1}^n (\alpha \eta_{t-l}^2 + \beta) \right) \sigma_{t-n}^2.$$

En lugar de suponer la solución dada, la *construimos* como la serie

$$\sigma_t^2 := \omega \sum_{i=0}^{\infty} \prod_{l=1}^i (\alpha \eta_{t-l}^2 + \beta),$$

y comprobamos que está bien definida. Los η_{t-l} son i.i.d. con $\mathbb{E}[\alpha \eta_{t-l}^2 + \beta] = \alpha + \beta$ y los factores de cada producto son independientes, de modo que el término i -ésimo tiene esperanza $\omega (\alpha + \beta)^i$. Como todos los sumandos son no negativos, el teorema de convergencia monótona permite intercambiar esperanza y suma:

$$\mathbb{E}[\sigma_t^2] = \omega \sum_{i=0}^{\infty} (\alpha + \beta)^i = \frac{\omega}{1 - \alpha - \beta} < \infty,$$

y la serie geométrica converge por ser $\alpha + \beta < 1$. La serie que define σ_t^2 converge así en L^1 (y casi seguramente), tiene esperanza finita y constante, y por construirse con las mismas variables i.i.d. desplazadas en el tiempo su ley no depende de t ; además satisface la recursión (4.1). El término residual de la iteración finita, $\left(\prod_{l=1}^n (\alpha \eta_{t-l}^2 + \beta) \right) \sigma_{t-n}^2$, tiene esperanza $(\alpha + \beta)^n \mathbb{E}[\sigma_{t-n}^2] \rightarrow 0$, lo que confirma que la serie es el límite de las iteraciones.

Queda ver que $\epsilon_t = \sigma_t \eta_t$ es estacionario en covarianza, esto es, que su media, su varianza y sus autocovarianzas no dependen de t . La media es $\mathbb{E}[\epsilon_t] = \mathbb{E}[\sigma_t] \mathbb{E}[\eta_t] = 0$, y la varianza, $\mathbb{E}[\epsilon_t^2] = \mathbb{E}[\sigma_t^2] = \omega/(1 - \alpha - \beta)$, es finita y constante. Para las autocovarianzas, fijado $h \geq 1$,

como η_t es independiente de $\mathcal{F}_{t-1}$ con $\mathbb{E}[\eta_t] = 0$ y ϵ_{t-h} es $\mathcal{F}_{t-1}$ -medible,

$$\mathbb{E}[\epsilon_t \epsilon_{t-h}] = \mathbb{E}[\epsilon_{t-h} \mathbb{E}[\epsilon_t \mid \mathcal{F}_{t-1}]] = 0, \quad \text{ya que } \mathbb{E}[\epsilon_t \mid \mathcal{F}_{t-1}] = \sigma_t \mathbb{E}[\eta_t] = 0.$$

Media nula, varianza finita constante y autocovarianzas nulas: el proceso es estacionario en covarianza, lo que cierra la equivalencia [41, 42]. $\square$

A.7. Verosimilitud condicional del GARCH(1, 1)- t

Derivación de la log-verosimilitud condicional, Sección 4.1.5. Sea f_ν la densidad de la t de Student estandarizada de ν grados de libertad. Condicionada a la información hasta $t-1$, la innovación $\epsilon_t = \sigma_t \eta_t$ tiene densidad $\frac{1}{\sigma_t} f_\nu(\epsilon_t/\sigma_t)$, ya que es un cambio de escala de η_t por el factor σ_t , que es conocido en $t-1$. La log-verosimilitud condicional de la muestra $\epsilon_{1:T}$, dado un valor inicial σ_1^2 , es la suma de las contribuciones diarias

$$\ell(\theta) = \sum_{t=1}^T \left[\log f_\nu\left(\frac{\epsilon_t}{\sigma_t}\right) - \log \sigma_t \right],$$

donde cada σ_t se obtiene recorriendo la recursión (4.1) con los parámetros θ en evaluación. El término $-\log \sigma_t$ es el jacobiano del cambio de variable de η_t a ϵ_t .

A.8. Recursión de Adams–MacKay del BOCPD

Demostración de la Proposición 4.6 (Recursión de Adams–MacKay), Sección 4.1.6.

Demostración. Partimos de la conjunta del instante t e introducimos la run-length anterior marginalizando sobre sus valores posibles:

$$\mathbb{P}(r_t, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_t, r_{t-1}, x_{1:t}).$$

Cada sumando se descompone separando la nueva observación x_t del pasado $x_{1:t-1}$ mediante la regla del producto,

$$\mathbb{P}(r_t, r_{t-1}, x_{1:t}) = \mathbb{P}(r_t \mid r_{t-1}, x_{1:t-1}) \mathbb{P}(x_t \mid r_t, r_{t-1}, x_{1:t-1}) \mathbb{P}(r_{t-1}, x_{1:t-1}).$$

El primer factor es la dinámica de la run-length, que por construcción del modelo solo depende de r_{t-1} : dado un tramo de longitud r_{t-1} , en el paso siguiente o bien hay cambio, y entonces $r_t = 0$ con probabilidad $H(r_{t-1} + 1)$, o bien no lo hay, y entonces $r_t = r_{t-1} + 1$ con probabilidad $1 - H(r_{t-1} + 1)$. Es decir,

$$\mathbb{P}(r_t \mid r_{t-1}, x_{1:t-1}) = \begin{cases} H(r_{t-1} + 1), & r_t = 0, \\ 1 - H(r_{t-1} + 1), & r_t = r_{t-1} + 1, \\ 0, & \text{en otro caso.} \end{cases}$$

El segundo factor es la predictiva del dato nuevo dentro del tramo: condicionada a r_{t-1} , y por la independencia entre segmentos, la observación x_t depende solo de las r_{t-1} observaciones del tramo en curso, lo que da $\pi_{\text{pred}}^{(r_{t-1})}$. El tercer factor es la conjunta del paso anterior, ya disponible. En ambos mensajes interviene esta misma predictiva $\pi_{\text{pred}}^{(r_{t-1})}$ porque x_t se evalúa contra el segmento en curso, de longitud r_{t-1} : el reinicio se materializa en la run-length siguiente, $r_t = 0$, no en la pertenencia de x_t , que todavía corresponde a ese segmento.

Como la transición de la run-length concentra toda su masa en dos destinos, la marginalización sobre r_{t-1} se reparte en dos casos. Si $r_t = r_{t-1} + 1 > 0$, solo contribuye el valor concreto $r_{t-1} = r_t - 1$ (no hay otra forma de llegar a esa run-length sin reinicio), de donde

$$\mathbb{P}(r_t = r_{t-1} + 1, x_{1:t}) = \mathbb{P}(r_{t-1}, x_{1:t-1}) (1 - H(r_{t-1} + 1)) \pi_{\text{pred}}^{(r_{t-1})},$$

que es el mensaje de crecimiento. Si $r_t = 0$, contribuyen *todos* los valores de r_{t-1} , pues desde cualquier longitud puede producirse un reinicio, y la suma da

$$\mathbb{P}(r_t = 0, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_{t-1}, x_{1:t-1}) H(r_{t-1} + 1) \pi_{\text{pred}}^{(r_{t-1})},$$

que es el mensaje de reinicio. Finalmente, la posterior se obtiene de la conjunta dividiendo por la verosimilitud marginal del dato, $\mathbb{P}(x_{1:t}) = \sum_r \mathbb{P}(r_t = r, x_{1:t})$, lo que da la normalización del enunciado. $\square$

A.9. Pseudo-residuos del boosting logístico

Enunciado y demostración del resultado citado en la Sección 4.2.2 (gradient boosting).

Proposición A.1 (Pseudo-residuos del boosting logístico). *Si F es el logaritmo de la razón de momios y $p = \sigma(F) = (1 + e^{-F})^{-1}$ la probabilidad asociada, el pseudo-residuo de la pérdida logística es la diferencia entre la etiqueta y la probabilidad predicha,*

$$r_i = - \left. \frac{\partial L}{\partial F} \right|_{F(\mathbf{x}_i)} = y_i - p(\mathbf{x}_i).$$

Demostración. Con $p = \sigma(F)$ se tiene $dp/dF = p(1 - p)$. La contribución de un dato a la pérdida es $L = -y \log p - (1 - y) \log(1 - p)$, de donde

$$\frac{\partial L}{\partial p} = -\frac{y}{p} + \frac{1 - y}{1 - p} = \frac{p - y}{p(1 - p)}.$$

Por la regla de la cadena, $\partial L / \partial F = (\partial L / \partial p) p(1 - p) = p - y$, y el pseudo-residuo es su opuesto, $y - p$ [48]. $\square$

A.10. Pesos óptimos y ganancia de una división en XGBoost

Enunciado y demostración del resultado citado en la Sección 4.2.2 (XGBoost).

Proposición A.2 (Pesos óptimos y ganancia de una división). *Fijada la estructura q , con conjuntos de instancias por hoja $I_j = \{i : q(\mathbf{x}_i) = j\}$ y sumas $G_j = \sum_{i \in I_j} g_i$, $H_j = \sum_{i \in I_j} h_i$, el peso que minimiza la aproximación de segundo orden del objetivo y el valor óptimo correspondiente son*

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \quad \tilde{\mathcal{L}}^*(q) = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T.$$

En consecuencia, dividir una hoja en dos descendientes L y R reduce el objetivo en

$$\text{Gan} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma,$$

que es el criterio con el que se eligen los cortes.

Demostración. La expansión de Taylor de segundo orden de la pérdida y el descarte del término constante $l(y_i, \hat{y}_i^{(t-1)})$ dan

$$\tilde{\mathcal{L}}^{(t)} = \sum_{i=1}^n \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t(\mathbf{x}_i)^2 \right] + \Omega(f_t).$$

Como $f_t(\mathbf{x}_i) = w_j$ para todo $i \in I_j$, se agrupa por hoja,

$$\tilde{\mathcal{L}}^{(t)} = \sum_{j=1}^T \left[G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2 \right] + \gamma T.$$

Para la pérdida logística, la Proposición A.1 da $g_i = p_i - y_i$ y un cálculo análogo $h_i = p_i(1 - p_i) \geq 0$, luego $H_j + \lambda > 0$ y cada sumando es una parábola convexa en w_j . Su mínimo está en $w_j^* = -G_j/(H_j + \lambda)$, con valor $-\frac{1}{2}G_j^2/(H_j + \lambda)$; sumando sobre las hojas se obtiene $\tilde{\mathcal{L}}^*(q)$. La ganancia de una división es la diferencia entre el objetivo de la hoja madre y el de los dos hijos, que arroja la expresión del enunciado [49]. $\square$

Apéndice B

Figuras complementarias

Este anexo reúne las figuras que respaldan afirmaciones del cuerpo sin recargarlo. Cada una se cita en su sitio; aquí se agrupan por lo que sostienen: primero el mecanismo sobre SPY, después el panel.

B.1. Mecanismo sobre SPY




Figura B.1: Matriz régimen $\times$ dirección sobre SPY, en calibración y fuera de muestra. El régimen coincide con la caída del mismo día pero no anticipa el signo del siguiente: el *leverage* que explota RAM es contemporáneo, no predictivo.




Figura B.2: Acierto del agente (M5) y del aprendiz (M10) por régimen, sobre SPY. El aprendiz corrige sobre todo donde el agente más se equivoca.

B.2. Panel de diez activos




Figura B.3: Robustez a la ventana de calibración: el rescate se mantiene al desplazar el periodo con el que se cierran los umbrales de los detectores. El resultado no cuelga de una calibración concreta.




Figura B.4: Scores de PSA y GSO frente a su umbral ex ante, junto al sesgo casi constante del agente. Los dos detectores rara vez cruzan el umbral porque el agente apenas cambia de posición: están dormidos sobre este activo, no rotos.




Figura B.5: Dependencia SHAP de las señales de STRATA en el aprendiz: cómo cambia su contribución al variar cada *score*. El modelo no las usa de forma plana, las modula según el régimen.




Figura B.6: Cuota de importancia de las señales de STRATA a lo largo del tiempo, por reentrenamiento. Se mantiene mayoritaria en toda la ventana: el aprendiz se apoya en STRATA de forma estable, no en un tramo afortunado.




Figura B.7: Matrices de confusión de las seis estrategias sobre SPY, dirección predicha frente a la real. Enseñan de dónde sale el acierto de cada una, no solo su porcentaje: el agente carga el error en una clase y las derivadas de STRATA lo reparten mejor.




Figura B.8: Sensibilidad de la accuracy al umbral de decisión sobre SPY: M8 frente a τ del detector RAM y M10 frente a su umbral de probabilidad. Las dos curvas son planas en una meseta alrededor del valor canónico (marcado), señal de robustez y no de ajuste a un punto.




Figura B.9: p de McNemar del rescate frente al agente, por estrategia y régimen, con el nivel $\alpha = 0,10$ marcado. El rescate en acierto es significativo en los dos regímenes.




Figura B.10: Dos casos trabajados, uno por canal. A la izquierda, XLE (*leverage* fuerte): el régimen es direccional y la regla rescata el riesgo del agente. A la derecha, MARA (*leverage* invertido): el régimen no informa el signo y el aprendiz rescata por la vía del sesgo del agente cruzado con el régimen. Cada panel muestra la dirección del agente, la del supervisor que rescata y el régimen vigente.




Figura B.11: Diagrama 2×2 del TOST del aprendiz frente a la regla M8, ejes accuracy (horizontal) y Sharpe (vertical). Las regiones marcan superioridad, equivalencia y no concluyente. M10 y AutoML caen en superioridad en accuracy y en no concluyente en Sharpe: el aprendiz afina la dirección sobre la regla y empata en riesgo.