

Universidad Complutense de Madrid
Facultad de Ciencias Matemáticas

Trabajo de Fin de Grado
Doble Grado en Matemáticas y Ciencia de Datos

STRATA: supervisión estadística en tiempo real de un agente de trading basado en LLMs

Autora: Raquel García

Tutor/es: [pendiente]

Curso académico [pendiente] — [fecha pendiente]

Índice general

1. Introducción	3
2. Estado del arte	4
2.1. Agentes LLM para decisiones financieras	4
2.2. Supervisión en tiempo de ejecución de sistemas ML y agentes	5
2.3. Régimen de mercado y gestión de riesgo como capa de control	5
El hueco que llena STRATA	6
3. Marco teórico	7
3.1. Preliminares y notación	7
3.2. STRATA a nivel técnico	8
3.3. Modelos de cambio de régimen: HMM gaussiano	9
3.3.1. Cambio de régimen en series financieras	9
3.3.2. Definición del HMM gaussiano	10
3.3.3. Algoritmo forward	11
3.3.4. Posterior filtrado frente a posterior suavizado	12
3.3.5. Estimación: el algoritmo de Baum-Welch (EM)	13
3.3.6. El algoritmo de Viterbi	14
3.3.7. Selección del número de estados	14
3.4. Volatilidad condicional: ARCH y GARCH(1,1)-t	15
3.4.1. De ARCH a GARCH	15
3.4.2. Estacionariedad y varianza incondicional	16
3.4.3. Innovaciones Student-t	17
3.4.4. Estimación por máxima verosimilitud	18
3.5. Detección bayesiana de puntos de cambio (BOCPD)	18
3.5.1. Run-length y detección online	18
3.5.2. Recursión de la distribución de run-length	19
3.5.3. Función de hazard y predictiva conjugada	21
3.6. STRATA aplicado: construcción, calibración y umbrales	21
3.6.1. Datos y calibración	21
3.6.2. RAM: desajuste entre régimen y acción	21
3.6.3. GSO: tamaño compatible con la volatilidad	22
3.6.4. PSA: coherencia temporal del agente	22
3.6.5. La capa de intervención	23

3.7.	Métricas de evaluación	23
3.7.1.	El ratio de Sharpe	23
3.7.2.	Sortino, drawdown máximo y Calmar	24
3.8.	Validación sin fuga temporal	25
3.8.1.	Causalidad: la regla <code>signal_lag=1</code>	25
3.8.2.	Validación walk-forward (rolling-origin)	25
3.8.3.	Purga y embargo	26
3.8.4.	Por qué no validación cruzada convencional, y el papel de CPCV . . .	26
3.9.	Contraste de hipótesis	27
3.9.1.	Test del signo binomial	27
3.9.2.	Test de McNemar pareado	27
3.9.3.	Test de Diebold-Mariano	28
3.9.4.	Contrastes de equivalencia (TOST)	29
3.9.5.	Bootstrap estacionario	29
3.9.6.	Deflated Sharpe Ratio	29
4.	Marco práctico: el caso de estudio SMCI	31
4.1.	Datos y caso de estudio	31
4.2.	El agente sin supervisar (M5)	31
4.3.	La regla a mano (M8) como referencia	32
4.4.	El meta-learner M10	32
4.5.	Resultado principal	32
4.6.	Robustez	33
4.7.	Interpretabilidad: M10 es inseparable de STRATA	33
4.8.	Lectura honesta y límites	34
5.	Conclusiones	35
	Bibliografía	36

Capítulo 1

Introducción

Capítulo 2

Estado del arte

2.1. Agentes LLM para decisiones financieras

En pocos años, los grandes modelos de lenguaje han reorganizado campos enteros, de la programación a la medicina, al convertirse en sistemas capaces de razonar sobre texto especializado y no solo de procesarlo. Las finanzas no han sido una excepción. Los modelos de lenguaje empezaron a usarse como motor de decisión financiera cuando se comprobó que un modelo adaptado al dominio podía sostener un razonamiento económico sobre texto, y no limitarse a clasificar el sentimiento de una noticia [1]. El interés se desplazó pronto de si un modelo entiende los mercados a cómo coordinar varios para que decidan en conjunto. La respuesta dominante ha sido la arquitectura multiagente, en la que distintas personalidades inversoras deliberan y un gestor de riesgo modera la posición resultante [2]. Ese gestor de riesgo es interno al agente y heurístico. Vive dentro del mismo sistema que produce la decisión, compartiendo su información y por tanto sus sesgos. La evaluación rigurosa de estos agentes, en cambio, es reciente y todavía escasa. Los trabajos de *benchmarking* sistemático muestran que el rendimiento reportado depende en gran medida del protocolo de medición, y que numerosos resultados optimistas no resisten una validación temporal honesta [3]. Marcos de evaluación como DeepFund miden la decisión del agente sesión a sesión sobre retornos reales y evitan que el modelo se beneficie de haber visto antes esos datos; de ahí se concluye que muchos rendimientos aparentes se desvanecen al aplicar un corte temporal limpio. Validar honestamente en el tiempo exige que el periodo de prueba sea posterior a todo aquello que el modelo pudo haber visto, lo que se conoce como cut off. A esa fragilidad metodológica se añade un sesgo característico de estos modelos, el look-ahead. Cuando el periodo evaluado está dentro del preentrenamiento, el modelo no infiere sino que reproduce lo memorizado, y eso infla las métricas [4]. Para que la evaluación signifique algo, la ventana fuera de muestra (OOS) debe arrancar después del corte de entrenamiento del modelo empleado, decisión de diseño que se retomará en el capítulo 3.

El agente concreto que se estudia, una réplica de AI Hedge Fund con cinco personalidades inversoras, reproduce estos problemas cuando opera sin supervisión externa. Sobre SMCI, el activo del caso de estudio, y en la ventana OOS pierde dinero: su acierto direccional (la fracción de días en que predice correctamente el signo del retorno siguiente) es de 0,484, por debajo del nivel que daría una moneda, y una inversión inicial de €1000 termina en €978.

A este agente sin supervisar lo llamaremos M5 a lo largo de la memoria. Lo más informativo es la estructura de la pérdida, no su magnitud: el agente mantiene posición corta el 95 % de los días, un sesgo direccional casi constante. Que el fallo sea sistemático, y no fruto del azar, es lo que lo hace corregible desde fuera: una posición rígida que apenas atiende a la señal diaria deja margen a una capa que reintroduzca esa información. Ese patrón estructural en las decisiones del agente es el síntoma sobre el que se construye nuestra capa de supervisión.

2.2. Supervisión en tiempo de ejecución de sistemas ML y agentes

Vigilar un sistema mientras decide, y no solo medirlo una vez ha decidido, enlaza con la tradición de la detección de anomalías, cuyo problema central es declarar qué cuenta como comportamiento normal y cuantificar lo que se aparta de él [5]. Esa tradición es necesaria pero no suficiente para el caso que nos ocupa. Detectar una anomalía es señalarla; lo que se busca aquí es además actuar sobre ella en el mismo paso en que se produce. Esa segunda exigencia define la familia del control en tiempo de ejecución (*runtime enforcement*), que impone durante la ejecución un conjunto de restricciones que el agente no puede violar: se especifican condiciones que deben cumplirse y se intercepta cada acción antes de ejecutarla, bloqueando las que las incumplen. Existen ya métodos de este tipo, e incluso marcos de fiabilidad pensados para la IA agéntica que tratan la supervisión como una propiedad del sistema desde su diseño. La comparación con este trabajo es imperfecta, porque parten de objetos de control distintos: las reglas declarativas codifican qué está prohibido, mientras que aquí se modela cómo de coherente es una posición dado el estado del mercado.

Frente a los enfoques basados en reglas, nuestra capa de supervisión recurre a detectores estadísticos clásicos e interpretables que comparan la decisión del agente contra un modelo explícito del mercado. Son tres. RAM (*Regime-Action Mismatch*) juzga la coherencia entre la acción y el régimen de mercado mediante un modelo de Markov oculto; PSA (*Position Sizing Anomaly*) vigila la coherencia temporal del agente con un detector bayesiano de puntos de cambio; y GSO (*GARCH-bounded Sizing Override*) acota la exposición en función de la volatilidad estimada por un GARCH. La definición formal de los tres se tratará en el capítulo 3.

2.3. Régimen de mercado y gestión de riesgo como capa de control

Hamilton introduce la idea de que la serie no responde a un único mecanismo: hay estados con propiedades estadísticas distintas y la serie cambia de estado sin que lo observemos. La distribución de cada retorno depende del estado vigente, que permanece latente [6]. Su utilidad no es meramente descriptiva. Condicionar la asignación de la cartera al régimen estimado mejora las decisiones de forma económicamente apreciable, según una literatura ya consolidada en torno a la persistencia de estos estados y a su efecto sobre la composición óptima del riesgo [7, 8]. Sobre el eje continuo de la volatilidad opera una idea complementaria: dimensionar la posición para alcanzar una volatilidad objetivo (el *volatility targeting*) mejora las propiedades

de la serie de retornos y constituye el ancla teórica del detector GSO [9]. No hay consenso sobre el número de estados: los trabajos previos oscilan entre dos [7] y cuatro [8]. Se adopta una partición de tres regímenes (calma, estrés y crisis): la verosimilitud fuera de muestra descarta con holgura dos estados (Sección 3.3.7), y por encima de tres la ganancia no compensa la pérdida de interpretabilidad de estados nombrables y con lectura económica directa.

El régimen funciona como proxy direccional únicamente de forma condicional, y esa condicionalidad sostiene buena parte de la tesis a la vez que la limita. La condición es el *leverage effect* de los índices agregados: en activos como SPY los estados de alta volatilidad coinciden con tramos bajistas, de modo que conocer el régimen informa también sobre el signo probable del retorno [10, 11]. Esto no convierte al régimen en un predictor del retorno. El régimen no predice; el régimen ordena las decisiones del agente. La coincidencia entre volatilidad alta y caída no se da por igual en valores individuales con apalancamiento financiero débil, donde el efecto se diluye y el régimen pierde poder direccional, lo que delimita el alcance de la técnica y se documenta como limitación del trabajo. De esa tensión entre el estado del mercado, los cambios de opinión del agente y la volatilidad nace el diseño de los detectores que se desarrollan en el capítulo 3.

El hueco que llena STRATA

Estas tres líneas de investigación se han tocado, por separado, nuestra motivación es crear un sistema que las una y supervise en tiempo de ejecución las decisiones de un agente LLM con detectores estadísticos clásicos e interpretables, que lo compare mediante tests pareados contra el mismo agente sin supervisar y que atribuya el efecto a cada detector por separado. Una capa de auditoría que corregirá al agente cuando su decisión contradice un modelo explícito del mercado, cambiando la posición hacia la dirección del régimen y que monitoriza cada corrección. Los tres detectores miden ejes distintos (régimen discreto, coherencia temporal y volatilidad continua) para buscar la ortogonalidad.

Capítulo 3

Marco teórico

Este capítulo reúne la base matemática sobre la que se construye STRATA y fija la notación que usa el resto de la memoria. Tras unos preliminares que establecen la notación el desarrollo se organiza en cuatro bloques. El primero presenta STRATA a nivel técnico, sin matemática todavía: qué supervisa, con qué tres detectores y de qué forma interviene (Sección 3.2). El segundo desarrolla la teoría matemática que sostiene cada detector: el modelo oculto de Markov del régimen (Sección 3.3), el modelo GARCH de la volatilidad (Sección 3.4) y la detección bayesiana de puntos de cambio (Sección 3.5). El tercero construye STRATA sobre esa teoría y fija sus calibraciones y umbrales (Sección 3.6). El cuarto reúne las herramientas de validación: las métricas de evaluación, la ausencia de fuga temporal y los contrastes de hipótesis (Secciones 3.7, 3.8 y 3.9).

3.1. Preliminares y notación

Trabajamos con una serie de precios diarios de un activo. Denotamos por $P_t > 0$ el precio de cierre del día t , con $t \in \{0, 1, \dots, T\}$. La cantidad relevante no es el precio en sí, sino su variación relativa de un día al siguiente. Definimos el *log-retorno*

$$r_t^{\log} = \log\left(\frac{P_t}{P_{t-1}}\right) = \log P_t - \log P_{t-1}, \quad t \geq 1,$$

El log-retorno mide el crecimiento del precio en escala logarítmica; es positivo cuando el precio sube y negativo cuando baja.

Conviene compararlo con el *retorno simple* $R_t = (P_t - P_{t-1})/P_{t-1} = P_t/P_{t-1} - 1$, que es la definición intuitiva, la fracción ganada o perdida. Ambos se relacionan por $r_t^{\log} = \log(1 + R_t)$. La razón de preferir el log-retorno es su aditividad temporal. Consideremos el retorno acumulado entre los días t_0 y $t_0 + n$. En escala logarítmica,

$$\log\left(\frac{P_{t_0+n}}{P_{t_0}}\right) = \log\left(\prod_{j=1}^n \frac{P_{t_0+j}}{P_{t_0+j-1}}\right) = \sum_{j=1}^n \log\left(\frac{P_{t_0+j}}{P_{t_0+j-1}}\right) = \sum_{j=1}^n r_{t_0+j}^{\log}.$$

El log-retorno de varios días es la suma de los log-retornos diarios. El retorno simple, en cambio, se compone de forma multiplicativa, $1 + R_{[t_0, t_0+n]} = \prod_{j=1}^n (1 + R_{t_0+j})$, lo que complica cualquier

análisis que sume o promedie a lo largo del tiempo. Esta aditividad es la que justifica modelar $r_t^{\log}$ en lo que sigue: las sumas de variables aleatorias son más tratables que los productos, y los modelos lineales en el tiempo se expresan de forma natural.

Fijamos también la convención temporal que gobierna toda la validación y todo el back-test. La decisión de cartera tomada con la información disponible hasta el día t no puede recompensarse con el movimiento de ese mismo día, que ya ha ocurrido. Por eso, para evitar el *look-ahead*, el retorno que se contabiliza frente a una posición tomada en t es el del día siguiente,

$$r_{t+1} = \log\left(\frac{P_{t+1}}{P_t}\right).$$

Y así nos aseguramos la ausencia de fuga temporal: de aquí en adelante, todo producto entre una posición y un retorno usará r_{t+1} .

Por último, una medida de cuánto se mueve el activo en un tramo de tiempo. Dada una ventana de h días que termina en t , definimos la *volatilidad realizada*

$$RV_t = \sqrt{\sum_{j=0}^{h-1} (r_{t-j}^{\log})^2},$$

esto es, la raíz de la suma de cuadrados de los log-retornos de la ventana. RV_t es un estimador no paramétrico de la dispersión local de los retornos: crece cuando el activo encadena días de movimientos grandes y se reduce en los tramos planos. A diferencia de la volatilidad condicional σ_t que se introduce en la Sección 3.4, RV_t no presupone ningún modelo; es una lectura directa de los datos.

Las series de retornos financieros no se comportan como ruido blanco gaussiano. Tres regularidades empíricas, documentadas de forma sistemática en la literatura [12], motivan los modelos del resto del capítulo. La primera es que la distribución de los retornos tiene *colas pesadas*: los movimientos extremos son mucho más frecuentes de lo que predice una normal, lo que lleva a sustituir la gaussiana por una distribución de colas anchas como la t de Student en el modelo de volatilidad. El *agrupamiento de volatilidad* es la segunda: los días de gran movimiento tienden a seguirse unos a otros, así que la magnitud de los retornos sí está correlada en el tiempo aunque su signo apenas lo esté, y eso es lo que captura un modelo GARCH. Queda la tercera, la *poca autocorrelación* de los retornos en niveles: casi nula a partir del primer rezago, mientras que sus cuadrados o sus valores absolutos sí la presentan. La combinación de las tres sugiere que el comportamiento del activo alterna entre estados o regímenes con dinámicas distintas, idea que formaliza el modelo de cambio de régimen de la siguiente sección.

3.2. STRATA a nivel técnico

Cada día, el agente de trading toma una decisión sobre el activo. Lo resumimos en una terna: un *signo* (comprar o vender), un *tamaño* y una *confianza*. Esa terna determina una *posición* $w_t \in [-1, +1]$, donde el signo marca la dirección (larga si $w_t > 0$, corta si $w_t < 0$) y el módulo $|w_t|$ es la fracción de capital expuesta; la posición tomada en t se evalúa contra el

retorno del día siguiente, $w_t \cdot r_{t+1}$. STRATA no decide por el agente: *supervisa* esa decisión. Formalmente, si llamamos $\mathcal{A}$ al espacio de decisiones del agente y $\mathcal{M}_t$ a la información de mercado disponible hasta el día t (resumida en $x_{1:t}$), STRATA es la aplicación

$$\text{STRATA}: \mathcal{A} \times \mathcal{M}_t \longrightarrow [0, 1]^3, \quad (w_t, x_{1:t}) \longmapsto (\text{RAM}_t, \text{PSA}_t, \text{GSO}_t),$$

que a partir de la decisión del agente y de una lectura estadística del mercado produce tres *señales* sobre esa decisión, cada una en $[0, 1]$. STRATA no predice el retorno: mide en qué grado la decisión del agente es coherente con el estado del mercado.

Las señales provienen de tres detectores, cada uno a cargo de un eje distinto. **RAM** se centra en el régimen: comprueba si la dirección de la apuesta encaja con el estado de mercado que el modelo oculto de Markov de la Sección 3.3 considera vigente. **PSA** atiende al propio agente; con la detección bayesiana de puntos de cambio vigila si éste cambia de criterio de forma estructural, no por una simple fluctuación. **GSO** se ocupa del tamaño de la apuesta: contrasta el módulo de la posición con la volatilidad que estima el GARCH de la Sección 3.4, y salta cuando la apuesta es grande para lo agitado que está el mercado. Esta ortogonalidad de los tres ejes permite que cada detector vea algo que los otros dos no pueden ver.

La intervención puede ir desde solo registrar la señal hasta encoger la posición o sustituirla por completo. En este trabajo trataremos y analizaremos únicamente la variante más fuerte, que reorienta el signo de w_t hacia el régimen cuando la incoherencia es alta; los modos intermedios quedan sujetos a un posible trabajo futuro. La Sección 3.6 detalla cómo se construye cada señal a partir de su detector y cuándo actúa esta intervención.

Hay que distinguir desde el principio entre la capa de señales y las reglas que las consumen. Cuando escribimos STRATA nos referimos siempre a la capa que produce las señales, mientras que cuando hablamos de M8 o M10 estamos haciendo referencia a las estrategias que la utilizan. **M8** es una regla determinista de umbrales fijos, la capa de intervención que se detalla en la Sección 3.6.5, y la usamos como referencia interpretable. **M10**, en cambio, no aplica umbrales fijos sino que es un modelo de segundo nivel (un *meta-learner*) que toma como entradas las salidas del agente y de los detectores de STRATA, aprende a combinar esas mismas señales para decidir la dirección del día siguiente. Se entrena solo con el pasado y es el objeto central del caso de estudio, que se desarrollará en el capítulo de resultados.

3.3. Modelos de cambio de régimen: HMM gaussiano

3.3.1. Cambio de régimen en series financieras

Un único modelo con parámetros constantes describe mal una serie financiera larga. Un mercado en tendencia alcista tranquila y un mercado en plena caída no comparten ni media ni volatilidad de los retornos, y forzar un solo conjunto de parámetros para ambos promedia dos comportamientos que conviene separar. La alternativa clásica es admitir que la serie atraviesa distintos *regímenes*, cada uno con su propia ley de probabilidad, y que el régimen vigente cambia en el tiempo de forma no observable directamente. Hamilton formalizó esta idea para series económicas mediante un proceso de Markov sobre los estados no observados [6]: el

régimen sigue una cadena de Markov y, condicionado a él, la serie observada se distribuye según los parámetros de ese régimen.

En el caso que ocupa a esta memoria interpretamos los regímenes como estados de mercado: un régimen de *Calma*, con retornos de media ligeramente positiva y volatilidad baja; un régimen de *Estrés*, intermedio; y un régimen de *Crisis*, con volatilidad alta y retorno medio negativo. Esta lectura puede cambiar según el activo, como se discute en la Sección 3.3.7. El instrumento concreto es el modelo oculto de Markov gaussiano, que se define a continuación.

3.3.2. Definición del HMM gaussiano

Un *modelo oculto de Markov* (HMM) consta de una secuencia de estados ocultos y una secuencia de observaciones generadas por esos estados [13, 14]. Sea $z_t \in \{1, \dots, K\}$ el estado oculto (el régimen) en el día t , con K el número de regímenes. La sucesión $\{z_t\}$ es una cadena de Markov homogénea de primer orden: dado el estado en t , el estado en $t + 1$ no depende del pasado anterior,

$$\mathbb{P}(z_{t+1} = j \mid z_t = i, z_{t-1}, \dots, z_1) = \mathbb{P}(z_{t+1} = j \mid z_t = i).$$

Recogemos estas probabilidades en la *matriz de transición* $A \in \mathbb{R}^{K \times K}$, de entradas

$$A_{ij} = \mathbb{P}(z_{t+1} = j \mid z_t = i), \quad A_{ij} \geq 0, \quad \sum_{j=1}^K A_{ij} = 1 \quad \forall i,$$

y la ley del estado inicial en la *distribución inicial* $\pi = (\pi_1, \dots, \pi_K)$ con $\pi_k = \mathbb{P}(z_1 = k)$ y $\sum_k \pi_k = 1$.

El estado no se observa; lo que se observa es x_t , el vector de características del día t (en nuestro caso, el log-retorno y la volatilidad realizada RV_t con ventana de 21 días). Suponemos *emisiones gaussianas*: condicionada al régimen k , la observación es normal multivariante,

$$x_t \mid z_t = k \sim \mathcal{N}(\mu_k, \Sigma_k),$$

con μ_k el vector de medias del régimen k y Σ_k su matriz de covarianzas. Escribimos la densidad de emisión como

$$b_k(x) = \mathcal{N}(x \mid \mu_k, \Sigma_k).$$

El modelo asume dos hipótesis de independencia condicional, palanca de toda derivación posterior. La observación de cada día depende solo del estado de ese día,

$$\mathbb{P}(x_t \mid z_t, z_{t-1}, \dots, z_1, x_{t-1}, \dots, x_1) = \mathbb{P}(x_t \mid z_t) = b_{z_t}(x_t), \quad (*)$$

y la dinámica de los estados es markoviana de primer orden.

El conjunto de parámetros es $\lambda = (A, \pi, \{\mu_k, \Sigma_k\}_{k=1}^K)$. Para una secuencia observada $x_{1:T} = (x_1, \dots, x_T)$ y una trayectoria oculta $z_{1:T}$, la probabilidad conjunta se factoriza según

el grafo del modelo:

$$\mathbb{P}(x_{1:T}, z_{1:T} \mid \lambda) = \pi_{z_1} b_{z_1}(x_1) \prod_{t=2}^T A_{z_{t-1}z_t} b_{z_t}(x_t).$$

La verosimilitud de los datos observados se obtiene marginalizando sobre todas las trayectorias ocultas posibles,

$$\mathbb{P}(x_{1:T} \mid \lambda) = \sum_{z_{1:T}} \mathbb{P}(x_{1:T}, z_{1:T} \mid \lambda).$$

Esta suma recorre K^T trayectorias, así que evaluarla término a término es inviable salvo para T minúsculos. El algoritmo *forward* la calcula en tiempo lineal en T .

3.3.3. Algoritmo forward

Definimos la *variable forward*

$$\alpha_t(k) = \mathbb{P}(x_{1:t}, z_t = k \mid \lambda),$$

la masa de probabilidad conjunta que el modelo asigna a la trayectoria de observaciones hasta t y al hecho de estar en el régimen k precisamente en ese instante. La verosimilitud completa se recupera de ella sin más que marginalizar el último estado: $\mathbb{P}(x_{1:T} \mid \lambda) = \sum_k \alpha_T(k)$. El resultado central, clásico en el tratamiento del HMM [13, 15], es que α_t admite una recursión.

Proposición 3.1 (Recursión forward). *Para $t \geq 1$ se tiene la inicialización $\alpha_1(k) = \pi_k b_k(x_1)$ y, para todo $j \in \{1, \dots, K\}$,*

$$\alpha_{t+1}(j) = b_j(x_{t+1}) \sum_{k=1}^K \alpha_t(k) A_{kj}.$$

Demostración. La inicialización es inmediata: $\alpha_1(k) = \mathbb{P}(x_1, z_1 = k) = \mathbb{P}(z_1 = k) \mathbb{P}(x_1 \mid z_1 = k) = \pi_k b_k(x_1)$, usando $(*)$ en el segundo factor.

Para el paso recursivo partimos de la definición e introducimos el estado anterior z_t marginalizando sobre sus K valores posibles:

$$\alpha_{t+1}(j) = \mathbb{P}(x_{1:t+1}, z_{t+1} = j) = \sum_{k=1}^K \mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j).$$

Descomponemos cada sumando separando la última observación x_{t+1} del resto mediante la regla del producto,

$$\mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j) = \mathbb{P}(x_{t+1} \mid x_{1:t}, z_t = k, z_{t+1} = j) \mathbb{P}(x_{1:t}, z_t = k, z_{t+1} = j).$$

Por la independencia condicional de las emisiones $(*)$, la observación x_{t+1} depende solo de su propio estado $z_{t+1} = j$, de modo que el primer factor es

$$\mathbb{P}(x_{t+1} \mid x_{1:t}, z_t = k, z_{t+1} = j) = \mathbb{P}(x_{t+1} \mid z_{t+1} = j) = b_j(x_{t+1}).$$

El segundo factor se descompone a su vez aislando la transición $z_t = k \rightarrow z_{t+1} = j$:

$$\mathbb{P}(x_{1:t}, z_t = k, z_{t+1} = j) = \mathbb{P}(z_{t+1} = j \mid x_{1:t}, z_t = k) \mathbb{P}(x_{1:t}, z_t = k).$$

La Markovianidad de la cadena, junto con la independencia condicional de las emisiones (*), hace que, fijado z_t , el estado z_{t+1} sea independiente de $x_{1:t}$ y de los estados anteriores (es la d-separación en el grafo del modelo); por tanto $\mathbb{P}(z_{t+1} = j \mid x_{1:t}, z_t = k) = A_{kj}$. El factor restante es, por definición, $\alpha_t(k)$. Reuniendo los tres trozos,

$$\mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j) = b_j(x_{t+1}) A_{kj} \alpha_t(k),$$

y al sumar en k el factor $b_j(x_{t+1})$ no depende del índice de la suma y sale fuera:

$$\alpha_{t+1}(j) = b_j(x_{t+1}) \sum_{k=1}^K \alpha_t(k) A_{kj},$$

que es lo que se quería probar. $\square$

La recursión reduce el coste de K^T a $\mathcal{O}(TK^2)$ operaciones: en cada paso se actualizan K variables y cada una suma sobre K términos. En la práctica los $\alpha_t(k)$ decaen exponencialmente con t y se trabaja con su logaritmo o con una normalización por paso para evitar el desbordamiento numérico, pero la estructura de la recursión es la enunciada.

3.3.4. Posterior filtrado frente a posterior suavizado

La variable forward responde a una probabilidad conjunta, pero lo que interesa para decidir es la probabilidad del régimen *dado* lo observado. Definimos el *posterior filtrado*

$$\gamma_t^f(k) = \mathbb{P}(z_t = k \mid x_{1:t}),$$

la probabilidad de estar en el régimen k en el instante t condicionada únicamente a las observaciones disponibles hasta ese instante. Se obtiene normalizando la variable forward sobre los estados.

Proposición 3.2 (Filtrado a partir del forward). *Para todo $t \geq 1$ y todo k ,*

$$\gamma_t^f(k) = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)}.$$

Demostración. Por la definición de probabilidad condicional y la de α_t ,

$$\gamma_t^f(k) = \mathbb{P}(z_t = k \mid x_{1:t}) = \frac{\mathbb{P}(x_{1:t}, z_t = k)}{\mathbb{P}(x_{1:t})} = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)},$$

donde en el denominador se ha usado $\mathbb{P}(x_{1:t}) = \sum_j \mathbb{P}(x_{1:t}, z_t = j) = \sum_j \alpha_t(j)$. $\square$

El adjetivo *filtrado* es preciso y tiene una consecuencia que es el eje de toda la memoria. En su definición, $\gamma_t^f(k)$ condiciona solo sobre $x_{1:t}$, es decir, sobre el pasado y el presente. La

recursión de la Proposición 3.1 lo confirma a nivel de cómputo: $\alpha_t(k)$ se construye a partir de $\alpha_{t-1}(\cdot)$ y de x_t exclusivamente, sin que en ningún momento intervenga $x_{t+1}, x_{t+2}, \dots$. Por tanto, la estimación del régimen en t es *causal*: podría calcularse en tiempo real, el mismo día t , con la información que existe ese día.

Esto contrasta con el *posterior suavizado*

$$\mathbb{P}(z_t = k \mid x_{1:T}),$$

que condiciona sobre la secuencia completa hasta el final T , incluyendo $x_{t+1:T}$. El suavizado es una estimación mejor del régimen pasado precisamente porque incorpora lo que ocurrió después: el conocimiento del futuro afina el juicio sobre el presente. Se calcula con el algoritmo forward-backward, que combina la variable forward con una variable backward que recorre la secuencia en sentido inverso [16, 13]. Esa misma virtud lo descalifica para nuestro uso. Emplear el suavizado dentro de un sistema de decisión introduciría *look-ahead*: la decisión del día t quedaría contaminada por información de días posteriores que en operativa real no se conocen. Por esta razón, **STRATA usa exclusivamente el posterior filtrado** γ_t^f , nunca el suavizado. La causalidad del filtrado, demostrada arriba a partir de la estructura de la recursión, es lo que garantiza que el sistema sea reproducible en tiempo real y que la validación de los capítulos posteriores no incurra en fuga temporal.

3.3.5. Estimación: el algoritmo de Baum-Welch (EM)

Hasta aquí se ha supuesto conocido el conjunto de parámetros λ . En la práctica λ debe estimarse a partir de los datos, y como los estados $z_{1:T}$ no se observan no puede maximizarse la verosimilitud directamente. El algoritmo de Baum-Welch resuelve esto como una instancia del esquema de esperanza-maximización (EM): alterna una estimación de los estados ocultos con una reestimación de los parámetros, garantizando que la verosimilitud no decrece en cada iteración [16, 13].

En el *paso E* (esperanza) se calculan, con los parámetros actuales, los posteriores de los estados y de las transiciones. Se necesitan el posterior suavizado puntual $\mathbb{P}(z_t = k \mid x_{1:T})$ y el posterior suavizado de pares $\mathbb{P}(z_t = i, z_{t+1} = j \mid x_{1:T})$, ambos obtenidos con el algoritmo forward-backward. Aquí sí se emplea el suavizado, y es legítimo: el ajuste del modelo se hace una sola vez, fuera de línea, sobre el periodo de calibración completo, no como parte de una decisión en tiempo real. La causalidad solo se exige en la fase de explotación, donde rige el filtrado.

En el *paso M* (maximización) se reestiman los parámetros maximizando la esperanza calculada en el paso E, lo que da fórmulas cerradas. La distribución inicial y la matriz de transición se actualizan como frecuencias esperadas,

$$\hat{\pi}_k = \mathbb{P}(z_1 = k \mid x_{1:T}), \quad \hat{A}_{ij} = \frac{\sum_{t=1}^{T-1} \mathbb{P}(z_t = i, z_{t+1} = j \mid x_{1:T})}{\sum_{t=1}^{T-1} \mathbb{P}(z_t = i \mid x_{1:T})},$$

y las medias y covarianzas de cada régimen, como promedios ponderados por el posterior del

estado,

$$\hat{\mu}_k = \frac{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T}) x_t}{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T})}, \quad \hat{\Sigma}_k = \frac{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T}) (x_t - \hat{\mu}_k)(x_t - \hat{\mu}_k)^\top}{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T})}.$$

El algoritmo itera paso E y paso M hasta que la verosimilitud se estabiliza. Que la sucesión de verosimilitudes sea monótona no decreciente y que el procedimiento converja a un punto estacionario es un resultado conocido de la teoría de EM, que aquí se enuncia sin demostrar y se remite a la referencia [16, 13]. El óptimo alcanzado es local y depende de la inicialización, de ahí la importancia de fijar la semilla y de partir de una inicialización razonable, como se documenta en el capítulo de metodología.

3.3.6. El algoritmo de Viterbi

El filtrado y el suavizado responden a una pregunta puntual: cuál es la probabilidad del régimen *en un instante dado*. Una pregunta distinta es cuál es la *trayectoria* de estados más probable en su conjunto, esto es, la secuencia $z_{1:T}^*$ que maximiza la probabilidad conjunta a posteriori,

$$z_{1:T}^* = \arg \max_{z_{1:T}} \mathbb{P}(z_{1:T} \mid x_{1:T}, \lambda).$$

Esto es el estimador MAP de la trayectoria completa, y lo resuelve el algoritmo de Viterbi mediante programación dinámica, con una recursión análoga a la del forward pero sustituyendo la suma sobre estados por un máximo [17]. La distinción es importante y no anecdótica: encadenar los modos del filtrado instante a instante, $\arg \max_k \gamma_t^f(k)$ para cada t , no produce en general la misma secuencia que Viterbi, porque la concatenación de óptimos puntuales puede dar una trayectoria que la matriz de transición considera improbable o incluso imposible. Viterbi optimiza la trayectoria como un todo y respeta las transiciones. En esta memoria el detector de régimen se apoya en el filtrado puntual por la exigencia de causalidad de la Sección 3.3.4; Viterbi se usa de forma auxiliar para la lectura interpretativa de la secuencia de regímenes sobre el periodo de calibración, donde la trayectoria global es lo que se quiere visualizar.

3.3.7. Selección del número de estados

Queda fijar K , el número de regímenes. Un valor demasiado pequeño no distingue estados de mercado realmente diferentes; uno demasiado grande sobreajusta y fragmenta la serie en regímenes sin contenido interpretable, además de multiplicar los parámetros a estimar. El criterio que seguimos combina dos exigencias. La primera es estadística: para cada candidato de K se ajusta el HMM sobre el tramo de entrenamiento y se evalúa la *log-verosimilitud held-out* sobre un tramo de validación posterior en el tiempo, nunca solapado con el de entrenamiento, de modo que la comparación respeta el orden temporal de la serie y no premia el sobreajuste [13]. La segunda es de interpretabilidad: los regímenes resultantes deben admitir una lectura económica clara y estable. Esta decisión se verá con más detalle en el capítulo siguiente pero podemos anticipar que la combinación de ambos criterios fija $K = 3$ como la calibración de referencia del método siendo estos tres estados: calma, estrés y crisis.

3.4. Volatilidad condicional: ARCH y GARCH(1,1)-t

3.4.1. De ARCH a GARCH

El HMM reparte la volatilidad entre unos pocos estados discretos, cada uno con su covarianza Σ_k constante. Esa descripción es útil para clasificar el mercado en regímenes, pero es gruesa: dentro de un mismo régimen la dispersión de los retornos no es fija, sino que sube y baja de forma continua. El agrupamiento de volatilidad descrito entre los hechos estilizados de la Sección 3.1 pide un modelo en el que la varianza de hoy dependa explícitamente de lo agitado que haya estado el pasado reciente. Ese es el cometido de la familia ARCH/GARCH.

Engle introdujo el modelo *ARCH* (heterocedasticidad condicional autorregresiva) para capturar precisamente este fenómeno [18]. La idea es modelar el retorno como un ruido de varianza variable en el tiempo, y hacer que esa varianza sea función de los errores recientes al cuadrado. Centramos antes la serie restando su media, y trabajamos con la innovación $\epsilon_t = r_t^{\log} - \mu$, donde μ es la media (no condicional) del retorno. En un ARCH de orden q , $\text{ARCH}(q)$, la varianza condicional de la innovación, que denotamos σ_t^2 , se escribe

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2, \quad \omega > 0, \quad \alpha_i \geq 0,$$

con la convención $\epsilon_t = \sigma_t z_t$, donde z_t es un ruido i.i.d. de media 0 y varianza 1 que se especifica más abajo. Que σ_t^2 sea *condicional* significa que es la varianza de ϵ_t dada la información hasta $t-1$: depende solo del pasado, no del propio ϵ_t . Un error grande en cualquiera de los q días anteriores eleva σ_t^2 , lo que reproduce el agrupamiento: tras un golpe, la volatilidad esperada sube.

La limitación práctica de ARCH es que reproducir la persistencia observada en los datos exige un orden q alto, y con él muchos parámetros α_i que estimar, lo que vuelve el modelo inestable y propenso a violar las restricciones de no negatividad. Bollerslev resolvió esta cuestión generalizando el modelo: el *GARCH* (ARCH generalizado) añade a la recursión términos de la propia varianza condicional pasada, de modo que la persistencia se consigue con pocos parámetros [19]. La especificación que se usa en toda la memoria es la más parsimoniosa y, a la vez, la más empleada en finanzas, el $\text{GARCH}(1,1)$. Definimos

$$\epsilon_t = \sigma_t z_t, \quad z_t \text{ i.i.d.}, \quad \mathbb{E}[z_t] = 0, \quad \text{Var}(z_t) = 1,$$

y la recursión de la varianza condicional

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \omega > 0, \quad \alpha \geq 0, \quad \beta \geq 0. \quad (3.1)$$

La varianza de hoy combina tres ingredientes: un suelo constante ω , la sorpresa del día anterior ϵ_{t-1}^2 (término ARCH, peso α) y la propia varianza del día anterior σ_{t-1}^2 (término GARCH, peso β). El último es el que aporta memoria larga con un solo parámetro: σ_{t-1}^2 ya resume todo el pasado, así que arrastrarla evita tener que sumar muchos rezagos de ϵ^2 . La cantidad $\sigma_t = \sqrt{\sigma_t^2}$ es la *volatilidad condicional*, la desviación típica de la innovación dada la información hasta $t-1$, y es la que utiliza el detector GSO de la Parte B. Las cifras de volatilidad de la memoria

se reportan *anualizadas*: la σ_t diaria se multiplica por $\sqrt{252}$, el número aproximado de días de mercado de un año, para expresarla en la escala anual habitual en finanzas.

3.4.2. Estacionariedad y varianza incondicional

La recursión (3.1) solo define un proceso bien comportado bajo una condición sobre los parámetros. El siguiente resultado la caracteriza y, de paso, da la varianza a largo plazo del proceso.

Teorema 3.3 (Estacionariedad en covarianza del GARCH(1,1)). *Sea $\{\epsilon_t\}$ el proceso definido por $\epsilon_t = \sigma_t z_t$ con $\{z_t\}$ i.i.d. de media 0 y varianza 1 y la recursión (3.1), con $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$. Entonces $\{\epsilon_t\}$ admite una solución estacionaria en covarianza con varianza incondicional finita si y solo si*

$$\alpha + \beta < 1,$$

y en ese caso la varianza incondicional vale

$$\text{Var}(\epsilon_t) = \frac{\omega}{1 - \alpha - \beta}.$$

Demostración. Supongamos primero que existe una solución estacionaria en covarianza, lo que significa, en particular, que $\text{Var}(\epsilon_t)$ es finita y no depende de t ; la llamamos $\bar{\sigma}^2 := \text{Var}(\epsilon_t)$. Calculamos la varianza incondicional de ϵ_t por la ley de la varianza total, usando que $\mathbb{E}[\epsilon_t] = 0$ (pues $\mathbb{E}[\epsilon_t] = \mathbb{E}[\sigma_t] \mathbb{E}[z_t] = 0$, al ser σ_t función del pasado e independiente de z_t , y $\mathbb{E}[z_t] = 0$):

$$\text{Var}(\epsilon_t) = \mathbb{E}[\epsilon_t^2] = \mathbb{E}[\mathbb{E}[\epsilon_t^2 \mid \mathcal{F}_{t-1}]],$$

donde $\mathcal{F}_{t-1}$ es la información hasta $t-1$. Como σ_t es función de $\mathcal{F}_{t-1}$ y z_t es independiente de $\mathcal{F}_{t-1}$ con $\mathbb{E}[z_t^2] = \text{Var}(z_t) = 1$,

$$\mathbb{E}[\epsilon_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2 \mathbb{E}[z_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2,$$

de donde $\mathbb{E}[\epsilon_t^2] = \mathbb{E}[\sigma_t^2]$. La misma identidad aplicada en $t-1$ da $\mathbb{E}[\epsilon_{t-1}^2] = \mathbb{E}[\sigma_{t-1}^2]$. Tomamos ahora esperanzas en la recursión (3.1):

$$\mathbb{E}[\sigma_t^2] = \omega + \alpha \mathbb{E}[\epsilon_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2] = \omega + \alpha \mathbb{E}[\sigma_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2].$$

Por estacionariedad, $\mathbb{E}[\sigma_t^2] = \mathbb{E}[\sigma_{t-1}^2] =: m$, constante en el tiempo. Sustituyendo,

$$m = \omega + (\alpha + \beta) m \iff m(1 - \alpha - \beta) = \omega.$$

Como $\omega > 0$ y $m = \mathbb{E}[\sigma_t^2] = \text{Var}(\epsilon_t) > 0$ es finita, el factor $1 - \alpha - \beta$ ha de ser estrictamente positivo, es decir, $\alpha + \beta < 1$, y entonces

$$\text{Var}(\epsilon_t) = m = \frac{\omega}{1 - \alpha - \beta}.$$

Esto prueba la necesidad de la condición y la fórmula de la varianza.

Recíprocamente, supongamos $\alpha + \beta < 1$. Iterando la recursión (3.1) hacia atrás n pasos, y usando de nuevo $\mathbb{E}[\epsilon_{t-i}^2 \mid \mathcal{F}_{t-i-1}] = \sigma_{t-i}^2$, se obtiene

$$\sigma_t^2 = \omega \sum_{i=0}^{n-1} \prod_{l=1}^i (\alpha z_{t-l}^2 + \beta) + \left(\prod_{l=1}^n (\alpha z_{t-l}^2 + \beta) \right) \sigma_{t-n}^2,$$

donde se ha reescrito $\alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2 = (\alpha z_{t-1}^2 + \beta) \sigma_{t-1}^2$. Tomando esperanzas, y como los z_{t-l} son i.i.d. con $\mathbb{E}[\alpha z_{t-l}^2 + \beta] = \alpha + \beta$, cada producto esperado vale $(\alpha + \beta)^i$. La serie geométrica $\sum_{i \geq 0} (\alpha + \beta)^i$ converge por ser $\alpha + \beta < 1$, el término residual $(\alpha + \beta)^n \mathbb{E}[\sigma_{t-n}^2] \rightarrow 0$, y el límite

$$\mathbb{E}[\sigma_t^2] = \omega \sum_{i=0}^{\infty} (\alpha + \beta)^i = \frac{\omega}{1 - \alpha - \beta}$$

es finito y constante en t . Con varianza incondicional finita y constante, y dado que las autocovarianzas de ϵ_t son nulas (los ϵ_t son una sucesión de diferencias de martingala no correladas), el proceso es estacionario en covarianza, lo que cierra la equivalencia. $\square$

La suma $\alpha + \beta$ mide la *persistencia* de la volatilidad: cuán despacio se reabsorbe un golpe. Cuando $\alpha + \beta$ está cerca de 1, la varianza incondicional $\omega/(1 - \alpha - \beta)$ explota y los choques tardan muchísimo en disiparse; en series financieras diarias es habitual estimar valores muy próximos a la unidad, signo de volatilidad muy persistente. El caso límite $\alpha + \beta = 1$ define el modelo *IGARCH* (GARCH integrado), en el que la varianza incondicional ya no es finita y un choque tiene efecto permanente sobre la volatilidad esperada, de forma análoga a una raíz unitaria en la media. En esa frontera el Teorema 3.3 deja de garantizar estacionariedad en covarianza, y la interpretación de σ_t como fluctuación alrededor de un nivel de largo plazo se pierde.

3.4.3. Innovaciones Student-t

Falta especificar la ley del ruido z_t . La elección más simple, $z_t \sim \mathcal{N}(0, 1)$, reproduce el agrupamiento de volatilidad pero subestima la frecuencia de los movimientos extremos: incluso con varianza variable, un GARCH gaussiano genera colas demasiado finas frente a las que muestran los retornos reales. Como las colas pesadas eran uno de los hechos estilizados de la Sección 3.1, conviene un ruido con colas más anchas. Bollerslev propuso sustituir la normal por una t de Student estandarizada [20].

Tomamos entonces z_t i.i.d. con distribución t de Student de ν grados de libertad, reescalada para tener varianza unidad,

$$z_t \sim t_\nu \text{ estandarizada}, \quad \mathbb{E}[z_t] = 0, \quad \text{Var}(z_t) = 1, \quad \nu > 2.$$

El parámetro ν , los *grados de libertad*, controla el grosor de las colas: cuanto menor es ν , más probabilidad acumula la distribución en los extremos y más frecuentes son los retornos atípicos. La restricción $\nu > 2$ es necesaria para que la varianza exista y el reescalado a varianza unidad tenga sentido. En el límite $\nu \rightarrow \infty$ la t de Student converge a la normal estándar, de modo que el GARCH(1, 1) gaussiano queda como caso particular del GARCH(1, 1)- t ; estimar ν finito y

pequeño es, por tanto, evidencia directa de colas más pesadas que las gaussianas. Esta es la especificación que se usa en la memoria y la que abrevia el rótulo GARCH(1,1)- t .

3.4.4. Estimación por máxima verosimilitud

Los parámetros $\theta = (\omega, \alpha, \beta, \nu)$ se estiman por máxima verosimilitud condicional. Sea f_ν la densidad de la t de Student estandarizada de ν grados de libertad. Condicionada a la información hasta $t-1$, la innovación $\epsilon_t = \sigma_t z_t$ tiene densidad $\frac{1}{\sigma_t} f_\nu(\epsilon_t/\sigma_t)$, ya que es un cambio de escala de z_t por el factor σ_t , que es conocido en $t-1$. La log-verosimilitud condicional de la muestra $\epsilon_{1:T}$, dado un valor inicial σ_1^2 , es la suma de las contribuciones diarias

$$\ell(\theta) = \sum_{t=1}^T \left[\log f_\nu\left(\frac{\epsilon_t}{\sigma_t}\right) - \log \sigma_t \right],$$

donde cada σ_t se obtiene recorriendo la recursión (3.1) con los parámetros θ en evaluación. El término $-\log \sigma_t$ es el jacobiano del cambio de variable de z_t a ϵ_t . No existe solución cerrada para el máximo, así que se maximiza $\ell(\theta)$ numéricamente sobre la región admisible $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$, $\nu > 2$.

El estimador resultante hereda las buenas propiedades de la máxima verosimilitud bajo condiciones de regularidad. Bajo el modelo correctamente especificado y la condición de estacionariedad del Teorema 3.3, el estimador máximo-verosímil $\hat{\theta}$ es consistente y asintóticamente normal, con matriz de covarianzas el inverso de la información de Fisher; estos resultados se enuncian aquí sin demostración y se remiten a las referencias originales [19, 20]. Conviene una cautela: la normalidad asintótica de $\hat{\beta}$ y $\hat{\alpha}$ se degrada cuando $\alpha + \beta$ se aproxima a la frontera 1, justo el régimen IGARCH discutido arriba, lo que se tiene presente al interpretar los intervalos de confianza de los parámetros estimados en el capítulo de resultados.

3.5. Detección bayesiana de puntos de cambio (BOCPD)

3.5.1. Run-length y detección online

Los dos modelos anteriores miran el mercado. El detector que ahora se introduce mira al *agente*: vigila si la serie de decisiones (en concreto, el tamaño de las posiciones que va tomando) sufre una ruptura estructural, un cambio de comportamiento que no se explica como fluctuación dentro del mismo patrón. El instrumento es la detección bayesiana de puntos de cambio online de Adams y MacKay [21].

Sea $x_{1:t}$ la secuencia observada hasta el día t , donde aquí x_t es la magnitud que se vigila (el tamaño de la posición del agente). Un *punto de cambio* es un instante en el que los parámetros que generan la serie cambian; entre dos puntos de cambio consecutivos la serie se considera generada por un mismo modelo con parámetros fijos. La variable central es la *run-length* r_t , el número de pasos transcurridos desde el último punto de cambio:

$$r_t \in \{0, 1, 2, \dots\}, \quad r_t = 0 \Leftrightarrow \text{hay un punto de cambio en } t,$$

y $r_t = r$ indica que el día actual y los r días previos se atribuyen al mismo segmento, todavía

sin ruptura. La run-length crece de uno en uno mientras no hay cambio ($r_t = r_{t-1} + 1$) y se reinicia a 0 cuando lo hay.

La distinción entre detección *online* y *offline* es decisiva para esta memoria. Un detector *offline* dispone de toda la serie $x_{1:T}$ y localiza los cambios mirando hacia delante y hacia atrás; es más preciso, pero no es causal. Un detector *online* estima la run-length usando únicamente $x_{1:t}$, la información disponible en el instante t , sin asomarse al futuro. El método de Adams y MacKay es online por construcción: en cada día actualiza la distribución de r_t a partir de la del día anterior y de la nueva observación. Esta causalidad es exactamente la que exige el detector PSA, igual que el filtrado del HMM frente al suavizado (Sección 3.3.4): una alarma de cambio de comportamiento del agente solo es legítima si pudo emitirse el mismo día, sin conocer lo que el agente hizo después.

3.5.2. Recursión de la distribución de run-length

El objetivo es calcular, de forma online, la distribución posterior de la run-length, $\mathbb{P}(r_t \mid x_{1:t})$. Se obtiene normalizando la conjunta $\mathbb{P}(r_t, x_{1:t})$, que admite una recursión. Necesitamos dos ingredientes. El primero es la *función de hazard* $H(r)$, la probabilidad de que se produzca un cambio dado que el tramo actual lleva ya r pasos sin él,

$$H(r) = \mathbb{P}(r_t = 0 \mid r_{t-1} = r - 1),$$

que gobierna la frecuencia a priori de los puntos de cambio. El segundo es la *predictiva posterior* del modelo de observación dentro de un tramo: dado que la run-length actual es $r_{t-1} = r$, la densidad del nuevo dato condicionada a las observaciones de ese mismo tramo,

$$\pi_{\text{pred}}^{(r)} = \mathbb{P}(x_t \mid r_{t-1} = r, x_{1:t-1}),$$

que se calcula con las observaciones acumuladas desde el último reinicio. Con estos dos elementos derivamos la recursión.

Proposición 3.4 (Recursión de Adams–MacKay). *La distribución conjunta de la run-length y los datos satisface, partiendo de $\mathbb{P}(r_{t-1}, x_{1:t-1})$, los dos mensajes siguientes. El mensaje de crecimiento (no hay cambio, $r_t = r_{t-1} + 1$):*

$$\mathbb{P}(r_t = r_{t-1} + 1, x_{1:t}) = \mathbb{P}(r_{t-1}, x_{1:t-1}) (1 - H(r_{t-1} + 1)) \pi_{\text{pred}}^{(r_{t-1})},$$

y el mensaje de reinicio (hay cambio, $r_t = 0$):

$$\mathbb{P}(r_t = 0, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_{t-1}, x_{1:t-1}) H(r_{t-1} + 1) \pi_{\text{pred}}^{(r_{t-1})}.$$

La posterior de la run-length se recupera normalizando,

$$\mathbb{P}(r_t \mid x_{1:t}) = \frac{\mathbb{P}(r_t, x_{1:t})}{\sum_r \mathbb{P}(r_t = r, x_{1:t})}.$$

Demostración. Partimos de la conjunta del instante t e introducimos la run-length anterior

marginalizando sobre sus valores posibles:

$$\mathbb{P}(r_t, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_t, r_{t-1}, x_{1:t}).$$

Cada sumando se descompone separando la nueva observación x_t del pasado $x_{1:t-1}$ mediante la regla del producto,

$$\mathbb{P}(r_t, r_{t-1}, x_{1:t}) = \mathbb{P}(r_t \mid r_{t-1}, x_{1:t-1}) \mathbb{P}(x_t \mid r_t, r_{t-1}, x_{1:t-1}) \mathbb{P}(r_{t-1}, x_{1:t-1}).$$

El primer factor es la dinámica de la run-length, que por construcción del modelo solo depende de r_{t-1} : dado un tramo de longitud r_{t-1} , en el paso siguiente o bien hay cambio, y entonces $r_t = 0$ con probabilidad $H(r_{t-1} + 1)$, o bien no lo hay, y entonces $r_t = r_{t-1} + 1$ con probabilidad $1 - H(r_{t-1} + 1)$. Es decir,

$$\mathbb{P}(r_t \mid r_{t-1}, x_{1:t-1}) = \begin{cases} H(r_{t-1} + 1), & r_t = 0, \\ 1 - H(r_{t-1} + 1), & r_t = r_{t-1} + 1, \\ 0, & \text{en otro caso.} \end{cases}$$

El segundo factor es la predictiva del dato nuevo dentro del tramo: condicionada a r_{t-1} , la observación x_t depende solo de las observaciones del tramo en curso, lo que da $\pi_{\text{pred}}^{(r_{t-1})}$. El tercer factor es la conjunta del paso anterior, ya disponible.

Como la transición de la run-length concentra toda su masa en dos destinos, la marginalización sobre r_{t-1} se reparte en dos casos. Si $r_t = r_{t-1} + 1 > 0$, solo contribuye el valor concreto $r_{t-1} = r_t - 1$ (no hay otra forma de llegar a esa run-length sin reinicio), de donde

$$\mathbb{P}(r_t = r_{t-1} + 1, x_{1:t}) = \mathbb{P}(r_{t-1}, x_{1:t-1}) (1 - H(r_{t-1} + 1)) \pi_{\text{pred}}^{(r_{t-1})},$$

que es el mensaje de crecimiento. Si $r_t = 0$, contribuyen *todos* los valores de r_{t-1} , pues desde cualquier longitud puede producirse un reinicio, y la suma da

$$\mathbb{P}(r_t = 0, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_{t-1}, x_{1:t-1}) H(r_{t-1} + 1) \pi_{\text{pred}}^{(r_{t-1})},$$

que es el mensaje de reinicio. Finalmente, la posterior se obtiene de la conjunta dividiendo por la verosimilitud marginal del dato, $\mathbb{P}(x_{1:t}) = \sum_r \mathbb{P}(r_t = r, x_{1:t})$, lo que da la normalización del enunciado. $\square$

La recursión es enteramente causal: $\mathbb{P}(r_t, x_{1:t})$ se construye a partir de $\mathbb{P}(r_{t-1}, x_{1:t-1})$ y de la observación x_t , sin recurrir a ningún dato posterior. Por eso sirve para PSA. El soporte de r_t crece un paso en cada iteración, así que en la práctica se trunca la distribución descartando las run-lengths cuya probabilidad cae por debajo de un umbral, lo que mantiene el coste acotado sin alterar de forma apreciable la inferencia.

3.5.3. Función de hazard y predictiva conjugada

Para cerrar el modelo hay que fijar la función de hazard y la predictiva. La elección estándar para la hazard es la *constante*,

$$H(r) = \frac{1}{\lambda}, \quad \lambda > 0,$$

independiente de r . Bajo esta elección la dinámica de la run-length carece de memoria: la probabilidad de que el segmento actual termine en el paso siguiente es siempre $1/\lambda$, sea cual sea el tiempo que lleve vigente. La longitud de cada segmento queda entonces distribuida como una geométrica de parámetro $1/\lambda$ y media λ pasos. El parámetro λ codifica, por tanto, la escala temporal esperada entre rupturas y es el único hiperparámetro de la dinámica.

La predictiva $\pi_{\text{pred}}^{(r)}$ se calcula de forma cerrada eligiendo el modelo de observación dentro de un tramo en una familia exponencial con su *previa conjugada*: la posterior de los parámetros del tramo pertenece entonces a la misma familia que la previa, y la predictiva del dato nuevo tiene expresión analítica que se actualiza de forma incremental al llegar cada observación. Esta conjugación es lo que hace que la recursión de la Proposición 3.4 sea barata de evaluar día a día. La especificación concreta del modelo de observación de PSA se detalla en el capítulo de metodología. Como contexto, el trabajo de Fearnhead sobre inferencia exacta para modelos multipunto desarrolla los métodos de cálculo de estas distribuciones predictivas y de la partición en tramos sobre los que se apoya el enfoque online [22].

3.6. STRATA aplicado: construcción, calibración y umbrales

Cada detector produce una señal numérica que mide un tipo de incoherencia entre la decisión del agente y el estado del mercado; cuando esa señal supera un umbral, STRATA interviene.

3.6.1. Datos y calibración

Los tres modelos se estiman una sola vez, sobre un periodo de calibración fijo y anterior al periodo de evaluación, y no se reentrenan después. Esta separación entre calibración y explotación impide que cualquier parámetro de STRATA haya visto los datos sobre los que luego se le juzga. Fijar un único periodo de calibración presupone que la estructura de la serie es razonablemente estable dentro de él, hipótesis que se puede contrastar con el test de cambios estructurales múltiples de Bai y Perron [23, 24], que localiza el número y la posición de las rupturas en los parámetros de un modelo. La estabilidad suficiente en ese periodo es lo que justifica fijar los parámetros una vez en lugar de moverlos con el tiempo.

3.6.2. RAM: desajuste entre régimen y acción

El detector RAM mide si la dirección de la apuesta del agente es coherente con el régimen de mercado. Toma como entrada el posterior filtrado γ_t^f de la Sección 3.3.4: para cada día, una distribución de probabilidad sobre los tres regímenes. Lo que falta es asociar esos regímenes a direcciones de mercado, y ahí entra el único ingrediente económico del detector.

En los índices bursátiles agregados, el retorno y la volatilidad están correlados negativamente: los tramos de alta volatilidad coinciden con caídas y los de baja volatilidad con subidas. Black documentó este fenómeno y lo llamó *leverage effect* [10]; Christie lo estudió de forma sistemática [11]. En un índice, por tanto, el régimen de alta volatilidad que identifica el HMM adquiere una lectura direccional: alta volatilidad tiende a significar mercado a la baja. Esa correspondencia es una propiedad de los índices, no una ley universal; en una acción individual el leverage effect es débil y la asociación entre nivel de volatilidad y dirección se diluye. Por eso STRATA no fija la dirección de cada régimen a mano, sino que la aprende del dato: para cada régimen k se toma el signo de su media de log-retorno, esto es, la componente de retorno del vector μ_k estimado en la calibración, de modo que el régimen de media más negativa se asocia a la dirección bajista y el de media más positiva a la alcista. Este prior por activo es lo que permite aplicar RAM a cualquier serie sin suponer que se comporta como un índice.

Con el prior fijado, el *RAM score* es la masa de probabilidad filtrada sobre los regímenes en los que la acción del agente es incoherente con la dirección aprendida. Si el agente abre una posición larga, la incoherencia se acumula en los regímenes bajistas; si la abre corta, en los alcistas. El score vive en $[0, 1]$: cuanto más alto, más probabilidad pone el HMM en que el agente apuesta contra el régimen. El detector se activa con tres umbrales fijados ex ante, 0,25, $\tau = 0,50$ y 0,70, que marcan severidad baja, media y alta. El umbral operativo es el central, $\tau = 0,50$: equivale a intervenir cuando la dirección contraria a la apuesta acumula más de la mitad de la probabilidad de régimen, esto es, a la regla de mayoría. No es un parámetro ajustado contra los datos, sino una elección normativa; además, en la práctica el score tiende a concentrar su masa cerca de 0 o de 1, de modo que el acierto del detector apenas cambia para umbrales en un entorno de 0,5.

3.6.3. GSO: tamaño compatible con la volatilidad

GSO se ocupa del tamaño de la apuesta: comprueba si es compatible con la volatilidad vigente. Su referencia teórica es el *volatility targeting*, que dimensiona la posición de forma inversamente proporcional a la volatilidad estimada para mantener el riesgo aproximadamente constante. Moreira y Muir mostraron que escalar la exposición en sentido inverso a la volatilidad mejora el rendimiento ajustado por riesgo [9]. GSO toma la volatilidad condicional σ_t del GARCH(1, 1)- t de la Sección 3.4, calculada con información hasta $t - 1$, y compara el tamaño $|w_t|$ del agente con la banda que prescribiría el volatility targeting. Cuando el tamaño excede esa banda, GSO lo interpreta como sobreexposición y emite señal. Los umbrales se fijan en los percentiles 95 y 99 de la distribución de la discrepancia sobre el periodo de calibración.

Sobre los datos estudiados, GSO rara vez supera la severidad media: el tamaño que toma el agente casi nunca viola la banda de forma marcada. Es una limitación del detector sobre este activo, que recojo en los resultados.

3.6.4. PSA: coherencia temporal del agente

PSA vigila la coherencia temporal del agente: detecta si cambia de criterio de forma estructural, no como fluctuación dentro de un mismo patrón. Aplica la detección bayesiana de puntos de cambio de la Sección 3.5 a la serie de tamaños de posición del agente. En lugar

de la probabilidad absoluta de cambio usa su incremento de un día al siguiente, que detecta el momento de la ruptura y no el estado posterior a ella. La dinámica de puntos de cambio se gobierna con una función de hazard constante $H = 1/\lambda$ con $\lambda = 60$, que fija a priori la escala temporal entre rupturas en unos sesenta días de mercado, la media de la geométrica de la Sección 3.5.3; no es un valor optimizado contra el periodo de evaluación, sino una escala interpretable que se comprobó robusta por un análisis de sensibilidad en la calibración. Los umbrales operativos siguen el mismo criterio que RAM y GSO: los percentiles 95 y 99 sobre el periodo de calibración.

3.6.5. La capa de intervención

Las tres señales alimentan la capa de intervención sobre la posición w_t , que actúa en tres pasos. Primero, el GSO acota la magnitud $|w_t|$ al límite que permite la volatilidad estimada, la banda GARCH. Después, cuando el RAM score supera el gate $\tau = 0,50$, la intervención reorienta el signo: reemplaza la posición por la más próxima dentro de la banda admisible que marca el régimen —es el único paso que cambia la dirección—. Por último, ante un cambio brusco de *sizing* señalado por el PSA, la posición resultante se frena a la mitad. La intervención trabaja solo con el posterior filtrado del régimen. La regla de referencia M8 es exactamente esta configuración, con `signal_lag = 1`.

3.7. Métricas de evaluación

Para juzgar si una estrategia lo hace bien no basta con mirar cuánto gana: hay que poner el rendimiento en relación con el riesgo asumido. Las métricas que siguen sirven a ese fin, todas a partir de la serie de retornos de la estrategia o de la trayectoria de su capital. Ninguna prueba nada por sí sola: son enriquecimiento ilustrativo, y la prueba estadística del trabajo descansa en los contrastes de la Sección 3.9.

3.7.1. El ratio de Sharpe

El *ratio de Sharpe* resume rendimiento y riesgo en un solo número, dividiendo el retorno medio en exceso por la volatilidad de ese retorno [25]. Sea r el retorno de la estrategia en un periodo y r_f el *retorno libre de riesgo*, lo que se obtendría sin asumir riesgo alguno (por ejemplo, en deuda pública a corto plazo). El ratio de Sharpe se define como

$$S = \frac{\mathbb{E}[r] - r_f}{\sqrt{\text{Var}(r)}},$$

esto es, el retorno medio por encima del activo sin riesgo dividido por la desviación típica del retorno. El numerador mide cuánto se gana de más por asumir riesgo; el denominador mide el riesgo asumido. Un Sharpe alto indica que cada unidad de riesgo se remunera bien. Como se calcula sobre retornos diarios pero se reporta en escala anual, se *anualiza* multiplicando por $\sqrt{252}$, bajo el supuesto de retornos diarios aproximadamente independientes, donde 252 es el número aproximado de días de mercado en un año.

El ratio de Sharpe es la medida estándar de rendimiento ajustado por riesgo, pero esta memoria no lo reporta nunca aislado, porque es *frágil* por dos motivos. No es robusto: penaliza por igual la variabilidad al alza y a la baja, aunque al inversor solo le preocupe la segunda, y un puñado de retornos extremos puede distorsionar la varianza del denominador. Y su lectura como cantidad estable supone que los retornos son aproximadamente normales e independientes, hipótesis que los hechos estilizados de la Sección 3.1 desmienten. Un Sharpe muestral elevado puede ser, así, fruto del azar o de haber probado muchas estrategias, problema que aborda el Deflated Sharpe Ratio de la Sección 3.9.

3.7.2. Sortino, drawdown máximo y Calmar

El ratio de Sharpe admite refinamientos que corrigen alguna de sus limitaciones y que se usan en la memoria como medidas complementarias. El ratio de Sortino se debe a Sortino y Price [26], que recogen la idea de riesgo a la baja de Sortino y van der Meer [27]; el ratio de Calmar fue propuesto por Young [28] en una publicación profesional, no académica, por lo que se cita con esa cautela. El drawdown máximo es una definición operativa estándar derivada de la trayectoria de la cartera.

El *ratio de Sortino* responde a la objeción de que penalizar la variabilidad al alza no tiene sentido. En lugar de la desviación típica completa del denominador del Sharpe, usa solo la *desviación a la baja*, calculada sobre los retornos que quedan por debajo de un umbral de referencia (típicamente cero o el retorno libre de riesgo). Si $r^- = \min(r - r_f, 0)$ recoge solo las desviaciones negativas, el ratio de Sortino es

$$\text{Sortino} = \frac{\mathbb{E}[r] - r_f}{\sqrt{\mathbb{E}[(r^-)^2]}}$$

con el mismo numerador que el Sharpe pero un denominador que mide únicamente el riesgo de pérdida. Una estrategia con muchas subidas bruscas y pocas bajadas tendrá un Sortino más alto que su Sharpe.

El *drawdown máximo* mide el riesgo de forma distinta, no por la dispersión sino por la peor racha. Dada la trayectoria acumulada del valor de la cartera, el drawdown en un instante es la caída relativa desde el máximo alcanzado hasta entonces, y el drawdown máximo es la mayor de esas caídas pico-valle a lo largo de todo el periodo. Si V_t es el valor de la cartera en t ,

$$\text{MDD} = \max_t \left(1 - \frac{V_t}{\max_{s \leq t} V_s} \right),$$

de modo que un drawdown máximo del 40 % significa que, en el peor momento, la cartera llegó a perder un cuarenta por ciento desde su techo previo. Es la medida que mejor refleja lo que un inversor sufre en la práctica.

Por último, el *ratio de Calmar* combina rendimiento y peor racha en un solo número, dividiendo el retorno anualizado por el drawdown máximo (en valor absoluto),

$$\text{Calmar} = \frac{\text{retorno anualizado}}{\text{MDD}}.$$

A diferencia del Sharpe, que mide el riesgo por la volatilidad, el Calmar lo mide por la mayor pérdida sufrida, y premia las estrategias que evitan caídas profundas. Estas tres cantidades acompañan al Sharpe para dar una imagen más completa del comportamiento de cada estrategia.

3.8. Validación sin fuga temporal

Un backtest brillante sobre datos pasados no vale nada si su evaluación usó, aunque sea de forma sutil, información que no estaba disponible al decidir. Esa contaminación es la *fuga temporal* o *look-ahead*; las salvaguardas que la impiden son condición necesaria para que las cifras del capítulo de resultados sean creíbles. La regla es la misma que en la Parte A: solo se usa información del pasado y del presente, nunca del futuro.

3.8.1. Causalidad: la regla `signal_lag=1`

La Sección 3.1 fijó esta regla; aquí se ve por qué es condición de ausencia de fuga. La posición w_t se decide con la información disponible hasta el cierre del día t . El retorno de ese mismo día, r_t , ya se ha producido cuando se decide: forma parte de la información que entra en la decisión. Contabilizar la ganancia como $w_t \cdot r_t$ sería, por tanto, recompensar la posición con un movimiento que ya se conocía al tomarla, lo que equivale a permitir que la decisión mire su propio resultado. Es *look-ahead* en su forma más directa y produce backtests artificialmente brillantes que se desploman en operativa real.

La regla correcta, que en el código lleva el nombre `signal_lag=1`, es contabilizar la posición de t contra el retorno del día siguiente:

$$\text{resultado del día} = w_t \cdot r_{t+1}.$$

La posición se fija en t y se evalúa con el primer retorno que aún no se conocía, el de $t + 1$. Esta es la única convención que reportamos. Encaja con el filtrado causal de la Sección 3.3.4: el régimen γ_t^f que alimenta la decisión en t se calcula solo con $x_{1:t}$, y la decisión resultante se enfrenta a r_{t+1} . La construcción es la recomendada en la literatura sobre evaluación de estrategias financieras, que insiste en alinear el etiquetado de cada decisión con el horizonte en el que se materializa su resultado [29].

3.8.2. Validación walk-forward (rolling-origin)

La convención `signal_lag=1` asegura la causalidad de una decisión aislada, pero el meta-learner del caso de estudio *aprende* de los datos, y validar un modelo que aprende exige un protocolo que reproduzca cómo se usaría en operativa real. El que adoptamos es el *walk-forward* de origen rodante (*rolling-origin*), el estándar para evaluar predicción sobre series temporales [30, 31]: el modelo se entrena solo con el pasado, predice un tramo futuro, y la ventana de entrenamiento avanza en el tiempo repitiendo el ciclo.

Se reserva un *periodo de arranque* (*burn-in*) inicial, que sirve para el primer entrenamiento y no se puntúa. A partir de ahí, cada cierto número de días el modelo se reentrena con

toda la información disponible hasta esa fecha y predice el bloque siguiente, estrictamente futuro respecto al entrenamiento. Como la ventana se expande y nunca retrocede, ninguna predicción usa datos posteriores al día en que se emite: el protocolo es causal por construcción y *desplegable*: reproduce lo que se haría en producción, reentrenando de forma periódica y operando hacia delante. Los valores concretos del burn-in y de la frecuencia de reentrenamiento se fijan en el capítulo de resultados.

3.8.3. Purga y embargo

Aun separando entrenamiento y prueba en el tiempo, puede aparecer una fuga sutil en la *frontera* entre ambos, y dos mecanismos la corrigen [29]. La *purga* elimina del entrenamiento las muestras cuyo intervalo de etiqueta se solapa con el de prueba; con etiquetas de horizonte un día basta con purgar la última observación de entrenamiento, cuya etiqueta toca el primer día de prueba. El *embargo* es un margen adicional que se descarta tras la frontera para neutralizar la autocorrelación serial, capaz de filtrar información aun sin solapamiento de etiquetas.

El tamaño del embargo no lo fija el horizonte de la etiqueta, sino el esquema de validación. En el walk-forward *rolling-origin* el entrenamiento queda íntegramente antes de la prueba, de modo que la purga cubre el único solapamiento posible y el embargo se reduce a un margen mínimo de un día. La validación combinatoria con purga (CPCV, más abajo) coloca en cambio bloques de entrenamiento a *ambos* lados de cada bloque de prueba, así que cada fold tiene dos fronteras que proteger; López de Prado dimensiona ahí el embargo como una fracción del tamaño de muestra, para absorber la autocorrelación residual, lo que lleva a valores mayores (≥ 5 días en este trabajo) [29]. La diferencia entre un embargo y otro es estructural, no un ajuste para mejorar una cifra.

3.8.4. Por qué no validación cruzada convencional, y el papel de CPCV

La validación cruzada por particiones (KFold) baraja las muestras en bloques al azar, entrena en unos y evalúa en otros. Sobre datos independientes es impecable, pero sobre una serie temporal es inadmisibile: al barajar, coloca en el entrenamiento muestras posteriores a las de prueba, y el modelo aprende del futuro respecto al periodo en el que se le evalúa. La memoria proscribiera el KFold convencional en series temporales.

Una alternativa más sofisticada es la *validación cruzada combinatoria con purga* (CPCV) [29]: divide la serie en bloques contiguos, forma muchas combinaciones de bloques de prueba y aplica purga y embargo en cada frontera. Respeta el orden temporal dentro de cada bloque y produce muchas trayectorias de validación, lo que estabiliza la estimación. Tiene, sin embargo, una propiedad que la descalifica como medida de rendimiento *desplegable*: para predecir un bloque, CPCV puede entrenar con bloques cronológicamente posteriores a él, información que no estaría disponible en operativa real. El resultado que reportamos como desplegable es el del walk-forward; CPCV se incluye solo como *contraste*, para cuantificar cuánto cambia la estimación cuando se permite ese uso del futuro.

Probar muchas configuraciones de una estrategia, o generar muchas particiones, multiplica las oportunidades de que un buen resultado aparezca por azar: con suficientes intentos, alguno parecerá excelente aunque no haya señal real. Es el problema de *selección* o *multiplicidad*, y

motiva el Deflated Sharpe Ratio de la Sección 3.9 [32], que descuenta del Sharpe observado el efecto de haber buscado entre muchas alternativas.

3.9. Contraste de hipótesis

Toda cifra que la memoria reporta como evidencia va acompañada de un contraste estadístico que mide si es compatible con el azar o lo excede de forma significativa. Todos siguen el mismo esquema. Se parte de una hipótesis nula que representa la ausencia del efecto buscado; bajo ella, el estadístico tiene una distribución conocida, y se rechaza la nula solo cuando el valor observado sería demasiado raro si fuera cierta. Lo que sigue desarrolla cada contraste con su hipótesis nula, su estadístico, la distribución bajo la nula y el lugar de la memoria donde se aplica.

3.9.1. Test del signo binomial

La primera pregunta sobre el agente es elemental: ¿acierta la dirección del mercado más de lo que acertaría al azar? Acertar la dirección significa que el signo de la posición coincide con el signo del retorno realizado. Si el agente no tuviera ninguna capacidad, cada acierto sería como lanzar una moneda equilibrada.

Hipótesis nula. La probabilidad de acierto direccional es $p = 0,5$; el agente acierta el signo por azar.

Estadístico y distribución bajo la nula. Sobre n decisiones, se cuenta el número X de aciertos. Bajo H_0 , cada decisión es un ensayo de Bernoulli independiente con probabilidad 0,5, de modo que

$$X \sim \text{Binomial}(n, 0,5).$$

El contraste es exacto: el p -valor se calcula directamente con la distribución binomial, sumando la probabilidad de observar un número de aciertos al menos tan extremo como el observado, sin recurrir a ninguna aproximación normal [33].

Uso en la memoria. Se aplica al acierto direccional del agente sin supervisar (M5) para contrastar si su tasa de acierto difiere significativamente de 0,5. La hipótesis central de la memoria parte precisamente del caso en que el agente acierta menos de la mitad de las veces, que es donde la supervisión de STRATA tiene margen para aportar.

3.9.2. Test de McNemar pareado

Lo informativo es comparar dos estrategias sobre *las mismas* decisiones: importa quién acierta cuando difieren, más que la tasa de acierto absoluta de cada una. Como la regla de referencia M8 y el agente sin supervisar (M5) se enfrentan exactamente a los mismos días y a los mismos retornos, sus aciertos están pareados, y un contraste que ignore ese emparejamiento desperdicia información. El test de McNemar está diseñado para datos pareados de respuesta binaria [34].

Se organiza la comparación en una tabla 2×2 que clasifica cada día según acierte o falle cada estrategia. Las casillas que importan son las *discordancias*: sea b el número de días en

que M8 acierta y M5 falla, y c el número de días en que M5 acierta y M8 falla. Los días en que ambas aciertan o ambas fallan no aportan información sobre cuál es mejor y no entran en el estadístico.

Hipótesis nula. Las discordancias son simétricas, $b = c$: ninguna de las dos estrategias tiene más probabilidad que la otra de acertar cuando difieren. Equivale a que la supervisión no cambia el acierto.

Estadístico y distribución bajo la nula. Con la corrección de continuidad de Edwards [35], el estadístico es

$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c} \sim \chi_1^2,$$

una chi-cuadrado con un grado de libertad cuando H_0 es cierta. La corrección, restar 1 al valor absoluto de la diferencia, ajusta el hecho de que se aproxima una distribución discreta por una continua y evita inflar la significación cuando las discordancias son pocas. Cuando $b + c$ es pequeño, la aproximación chi-cuadrado deja de ser fiable y se usa en su lugar el contraste binomial exacto: bajo H_0 , condicionado al total de discordancias $b + c$, el número b sigue una Binomial($b + c, 0.5$).

Uso en la memoria. Es el contraste pareado central para comparar el acierto direccional de dos estrategias sobre los mismos días. Se usa para comparar el meta-learner M10 con el agente M5, con la regla a mano M8 y con las estrategias triviales.

3.9.3. Test de Diebold-Mariano

El acierto direccional es binario y deja fuera la magnitud del resultado. Para comparar dos estrategias por su rendimiento continuo, el resultado económico día a día, se usa el contraste de Diebold y Mariano, concebido para comparar la exactitud predictiva de dos procedimientos [36]. Se parte de una función de pérdida que mide lo mal que lo hace cada estrategia en cada día (en la memoria, la pérdida ligada al resultado de la posición) y se forma el *diferencial de pérdida* diario d_t , la diferencia entre la pérdida de una estrategia y la de la otra.

Hipótesis nula. Las dos estrategias tienen igual exactitud predictiva, es decir, el diferencial de pérdida tiene media poblacional cero: $\mathbb{E}[d_t] = 0$.

Estadístico y distribución bajo la nula. Sea $\bar{d}$ la media muestral del diferencial. El estadístico es

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}} \sim N(0, 1),$$

asintóticamente normal estándar bajo H_0 . La clave está en el denominador: como los diferenciales diarios están autocorrelados, su varianza no puede estimarse como si fueran independientes, y se usa un estimador de la *varianza de largo plazo* robusto a heterocedasticidad y autocorrelación (HAC) en el sentido de Newey y West [37], que acumula las autocovarianzas relevantes del diferencial. Sin esa corrección, el contraste sobreestimaría la significación.

Uso en la memoria. Compara la exactitud de dos estrategias por su resultado económico diario, teniendo en cuenta la autocorrelación de los diferenciales. Se usa para contrastar el rendimiento del meta-learner M10 frente a los baselines.

3.9.4. Contrastes de equivalencia (TOST)

Que un contraste de diferencia no resulte significativo no permite concluir que las dos estrategias sean iguales: para afirmar equivalencia hace falta un contraste diseñado para ello. Para *afirmar* que dos estrategias son equivalentes hace falta un contraste diseñado a tal fin, no la mera ausencia de significación en un contraste de diferencia. El procedimiento de los dos contrastes unilaterales (TOST, *Two One-Sided Tests*) cumple ese papel [38]. Se fija de antemano una *banda de equivalencia* $[-\delta, \delta]$, el margen dentro del cual dos estrategias se consideran indistinguibles a efectos prácticos.

Hipótesis nula. La de *no equivalencia*: la diferencia verdadera entre las dos estrategias cae fuera de la banda, es decir, $\Delta \leq -\delta$ o bien $\Delta \geq \delta$.

Estadístico y distribución bajo la nula. La nula compuesta se descompone en dos contrastes unilaterales que se resuelven por separado: uno contrasta $\Delta \leq -\delta$ y el otro $\Delta \geq \delta$, cada uno con su estadístico tipo t (o normal en muestras grandes). Se declara la equivalencia solo si *ambos* se rechazan al nivel fijado, lo que sitúa la diferencia dentro de la banda con la confianza deseada. La inversión de los papeles habituales (la equivalencia pasa a ser la hipótesis alternativa) es lo que permite afirmar equivalencia en sentido estadístico, y no solo no poder distinguir.

Uso en la memoria. Permite afirmar de forma positiva que dos estrategias son equivalentes dentro de una banda, y no solo que no se distinguen. Se incluye por completitud del instrumental de contraste; su aplicación concreta se detalla en el capítulo de resultados.

3.9.5. Bootstrap estacionario

Muchas cantidades de interés, como la diferencia de ratios de Sharpe entre dos estrategias, no tienen una distribución muestral de forma cerrada manejable, sobre todo cuando los retornos están autocorrelados. El *bootstrap* estima la distribución de un estadístico remuestreando los propios datos, pero el bootstrap clásico, que remuestrea observaciones individuales de forma independiente, destruye la dependencia serial de una serie temporal y subestima la variabilidad. El *bootstrap estacionario* de Politis y Romano resuelve esto remuestreando *bloques* de observaciones consecutivas en lugar de observaciones sueltas, con longitud de bloque aleatoria de distribución geométrica [39]. Al pegar bloques contiguos se preserva la estructura de dependencia local; al hacer la longitud aleatoria se evita el artefacto de un tamaño de bloque fijo y se garantiza que las series remuestreadas sean estacionarias.

Uso en la memoria. Se emplea para construir intervalos de confianza del diferencial de ratios de Sharpe, ΔSharpe , entre estrategias: se remuestrean muchas trayectorias por bloques, se recalcula el estadístico en cada una y se toma el intervalo a partir de la distribución resultante. La longitud media de bloque se fija en función del tamaño de muestra, del orden de $\sqrt{N}$ con N el número de observaciones, criterio habitual para equilibrar sesgo y varianza.

3.9.6. Deflated Sharpe Ratio

El último contraste cierra el problema de multiplicidad anticipado en la Sección 3.8. Un ratio de Sharpe muestral elevado puede no reflejar habilidad si se ha obtenido tras probar muchas estrategias, o si la muestra es corta, o si los retornos se alejan de la normalidad. El

Deflated Sharpe Ratio (DSR) corrige el Sharpe observado por estos tres factores y lo convierte en una probabilidad: la de que el Sharpe verdadero sea positivo, una vez descontado lo que cabría esperar por azar tras la búsqueda realizada [32].

Hipótesis nula. El Sharpe verdadero de la estrategia es nulo (o no supera el máximo que el azar produciría dado el número de pruebas realizadas); el Sharpe observado es fruto de la selección y del ruido muestral.

Mecánica del ajuste. La corrección parte del hecho de que, al probar N estrategias independientes sin habilidad alguna, el máximo de sus Sharpe muestrales crece con N por puro azar; el DSR descuenta ese máximo esperado. Además incorpora la longitud de la muestra y los momentos de orden superior de los retornos (asimetría y curtosis), porque la distribución del estimador del Sharpe se desvía de la normal cuando los retornos tienen colas pesadas, justo el caso financiero. El resultado es un Sharpe “desinflado” acompañado de un p -valor; un DSR que sigue siendo significativo es evidencia de que el rendimiento sobrevive al escrutinio de la multiplicidad. Harvey, Liu y Zhu [40] documentan que la abundancia de estrategias probadas en finanzas produce hallazgos espurios con alta frecuencia; de ahí que los umbrales de significación deban ser más severos que los habituales en otras disciplinas.

Uso en la memoria. Se aplica al ratio de Sharpe del meta-learner M10 para comprobar si su rendimiento ajustado por riesgo sobrevive a la corrección por multiplicidad, no-normalidad y longitud de muestra, en lugar de reportar el Sharpe muestral en bruto.

Capítulo 4

Marco práctico: el caso de estudio SMCI

Este capítulo responde a la pregunta operativa del trabajo sobre un activo concreto: en un benchmark justo, ¿un meta-learner desplegable que consume las señales de STRATA mejora la dirección del agente y supera a las estrategias triviales? Sobre SMCI la respuesta es sí, aunque solo de forma nominal. M10 gana a todos los baselines y la ventaja resiste a varias particiones; la significancia plena queda como trabajo futuro.

4.1. Datos y caso de estudio

El activo del caso de estudio es **SMCI**, elegido por un criterio metodológico: sus dos clases direccionales están casi equilibradas. El *buy-and-hold* (comprar y mantener, siempre largo) acierta el 48,4 % de los días, así que la comparación con lo trivial es exigente. La regla de no-habilidad, predecir siempre la clase mayoritaria (*ZeroR* [41, 42]), no se lleva por delante a un modelo solo por el desbalance; en SMCI acierta el 51,6 %, materializada como “siempre corto”.

Los tres detectores de STRATA se calibran una sola vez sobre 2000–2024-09 y se congelan (Sección 3.6.1). La evaluación es fuera de muestra: $n = 250$ días posteriores al arranque del walk-forward. Todos caen tras el corte de conocimiento del modelo de lenguaje que mueve al agente, así que esas decisiones no pudieron memorizarse en su entrenamiento. El protocolo causal y desplegable es el de las Secciones 3.8.1 y 3.8.2.

4.2. El agente sin supervisar (M5)

El agente de trading por sí solo, que denotamos M5, es un perdedor direccional sobre SMCI: acierta el 48,4 % de las direcciones, por debajo del azar. Su comportamiento está además muy sesgado, con posición corta el 95 % de los días. De aquí parte el problema: sin supervisar, el agente pierde dinero y no llega al medio acierto. La hipótesis del trabajo es que las señales de STRATA, bien explotadas, recuperan parte de esa dirección perdida.

4.3. La regla a mano (M8) como referencia

La regla determinista M8 aplica la intervención de STRATA descrita en la Sección 3.6.5: cuando el RAM score supera el gate $\tau = 0,50$, sustituye la dirección del agente por la que marca el régimen. Sobre SMCI, M8 acierta el 49,6 %, apenas por encima de M5. La razón es mecánica: el agente ya va casi siempre corto, y el régimen de SMCI también sesga a corto, de modo que la dirección del agente y la del régimen coinciden la mayor parte del tiempo y STRATA solo encuentra incoherencia que corregir en torno al 3 % de los días. M8 cumple aquí el papel de *referencia interpretable*: una regla transparente sobre la que medir cuánto añade un modelo que aprende.

4.4. El meta-learner M10

M10, el modelo central del caso de estudio, es un clasificador binario XGBoost [43]: cada día estima la probabilidad de que el retorno del día siguiente sea positivo. Lo hace a partir de **veintidós variables**: las quince de la decisión del agente (cinco personalidades, cada una con signo, tamaño y confianza) y las siete señales de STRATA y de régimen (los tres scores RAM, PSA y GSO, las tres probabilidades de régimen y la volatilidad condicional del GARCH). La posición del día es el signo de la probabilidad estimada menos 0,5.

El modelo sigue el protocolo walk-forward de la Sección 3.8.2: arranque de 150 días, reentrenamiento cada 21 con toda la historia, y embargo de un día. Para reducir la varianza del azar interno se promedia un *ensemble* de diez modelos que solo difieren en la semilla. Es *bagging* [44, 45]: el promedio cancela ruido sin crear señal, y no introduce optimismo. M10 no usa la validación cruzada combinatoria, que mira el futuro y queda como contraste (Sección 3.8.4). Tampoco lleva variables de momento ni abstención, descartadas porque no mejoran la accuracy fuera de muestra.

4.5. Resultado principal

La Tabla 4.1 resume el resultado sobre todo el periodo de evaluación. **M10 acierta el 55,2 % de las direcciones, por encima del agente (48,4 %), de la regla a mano (49,6 %), de comprar-y-mantener (48,4 %) y de la clase mayoritaria (51,6 %).** Es el único que los supera a todos a la vez, incluida la clase mayoritaria, que en SMCI equivale a “siempre corto”. En el plano económico, ilustrativo y no probatorio, M10 multiplica el capital por 3,24 frente al 0,71 de comprar-y-mantener, con un ratio de Sharpe de +1,84. Ese Sharpe es positivo con probabilidad 0,976; penalizado por las configuraciones exploradas a lo largo del estudio, el Deflated Sharpe Ratio baja a 0,72, por debajo del umbral de habilidad. La habilidad económica no queda probada: el rendimiento se reporta como ilustración y la prueba del trabajo descansa en la accuracy.

El 0,552 hay que acompañarlo de su contraste. La ventaja de M10 es **nominal, no significativa** al tamaño de muestra disponible: el binomial frente a la clase mayoritaria, que es el baseline de no-habilidad correcto, da $p = 0,14$; la permutación por bloques frente a comprar-y-mantener da $p = 0,047$, que no sobrevive a la corrección por multiplicidad; el

Tabla 4.1: Resultado sobre SMCi (OOS, $n = 250$ días, walk-forward, embargo= 1). Fuente: `m10_smci_valtest_robustez.json` / `RESULTADOS_OBJETIVO.md` §1bis.

Estrategia	Accuracy	Sharpe	Equity
M10-WF ensemble (modelo)	0,552	+1,84	3,24×
Trivial: clase mayoritaria (= siempre corto)	0,516	—	—
M8 (regla a mano STRATA)	0,496	+0,33	1,02×
M5 (agente solo)	0,484	−0,24	0,98×
Trivial: comprar y mantener (siempre largo)	0,484	+0,03	0,71×

McNemar pareado frente al agente da $p = 0,16$. Con un horizonte de unos 250 días, acotado porque el agente solo existe tras el corte del modelo de lenguaje, ningún sistema de decisión diaria alcanza significancia plena frente a un benchmark justo: es una consecuencia del tamaño de muestra y de la eficiencia de los mercados a horizonte diario. El criterio del trabajo es el que la literatura admite en este régimen de muestra: superar a lo trivial de forma nominal y *consistente*, dejando la significancia plena como trabajo futuro con un periodo más largo.

4.6. Robustez

La ventaja de M10 no depende del corte concreto de los datos. La Tabla 4.2 la evalúa sobre tres particiones cronológicas estándar, 60/40, 70/30 y 80/20: en las tres, y tanto en validación como en test, M10 supera al agente, a la regla y a comprar-y-mantener. Que gane en los tres cortes hace improbable que el resultado sea un artefacto de una partición afortunada.

Tabla 4.2: Robustez a la partición: accuracy de M10 frente a los baselines en validación y test de tres cortes cronológicos. M10 gana a todos en los tres. Fuente: `m10_smci_valtest_robustez.json`.

Partición (val / test)	Accuracy M10 (val)	Accuracy M10 (test)	n_{test}
60 / 40	0,520	0,600	100
70 / 30	0,526	0,613	75
80 / 20	0,535	0,620	50

La robustez se confirma en el tiempo. Sobre ventanas rodantes a lo largo del periodo de evaluación, M10 supera a comprar-y-mantener en el 71–82 % de las ventanas y al agente en el 67–76 %, según el tamaño de ventana. La ventaja se sostiene a lo largo del periodo, no en un único tramo. El protocolo es igual de estable: la accuracy apenas se mueve al variar la frecuencia de reentrenamiento, y el embargo se fija en uno por el horizonte de la etiqueta (Sección 3.8.3), no para maximizar una cifra.

4.7. Interpretabilidad: M10 es inseparable de STRATA

La ventaja de M10 proviene de las señales de STRATA, no de un conjunto cualquiera de variables. Lo confirman dos análisis. El primero es una ablación: un M10 entrenado solo con las quince variables del agente, sin las siete señales de STRATA, cae al 46,8 %, en torno al del agente (que acierta el 48,4 %); añadir las siete señales lo lleva al 55,2 %, una mejora pareada con $p = 0,05$ en el test de McNemar. El segundo es la importancia por valores de Shapley

(SHAP) [46] sobre el ensemble: las siete señales de STRATA y de régimen concentran el 41,4% de la importancia total, por delante de las variables del agente. Sin esas señales el modelo retrocede al nivel del agente; con ellas recupera la dirección. Por construcción, el meta-learner es inseparable de STRATA: es lo que da sentido al nombre del sistema.

4.8. Lectura honesta y límites

En SMCI los tres modelos, M5, M8 y M10, apuestan en la misma dirección la mayor parte del tiempo, porque el agente ya está alineado con un régimen que también sesga a corto. La supervisión de STRATA rescata de forma marcada al agente solo cuando este va a contracorriente de un régimen que acierta, una condición que SMCI cumple poco y que delimita el alcance del método. Con todo, su acierto no se reduce a apostar siempre a la baja: sobre el periodo completo M10 va corto en torno al 47% de los días, y aun así gana a la estrategia constante “siempre corto”.

La limitación principal es el tamaño y la naturaleza de la muestra. El agente solo existe sobre el periodo posterior al corte del modelo de lenguaje, lo que acota la evaluación a unos 250 días y vuelve inalcanzable la significancia plena frente a un benchmark justo. Las dos extensiones inmediatas, la generalización a otros agentes y a otros activos, son costosas en inferencia y en tiempo por las razones que cuantifico en el Capítulo 5, y quedan como trabajo futuro. Sí queda algo firme: sobre este activo el protocolo funciona y es desplegable. En un benchmark honesto recupera la dirección del agente y supera a la regla a mano y a lo trivial.

Capítulo 5

Conclusiones

Bibliografía

- [1] Hongyang Yang, Xiao-Yang Liu y Christina Dan Wang. “FinGPT: Open-Source Financial Large Language Models”. En: *arXiv preprint arXiv:2306.06031* (2023). FinLLM Workshop @ IJCAI 2023. DOI: 10.48550/arXiv.2306.06031.
- [2] Yijia Xiao et al. “TradingAgents: Multi-Agents LLM Financial Trading Framework”. En: *arXiv preprint arXiv:2412.20138* (2024). DOI: 10.48550/arXiv.2412.20138.
- [3] Changlun Li et al. “Will LLMs be Professional at Fund Investment? DeepFund: A Live Arena Perspective”. En: *arXiv preprint arXiv:2503.18313* (2025). NeurIPS 2025 (poster). DOI: 10.48550/arXiv.2503.18313.
- [4] Mostapha Benhenda. “Look-Ahead-Bench: a Standardized Benchmark of Look-ahead Bias in Point-in-Time LLMs for Finance”. En: *arXiv preprint arXiv:2601.13770* (2026). DOI: 10.48550/arXiv.2601.13770.
- [5] Varun Chandola, Arindam Banerjee y Vipin Kumar. “Anomaly detection: A survey”. En: *ACM Computing Surveys* 41.3 (2009), págs. 1-58. DOI: 10.1145/1541880.1541882.
- [6] James D. Hamilton. “A new approach to the economic analysis of nonstationary time series and the business cycle”. En: *Econometrica* 57.2 (1989), págs. 357-384.
- [7] Andrew Ang y Geert Bekaert. “International asset allocation with regime shifts”. En: *The Review of Financial Studies* 15.4 (2002), págs. 1137-1187. DOI: 10.1093/rfs/15.4.1137.
- [8] Massimo Guidolin y Allan Timmermann. “Asset allocation under multivariate regime switching”. En: *Journal of Economic Dynamics and Control* 31.11 (2007), págs. 3503-3544.
- [9] Alan Moreira y Tyler Muir. “Volatility-managed portfolios”. En: *The Journal of Finance* 72.4 (2017), págs. 1611-1644.
- [10] Fischer Black. “Studies of stock price volatility changes”. En: *Proceedings of the 1976 Meetings of the American Statistical Association, Business and Economic Statistics Section*. 1976, págs. 177-181.
- [11] Andrew A. Christie. “The stochastic behavior of common stock variances: Value, leverage and interest rate effects”. En: *Journal of Financial Economics* 10.4 (1982), págs. 407-432.
- [12] Rama Cont. “Empirical properties of asset returns: stylized facts and statistical issues”. En: *Quantitative Finance* 1.2 (2001), págs. 223-236. DOI: 10.1080/713665670.
- [13] Lawrence R. Rabiner. “A tutorial on hidden Markov models and selected applications in speech recognition”. En: *Proceedings of the IEEE* 77.2 (1989), págs. 257-286.

- [14] Olivier Cappé, Eric Moulines y Tobias Rydén. *Inference in Hidden Markov Models*. Springer Series in Statistics. New York: Springer, 2005. ISBN: 9780387402642. DOI: 10.1007/0-387-28982-8.
- [15] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006. ISBN: 9780387310732.
- [16] Leonard E. Baum et al. “A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains”. En: *The Annals of Mathematical Statistics* 41.1 (1970), págs. 164-171.
- [17] Andrew J. Viterbi. “Error bounds for convolutional codes and an asymptotically optimum decoding algorithm”. En: *IEEE Transactions on Information Theory* 13.2 (1967), págs. 260-269.
- [18] Robert F. Engle. “Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation”. En: *Econometrica* 50.4 (1982), págs. 987-1007.
- [19] Tim Bollerslev. “Generalized autoregressive conditional heteroskedasticity”. En: *Journal of Econometrics* 31.3 (1986), págs. 307-327.
- [20] Tim Bollerslev. “A conditionally heteroskedastic time series model for speculative prices and rates of return”. En: *The Review of Economics and Statistics* 69.3 (1987), págs. 542-547.
- [21] Ryan P. Adams y David J. C. MacKay. “Bayesian online changepoint detection”. En: *arXiv preprint arXiv:0710.3742* (2007).
- [22] Paul Fearnhead. “Exact and efficient Bayesian inference for multiple changepoint problems”. En: *Statistics and Computing* 16.2 (2006), págs. 203-213.
- [23] Jushan Bai y Pierre Perron. “Estimating and testing linear models with multiple structural changes”. En: *Econometrica* 66.1 (1998), págs. 47-78. DOI: 10.2307/2998540.
- [24] Jushan Bai y Pierre Perron. “Computation and analysis of multiple structural change models”. En: *Journal of Applied Econometrics* 18.1 (2003), págs. 1-22. DOI: 10.1002/jae.659.
- [25] William F. Sharpe. “The Sharpe ratio”. En: *The Journal of Portfolio Management* 21.1 (1994), págs. 49-58.
- [26] Frank A. Sortino y Lee N. Price. “Performance measurement in a downside risk framework”. En: *The Journal of Investing* 3.3 (1994), págs. 59-64. DOI: 10.3905/joi.3.3.59.
- [27] Frank A. Sortino y Robert van der Meer. “Downside risk”. En: *The Journal of Portfolio Management* 17.4 (1991), págs. 27-31. DOI: 10.3905/jpm.1991.409343.
- [28] Terry W. Young. *Calmar ratio: A smoother tool*. *Futures*, vol. 20, no. 12, p. 40. Revista profesional sin revisión por pares; sin DOI. 1991.
- [29] Marcos López de Prado. *Advances in Financial Machine Learning*. Hoboken, NJ: Wiley, 2018.

- [30] Leonard J. Tashman. “Out-of-sample tests of forecasting accuracy: an analysis and review”. En: *International Journal of Forecasting* 16.4 (2000), págs. 437-450. DOI: 10.1016/S0169-2070(00)00065-0.
- [31] Christoph Bergmeir, Rob J. Hyndman y Bonsoo Koo. “A note on the validity of cross-validation for evaluating autoregressive time series prediction”. En: *Computational Statistics & Data Analysis* 120 (2018), págs. 70-83. DOI: 10.1016/j.csda.2017.11.003.
- [32] David H. Bailey y Marcos López de Prado. “The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality”. En: *The Journal of Portfolio Management* 40.5 (2014), págs. 94-107.
- [33] William J. Conover. *Practical Nonparametric Statistics*. 3.^a ed. New York: Wiley, 1999.
- [34] Quinn McNemar. “Note on the sampling error of the difference between correlated proportions or percentages”. En: *Psychometrika* 12.2 (1947), págs. 153-157.
- [35] Allen L. Edwards. “Note on the “correction for continuity” in testing the significance of the difference between correlated proportions”. En: *Psychometrika* 13.3 (1948), págs. 185-187.
- [36] Francis X. Diebold y Roberto S. Mariano. “Comparing predictive accuracy”. En: *Journal of Business & Economic Statistics* 13.3 (1995), págs. 253-263.
- [37] Whitney K. Newey y Kenneth D. West. “A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix”. En: *Econometrica* 55.3 (1987), págs. 703-708. DOI: 10.2307/1913610.
- [38] Donald J. Schuirmann. “A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability”. En: *Journal of Pharmacokinetics and Biopharmaceutics* 15.6 (1987), págs. 657-680.
- [39] Dimitris N. Politis y Joseph P. Romano. “The stationary bootstrap”. En: *Journal of the American Statistical Association* 89.428 (1994), págs. 1303-1313.
- [40] Campbell R. Harvey, Yan Liu y Heqing Zhu. “... and the cross-section of expected returns”. En: *The Review of Financial Studies* 29.1 (2016), págs. 5-68.
- [41] Ian H. Witten et al. *Data Mining: Practical Machine Learning Tools and Techniques*. 4.^a ed. Burlington, MA: Morgan Kaufmann, 2016. ISBN: 9780128042915.
- [42] Max Kuhn. “Building Predictive Models in R Using the caret Package”. En: *Journal of Statistical Software* 28.5 (2008), págs. 1-26. DOI: 10.18637/jss.v028.i05.
- [43] Tianqi Chen y Carlos Guestrin. “XGBoost: A scalable tree boosting system”. En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, págs. 785-794. DOI: 10.1145/2939672.2939785.
- [44] Leo Breiman. “Bagging predictors”. En: *Machine Learning* 24.2 (1996), págs. 123-140. DOI: 10.1007/BF00058655.
- [45] Thomas G. Dietterich. “Ensemble methods in machine learning”. En: *Multiple Classifier Systems (MCS 2000)*. Vol. 1857. Lecture Notes in Computer Science. Berlin, Heidelberg: Springer, 2000, págs. 1-15. DOI: 10.1007/3-540-45014-9_1.

- [46] Scott M. Lundberg y Su-In Lee. “A unified approach to interpreting model predictions”. En: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. Curran Associates, Inc., 2017, págs. 4766-4777. URL: <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.