

UNIVERSIDAD COMPLUTENSE DE MADRID
FACULTAD DE CIENCIAS MATEMÁTICAS



UNIVERSIDAD COMPLUTENSE
MADRID

TRABAJO DE FIN DE GRADO

STRATA: supervisión estadística en tiempo real
de un agente de trading basado en LLMs

Tutor: Daniel Vélez Serrano

Raquel García Hernández

Doble Grado en Matemáticas y Ciencia de Datos

Curso académico 2025-2026

Resumen

This work designs STRATA, a statistical runtime-supervision layer for an LLM trading agent as a solution for the increasing confidence on indeterministic methods as the truth. The agent, a replica of AI Hedge Fund with five investor personalities, decides a direction and a size for each asset and day, and out of sample it loses money: on SPY it predicts the sign of the next return on 0,366 of the days, below a coin toss, and an initial €1000 ends at €700. STRATA audits each decision in runtime with three orthogonal classical detectors (a hidden Markov regime model, a Bayesian change-point detector and a GARCH volatility band) and rectifies it when it contradicts an explicit market model. We test, with paired statistics, whether this supervision rescues the agent in directional accuracy and in risk, we attribute the effect to each detector, and we check whether a meta-learner rediscovers STRATA’s signals rather than discarding them. The rescue is statistically significant and its mechanics are interpretable. STRATA does not significantly beat a passive position, which is left as future work.

Keywords: runtime supervision, LLM trading agent, hidden Markov model, GARCH, change-point detection, meta-labeling.

Índice general

1. Introducción	3
1.1. Motivación: un agente que pierde	3
1.2. La idea: supervisión estadística externa	4
1.3. Objetivos y plan de trabajo	4
2. Estado del arte	6
2.1. Agentes LLM en finanzas	6
2.2. Supervisión en tiempo de ejecución	7
2.3. Régimen de mercado y riesgo	7
3. Cómo funciona STRATA	8
3.1. Tres detectores: RAM, PSA, GSO	8
3.1.1. Preliminares y notación	8
3.1.2. La salida del agente	9
3.1.3. STRATA a nivel técnico	10
3.1.4. Modelos de cambio de régimen: HMM gaussiano	11
3.1.5. Volatilidad condicional: ARCH y GARCH(1,1)-t	15
3.1.6. Detección bayesiana de puntos de cambio (BOCPD)	19
3.1.7. STRATA aplicado: construcción, calibración y umbrales	21
3.2. De la alerta a la acción: M8, M10, AutoML	24
3.2.1. El problema de aprendizaje supervisado	24
3.2.2. Árboles de decisión	25
3.2.3. Gradient boosting	25
3.2.4. XGBoost y el meta-learner M10	26
3.2.5. Apilamiento y super learner	27
3.2.6. Búsqueda automatizada: H2O AutoML	27
3.2.7. Catálogo de estrategias	28
3.3. Cómo se mide el rescate	28
3.3.1. Métricas de evaluación	28
3.3.2. Validación	30
3.3.3. Contraste de hipótesis	32

4. STRATA sobre SPY, paso a paso	36
4.1. Anatomía de una intervención	36
4.2. Seis estrategias frente al agente	39
4.3. Qué rescata STRATA	41
5. ¿Se generaliza? El panel de diez activos	43
5.1. Rescate agregado: pooled, equivalencia, complementariedad	43
5.1.1. La compuerta de régimen y la activación de detectores	43
5.1.2. Accuracy por activo: dónde se bate a la trivial	45
5.1.3. Pooled-10: el rescate en riesgo	45
5.1.4. Equivalencia: el aprendiz redescubre STRATA y bate a la regla	47
5.1.5. Complementariedad: bull, bear y diferencia en diferencias	48
5.2. El patrón: ley del leverage y clustering	51
5.2.1. La ley del <i>leverage</i>	51
5.2.2. Clustering: la naturaleza dibuja los grupos	51
5.3. Qué no sobrevive a un test	55
6. Conclusiones	56
6.1. Veredicto en tres niveles	56
6.2. La ley del leverage	57
6.3. Aportaciones	57
6.4. Limitaciones	57
6.5. Líneas futuras	58
6.6. Cierre	58
Bibliografía	59
A. Demostraciones	65
A.1. Recursión forward del HMM	65
A.2. Filtrado y causalidad del HMM	66
A.3. Fórmulas de actualización del paso M de Baum-Welch	66
A.4. Recursión de Viterbi	67
A.5. Monotonía del algoritmo EM	67
A.6. Estacionariedad y varianza incondicional del GARCH(1,1)	67
A.7. Verosimilitud condicional del GARCH(1,1)- t	69
A.8. Recursión de Adams–MacKay del BOCPD	69
A.9. Pseudo-residuos del boosting logístico	70
A.10. Pesos óptimos y ganancia de una división en XGBoost	70

Capítulo 1

Introducción

1.1. Motivación: un agente que pierde

Los agentes basados en grandes modelos de lenguaje ya toman decisiones de inversión. Con ese despliegue ha crecido una demanda concreta: supervisión continua y trazable de lo que el agente decide [1]. El sector la resuelve mediante supervisión humana constante. Pero la creciente libertad que estamos otorgando a la inteligencia artificial está haciendo que tome decisiones imperceptibles para un humano y es por eso que cada vez es mayor la preocupación por desarrollar guardrails, supervisión automática, que impida a los agentes hacer lo que quieran.

El problema es que todo lo que viviendo ha pasado de ser un supuesto de ciencia ficción a una realidad en muy poco tiempo, la inteligencia artificial ya ha marcado un antes y un después y no son pocas las personas que ya ponen su dinero en inversiones donde estos agentes están detrás y no dejan de ser sistemas no deterministas: ante la misma pregunta puede responder cosas distintas, y acierta o se equivoca sin avisar de cuándo. Esa naturaleza choca con la del dinero, donde un mínimo fallo puede conllevar una gran pérdida.

Esto sugiere que la necesidad de una herramienta más estricta en el sector financiero es real. Los agentes LLM ejecutan instrucciones con fidelidad antes que maximizar beneficio [2]; su confianza declarada está mal calibrada y son manipulables. Esta motivación ha sido la que me ha hecho encontrar un hueco entre la supervisión que se reclama y la herramienta falsable que la haría real.

El agente que estudiamos es una réplica de AI Hedge Fund: cinco personalidades inversoras sobre un mismo modelo de lenguaje que deciden, para cada activo y cada día, una dirección y un tamaño. Sin supervisión pierde dinero. Sobre SPY acierta la dirección el 0,366 de los días, por debajo de lo que daría una moneda, y una inversión inicial de €1000 termina en €700. El fenómeno no es propio de SPY: el agente acierta por debajo del medio punto en siete de los diez activos del panel que estudiamos.

La pérdida tiene estructura. El agente mantiene una posición casi rígida que apenas atiende a la señal del día. Un fallo sistemático se puede corregir desde fuera, y ese es el problema que vamos a atacar.

1.2. La idea: supervisión estadística externa

STRATA es la solución, un sistema diseñado para este problema: un supervisor estadístico exógeno y falsable diseñado para auditar cada decisión en tiempo de ejecución y rectificarla cuando contradice el comportamiento del mercado. Lo sostienen tres detectores ortogonales, cada uno sobre un modelo estadístico clásico que el capítulo 3 formaliza: RAM mira la coherencia de la apuesta con el régimen de mercado, PSA la coherencia temporal de las decisiones del agente y GSO la compatibilidad del tamaño con la volatilidad. Cuando uno se dispara, STRATA actúa sobre la decisión: la registra, atenúa su tamaño o la sustituye. La corrección se contrasta de forma pareada contra el mismo agente sin supervisar, decisión a decisión.

La idea de una etapa secundaria que vigila a un modelo primario no es nueva: el *meta-labeling* de López de Prado [3] añade un segundo modelo que decide si actuar sobre la señal del primero. STRATA recoge esa lógica y la lleva más lejos. Aquí el primario es el agente LLM, y el supervisor son tres detectores estadísticos clásicos que juzgan su decisión desde ejes independientes y la registran, atenúan o sustituyen. La intervención es exógena: depende de lo que los detectores leen del mercado, no de lo que el agente declare. Eso la separa del equipo de riesgo de TradingAgents [4], un agente deliberativo interno que comparte la información y los sesgos del sistema.

La hipótesis que ponemos a prueba es falsable: ¿filtrar o atenuar las decisiones del agente con detectores estadísticos clásicos lo rescata de forma significativa? La falsamos en varios niveles: las diferencias entre las decisiones del agente supervisado y el agente solo, la atribución de cada detector en el dinero perdido y ganado después de invertir un capital inicial, y el papel de las señales que genera STRATA dentro de un meta-learner.

1.3. Objetivos y plan de trabajo

El trabajo persigue un objetivo primario:

Además de cuatro objetivos secundarios:

1. Formalizar tres detectores estadísticos clásicos que auditen en tiempo de ejecución las decisiones de un agente LLM de trading.
2. Probar, con contrastes pareados, si esa supervisión rescata al agente cuando pierde, tanto en acierto direccional como en riesgo.
3. Atribuir el efecto a cada detector y caracterizar en qué activos funciona y por qué.
4. Comprobar si un meta-learner libre redescubre las señales de STRATA en lugar de prescindir de ellas.

Tratamos de cubrir los objetivos en el siguiente orden. El capítulo 2 sitúa el trabajo entre los agentes LLM de trading, la supervisión en tiempo de ejecución y los modelos de régimen y volatilidad. El capítulo 3 formaliza los tres detectores, las estrategias que derivan de ellos y el protocolo de medición fuera de muestra. El capítulo 4 lleva STRATA al caso de SPY, paso a

paso. El capítulo 5 prueba el rescate sobre el panel de diez activos y busca el patrón que lo ordena. Cierran las conclusiones y las líneas futuras (capítulo 6). El recorrido empieza por el estado del arte.

Capítulo 2

Estado del arte

Nuestro problema a tratar aparece en el cruce de las siguientes secciones.

2.1. Agentes LLM en finanzas

Un LLM es una red que predice la siguiente palabra a partir del contexto, mediante un mecanismo de atención [5]. Por sí solo solo escribe: se vuelve un *agente* cuando lo envolvemos en un bucle que razona, llama a herramientas y actúa sobre un entorno [6, 7]. De ahí salieron sistemas que deciden inversiones en lugar de redactar [8]. El foco se desplazó pronto de si un modelo entiende los mercados a cómo coordinar varios, y hoy domina la arquitectura multiagente: varias personalidades inversoras deliberan y un gestor modera la posición final [4, 9]. El control de riesgo que incorporan vive dentro del propio sistema y comparte sus sesgos: el equipo de riesgo de TradingAgents razona en lenguaje natural [4] y AlphaAgents ajusta la cartera a la tolerancia del inversor [9], pero ninguno audita con un modelo estadístico externo si cada decisión es coherente con el mercado observado.

Los agentes LLM ejecutan las instrucciones con fidelidad antes que maximizar beneficio, aun cuando eso les hace perder [2], y su confianza declarada está peor calibrada que la de un humano: se muestran sobreconfiados justo cuando fallan [10, 11]. Cambian de estilo inversor sin que el cambio responda a su propio criterio [12] y resultan manipulables ante datos diseñados para engañarlos [13]. Un agente rígido cuya certeza no es fiable pide un supervisor exógeno. Y la evaluación es frágil: muchos resultados optimistas no aguantan una validación temporal honesta [14], y el *look-ahead* infla las métricas cuando el periodo de prueba cae dentro del preentrenamiento [15]; por eso nuestra ventana fuera de muestra empieza tras el corte de entrenamiento del modelo.

El agente que estudiamos es una réplica de AI Hedge Fund [16], un sistema de cinco personalidades que emulan a inversores reconocidos (Buffett, Wood, Druckenmiller, Burry y Ackman) sobre un mismo modelo de lenguaje. Para cada activo y día cada personalidad emite una señal direccional con un grado de confianza; un agente de riesgo fija el límite de posición según la volatilidad, y un gestor integra las cinco señales y ese límite en una sola decisión, dirección y tamaño, por criterio propio y no por voto. Esa decisión diaria es lo que STRATA supervisa. A ese agente sin supervisar lo llamamos M5: el que pierde dirección y dinero (Sección 1.1) y el punto de partida que el resto de la memoria intenta rescatar.

2.2. Supervisión en tiempo de ejecución

La industria ya pide vigilar a estos agentes mientras operan. El discurso profesional lo resume en una consigna, *guardrails, but no handcuffs*: barreras que acoten al agente sin maniatarlo, con monitorización continua, trazas de auditoría y salidas que escalen a un humano [1]. Entre los controles aparece, casi de pasada, la *validación estadística*: que las salidas se alineen con normas estadísticas realistas [1]. La demanda queda en eslogan, sin decir qué norma, qué contraste ni cómo se mide que la corrección funcione. STRATA lo convierte en detectores falsables con contraste pareado.

Vigilar mientras se decide enlaza con la detección de anomalías [17] y con el control en tiempo de ejecución (*runtime enforcement*), que intercepta cada acción y bloquea la que incumple una condición [18, 19]. Una regla declarativa codifica qué está prohibido; nosotros modelamos cómo de coherente es una posición con el estado del mercado, con tres detectores estadísticos clásicos e interpretables: RAM mira la coherencia con el régimen (modelo de Markov oculto), PSA la coherencia temporal del agente (puntos de cambio bayesianos) y GSO la compatibilidad del tamaño con la volatilidad (GARCH). Los tres descansan en cómo se describe hoy el régimen de mercado y su riesgo.

2.3. Régimen de mercado y riesgo

La idea de fondo de RAM viene de Hamilton: una serie financiera no responde a un único mecanismo, sino que atraviesa estados latentes con propiedades estadísticas distintas y cambia de estado sin que lo veamos, de modo que la distribución de cada retorno depende del estado vigente [20]. Condicionar la cartera al régimen mejora las decisiones de forma apreciable [21, 22]. Sobre el eje continuo de la volatilidad opera la idea que ancla a GSO: dimensionar la posición para alcanzar una volatilidad objetivo (el *volatility targeting*) mejora las propiedades de la serie de retornos [23]. La literatura usa de dos [21] a cuatro [22] estados; usamos tres (calma, estrés y crisis): la verosimilitud fuera de muestra descarta dos y por encima de tres se pierde lectura. El régimen funciona como proxy direccional solo de forma condicional, y esa condición sostiene y limita la tesis: el *leverage effect* de los índices agregados hace que en activos como SPY los estados de alta volatilidad coincidan con tramos bajistas, de modo que conocer el régimen informa del signo probable del retorno [24, 25]. El régimen no predice el retorno: ordena las decisiones del agente. La coincidencia se diluye en valores con apalancamiento débil, donde el régimen pierde poder direccional, y ahí está el límite de la técnica. Estas tres líneas se han tocado por separado; STRATA las une con detectores estadísticos clásicos y exógenos, que el capítulo siguiente formaliza.

Capítulo 3

Cómo funciona STRATA

El capítulo anterior dejó abierto un hueco: ninguna de las tres líneas que recorre, agentes LLM de trading, supervisión en tiempo de ejecución y modelos clásicos de régimen y volatilidad, las había combinado sobre un mismo agente. STRATA llena ese hueco, y este capítulo reúne la base matemática que lo sostiene y fija la notación del resto de la memoria: los tres detectores y la capa que convierte sus señales en intervención, las estrategias que aprenden sobre esas señales y el protocolo con que medimos el rescate. El caso de SPY, donde el sistema se pone a prueba, queda para el capítulo 4.

3.1. Tres detectores: RAM, PSA, GSO

3.1.1. Preliminares y notación

Trabajamos con una serie de precios diarios de un activo. Denotamos por $P_t > 0$ el precio de cierre del día t , con $t \in \{0, 1, \dots, T\}$. La cantidad relevante no es el precio en sí, sino su variación relativa de un día al siguiente. Definimos el *log-retorno*

$$r_t^{\log} = \log\left(\frac{P_t}{P_{t-1}}\right) = \log P_t - \log P_{t-1}, \quad t \geq 1,$$

El log-retorno mide el crecimiento del precio en escala logarítmica; es positivo cuando el precio sube y negativo cuando baja.

Comparémoslo con el *retorno simple* $R_t = (P_t - P_{t-1})/P_{t-1} = P_t/P_{t-1} - 1$, que es la definición intuitiva, la fracción ganada o perdida. Ambos se relacionan por $r_t^{\log} = \log(1 + R_t)$. La razón de preferir el log-retorno es su aditividad temporal. Consideremos el retorno acumulado entre los días t_0 y $t_0 + n$. En escala logarítmica,

$$\log\left(\frac{P_{t_0+n}}{P_{t_0}}\right) = \log\left(\prod_{j=1}^n \frac{P_{t_0+j}}{P_{t_0+j-1}}\right) = \sum_{j=1}^n \log\left(\frac{P_{t_0+j}}{P_{t_0+j-1}}\right) = \sum_{j=1}^n r_{t_0+j}^{\log}.$$

El log-retorno de varios días es la suma de los log-retornos diarios. El retorno simple, en cambio, se compone de forma multiplicativa, $1 + R_{[t_0, t_0+n]} = \prod_{j=1}^n (1 + R_{t_0+j})$, lo que complica cualquier análisis que sume o promedie a lo largo del tiempo. Esta aditividad es la que justifica modelar $r_t^{\log}$ en lo que sigue: las sumas de variables aleatorias son más tratables que los productos, y

los modelos lineales en el tiempo se expresan de forma natural.

Fijamos también la convención temporal que gobierna toda la validación y todo el back-test. La decisión de cartera tomada con la información disponible hasta el día t no puede recompensarse con el movimiento de ese mismo día, que ya ha ocurrido. Por eso, para evitar el *look-ahead*, el retorno que se contabiliza frente a una posición tomada en t es el del día siguiente,

$$r_{t+1} = \log\left(\frac{P_{t+1}}{P_t}\right).$$

Y así nos aseguramos la ausencia de fuga temporal: de aquí en adelante, todo producto entre una posición y un retorno usará r_{t+1} .

Por último, una medida de cuánto se mueve el activo en un tramo de tiempo. Dada una ventana de h días que termina en t , definimos la *volatilidad realizada*

$$RV_t = \sqrt{\sum_{j=0}^{h-1} (r_{t-j}^{\log})^2},$$

esto es, la raíz de la suma de cuadrados de los log-retornos de la ventana. RV_t es un estimador no paramétrico de la dispersión local de los retornos: crece cuando el activo encadena días de movimientos grandes y se reduce en los tramos planos. A diferencia de la volatilidad condicional σ_t que se introduce en la Sección 3.1.5, RV_t no presupone ningún modelo; es una lectura directa de los datos.

Las series de retornos financieros no se comportan como ruido blanco gaussiano. Tres regularidades empíricas, documentadas de forma sistemática en la literatura [26], motivan los modelos del resto del capítulo. La primera es que la distribución de los retornos tiene *colas pesadas*: los movimientos extremos son mucho más frecuentes de lo que predice una normal, lo que lleva a sustituir la gaussiana por una distribución de colas anchas como la t de Student en el modelo de volatilidad. El *agrupamiento de volatilidad* es la segunda: los días de gran movimiento tienden a seguirse unos a otros, así que la magnitud de los retornos sí está correlada en el tiempo aunque su signo apenas lo esté, y eso es lo que captura un modelo GARCH. Queda la tercera, la *poca autocorrelación* de los retornos en niveles: casi nula a partir del primer rezago, mientras que sus cuadrados o sus valores absolutos sí la presentan. La combinación de las tres sugiere que el comportamiento del activo alterna entre estados o regímenes con dinámicas distintas, idea que el modelo de cambio de régimen formaliza.

3.1.2. La salida del agente

El objeto que STRATA supervisa es la decisión diaria de un agente de trading construido sobre un modelo de lenguaje. Las cinco personalidades y la arquitectura multiagente del fondo se describieron en la Sección 2.1. Para la capa de supervisión, lo que importa es la salida: cada día, y para cada activo, el agente emite una dirección, un tamaño y la confianza con que los emite. La Sección 3.1.3 la formaliza como una posición $w_t \in [-1, +1]$, el objeto sobre el que actúan los detectores. Las señales de las cinco personalidades reaparecen además como variables de entrada del meta-learner de la Sección 3.2.1, junto a las lecturas estadísticas de STRATA.

STRATA trata al agente como una caja negra: supervisa su decisión sin abrir el modelo ni reconstruir su razonamiento. Es la respuesta natural a sus dos rasgos. El modelo es opaco, su salida no tiene forma cerrada y su entrenamiento pudo ver parte del periodo de prueba; frente a eso, una capa externa que contrasta la decisión con un modelo explícito del mercado es más fiable que confiar en la coherencia interna del propio agente. El capítulo 4 documenta que esa decisión, sobre el caso de estudio, acierta la dirección menos de la mitad de los días, con un fallo sistemático y por tanto corregible desde fuera.

3.1.3. STRATA a nivel técnico

Cada día, el agente de trading toma una decisión sobre el activo. Lo resumimos en una terna: un *signo* (comprar o vender), un *tamaño* y una *confianza*. Esa terna determina una *posición* $w_t \in [-1, +1]$, donde el signo marca la dirección (larga si $w_t > 0$, corta si $w_t < 0$) y el módulo $|w_t|$ es la fracción de capital expuesta; la posición tomada en t se evalúa contra el retorno del día siguiente, $w_t \cdot r_{t+1}$. STRATA no decide por el agente: *supervisa* esa decisión. Formalmente, si llamamos $\mathcal{A}$ al espacio de decisiones del agente y $\mathcal{M}_t$ a la información de mercado disponible hasta el día t (resumida en $x_{1:t}$), STRATA es la aplicación

$$\text{STRATA}: \mathcal{A} \times \mathcal{M}_t \longrightarrow [0, 1]^3, \quad (w_t, x_{1:t}) \longmapsto (\text{RAM}_t, \text{PSA}_t, \text{GSO}_t),$$

que a partir de la decisión del agente y de una lectura estadística del mercado produce tres *señales* sobre esa decisión, cada una en $[0, 1]$. STRATA no predice el retorno: mide en qué grado la decisión del agente es coherente con el estado del mercado.

Las señales provienen de tres detectores, cada uno a cargo de un eje distinto. **RAM** se centra en el régimen: comprueba si la dirección de la apuesta encaja con el estado de mercado que el modelo oculto de Markov de la Sección 3.1.4 considera vigente. **PSA** atiende al propio agente; con la detección bayesiana de puntos de cambio vigila si éste cambia de criterio de forma estructural, no por una simple fluctuación. **GSO** se ocupa del tamaño de la apuesta: contrasta el módulo de la posición con la volatilidad que estima el GARCH de la Sección 3.1.5, y salta cuando la apuesta es grande para lo agitado que está el mercado. Esta ortogonalidad de los tres ejes permite que cada detector vea algo que los otros dos no pueden ver.

La intervención puede ir desde solo registrar la señal hasta encoger la posición o sustituirla por completo. Solo analizamos la variante más fuerte, que reorienta el signo de w_t hacia el régimen cuando la incoherencia es alta; los modos intermedios quedan como trabajo futuro. La Sección 3.1.7 detalla cómo se construye cada señal a partir de su detector y cuándo actúa esta intervención.

Hay que distinguir desde el principio entre la capa de señales y las reglas que las consumen. Cuando escribimos STRATA nos referimos siempre a la capa que produce las señales, mientras que cuando hablamos de M8 o M10 estamos haciendo referencia a las estrategias que la utilizan. **M8** es una regla determinista de umbrales fijos, la capa de intervención que se detalla en la Sección 3.1.7, y la usamos como referencia interpretable. **M10**, en cambio, no aplica umbrales fijos sino que es un modelo de segundo nivel (un *meta-learner*) que toma como entradas las salidas del agente y de los detectores de STRATA, aprende a combinar esas mismas señales

para decidir la dirección del día siguiente. Se entrena solo con el pasado y es el objeto central del caso de estudio, que se desarrollará en el capítulo 4.

3.1.4. Modelos de cambio de régimen: HMM gaussiano

RAM quiere saber una cosa muy concreta: si la dirección de la apuesta del agente encaja con el estado en que está el mercado. Para ello necesita primero una lectura del estado, y la lectura nace de la idea de que el mercado no se comporta siempre igual, sino que atraviesa fases distintas, calma, estrés, crisis, que no vemos directamente pero podemos inferir de los retornos. El modelo oculto de Markov gaussiano formaliza esa lectura del estado latente.

Cambio de régimen en series financieras

Un único modelo con parámetros constantes describe mal una serie financiera larga. Un mercado en tendencia alcista tranquila y un mercado en plena caída no comparten ni media ni volatilidad de los retornos, y forzar un solo conjunto de parámetros para ambos promedia dos comportamientos que conviene separar. La alternativa clásica es admitir que la serie atraviesa distintos *regímenes*, cada uno con su propia ley de probabilidad, y que el régimen vigente cambia en el tiempo de forma no observable directamente. Hamilton formalizó esta idea para series económicas mediante un proceso de Markov sobre los estados no observados [20]: el régimen sigue una cadena de Markov y, condicionado a él, la serie observada se distribuye según los parámetros de ese régimen.

En el caso que nos ocupa interpretamos los regímenes como estados de mercado: un régimen de *Calma*, con retornos de media ligeramente positiva y volatilidad baja; un régimen de *Estrés*, intermedio; y un régimen de *Crisis*, con volatilidad alta y retorno medio negativo. Esta lectura puede cambiar según el activo, como se discute en la Sección 3.1.4.

Definición del HMM gaussiano

Un *modelo oculto de Markov* (HMM) consta de una secuencia de estados ocultos y una secuencia de observaciones generadas por esos estados [27, 28]. Sea $z_t \in \{1, \dots, K\}$ el estado oculto (el régimen) en el día t , con K el número de regímenes. La sucesión $\{z_t\}$ es una cadena de Markov homogénea de primer orden: dado el estado en t , el estado en $t + 1$ no depende del pasado anterior,

$$\mathbb{P}(z_{t+1} = j \mid z_t = i, z_{t-1}, \dots, z_1) = \mathbb{P}(z_{t+1} = j \mid z_t = i).$$

Recogemos estas probabilidades en la *matriz de transición* $A \in \mathbb{R}^{K \times K}$, de entradas

$$A_{ij} = \mathbb{P}(z_{t+1} = j \mid z_t = i), \quad A_{ij} \geq 0, \quad \sum_{j=1}^K A_{ij} = 1 \quad \forall i,$$

y la ley del estado inicial en la *distribución inicial* $\pi = (\pi_1, \dots, \pi_K)$ con $\pi_k = \mathbb{P}(z_1 = k)$ y $\sum_k \pi_k = 1$.

El estado no se observa; lo que se observa es x_t , el vector de características del día t (en nuestro caso, el log-retorno y la volatilidad realizada RV_t con ventana de 21 días). Suponemos *emisiones gaussianas*: condicionada al régimen k , la observación es normal multivariante,

$$x_t \mid z_t = k \sim \mathcal{N}(\mu_k, \Sigma_k),$$

con μ_k el vector de medias del régimen k y Σ_k su matriz de covarianzas. Escribimos la densidad de emisión como

$$b_k(x) = \mathcal{N}(x \mid \mu_k, \Sigma_k).$$

El modelo asume dos hipótesis de independencia condicional, palanca de toda derivación posterior. La observación de cada día depende solo del estado de ese día,

$$\mathbb{P}(x_t \mid z_t, z_{t-1}, \dots, z_1, x_{t-1}, \dots, x_1) = \mathbb{P}(x_t \mid z_t) = b_{z_t}(x_t), \quad (*)$$

y la dinámica de los estados es markoviana de primer orden.

El conjunto de parámetros es $\lambda = (A, \pi, \{\mu_k, \Sigma_k\}_{k=1}^K)$. Para una secuencia observada $x_{1:T} = (x_1, \dots, x_T)$ y una trayectoria oculta $z_{1:T}$, la probabilidad conjunta se factoriza según el grafo del modelo:

$$\mathbb{P}(x_{1:T}, z_{1:T} \mid \lambda) = \pi_{z_1} b_{z_1}(x_1) \prod_{t=2}^T A_{z_{t-1}z_t} b_{z_t}(x_t).$$

La verosimilitud de los datos observados se obtiene marginalizando sobre todas las trayectorias ocultas posibles,

$$\mathbb{P}(x_{1:T} \mid \lambda) = \sum_{z_{1:T}} \mathbb{P}(x_{1:T}, z_{1:T} \mid \lambda).$$

Esta suma recorre K^T trayectorias, así que evaluarla término a término es inviable salvo para T minúsculos. El algoritmo *forward* la calcula en tiempo lineal en T .

Algoritmo forward

Definimos la *variable forward*

$$\alpha_t(k) = \mathbb{P}(x_{1:t}, z_t = k \mid \lambda),$$

la masa de probabilidad conjunta que el modelo asigna a la trayectoria de observaciones hasta t y al hecho de estar en el régimen k precisamente en ese instante. La verosimilitud completa se recupera de ella sin más que marginalizar el último estado: $\mathbb{P}(x_{1:T} \mid \lambda) = \sum_k \alpha_T(k)$. El resultado central, clásico en el tratamiento del HMM [27, 29], es que α_t admite una recursión.

Proposición 3.1 (Recursión forward). *Para $t \geq 1$ se tiene la inicialización $\alpha_1(k) = \pi_k b_k(x_1)$ y, para todo $j \in \{1, \dots, K\}$,*

$$\alpha_{t+1}(j) = b_j(x_{t+1}) \sum_{k=1}^K \alpha_t(k) A_{kj}.$$

La inicialización es inmediata por la definición de α_1 y la independencia condicional (*); el paso recursivo se obtiene introduciendo el estado anterior z_t por marginalización y separando la última observación x_{t+1} con la regla del producto. El desarrollo está en el Anexo A.1.

La recursión reduce el coste de K^T a $\mathcal{O}(TK^2)$ operaciones: en cada paso se actualizan K variables y cada una suma sobre K términos. En la práctica los $\alpha_t(k)$ decaen exponencialmente con t y se trabaja con su logaritmo o con una normalización por paso para evitar el desbordamiento numérico, pero la estructura de la recursión es la enunciada.

Posterior filtrado frente a posterior suavizado

La variable forward responde a una probabilidad conjunta, pero lo que interesa para decidir es la probabilidad del régimen *dado* lo observado. Definimos el *posterior filtrado*

$$\gamma_t^f(k) = \mathbb{P}(z_t = k \mid x_{1:t}),$$

la probabilidad de estar en el régimen k en el instante t condicionada únicamente a las observaciones disponibles hasta ese instante. Se obtiene normalizando la variable forward sobre los estados [27, 29].

Proposición 3.2 (Filtrado a partir del forward). *Para todo $t \geq 1$ y todo k ,*

$$\gamma_t^f(k) = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)}.$$

Basta dividir la probabilidad conjunta $\alpha_t(k) = \mathbb{P}(x_{1:t}, z_t = k)$ por la marginal $\mathbb{P}(x_{1:t}) = \sum_j \alpha_t(j)$. El adjetivo *filtrado* es preciso, y su consecuencia es el eje de toda la memoria.

Corolario 3.3 (Causalidad del filtrado). *Para cada t , el posterior filtrado γ_t^f es función únicamente de las observaciones $x_{1:t}$. En particular, puede calcularse en tiempo real el día t sin recurrir a ninguna observación posterior.*

El argumento es inductivo sobre t , apoyado en que la recursión forward construye cada α_t a partir de α_{t-1} y de x_t ; el desarrollo de ambas pruebas está en el Anexo A.2. Esa causalidad es lo que permite usar el filtrado en producción: cada día STRATA estima el régimen con lo que ya conoce.

Esto contrasta con el *posterior suavizado*

$$\mathbb{P}(z_t = k \mid x_{1:T}),$$

que condiciona sobre la secuencia completa hasta el final T , incluyendo $x_{t+1:T}$. El suavizado es una estimación mejor del régimen pasado precisamente porque incorpora lo que ocurrió después: el conocimiento del futuro afina el juicio sobre el presente. Se calcula con el algoritmo forward-backward, que combina la variable forward con una variable backward que recorre la secuencia en sentido inverso [30, 27]. Esa misma virtud lo descalifica para nuestro uso. Emplear el suavizado dentro de un sistema de decisión introduciría *look-ahead*: la decisión del día t quedaría contaminada por información de días posteriores que en operativa real no se

conocen. Por esta razón, **STRATA usa exclusivamente el posterior filtrado** γ_t^f , nunca el suavizado: solo así, por el Corolario 3.3, el sistema es reproducible en tiempo real.

Estimación: el algoritmo de Baum-Welch (EM)

Hasta aquí se ha supuesto conocido el conjunto de parámetros λ . En la práctica λ debe estimarse a partir de los datos, y como los estados $z_{1:T}$ no se observan no puede maximizarse la verosimilitud directamente. El algoritmo de Baum-Welch resuelve esto como una instancia del esquema de esperanza-maximización (EM): alterna una estimación de los estados ocultos con una reestimación de los parámetros, de forma que la verosimilitud observada no decrece en cada iteración [30, 31].

En el *paso E* (esperanza) se calculan, con los parámetros actuales, los posteriores de los estados y de las transiciones, esto es, el posterior suavizado puntual $\mathbb{P}(z_t = k \mid x_{1:T})$ y el de pares $\mathbb{P}(z_t = i, z_{t+1} = j \mid x_{1:T})$, ambos obtenidos con el algoritmo forward-backward. Aquí sí se emplea el suavizado, y es legítimo: el ajuste del modelo se hace una sola vez, fuera de línea, sobre el periodo de calibración completo, no como parte de una decisión en tiempo real. La causalidad solo se exige en la fase de explotación, donde rige el filtrado.

En el *paso M* (maximización) se reestiman los parámetros maximizando la esperanza calculada en el paso E, lo que da fórmulas cerradas: la distribución inicial y la matriz de transición se actualizan como frecuencias esperadas, y las medias y covarianzas de cada régimen como promedios ponderados por el posterior del estado. Las fórmulas de actualización están en el Anexo A.3. Lo que justifica el procedimiento es que ningún paso empeora el ajuste.

Lema 3.4 (Monotonía de EM). *Sea λ' el conjunto de parámetros que produce un paso de EM a partir de λ . Entonces la verosimilitud observada no decrece:*

$$\mathbb{P}(x_{1:T} \mid \lambda') \geq \mathbb{P}(x_{1:T} \mid \lambda).$$

La demostración se encuentra en el Anexo A.

El algoritmo itera los pasos E y M hasta que la verosimilitud se estabiliza. Su convergencia a un punto estacionario de la verosimilitud, bajo condiciones de regularidad, es un resultado clásico de la teoría de EM [31]. El óptimo alcanzado es local y depende de la inicialización, de ahí la importancia de fijar la semilla y de partir de una inicialización razonable.

El algoritmo de Viterbi

El filtrado y el suavizado responden a una pregunta puntual: cuál es la probabilidad del régimen *en un instante dado*. Una pregunta distinta es cuál es la *trayectoria* de estados más probable en su conjunto, esto es, la secuencia $z_{1:T}^*$ que maximiza la probabilidad conjunta a posteriori,

$$z_{1:T}^* = \arg \max_{z_{1:T}} \mathbb{P}(z_{1:T} \mid x_{1:T}, \lambda).$$

Esto es el estimador MAP de la trayectoria completa, y lo resuelve el algoritmo de Viterbi mediante programación dinámica, con una recursión análoga a la del forward que sustituye la suma sobre estados por un máximo [32]; su desarrollo está en el Anexo A.4. La distinción es

importante y no anecdótica: encadenar los modos del filtrado instante a instante, $\arg \max_k \gamma_t^f(k)$ para cada t , no produce en general la misma secuencia que Viterbi, porque la concatenación de óptimos puntuales puede dar una trayectoria que la matriz de transición considera improbable o incluso imposible. Viterbi optimiza la trayectoria como un todo y respeta las transiciones. En esta memoria el detector de régimen se apoya en el filtrado puntual por la exigencia de causalidad de la Sección 3.1.4; Viterbi se usa de forma auxiliar para la lectura interpretativa de la secuencia de regímenes sobre el periodo de calibración, donde la trayectoria global es lo que se quiere visualizar.

Selección del número de estados

Queda fijar K , el número de regímenes. Un valor demasiado pequeño no distingue estados de mercado realmente diferentes; uno demasiado grande sobreajusta y fragmenta la serie en regímenes sin contenido interpretable, además de multiplicar los parámetros a estimar. El criterio que seguimos combina dos exigencias. La primera es estadística: para cada candidato de K se ajusta el HMM sobre el tramo de entrenamiento y se evalúa la *log-verosimilitud held-out*

$$\ell_{\text{val}}(K) = \sum_{t \in \text{val}} \log \mathbb{P}(x_t \mid x_{1:t-1}, \hat{\lambda}_K),$$

con $\hat{\lambda}_K$ el modelo de K estados ajustado en el entrenamiento, sobre un tramo de validación posterior en el tiempo, nunca solapado con el de entrenamiento, de modo que la comparación respeta el orden temporal de la serie y no premia el sobreajuste [27]. La segunda es de interpretabilidad: los regímenes resultantes deben admitir una lectura económica clara y estable. Esta decisión se desarrolla en el capítulo siguiente; podemos anticipar que la combinación de ambos criterios fija $K = 3$ como la calibración de referencia del método, con los tres estados ya descritos: calma, estrés y crisis.

3.1.5. Volatilidad condicional: ARCH y GARCH(1,1)-t

GSO se ocupa del tamaño de la apuesta, y para juzgarlo necesita una medida de cuánto se mueve el mercado ahora mismo. El HMM reparte la volatilidad en unos pocos estados discretos, una lectura útil pero gruesa: dentro de un mismo régimen, la dispersión de los retornos sube y baja de forma continua. El modelo GARCH captura justamente esa volatilidad que cambia día a día, y es el que alimenta a GSO.

Series temporales y heterocedasticidad condicional

Una serie de retornos financieros es una realización de un *proceso estocástico* en tiempo discreto: una sucesión de variables aleatorias $\{r_t^{\log}\}_{t \geq 1}$ indexada por el tiempo. Modelarla es describir su ley conjunta, que la regla de la cadena factoriza en un producto de distribuciones condicionales,

$$\mathbb{P}(r_{1:T}^{\log}) = \prod_{t=1}^T \mathbb{P}(r_t^{\log} \mid \mathcal{F}_{t-1}),$$

donde $\mathcal{F}_{t-1}$ es la *filtración*, la σ -álgebra generada por el pasado hasta $t - 1$. Modelar las distribuciones condicionales es, por tanto, modelar la conjunta, y es lo que da pie a la verosimilitud condicional de la Sección 3.1.5. El objeto central son su media y su varianza condicionales, $\mathbb{E}[r_t^{\log} | \mathcal{F}_{t-1}]$ y $\text{Var}(r_t^{\log} | \mathcal{F}_{t-1})$, frente a sus versiones *incondicionales* $\mathbb{E}[r_t^{\log}]$ y $\text{Var}(r_t^{\log})$, que no dependen del instante t y nos dan información del comportamiento de la serie [33, 34].

El punto de partida más simple es el *ruido blanco*: una sucesión de media cero, varianza constante e incorrelada a todo rezago. No tiene estructura explotable en sus dos primeros momentos, y un modelo de varianza condicional constante homocedástico hereda esa rigidez. Pero incorrelación no es independencia: un proceso puede ser ruido blanco y, aun así, guardar estructura temporal en momentos de orden superior. Es lo que muestran las regularidades empíricas de la Sección 3.1.1: el signo de los retornos es casi impredecible (poca autocorrelación en niveles), mientras que su *magnitud* se agrupa en el tiempo, de modo que la varianza condicional depende del pasado. Esta *heterocedasticidad condicional* es la diferencia entre incorrelación e independencia que los modelos ARCH explotan [26].

Modelaremos el retorno como $r_t^{\log} = \mu + \epsilon_t$, separando la media de la *innovación* $\epsilon_t = \sigma_t \eta_t$, con η_t un ruido i.i.d. y toda la dinámica de interés en la varianza condicional $\text{Var}(\epsilon_t | \mathcal{F}_{t-1}) = \sigma_t^2$. Como en niveles los retornos son prácticamente incorrelados, no imponemos dinámica autorregresiva en la media y la tomamos constante; la riqueza del modelo vive en σ_t^2 . La innovación resultante es una *diferencia de martingala*, $\mathbb{E}[\epsilon_t | \mathcal{F}_{t-1}] = 0$: incorrelada, pero no independiente.

Dos nociones de estacionariedad recorren el capítulo. Un proceso con segundo momento finito es *estacionario en covarianza* (o débilmente estacionario) si su media es constante y su autocovarianza $\text{Cov}(r_t^{\log}, r_{t+h}^{\log})$ depende solo del desfase h y no de t ; es *estrictamente estacionario* si la ley conjunta de cualquier bloque $(r_{t_1}^{\log}, \dots, r_{t_k}^{\log})$ es invariante frente a una traslación común de los índices [35]. Bajo segundo momento finito la estricta implica la débil. La estacionariedad en covarianza es la que caracteriza el Teorema 3.5: modelar la varianza condicional como variable en el tiempo es compatible con que el proceso siga siendo estacionario en covarianza, pues su varianza *incondicional* se mantiene constante siempre que los parámetros cumplan la condición $\alpha + \beta < 1$ de ese teorema, aunque la *condicional* fluctúe día a día.

De ARCH a GARCH

El HMM reparte la volatilidad entre unos pocos estados discretos, cada uno con su covarianza Σ_k constante. Esa descripción es útil para clasificar el mercado en regímenes, pero es gruesa: dentro de un mismo régimen la dispersión de los retornos no es fija, sino que sube y baja de forma continua. El agrupamiento de volatilidad descrito entre las regularidades empíricas de la Sección 3.1.1 pide un modelo en el que la varianza de hoy dependa explícitamente de lo agitado que haya estado el pasado reciente. Ese es el cometido de la familia ARCH/GARCH.

Engle introdujo el modelo *ARCH* (heterocedasticidad condicional autorregresiva) para capturar precisamente este fenómeno [36]. La idea es hacer que la varianza de la innovación $\epsilon_t = r_t^{\log} - \mu$ de la subsección anterior sea función de los errores recientes al cuadrado. En un ARCH de orden q , $\text{ARCH}(q)$, la varianza condicional de la innovación, que denotamos σ_t^2 , se

escribe

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2, \quad \omega > 0, \quad \alpha_i \geq 0,$$

con la convención $\epsilon_t = \sigma_t \eta_t$, donde η_t es un ruido i.i.d. de media 0 y varianza 1 que se especifica más abajo. Denotamos por $\mathcal{F}_t = \sigma(\epsilon_s : s \leq t)$ la filtración generada por las innovaciones hasta t . Que σ_t^2 sea *condicional* significa que es la varianza de ϵ_t dada $\mathcal{F}_{t-1}$: es $\mathcal{F}_{t-1}$ -medible, depende solo del pasado y no del propio ϵ_t . Un error grande en cualquiera de los q días anteriores eleva σ_t^2 , lo que reproduce el agrupamiento: tras un golpe, la volatilidad esperada sube.

La limitación práctica de ARCH es que reproducir la persistencia observada en los datos exige un orden q alto, y con él muchos parámetros α_i que estimar, lo que vuelve el modelo inestable y propenso a violar las restricciones de no negatividad. Bollerslev resolvió esta cuestión generalizando el modelo: el *GARCH* (ARCH generalizado) añade a la recursión términos de la propia varianza condicional pasada, de modo que la persistencia se consigue con pocos parámetros [37]. El modelo elegido será el GARCH(1,1), la versión más sencilla, la que consigue esa persistencia con menos parámetros, y la más extendida en finanzas. Definimos

$$\epsilon_t = \sigma_t \eta_t, \quad \eta_t \text{ i.i.d.}, \quad \mathbb{E}[\eta_t] = 0, \quad \text{Var}(\eta_t) = 1,$$

y la recursión de la varianza condicional

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \omega > 0, \quad \alpha \geq 0, \quad \beta \geq 0. \quad (3.1)$$

La varianza de hoy combina tres ingredientes: un suelo constante ω , la sorpresa del día anterior ϵ_{t-1}^2 (término ARCH, peso α) y la propia varianza del día anterior σ_{t-1}^2 (término GARCH, peso β). El último es el que aporta memoria larga con un solo parámetro: σ_{t-1}^2 ya resume todo el pasado, así que arrastrarla evita tener que sumar muchos rezagos de ϵ^2 . La cantidad $\sigma_t = \sqrt{\sigma_t^2}$ es la *volatilidad condicional*, la desviación típica de la innovación dada la información hasta $t-1$, y es la que utiliza el detector GSO de la Parte B. Las cifras de volatilidad se reportan *anualizadas*. Una volatilidad diaria es un número pequeño y poco intuitivo; la escala anual es la que se usa en finanzas para comparar activos y leer el riesgo de manera más intuitiva. Para pasar de la diaria a la anual multiplicamos σ_t por $\sqrt{252}$: como las varianzas de días aproximadamente independientes se suman, la desviación típica crece con la raíz del número de días, y el año bursátil tiene unos 252.

Estacionariedad y varianza incondicional

La recursión (3.1) solo define un proceso bien comportado bajo una condición sobre los parámetros. El siguiente resultado la caracteriza y, de paso, da la varianza a largo plazo del proceso.

Teorema 3.5 (Estacionariedad en covarianza del GARCH(1,1)). *Sea $\{\epsilon_t\}$ el proceso definido por $\epsilon_t = \sigma_t \eta_t$ con $\{\eta_t\}$ i.i.d. de media 0 y varianza 1 y la recursión (3.1), con $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$. Entonces $\{\epsilon_t\}$ admite una solución estacionaria en covarianza con varianza incondicional finita si y solo si*

$$\alpha + \beta < 1,$$

y en ese caso la varianza incondicional vale

$$\text{Var}(\epsilon_t) = \frac{\omega}{1 - \alpha - \beta}.$$

La demostración se encuentra en el Anexo A.

La suma $\alpha + \beta$ mide la *persistencia* de la volatilidad: cuán despacio se reabsorbe un golpe. Cuando $\alpha + \beta$ está cerca de 1, la varianza incondicional $\omega/(1 - \alpha - \beta)$ explota y los choques tardan muchísimo en disiparse; en series financieras diarias es habitual estimar valores muy próximos a la unidad, signo de volatilidad muy persistente. El caso límite $\alpha + \beta = 1$ define el modelo *IGARCH* (GARCH integrado) [38], en el que la varianza incondicional ya no es finita y un choque tiene efecto permanente sobre la volatilidad esperada, de forma análoga a una raíz unitaria en la media. En esa frontera el Teorema 3.5 deja de garantizar estacionariedad en covarianza, y la interpretación de σ_t como fluctuación alrededor de un nivel de largo plazo se pierde. Distinguimos esta estacionariedad en covarianza, que exige $\alpha + \beta < 1$, de la estacionariedad estricta, que se cumple bajo la condición más débil $\mathbb{E}[\log(\alpha\eta_t^2 + \beta)] < 0$ [39].

Innovaciones Student-t

Falta especificar la ley del ruido η_t . La elección más simple, $\eta_t \sim \mathcal{N}(0, 1)$, reproduce el agrupamiento de volatilidad pero subestima la frecuencia de los movimientos extremos: incluso con varianza variable, un GARCH gaussiano genera colas demasiado finas frente a las que muestran los retornos reales. Como las colas pesadas eran una de las regularidades empíricas de la Sección 3.1.1, el ruido necesita colas más anchas. Bollerslev propuso sustituir la normal por una t de Student estandarizada [40].

Tomamos entonces η_t i.i.d. con distribución t de Student de ν grados de libertad, reescalada para tener varianza unidad,

$$\eta_t \sim t_\nu \text{ estandarizada}, \quad \mathbb{E}[\eta_t] = 0, \quad \text{Var}(\eta_t) = 1, \quad \nu > 2.$$

El parámetro ν , los *grados de libertad*, controla el grosor de las colas: cuanto menor es ν , más probabilidad acumula la distribución en los extremos y más frecuentes son los retornos atípicos. La restricción $\nu > 2$ es necesaria para que la varianza exista y el reescalado a varianza unidad tenga sentido. En el límite $\nu \rightarrow \infty$ la t de Student converge a la normal estándar, de modo que el GARCH(1, 1) gaussiano queda como caso particular del GARCH(1, 1)- t ; estimar ν finito y pequeño indica, dentro del modelo, que las innovaciones estandarizadas tienen colas más pesadas que la gaussiana. Esta es la especificación que se usa en la memoria y la que abrevia el rótulo GARCH(1, 1)- t .

Estimación por máxima verosimilitud

Los parámetros $\theta = (\omega, \alpha, \beta, \nu)$ se estiman por máxima verosimilitud condicional. Sea f_ν la densidad de la t de Student estandarizada de ν grados de libertad. La log-verosimilitud

condicional de la muestra $\epsilon_{1:T}$, dado un valor inicial σ_1^2 , es la suma de las contribuciones diarias

$$\ell(\theta) = \sum_{t=1}^T \left[\log f_\nu \left(\frac{\epsilon_t}{\sigma_t} \right) - \log \sigma_t \right],$$

donde cada σ_t se obtiene recorriendo la recursión (3.1) con los parámetros θ en evaluación y el término $-\log \sigma_t$ es el jacobiano del cambio de variable de η_t a ϵ_t . La derivación de la verosimilitud, a partir de que $\epsilon_t = \sigma_t \eta_t$ es un cambio de escala de η_t por el factor σ_t conocido en $t-1$, está en el Anexo A.7. No existe solución cerrada para el máximo, así que se maximiza $\ell(\theta)$ numéricamente sobre la región admisible $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$, $\nu > 2$.

El estimador resultante hereda las buenas propiedades de la máxima verosimilitud bajo condiciones de regularidad. Bajo el modelo correctamente especificado, la condición de estacionariedad del Teorema 3.5 y condiciones adicionales de regularidad (en particular, momentos suficientes de las innovaciones, $\nu > 4$ para el cuarto momento, y un óptimo interior a la región admisible), el estimador máximo-verosímil $\hat{\theta}$ es consistente y asintóticamente normal, con matriz de covarianzas el inverso de la información de Fisher. La prueba de estas propiedades para el GARCH no figura en los trabajos que introducen el modelo, sino en su tratamiento posterior, al que se remite [41]. Una cautela: la normalidad asintótica de $\hat{\alpha}$ y $\hat{\beta}$ se degrada cuando $\alpha + \beta$ se aproxima a la frontera 1, justo el régimen IGARCH discutido arriba, lo que tenemos presente al interpretar los intervalos de confianza de los parámetros estimados.

3.1.6. Detección bayesiana de puntos de cambio (BOCPD)

PSA es el detector que mira al agente en lugar de al mercado. Su pregunta es si el agente ha roto con su manera habitual de operar, y la responde estimando día a día cuánto tiempo lleva bajo el mismo patrón; cuando esa cuenta se reinicia, ha habido una ruptura. La detección bayesiana de puntos de cambio formaliza ese conteo del tiempo bajo un mismo patrón.

Run-length y detección online

Los dos modelos anteriores miran el mercado. El detector que ahora se introduce mira al *agente*: vigila si la serie de decisiones (en concreto, el tamaño de las posiciones que va tomando) sufre una ruptura estructural, un cambio de comportamiento que no se explica como fluctuación dentro del mismo patrón. El instrumento es la detección bayesiana de puntos de cambio online de Adams y MacKay [42].

Sea $x_{1:t}$ la secuencia observada hasta el día t , donde aquí x_t es la magnitud que se vigila (el tamaño de la posición del agente). Un *punto de cambio* es un instante en el que los parámetros que generan la serie cambian; entre dos puntos de cambio consecutivos la serie se considera generada por un mismo modelo con parámetros fijos. Adoptamos el *modelo de particiones por producto* [42]: los segmentos que delimitan los puntos de cambio son independientes entre sí y, dentro de cada uno, las observaciones son i.i.d. según el modelo del segmento. Esta hipótesis, análoga a la independencia condicional (*) del HMM, es la que sostiene la recursión que sigue. La variable central es la *run-length* r_t , el número de pasos transcurridos desde el último punto

de cambio:

$$r_t \in \{0, 1, 2, \dots\}, \quad r_t = 0 \Leftrightarrow \text{hay un punto de cambio en } t,$$

y $r_t = r$ indica que el día actual y los r días previos se atribuyen al mismo segmento, todavía sin ruptura. La run-length crece de uno en uno mientras no hay cambio ($r_t = r_{t-1} + 1$) y se reinicia a 0 cuando lo hay.

La distinción entre detección *online* y *offline* es decisiva para esta memoria. Un detector *offline* dispone de toda la serie $x_{1:T}$ y localiza los cambios mirando hacia delante y hacia atrás; es más preciso, pero no es causal. Un detector *online* estima la run-length usando únicamente $x_{1:t}$, la información disponible en el instante t , sin asomarse al futuro. El método de Adams y MacKay es online por construcción: en cada día actualiza la distribución de r_t a partir de la del día anterior y de la nueva observación. Esta causalidad es exactamente la que exige el detector PSA, igual que el filtrado del HMM frente al suavizado: una alarma de cambio de comportamiento del agente solo es legítima si pudo emitirse el mismo día, sin conocer lo que el agente hizo después.

Recursión de la distribución de run-length

El objetivo es calcular, de forma online, la distribución posterior de la run-length, $\mathbb{P}(r_t \mid x_{1:t})$. Se obtiene normalizando la conjunta $\mathbb{P}(r_t, x_{1:t})$, que admite una recursión. Necesitamos dos ingredientes. El primero es la *función de hazard* $H(r)$, la probabilidad de que se produzca un cambio dado que el tramo actual lleva ya r pasos sin él,

$$H(r) = \mathbb{P}(r_t = 0 \mid r_{t-1} = r - 1),$$

que gobierna la frecuencia a priori de los puntos de cambio. El segundo es la *predictiva posterior* del modelo de observación dentro de un tramo: dado que la run-length actual es $r_{t-1} = r$, la densidad del nuevo dato condicionada a las observaciones de ese mismo tramo,

$$\pi_{\text{pred}}^{(r)} = \mathbb{P}(x_t \mid r_{t-1} = r, x_{1:t-1}),$$

que se calcula con las observaciones acumuladas desde el último reinicio. Con estos dos elementos derivamos la recursión [42].

Proposición 3.6 (Recursión de Adams–MacKay). *La distribución conjunta de la run-length y los datos satisface, partiendo de $\mathbb{P}(r_{t-1}, x_{1:t-1})$, los dos mensajes siguientes. El mensaje de crecimiento (no hay cambio, $r_t = r_{t-1} + 1$):*

$$\mathbb{P}(r_t = r_{t-1} + 1, x_{1:t}) = \mathbb{P}(r_{t-1}, x_{1:t-1}) (1 - H(r_{t-1} + 1)) \pi_{\text{pred}}^{(r_{t-1})},$$

y el mensaje de reinicio (hay cambio, $r_t = 0$):

$$\mathbb{P}(r_t = 0, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_{t-1}, x_{1:t-1}) H(r_{t-1} + 1) \pi_{\text{pred}}^{(r_{t-1})}.$$

La posterior de la run-length se recupera normalizando,

$$\mathbb{P}(r_t \mid x_{1:t}) = \frac{\mathbb{P}(r_t, x_{1:t})}{\sum_r \mathbb{P}(r_t = r, x_{1:t})}.$$

La demostración se encuentra en el Anexo A.

La recursión es enteramente causal: $\mathbb{P}(r_t, x_{1:t})$ se construye a partir de $\mathbb{P}(r_{t-1}, x_{1:t-1})$ y de la observación x_t , sin recurrir a ningún dato posterior. Por eso sirve para PSA. El soporte de r_t crece un paso en cada iteración, así que en la práctica se trunca la distribución descartando las run-lengths cuya probabilidad cae por debajo de un umbral, lo que mantiene el coste acotado sin alterar de forma apreciable la inferencia.

Función de hazard y predictiva conjugada

Para cerrar el modelo hay que fijar la función de hazard y la predictiva. La elección estándar para la hazard es la *constante*,

$$H(r) = \frac{1}{\lambda}, \quad \lambda > 0,$$

independiente de r . Bajo esta elección la dinámica de la run-length carece de memoria: la probabilidad de que el segmento actual termine en el paso siguiente es siempre $1/\lambda$, sea cual sea el tiempo que lleve vigente. La longitud de cada segmento queda entonces distribuida como una geométrica de parámetro $1/\lambda$ y media λ pasos. El parámetro λ codifica, por tanto, la escala temporal esperada entre rupturas y es el único hiperparámetro de la dinámica.

La predictiva $\pi_{\text{pred}}^{(r)}$ se calcula de forma cerrada eligiendo el modelo de observación dentro de un tramo en una familia exponencial con su *previa conjugada*: la posterior de los parámetros del tramo pertenece entonces a la misma familia que la previa, y la predictiva del dato nuevo tiene expresión analítica que se actualiza de forma incremental al llegar cada observación. Esta conjugación es lo que hace que la recursión de la Proposición 3.6 sea barata de evaluar día a día. El modelo de observación concreto de PSA forma parte de la calibración de los detectores. Como contexto, el trabajo de Fearnhead sobre inferencia exacta para modelos multipunto desarrolla los métodos de cálculo de estas distribuciones predictivas y de la partición en tramos sobre los que se apoya el enfoque online [43].

3.1.7. STRATA aplicado: construcción, calibración y umbrales

Cada detector produce una señal numérica que mide un tipo de incoherencia entre la decisión del agente y el estado del mercado; cuando esa señal supera un umbral, STRATA interviene.

Datos y calibración

Los tres modelos se estiman una sola vez, sobre un periodo de calibración fijo y anterior al periodo de evaluación, y no se reentrenan después. Esta separación entre la fase de calibración y producción impide que cualquier parámetro de STRATA haya visto los datos futuros. Fijar un único periodo de calibración presupone que la estructura de la serie es razonablemente estable dentro de él, hipótesis que se puede contrastar con el test de cambios estructurales

múltiples de Bai y Perron [44, 45], que localiza el número y la posición de las rupturas en los parámetros de un modelo.

RAM: desajuste entre régimen y acción

El detector RAM mide si la dirección de la apuesta del agente es coherente con el régimen de mercado. Toma como entrada el posterior filtrado γ_t^f de la Sección 3.1.4: para cada día, una distribución de probabilidad sobre los tres regímenes. Lo que falta es asociar esos regímenes a direcciones de mercado, y ahí entra el único ingrediente económico del detector.

En los índices bursátiles agregados, el retorno y la volatilidad están correlados negativamente: los tramos de alta volatilidad coinciden con caídas y los de baja volatilidad con subidas. Black documentó este fenómeno y lo llamó *leverage effect* [24]; Christie lo estudió de forma sistemática [25]. En un índice, por tanto, el régimen de alta volatilidad que identifica el HMM adquiere una lectura direccional: alta volatilidad tiende a significar mercado a la baja. Esa correspondencia es una propiedad de los índices, no una ley universal; en una acción individual el leverage effect es débil y la asociación entre nivel de volatilidad y dirección se diluye. Por eso STRATA no fija la dirección de cada régimen a mano, sino que la aprende del dato: para cada régimen k se toma el signo de su media de log-retorno, esto es, la componente de retorno del vector μ_k estimado en la calibración, de modo que el régimen de media más negativa se asocia a la dirección bajista y el de media más positiva a la alcista. Este prior por activo es lo que permite aplicar RAM a cualquier serie sin suponer que se comporta como un índice.

Con el prior fijado, formalizamos el detector. Para cada régimen k , sea $d_k = \text{sign}((\mu_k)_{\text{ret}}) \in \{-1, 0, +1\}$ su dirección aprendida (el signo de la componente de retorno de μ_k), y sea w_t la posición del agente.

Definición 3.7 (RAM score). El *RAM score* es la masa filtrada sobre los regímenes cuya dirección aprendida contradice la apuesta del agente,

$$\text{RAM}_t = \sum_{k=1}^K \gamma_t^f(k) \mathbf{1}\{\text{sign}(w_t) d_k < 0\} = \mathbb{P}(\text{sign}(w_t) d_{z_t} < 0 \mid x_{1:t}) \in [0, 1].$$

En los tres regímenes de la calibración (Calma alcista, $d = +1$; Crisis bajista, $d = -1$; Estrés neutro, $d = 0$) esto es $\text{RAM}_t = \gamma_t^f(\text{Crisis})$ si el agente va largo y $\text{RAM}_t = \gamma_t^f(\text{Calma})$ si va corto; el Estrés, sin dirección, nunca penaliza. El score vive en $[0, 1]$: cuanto más alto, más probabilidad pone el HMM en que el agente apuesta contra el régimen. El detector se activa con tres umbrales fijados ex ante, 0,25, $\tau = 0,50$ y 0,70, que marcan severidad baja, media y alta. El umbral operativo es el central, $\tau = 0,50$: equivale a intervenir cuando la dirección contraria a la apuesta acumula más de la mitad de la probabilidad de régimen, esto es, a la regla de mayoría. Además, veremos que en nuestro caso de estudio el score tiende a concentrar su masa cerca de 0 o de 1, de modo que el acierto del detector apenas cambia para umbrales en un entorno de 0,5.

GSO: tamaño compatible con la volatilidad

GSO se ocupa del tamaño de la apuesta: comprueba si es compatible con la volatilidad vigente. Su referencia teórica es el *volatility targeting*, que dimensiona la posición de forma inversamente proporcional a la volatilidad estimada ($\propto 1/\sigma$) para mantener el riesgo aproximadamente constante; Moreira y Muir documentan que una variante de este principio, el escalado por la inversa de la *varianza* ($1/\sigma^2$), mejora el rendimiento ajustado por riesgo [23]. GSO toma la volatilidad condicional σ_t del GARCH(1,1)- t de la Sección 3.1.5, calculada con información hasta $t - 1$, y la traduce en una banda de tamaño admisible.

Definición 3.8 (Banda de volatilidad y GSO score). Dada una volatilidad objetivo anualizada v^* ($v^* = 0,10$ en la memoria), la *banda* admisible y el *GSO score* son

$$b_t = \min\left(1, \frac{v^*}{\sigma_t}\right), \quad \text{GSO}_t = \frac{\max(0, |w_t| - b_t)}{b_t}.$$

El score mide la sobreexposición relativa: es nulo mientras el tamaño cabe en la banda y crece cuando la supera. GSO emite señal cuando GSO_t rebasa los percentiles 95 y 99 de su distribución sobre el periodo de calibración, y en la intervención recorta el tamaño a $\text{sign}(w_t) \min(|w_t|, b_t)$.

Sobre los datos estudiados, GSO rara vez supera la severidad media: el tamaño que toma el agente casi nunca viola la banda de forma marcada. Es una limitación del detector sobre este activo, que recogemos en los resultados.

PSA: coherencia temporal del agente

PSA vigila la coherencia temporal del agente: detecta si cambia de criterio de forma estructural, no como fluctuación dentro de un mismo patrón. Aplica la detección bayesiana de puntos de cambio de la Sección 3.1.6 a la serie de tamaños de posición del agente, con una función de hazard constante $H = 1/\lambda$, $\lambda = 250$, que fija a priori la escala temporal entre rupturas en un año bursátil, unos 250 días de mercado (la media de la geométrica de la Sección 3.1.6); es una escala interpretable, un cambio esperado al año, fijada a mano y sin optimizar contra el periodo de evaluación.

Definición 3.9 (PSA score). El *PSA score* es la masa posterior de la run-length sobre las rachas cortas, esto es, la probabilidad de que se haya producido un cambio reciente,

$$\text{PSA}_t = \sum_{r=0}^w \mathbb{P}(r_t = r \mid x_{1:t}),$$

con $w = 5$ la ventana de racha corta (en días de mercado). Crece cuando el *sizing* del agente acaba de romper con su patrón previo.

Los umbrales operativos siguen el mismo criterio que GSO: los percentiles 95 y 99 sobre el periodo de calibración. En la intervención, necesitamos un índice muy alto de PSA para frenar la posición resultante.

La capa de intervención

Las tres señales alimentan la capa de intervención, que transforma la posición w_t en una posición supervisada w_t^* por composición de tres operadores. Sea $\rho_t = +1$ si $\gamma_t^f(\text{Calma}) \geq \gamma_t^f(\text{Crisis})$ y $\rho_t = -1$ en otro caso, la dirección del régimen dominante.

Definición 3.10 (Capa de intervención M8). La posición supervisada es $w_t^* = (C_{\text{PSA}} \circ R_{\text{RAM}} \circ G_{\text{GSO}})(w_t)$, donde cada operador actúa solo si su detector dispara y es la identidad en caso contrario:

$$G_{\text{GSO}}(w) = \text{sign}(w) \min(|w|, b_t), \quad R_{\text{RAM}}(w) = \rho_t b_t, \quad C_{\text{PSA}}(w) = \frac{1}{2} w.$$

El disparo se produce con severidad *medium* o superior para GSO y RAM (es decir, $\text{RAM}_t \geq \tau$) y *high* para PSA.

El GSO acota la magnitud a la banda de volatilidad; el RAM, cuando $\text{RAM}_t \geq \tau$ con $\tau = 0,50$, reorienta la posición al signo del régimen con esa banda (el único paso que cambia la dirección); el PSA frena a la mitad ante un cambio brusco de *sizing*. La intervención trabaja solo con el posterior filtrado del régimen. La regla de referencia M8 es exactamente esta configuración, con $\text{signal_lag} = 1$.

3.2. De la alerta a la acción: M8, M10, AutoML

La regla M8 combina las tres señales con umbrales fijos, elegidos de antemano. La pregunta natural es si una combinación *aprendida* de esas mismas señales lo haría mejor: en lugar de fijar los umbrales a mano, un modelo puede estimar de los datos cómo pesar la información del agente y de STRATA para anticipar la dirección del día siguiente. Esa es la estrategia M10, y su generalización mediante búsqueda automatizada de modelos es la estrategia AutoML. Ambas se apoyan en el aprendizaje supervisado por árboles potenciados, que esta sección desarrolla con el mismo nivel de detalle que los modelos de los detectores, porque son el objeto central del capítulo de resultados y porque la objeción natural del tribunal (¿el modelo supervisado bate a STRATA o solo la redescubre?) exige tenerlos bien especificados.

3.2.1. El problema de aprendizaje supervisado

Cada día disponemos de un vector de características $\mathbf{x}_t \in \mathbb{R}^d$ con $d = 22$, que reúne toda la información del día: las ternas de las cinco personalidades del agente (Buffett, Wood, Druckenmiller, Burry y Ackman), cada una con su *signo*, *tamaño* y *confianza*, lo que aporta quince componentes, y las siete lecturas estadísticas de STRATA, a saber las tres señales RAM_t , PSA_t , GSO_t , las tres probabilidades de régimen filtradas $\gamma_t^f(\text{Calma})$, $\gamma_t^f(\text{Estrés})$, $\gamma_t^f(\text{Crisis})$ y la volatilidad condicional σ_t del GARCH. La etiqueta es la dirección realizada del día siguiente,

$$y_t = \mathbf{1}\{r_{t+1} > 0\} \in \{0, 1\},$$

de modo que el problema es de clasificación binaria causal: a partir de $\mathbf{x}_t$, conocido en t , predecir el signo de r_{t+1} . Un modelo produce una probabilidad estimada $p(\mathbf{x}_t) = \hat{\mathbb{P}}(y_t = 1 \mid \mathbf{x}_t)$,

y la posición asociada es

$$w_t = \text{sign}(p(\mathbf{x}_t) - \tfrac{1}{2}),$$

larga si el modelo da más de un medio a la subida y corta en caso contrario. Esta capa de segundo nivel, que aprende sobre las salidas de un primer nivel (el agente) en lugar de sobre los precios crudos, es un *meta-learner* en el sentido de López de Prado [3].

El ajuste minimiza la entropía cruzada (o *pérdida logística*) sobre el conjunto de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$,

$$L = - \sum_{i=1}^n [y_i \log p(\mathbf{x}_i) + (1 - y_i) \log (1 - p(\mathbf{x}_i))],$$

que es la verosimilitud negativa del modelo de Bernoulli y penaliza con dureza la confianza mal puesta. La familia de funciones $p(\cdot)$ que adoptamos es la de los árboles de decisión potenciados, que describimos a continuación de lo simple a lo compuesto.

3.2.2. Árboles de decisión

La pieza elemental es el árbol de decisión, una función constante a trozos sobre una partición del espacio de características en regiones rectangulares [46]. Un árbol con T hojas que inducen una partición $\{R_1, \dots, R_T\}$ de $\mathbb{R}^d$ se escribe

$$h(\mathbf{x}) = \sum_{j=1}^T w_j \mathbf{1}\{\mathbf{x} \in R_j\},$$

donde w_j es el valor asignado a la hoja j . Las regiones se construyen de forma recursiva y voraz: en cada nodo se elige la variable y el punto de corte que más reducen una medida de impureza, y se repite sobre los dos hijos hasta un criterio de parada. Un árbol aislado tiene poco sesgo pero mucha varianza, y su frontera escalonada rara vez generaliza bien por sí sola; la potencia aparece al combinar muchos árboles, que es lo que hacen el *boosting* y el apilamiento de las secciones siguientes.

3.2.3. Gradient boosting

El *gradient boosting* construye un predictor aditivo como suma de árboles ajustados en etapas [47]. Partiendo de un valor inicial F_0 , en la etapa m se añade un árbol h_m y se actualiza

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu \gamma_m h_m(\mathbf{x}),$$

con $\nu \in (0, 1]$ la tasa de aprendizaje (*shrinkage*). La idea de Friedman es interpretar el ajuste como un descenso de gradiente en el espacio de funciones: el árbol h_m se ajusta a los *pseudo-residuos*, el gradiente negativo de la pérdida evaluado en el modelo actual,

$$r_{im} = - \left[\frac{\partial L(y_i, F(\mathbf{x}_i))}{\partial F(\mathbf{x}_i)} \right]_{F=F_{m-1}},$$

y el paso γ_m se fija por minimización unidimensional de la pérdida en esa dirección. La siguiente proposición especializa los pseudo-residuos al caso logístico, que es el que usamos, y conecta el boosting con la verosimilitud de Bernoulli.

Proposición 3.11 (Pseudo-residuos del boosting logístico). *Si F es el logaritmo de la razón de momios y $p = \sigma(F) = (1 + e^{-F})^{-1}$ la probabilidad asociada, el pseudo-residuo de la pérdida logística es la diferencia entre la etiqueta y la probabilidad predicha,*

$$r_i = -\frac{\partial L}{\partial F} \Big|_{F(\mathbf{x}_i)} = y_i - p(\mathbf{x}_i).$$

El resultado sale de derivar la pérdida logística respecto de p y aplicar la regla de la cadena con $dp/dF = p(1 - p)$; el desarrollo está en el Anexo A.9.

Así, cada árbol corrige el error de probabilidad acumulado por los anteriores. El *shrinkage* ν y el submuestreo de filas y columnas en cada etapa (*stochastic gradient boosting*) regularizan el ajuste y reducen el sobreajuste [47, 46].

3.2.4. XGBoost y el meta-learner M10

XGBoost es una realización de gradient boosting que añade una regularización explícita sobre la complejidad de cada árbol y usa la curvatura de la pérdida, no solo su gradiente [48]. El objetivo de la etapa t , al incorporar el árbol $f_t(\mathbf{x}) = w_{q(\mathbf{x})}$ definido por su estructura q y sus pesos de hoja w , es

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t), \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2,$$

donde γ penaliza el número de hojas y λ la magnitud de los pesos. Desarrollando la pérdida hasta segundo orden en torno a la predicción acumulada, con gradiente $g_i = \partial_{\hat{y}} l(y_i, \hat{y}_i^{(t-1)})$ y hessiana $h_i = \partial_{\hat{y}}^2 l(y_i, \hat{y}_i^{(t-1)})$, el problema por hoja se vuelve cuadrático y admite solución cerrada.

Proposición 3.12 (Pesos óptimos y ganancia de una división). *Fijada la estructura q , con conjuntos de instancias por hoja $I_j = \{i : q(\mathbf{x}_i) = j\}$ y sumas $G_j = \sum_{i \in I_j} g_i$, $H_j = \sum_{i \in I_j} h_i$, el peso que minimiza la aproximación de segundo orden del objetivo y el valor óptimo correspondiente son*

$$w_j^* = -\frac{G_j}{H_j + \lambda}, \quad \tilde{\mathcal{L}}^*(q) = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T.$$

En consecuencia, dividir una hoja en dos descendientes L y R reduce el objetivo en

$$\text{Gan} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma,$$

que es el criterio con el que se eligen los cortes.

La demostración se encuentra en el Anexo A.

El *meta-learner* M10 del trabajo es XGBoost con esta especificación y los hiperparámetros fijados en la calibración: trescientos árboles de profundidad cuatro, tasa de aprendizaje $\nu = 0,05$, submuestreo de filas y columnas al ochenta por ciento, regularización $\lambda = 1$ y pérdida logística. Para rebajar la varianza del estimador, M10 promedia diez ajustes que solo difieren en la semilla de aleatorización,

$$\bar{p}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B p^{(b)}(\mathbf{x}), \quad B = 10,$$

una forma de agregación cuya reducción de varianza es la del promediado de predictores [49, 46]: si los B ajustes tienen varianza τ^2 y correlación media ϱ , la varianza del promedio es $\varrho \tau^2 + (1 - \varrho) \tau^2 / B$, menor que τ^2 siempre que la correlación no sea perfecta. La posición de M10 es $w_t = \text{sign}(\bar{p}(\mathbf{x}_t) - \frac{1}{2})$. El entrenamiento sigue el protocolo *walk-forward* de la Sección 3.3.2, con ventana expandible y embargo 1: cada modelo aprende solo del pasado y predice el tramo siguiente.

3.2.5. Apilamiento y super learner

El apilamiento (*stacking*) combina varios modelos base entrenando un segundo modelo, el *meta-learner*, sobre las predicciones que aquellos hacen fuera de muestra por validación cruzada [50]. Entrenar el meta-learner sobre predicciones *out-of-fold*, y no sobre las del propio ajuste, evita que un modelo base que sobreajusta arrastre al combinador. El *super learner* es la formalización de esta idea por van der Laan, Polley y Hubbard [51]. El meta-learner busca la combinación convexa de los modelos base que minimiza el riesgo de validación cruzada, y goza de una propiedad oráculo: asintóticamente, su riesgo es tan bueno como el del mejor de los modelos base, o el de su mejor combinación, sin conocerlo de antemano. Esta es exactamente la pieza *StackedEnsemble* que la búsqueda automatizada de la siguiente sección apila sobre sus modelos base.

3.2.6. Búsqueda automatizada: H2O AutoML

La estrategia AutoML relaja la elección de la familia del modelo: en vez de fijar XGBoost de antemano, deja que una búsqueda automatizada entrene y compare modelos de varias familias y devuelva el mejor. Usamos H2O AutoML [52], restringido a tres familias por activo: árboles potenciados (GBM), XGBoost y el apilamiento (StackedEnsemble) sobre los anteriores. Cada modelo se evalúa por validación cruzada purgada (la *K-fold* con *fold_column* y embargo de la Sección 3.3.2, no la convencional), y el *leader* es el de mayor AUC. La posición de AutoML es, igual que la de M10, $w_t = \text{sign}(p_1(\mathbf{x}_t) - \frac{1}{2})$, con p_1 la probabilidad del *leader*, y se reentrena con el mismo *walk-forward* causal.

La búsqueda se acota por número fijo de modelos y semilla fija, no por presupuesto de tiempo, y esa elección es la que hace el resultado reproducible y defendible: con un límite temporal, el conjunto de modelos explorado depende de la carga de la máquina y el *leader* cambia entre ejecuciones con la misma semilla, lo que invalidaría cualquier cifra reportada; con número fijo de modelos y semilla, la búsqueda es determinista. El papel metodológico de

AutoML es servir de control de universalidad (Capítulo 5): si ni siquiera una búsqueda sobre varias familias bate de forma robusta a las referencias triviales, se refuerza la conclusión de que la señal aprovechable ya está capturada con independencia de la familia de modelos elegida.

3.2.7. Catálogo de estrategias

Todas las estrategias evaluadas son funciones que devuelven una posición w_t contra r_{t+1} con $\text{signal_lag} = 1$; la probabilidad p_1 de los modelos supervisados es un paso intermedio.

Definición 3.13 (Estrategias evaluadas). Sobre el mismo periodo de prueba y con causalidad $\text{signal_lag} = 1$:

- **M5** (agente): la posición cruda del agente, $w_t = \text{sign}(\text{tamaño}_t)$, sin supervisión.
- **M8** (intervención): la regla determinista de umbrales fijos de la Definición 3.10, $w_t = w_t^*$.
- **M10** (meta-learner): el promedio de diez XGBoost sobre las 22 características, $w_t = \text{sign}(\bar{p}(\mathbf{x}_t) - \frac{1}{2})$.
- **AutoML**: el *leader* de la búsqueda H2O sobre GBM/XGBoost/StackedEnsemble, $w_t = \text{sign}(p_1(\mathbf{x}_t) - \frac{1}{2})$.
- **ZeroR**: la referencia trivial sin habilidad, que predice la clase mayoritaria del pasado estricto, $w_t = \text{sign}(\frac{1}{t-1} \sum_{s < t} y_s - \frac{1}{2})$, calculada de forma causal.
- **B&H** (*buy and hold*): comprar y mantener, $w_t \equiv 1$.

Las dos últimas son las referencias frente a las que cualquier estrategia con pretensión de habilidad debe demostrar valor: ZeroR fija el techo direccional que se alcanza sin información alguna, y B&H, la exposición pasiva al activo. El capítulo de resultados contrasta M5, M8, M10 y AutoML contra ambas y entre sí.

3.3. Cómo se mide el rescate

3.3.1. Métricas de evaluación

Para juzgar si una estrategia lo hace bien no basta con mirar cuánto gana: hay que poner el rendimiento en relación con el riesgo asumido. Las métricas que siguen enriquecen la lectura de los resultados, pero ninguna prueba nada por sí sola: la prueba estadística del trabajo descansa en los contrastes de la Sección 3.3.3.

Acierto direccional y matriz de confusión

La métrica primaria de este trabajo es el acierto direccional. Una estrategia produce cada día una posición w_t y se mide contra el retorno del día siguiente r_{t+1} ; acierta cuando la dirección apostada coincide con la realizada. La *accuracy direccional* es la fracción de días en que ambos signos concuerdan,

$$\text{Acc} = \frac{1}{n} \sum_t \mathbf{1}\{\text{sign}(w_t) = \text{sign}(r_{t+1})\}.$$

Mide la habilidad de la decisión sin pasar por la economía: cuánto del tiempo la apuesta acierta el signo del mercado.

El acierto diario se ordena en una *matriz de confusión* 2×2 que cruza lo apostado con lo ocurrido. Tomando la apuesta larga como clase positiva, un día puede ser verdadero positivo (larga y sube), verdadero negativo (corta y baja), falso positivo (larga y baja) o falso negativo (corta y sube). La accuracy es la masa de la diagonal, $(TP + TN)/n$. Del lado largo leemos también la *precisión*, $TP/(TP + FP)$, la fracción de apuestas alcistas que aciertan, y el *recall*, $TP/(TP + FN)$, la fracción de subidas que la estrategia capta. El objeto sobre el que operan los contrastes de la Sección 3.3.3 es más fino que estos escalares: es el *vector diario* de acierto/fallo $a_t = \mathbf{1}\{\text{sign}(w_t) = \text{sign}(r_{t+1})\} \in \{0, 1\}$, que alineado día a día entre dos estrategias da los pares sobre los que trabajan el sign test y McNemar.

Cuando la estrategia emite una probabilidad $p_1(\mathbf{x}_t)$ de subida antes de umbralizarla, disponemos de una métrica que no depende del umbral: el *AUC*, área bajo la curva ROC [53, 54]. La curva recorre todos los umbrales y, en cada uno, anota cuántas subidas reales capta frente a cuántas bajadas confunde con subidas. Su área responde a una pregunta directa: tomados al azar un día de subida y uno de bajada, con qué frecuencia el modelo da mayor p_1 al primero. Un área de 0,5 es puro azar; una de 1, un ordenamiento perfecto. La búsqueda automatizada de la Sección 3.2.6 elige su *leader* por este criterio.

Dos referencias triviales fijan el listón de toda accuracy, ya definidas en el catálogo de estrategias (Definición 3.13). *ZeroR* predice la clase mayoritaria del pasado estricto: su accuracy es la frecuencia de la dirección dominante, el techo que se alcanza sin información alguna. *B&H* (comprar y mantener) mide la exposición pasiva al activo. Una estrategia con pretensión de habilidad ha de batir a las dos, no solo a la moneda equilibrada.

El ratio de Sharpe

Las métricas de riesgo trabajan sobre los retornos diarios de la estrategia, $g_t = w_t \cdot r_{t+1}$, el resultado causal de aplicar la posición de t al movimiento de $t + 1$. La más extendida es el *ratio de Sharpe*, la recompensa por unidad de variabilidad que introdujo Sharpe [55, 56]: el cociente entre el retorno medio y su desviación típica,

$$\text{SR} = \frac{\bar{g}}{\hat{\sigma}_g}, \quad \bar{g} = \frac{1}{n} \sum_t g_t, \quad \hat{\sigma}_g^2 = \frac{1}{n-1} \sum_t (g_t - \bar{g})^2.$$

Cuanto retorno extrae la estrategia por cada punto de volatilidad que soporta. Como en la Sección 3.1.5, las cifras se reportan anualizadas, multiplicando el ratio diario por $\sqrt{252}$, la escala con que las desviaciones de días aproximadamente independientes acumulan a lo largo del año bursátil. Un Sharpe alto señala una estrategia que gana de forma estable; uno negativo, que pierde de media.

Drawdown máximo y Calmar

El Sharpe penaliza por igual la volatilidad al alza y a la baja, pero quien arriesga capital teme sobre todo las rachas malas. La *máxima caída* (*maximum drawdown*) las captura. Sobre la curva de capital acumulado $V_t = \prod_{s \leq t} (1 + g_s)$, es la mayor pérdida relativa desde un máximo

previo hasta un mínimo posterior,

$$\text{maxDD} = \max_t \frac{\max_{s \leq t} V_s - V_t}{\max_{s \leq t} V_s} \geq 0,$$

una cantidad no negativa que lee el peor tramo de la historia: cuánto habría perdido quien entró justo en el peor momento [57]. Es la medida de riesgo que más pesa en la lectura de los resultados del panel.

El *ratio de Calmar* relaciona el rendimiento con esa peor caída [58]: el rendimiento anualizado dividido por la máxima caída,

$$\text{Calmar} = \frac{\text{rendimiento anualizado}}{\text{maxDD}}.$$

El Sharpe divide por la volatilidad media; el Calmar, por el peor tramo, de modo que es sensible al episodio más adverso y no solo a la dispersión típica. Un activo de Sharpe razonable pero con un desplome puntual severo recibe un Calmar bajo, lo que lo delata como peligroso.

3.3.2. Validación

Un backtest sobre datos pasados no vale nada si su evaluación usó, aunque sea de forma sutil, información que no estaba disponible al decidir. Esa contaminación se conoce como *look-ahead*; las salvaguardas que la impiden son necesarias para que las cifras del capítulo de resultados sean fiables. La regla es la misma siempre: solo se usa información del pasado y del presente, nunca del futuro.

Causalidad: la regla `signal_lag=1`

La Sección 3.1.1 fijó esta regla; aquí vemos por qué es condición de ausencia de fuga. La posición w_t se decide con la información disponible hasta el cierre del día t . El retorno de ese mismo día, r_t , ya se ha producido cuando se decide: forma parte de la información que entra en la decisión. Contabilizar la ganancia como $w_t \cdot r_t$ sería, por tanto, estimar la posición con un movimiento que ya se conocía al tomarla, permitiendo que la decisión mire su propio resultado. Es *look-ahead* y produce backtests artificialmente buenos que se desploman en operativa real.

La regla correcta, que en el código lleva el nombre `signal_lag=1`, es contabilizar la posición de t contra el retorno del día siguiente:

$$\text{resultado del día} = w_t \cdot r_{t+1}.$$

La posición se fija en t y se evalúa con el primer retorno que aún no se conocía, el de $t + 1$. Encaja con el filtrado causal de la Sección 3.1.4: el régimen γ_t^f que alimenta la decisión en t se calcula solo con $x_{1:t}$, y la decisión resultante se enfrenta a r_{t+1} . Esta construcción es la recomendada en la literatura sobre evaluación de estrategias financieras, que insiste en alinear el etiquetado de cada decisión con el horizonte en el que se materializa su resultado [3].

Validación walk-forward (rolling-origin)

La convención `signal_lag=1` asegura la causalidad de una decisión aislada, pero el meta-learner del caso de estudio *aprende* de los datos, y validar un modelo que aprende necesita un protocolo que reproduzca cómo se usaría si queremos llevarlo a producción. El que adoptamos es el *walk-forward* de origen rodante (*rolling-origin*), el estándar para evaluar predicción sobre series temporales [59, 60]: el modelo se entrena solo con el pasado, predice un tramo futuro, y la ventana de entrenamiento avanza en el tiempo repitiendo el ciclo.

Se reserva un *periodo de arranque* (*burn-in*) inicial, que sirve para el primer entrenamiento y no se puntúa. A partir de ahí, cada cierto número de días el modelo se reentrena con *toda* la información disponible hasta esa fecha y predice el bloque siguiente, estrictamente futuro respecto al entrenamiento. Como la ventana se expande y nunca retrocede, ninguna predicción usa datos posteriores al día en que se emite. El protocolo es causal por construcción y *desplegable*, porque reproduce lo que se haría en la realidad: reentrenar de forma periódica y operar hacia delante. El burn-in y la frecuencia de reentrenamiento se calibran en el caso de estudio.

Purga y embargo

Reentrenar sobre el pasado y predecir el futuro no basta cuando la etiqueta de un día se define sobre un horizonte que se solapa con el bloque de evaluación. La *purga* corrige ese solape [3]: retira del entrenamiento toda observación cuyo horizonte de etiquetado, el día $t + 1$ al que apunta su retorno, caiga dentro del tramo evaluado. Si la dejáramos, el modelo aprendería en parte de los mismos días sobre los que luego se le mide. Purgarla rompe ese puente.

La purga no agota la fuga. Los retornos contiguos están autocorrelados, de modo que una muestra de entrenamiento inmediatamente anterior al test, aunque su etiqueta no solape, comparte estructura con las primeras muestras evaluadas. El *embargo* la corta descartando además los h días posteriores a cada bloque de test antes de readmitir muestras al entrenamiento [3]. En este trabajo el horizonte de la etiqueta es de un solo día, la dirección de r_{t+1} , así que un día de separación elimina el único solape posible: fijamos $h = 1$. Un embargo mayor descartaría información válida sin ganar protección.

Por qué no validación cruzada convencional. CPCV

Barajar los pliegues al azar rompe el orden del tiempo. La validación cruzada *K-fold* convencional reparte las muestras sin mirar la fecha, de modo que un pliegue de entrenamiento puede contener días posteriores a los del pliegue de test: el modelo aprende del futuro y se evalúa sobre el pasado. Esa fuga infla las métricas y no se reproduce en operativa real. Ningún resultado del trabajo descansa sobre la *K-fold* barajada.

La forma correcta de cortar los pliegues en el tiempo es la *validación cruzada combinatoria purgada* (CPCV), que combina los pliegues de forma exhaustiva y aplica a cada combinación la purga y el embargo de la subsección anterior [3, sec. 7.4]. De ella tomamos dos formas concretas. El meta-learner se valida con el walk-forward desplegable de la Sección 3.3.2, que con horizonte de etiqueta uno y origen rodante es la versión que reproduce el despliegue en el tiempo. La búsqueda automatizada valida internamente con una *K-fold purgada*: parte los

pliegues por una columna temporal y les aplica embargo, no los baraja al azar. La K -fold sin purgar aparece una sola vez en el trabajo, deliberadamente, como contraejemplo que mide el sesgo que introduce.

Agregación pooled y su alcance

El caso de estudio se construye sobre un activo, pero la prueba dura del rescate de riesgo necesita más muestra de la que da uno solo. Definimos la agregación *pooled* como la concatenación de las series diarias pareadas de los diez activos del panel en una única serie de $n \approx 2493$ días. En lugar de un contraste por activo, un solo contraste sobre el conjunto, que multiplica el tamaño de muestra y, con él, la potencia para distinguir del cero un efecto que en un activo aislado queda dentro del ruido.

El *pooling* tiene un coste que pesa al leer sus intervalos. Las series de los diez activos no son independientes: varios son índices con correlación cruzada alta ($\rho > 0,9$), de modo que apilar sus días aporta menos información nueva de lo que sugiere el conteo bruto $n \approx 2493$. El tamaño de muestra *efectivo* es menor que el nominal. El bootstrap estacionario de la Sección 3.3.3, con bloques de longitud media $\sqrt{n}$, amortigua en parte esta dependencia al remuestrear tramos contiguos en lugar de días sueltos, pero no la cancela: el intervalo de confianza pooled es algo más estrecho de lo que daría una muestra verdaderamente independiente, esto es, ligeramente optimista. Lo descontamos al interpretar el panel.

3.3.3. Contraste de hipótesis

La economía ilustra; la prueba vive aquí. Cada pregunta del trabajo tiene su contraste, con su hipótesis nula explícita y su estadístico. Los agrupamos por la pregunta que responden, de la dirección al riesgo y de la multiplicidad a la equivalencia, y cerramos con las herramientas de interpretabilidad y de agrupamiento que sostienen la parte de mecanismo.

Dirección: signo, McNemar y permutación por bloques

Bajo la hipótesis nula de no-habilidad, cada acierto diario es una Bernoulli de parámetro 0,5 y el número total de aciertos sigue una binomial. El *sign test* contrasta la accuracy observada contra ese 0,5 y rechaza cuando el exceso de aciertos es improbable bajo el azar [61]; los días sin movimiento ($r_{t+1} = 0$), de medida prácticamente nula en retornos diarios, se descartan del conteo. Lo acompañamos con el *intervalo de Wilson* para la proporción de acierto, que se comporta bien con muestras moderadas y cerca de los extremos, donde el intervalo normal ingenuo falla. Con este contraste medimos la primera afirmación del trabajo, que el agente acierta por debajo del azar.

La pregunta pareada es si una estrategia acierta más que otra sobre los mismos días. La responde el *test de McNemar*, que mira solo los días en que ambas discrepan [62]. Sean b los días en que la primera acierta y la segunda falla, y c los del caso opuesto; los días en que ambas coinciden no informan sobre cuál es mejor. Bajo la nula de igual habilidad, b y c se reparten por igual, y

$$\chi^2 = \frac{(b - c)^2}{b + c}$$

sigue asintóticamente una χ_1^2 . Cuando los discordantes son pocos usamos la versión exacta, una binomial de parámetro $\frac{1}{2}$ sobre los $b + c$ pares. McNemar es el test central de accuracy: con él contrastamos si una derivada de STRATA rescata al agente.

El sign test y McNemar tratan los días como intercambiables, y los aciertos de una serie financiera están autocorrelados. Para un nulo que respete esa estructura permutamos bloques contiguos de aciertos en lugar de días sueltos, lo que preserva la dependencia temporal local al construir la distribución del estadístico. La *permutación por bloques* da un p más conservador y más fiel a la serie, y blinda el rescate por sub-ventana y por régimen frente a la autocorrelación.

Riesgo: bootstrap estacionario y Sharpe deflactado

El rescate de riesgo se mide sobre la diferencia de Sharpe pareada entre dos estrategias, ΔSR . No hay fórmula cerrada fiable para su distribución bajo dependencia temporal, así que la estimamos por remuestreo. El *bootstrap estacionario* de Politis y Romano remuestrea la serie en bloques contiguos de longitud aleatoria geométrica de media $\sqrt{n}$, lo que reproduce la autocorrelación de los retornos y mantiene estacionaria la serie remuestreada [63]. De cada réplica recalculamos ΔSR ; el conjunto de réplicas da la distribución de la que tomamos los intervalos percentiles. Un intervalo que excluye el cero señala un rescate de riesgo distinguible de cero. Es el caballo de batalla del riesgo en el panel: del pooled-10, de los estratos por régimen y de la diferencia en diferencias.

Un Sharpe alto obtenido tras probar muchas variantes puede ser un artefacto de la búsqueda. El *Deflated Sharpe Ratio* cuantifica ese riesgo [64]. Penaliza el Sharpe observado en función de cuántas configuraciones se ensayaron y de que los retornos tengan colas más anchas que la gaussiana, lo que vuelve más ruidoso al estimador de Sharpe de lo que sugiere su error estándar. La cifra que devuelve es una probabilidad de habilidad genuina, ya depurada de la inflación por búsqueda. Un Sharpe que sobrevive a la deflación es habilidad; uno que cae con ella, suerte de búsqueda.

Multiplicidad: Bonferroni y Holm

Contrastamos varias estrategias contra el mismo agente, y probar m hipótesis al nivel α infla la probabilidad de que alguna resulte significativa por azar. Las correcciones por multiplicidad controlan la *tasa de error por familia*, la probabilidad de al menos un falso positivo en el conjunto. La de *Bonferroni* es la más simple: exige $p < \alpha/m$ en cada contraste, o equivalentemente ensancha cada intervalo de confianza al nivel $1 - \alpha/m$ [65]. Es conservadora pero transparente. La aplicamos a los intervalos del $\Delta Sharpe$ pooled, donde la cota de Bonferroni decide qué estrategias sobreviven.

La corrección de *Holm* alcanza el mismo control con más potencia [66]. Ordena los p -valores de menor a mayor, $p_{(1)} \leq \dots \leq p_{(m)}$, y compara el i -ésimo contra el umbral $\alpha/(m - i + 1)$, deteniéndose en el primer no rechazo. Solo el contraste más extremo paga el factor pleno m ; los siguientes se relajan. Así Holm rechaza al menos tanto como Bonferroni sin perder la garantía. Con él reportamos el rescate por régimen, donde se contrasta más de una estrategia a la vez.

Equivalencia: el TOST

Los contrastes anteriores buscan diferencias; a veces la pregunta es la contraria, si dos estrategias son *prácticamente iguales*. No rechazar la nula de igualdad no demuestra equivalencia, porque puede deberse a falta de potencia. El contraste correcto invierte la carga de la prueba: es el *TOST* (*two one-sided tests*) de Schuirmann [67]. Se fija de antemano un margen de equivalencia δ y se toma como hipótesis nula que la diferencia cae *fuera* de $[-\delta, +\delta]$,

$$H_0 : |\Delta| \geq \delta \quad \text{frente a} \quad H_1 : |\Delta| < \delta.$$

Rechazarla obliga a descartar activamente las dos desviaciones relevantes, la inferior a $-\delta$ y la superior a $+\delta$. Solo si el intervalo de confianza de la diferencia aterriza por completo entre $-\delta$ y $+\delta$ concluimos equivalencia. La similitud se convierte así en un criterio activo que hay que ganar. Lo aplicamos a la pregunta de si el aprendiz redescubre o bate a la regla M8.

Asociación: Pearson y Spearman

La ley del *leverage* relaciona dos magnitudes continuas por activo: el rescate de accuracy del aprendiz y la firma del leverage effect. Para medir esa asociación usamos dos coeficientes de correlación. El de *Pearson* cuantifica la relación lineal; el de *Spearman*, la monótona, calculando Pearson sobre los rangos, lo que lo hace robusto a valores atípicos y a no linealidades que conserven el orden. El p -valor de cada uno sale del estadístico

$$t = r \sqrt{\frac{n-2}{1-r^2}},$$

que bajo la nula de correlación nula sigue una t de Student con $n-2$ grados de libertad. La p depende de n , y la muestra de esta ley es pequeña: $n=10$ activos. Por eso fijamos de antemano el nivel $\alpha=0,10$, pre-registrado, y reportamos la asociación como tendencia. Con diez puntos no perseguimos $p < 0,05$ ni robustez *leave-one-out*, que ese tamaño no sostiene.

Complementariedad: diferencia en diferencias

La última pregunta sobre el reparto de funciones es si dos aprendices rescatan en regímenes distintos: si uno aporta más en mercado alcista y el otro en bajista. Un solo ΔSharpe no la responde, porque mezcla el efecto del aprendiz con el del régimen. La aislamos con un contraste de *diferencia en diferencias* (DiD): tomamos la diferencia de Sharpe de cada aprendiz frente al agente en cada régimen y comparamos esas diferencias entre regímenes,

$$\Delta\Delta\text{SR} = (\text{SR}_{\text{alza}}^A - \text{SR}_{\text{alza}}^B) - (\text{SR}_{\text{baja}}^A - \text{SR}_{\text{baja}}^B).$$

Un $\Delta\Delta\text{SR}$ distinto de cero indica que el reparto de fuerzas entre los dos aprendices cambia con el régimen, esto es, que se complementan. Su intervalo de confianza sale del bootstrap estacionario de la Sección 3.3.3. Es un contraste propio sobre nuestras series pareadas, pre-registrado; toma el nombre del estimador de tratamiento de la econometría, pero no su maquinaria de identificación.

Interpretabilidad: valores de Shapley e importancia por permutación

La objeción central al aprendiz es si bate a STRATA o solo la redescubre. Para responderla atribuimos su predicción a cada característica de entrada con los *valores de Shapley*, que cuantifican la contribución de cada variable promediada sobre todos los subconjuntos posibles de predictores; es la idea que la teoría de juegos cooperativos de Shapley formalizó para repartir con justicia el resultado entre los jugadores [68]. Para los ensembles de árboles del trabajo, TreeSHAP explota la estructura del árbol para evitar la enumeración: en lugar de recalcularla contribución sobre cada subconjunto de variables, recorre los nodos una vez por observación y acumula los valores de Shapley en ese mismo recorrido, con un coste polinómico en el tamaño del árbol [69]. Definimos la *cuota STRATA* como la fracción de importancia que se llevan las siete features de los detectores,

$$\text{cuota STRATA} = \frac{\sum_{j \in \text{STRATA}} |\text{SHAP}_j|}{\sum_j |\text{SHAP}_j|},$$

el cociente entre la importancia media absoluta de las features de STRATA y la del total de las veintidós. Una cuota superior a un medio dice que el aprendiz se apoya mayoritariamente en las señales de los detectores.

Como verificación agnóstica al modelo añadimos la *importancia por permutación* [70]: se permuta al azar una característica, rompiendo su relación con la etiqueta, y se mide cuánto se degrada la métrica de validación; la caída es la importancia de esa variable. No depende de la estructura interna del modelo, y confirma desde fuera el reparto que da SHAP. Los dos métodos coinciden en señalar las features de STRATA como las informativas.

Agrupamiento: silueta, Rand y PCA

La parte exploratoria del panel pregunta si la naturaleza de los activos dibuja grupos. Agrupamos los diez activos por sus rasgos con cuatro algoritmos de familias distintas: *k*-medias [71], el enlace aglomerativo de Ward [72], las mezclas gaussianas [31] y el clustering espectral [73]. Que partan de principios distintos es lo que hace informativo su acuerdo.

Juzgamos la partición con tres herramientas. La *silueta* mide, para cada activo, su cohesión con el propio grupo frente a su separación del más cercano, en una escala de -1 a 1 ; una media alta indica grupos compactos y bien separados. El *BIC* (criterio de información bayesiano) fija el número de grupos y de componentes en las mezclas gaussianas, penalizando la verosimilitud por el número de parámetros para no partir la muestra en más grupos de los que sostiene [74]. El *índice de Rand ajustado* compara dos particiones corregido por la concordancia que se esperaría al azar: vale 1 cuando coinciden y ronda 0 cuando no se parecen más que por casualidad [75]. Un Rand de 1 entre los cuatro métodos es un consenso fuerte. Por último, el *PCA* (análisis de componentes principales) proyecta los rasgos sobre las direcciones de máxima varianza [76], lo que deja leer en pocos ejes el factor que separa los grupos.

Con la maquinaria de detección, intervención, aprendizaje y medición ya fijada, el capítulo siguiente lleva STRATA al caso de SPY y mide, paso a paso, si rescata al agente que pierde.

Capítulo 4

STRATA sobre SPY, paso a paso

El agente solo (M5) acierta sobre SPY el 0,366 de las direcciones y pierde dinero: ese es el punto de partida. Aquí ponemos a trabajar la maquinaria del capítulo 3 sobre el primer caso, el ETF del S&P 500. Es el activo que mejor deja ver el mecanismo, porque su *leverage effect* de índice amplio da al régimen contenido direccional (Sección 3.1.7). Sobre él construimos la cadena entera: la intervención y su anatomía, las seis estrategias que compiten y la atribución de lo que STRATA rescata.

4.1. Anatomía de una intervención

Antes de cualquier número fijamos el protocolo, porque de él depende que los resultados sean creíbles. La causalidad es la del capítulo 3, con `signal_lag = 1`: la posición del día t multiplica al retorno del día $t + 1$, nunca al del propio día. Calibramos los tres detectores una sola vez sobre 2000-01-01 a 2024-09-30, veinticuatro años, y cerramos sus umbrales antes de mirar la evaluación. La evaluación arranca el 2024-10-01, después del corte de conocimiento del modelo de lenguaje: así descartamos que el agente memorizara esas decisiones en su entrenamiento.

Dos ventanas conviven, y nunca las mezclamos. El OOS completo tiene $n = 401$ días y sirve a las estrategias que no entrenan: el agente, la regla y las dos referencias triviales. La ventana desplegable tiene $n = 251$ días, los que quedan tras un arranque de ciento cincuenta de *walk-forward* de origen rodante, y es la de las estrategias que entrenan día a día. En ese *walk-forward* usamos embargo = 1, coherente con un horizonte de etiqueta de un día (Tashman 2000 [59]; López de Prado 2018 [3]). Mantenerlas separadas es una condición de honestidad: comparar un modelo entrenado sobre 251 días con una regla evaluada sobre 401 sería mezclar peras y manzanas.

La Tabla 4.1 recoge cada decisión de calibración con su criterio. El número de estados del HMM, $K = 3$, sale de una selección de modelo ex ante: la log-verosimilitud held-out y el BIC mejoran al pasar de dos a tres estados y la tabla anota los dos valores. El orden de los tres estados justifica su uso sobre SPY: el más volátil tiene el retorno medio de calibración más bajo y el más tranquilo el más alto. Esa gradación negativa entre volatilidad y retorno vuelve el régimen un proxy de la dirección en un índice amplio (Rabiner 1989 [27]); los etiquetamos Calma, Estrés y Crisis. La volatilidad la modelamos con un GARCH(1,1) de innovaciones t

de Student, porque los retornos diarios de renta variable tienen más movimientos extremos de los que admite una normal (Bollerslev 1987 [40]). El cambio estructural lo seguimos con BOCPD: el detector mantiene una distribución sobre cuántos días lleva el agente sin cambiar de conducta y la actualiza con cada observación nueva, sin mirar el futuro (Adams y MacKay 2007 [42]). Los tres umbrales son cuantiles de la calibración, que la tabla detalla.

Tabla 4.1: Decisiones de calibración de STRATA sobre SPY, con su criterio de fijación. Todas se cierran sobre 2000-01-01 a 2024-09-30, antes de la evaluación. Fuente: `k_selection.json`, `cache/models/strata_thresholds.json`.

Decisión	Valor	Criterio (cita)
Estados del HMM	$K = 3$	held-out $-1,30 > -1,69$; BIC $18\,775 < 24\,131$ [27]
Volatilidad	GARCH(1,1)- t	colas pesadas de los retornos [40]
Cambio estructural	BOCPD <i>online</i>	causalidad de la alarma [42]
Umbral RAM	$\tau = 0,50$	voto de mayoría del régimen
Umbral PSA	$P_{95} = 0,023$	cuantil de calibración
Umbral GSO	$P_{95} = 2,371$	cuantil de calibración

El *leverage* de un activo lo medimos con la correlación de Black, $\text{lev} = \text{corr}(r_t, \text{RV}_{t+1}^{21} - \text{RV}_t^{21})$, entre el retorno de hoy y el cambio de la volatilidad realizada a veintidós días: es negativa cuando una caída eleva la volatilidad del día siguiente. La Figura 4.1 muestra los tres regímenes pintados sobre el precio de SPY. Una precisión gobierna toda la lectura: en la calibración el retorno del mismo día baja con el régimen, pero la fracción de días al alza del día siguiente ronda 0,5 incluso en Crisis. El régimen separa por volatilidad y coincide con la caída del mismo día, no anticipa el signo de mañana.



Figura 4.1: Regímenes del HMM ($K = 3$) sobre el precio de SPY en el periodo de evaluación. Calma (volatilidad baja, retorno medio positivo), Estrés (intermedio) y Crisis (volatilidad alta, retorno medio negativo) ordenan por la firma del *leverage effect*. El sombreado marca el régimen vigente cada día; la coincidencia régimen $\leftrightarrow$ caída es contemporánea, no predictiva. Fuente: `regime_direction_table.json`.

Los tres detectores miran ejes ortogonales de la decisión del agente. RAM lee el régimen y comprueba si la dirección de la apuesta concuerda con el estado vigente: su *score* es la probabilidad que el HMM pone en que el agente apuesta contra el régimen, y dispara cuando $\text{RAM}_t \geq \tau = 0,50$. PSA vigila con BOCPD si el agente cambia de criterio de forma estructural (Adams y MacKay 2007 [42]). GSO contrasta el tamaño de la posición con la volatilidad del GARCH (Bollerslev 1986 [37]). Cuando RAM dispara, la intervención reorienta la posición al signo del régimen, fijado por un prior calibrado por activo a partir de la media del retorno de cada estado, nunca por una regla del tipo “Crisis implica corto” escrita a mano.

Sobre SPY actúa una sola supervisión (Tabla 4.2). RAM dispara casi un tercio de los días y acierta más al intervenir que el agente al que corrige; PSA dispara dos días y GSO ninguno. El motivo es que el agente mantiene una posición casi constante sobre SPY, corta la mayor parte de los días, de modo que sus *scores* de cambio y de tamaño quedan por debajo de los umbrales de calibración. PSA y GSO son detectores inertes como reglas sobre este activo, un hallazgo que registramos. La atribución de P&L cierra la lectura: todo el rescate acumulado sale de los días en que RAM dispara, y PSA y GSO aportan exactamente cero.

Tabla 4.2: Actividad de los tres detectores sobre el OOS completo de SPY ($n = 401$ días). “Acierto” es la fracción de direcciones correctas en los días en que el detector dispara; el P&L de rescate es el acumulado de la intervención en esos días. PSA y GSO apenas disparan: su columna de acierto no aplica. Fuente: `spy_intervention_anatomy.json`.

Detector	Tasa de disparo	Acierto M8	Acierto M5	P&L de rescate
RAM (régimen)	30,2 %	0,587	0,413	+0,312
PSA (cambio estructural)	0,5 %	—	—	0,000
GSO (volatilidad)	0,0 %	—	—	0,000

Que RAM acierte al intervenir no es casualidad, y la Figura 4.2 lo deja ver. En los días en que RAM está alto, seguir el régimen bate a seguir al agente; cuando RAM está bajo, la ventaja se diluye y la intervención no se activa. El detector funciona como una compuerta: deja pasar la decisión del agente salvo cuando choca con el régimen, y solo entonces la corrige. En SPY esa compuerta es todo el mecanismo de la regla, porque el canal de régimen es el único que se enciende.




Figura 4.2: Distribución de los *scores* de RAM, PSA y GSO sobre el OOS de SPY, con su umbral de disparo marcado (RAM $\tau = 0,50$, PSA $P_{95} = 0,023$, GSO $P_{95} = 2,371$). El *score* de RAM es bimodal y cruza el umbral con frecuencia; los de PSA y GSO se acumulan muy por debajo del suyo, de ahí que apenas disparan. Fuente: `spy_intervention_variants.json`.

La intervención puede ejecutarse de tres maneras, y la elección no es cosmética. Puede abstenerse los días dudosos cerrando la posición, reducir el tamaño a la mitad, o reorientar la dirección al signo del régimen, el modo que llamamos *override*. La Tabla 4.3 compara los tres sobre los días en mercado ($n = 232$). El *override*, que adoptamos como modo canónico, gana en acierto y en Sharpe; abstenerse y reducir apenas se distinguen del agente sin tocar. El valor está en corregir activamente la dirección cuando choca con el régimen, no en limitarse a evitar el riesgo.

La anatomía de esas intervenciones está en la matriz de confusión de la Figura 4.3: unas corrigen al agente cuando apostaba contra el régimen, otras meten ruido cuando el agente tenía razón. El saldo neto es positivo porque la intervención no es indiscriminada: crece con la

Tabla 4.3: Modos de intervención de M8 sobre SPY (días en mercado, $n = 232$). El modo canónico (*override*) reorienta la posición al signo del régimen; las alternativas se abstienen o reducen el tamaño. En negrita, el modo adoptado. Fuente: `spy_intervention_variants.json`.

Modo	Accuracy	Sharpe	Capital
Override (canónico)	0,478	−0,46	0,94×
Abstención	0,401	−2,10	0,81×
Reducir a la mitad	0,397	−2,75	0,75×
M5 (agente sin tocar)	0,397	−3,07	0,70×

discrepancia entre la apuesta del agente y el signo del régimen. Cuanto más se aleja el agente del estado del mercado, con más fuerza actúa la regla, y son justo esos días de discrepancia grande los que aportan el grueso del rescate.




Figura 4.3: Matriz de confusión de la intervención sobre SPY: dirección del agente (M5) frente a dirección tras intervenir (M8), sobre las 121 intervenciones. La diagonal de rescate (71 aciertos de la intervención cuando el agente fallaba) supera a la de daño (50). Fuente: `spy_intervention_anatomy.json`.

4.2. Seis estrategias frente al agente

Sobre el agente comparamos seis estrategias. M5 es el agente sin supervisar. M8 es la regla determinista de la intervención. M10 es el meta-learner, un ensemble de diez XGBoost sobre las veintidós características del agente y de STRATA. AutoML deja que H2O busque por reentrenamiento entre GBM, XGBoost y su apilamiento. Las dos referencias triviales son comprar y mantener (B&H) y la clase mayoritaria del pasado (ZeroR): marcan el listón que cualquier

pretensión de habilidad debe superar. La Tabla 4.4 las reúne sobre la ventana desplegable.

Tabla 4.4: Las seis estrategias sobre SPY, ventana desplegable ($n = 251$, `signal_lag = 1`). Accuracy direccional, Sharpe anualizado, máxima caída, ratio de Calmar (Young 1991 [58]) y capital final por euro invertido. En negrita, la mejor en cada columna. Fuente: `automl_runs/panel_mm25_inclGBM-XGB-SE_AUC_emb1_N0-150_step21_kfold_seed42.json`.

Estrategia	Accuracy	Sharpe	Máx. caída	Calmar	Capital
AutoML (búsqueda H2O)	0,574	+2,68	−5,5 %	6,93	1,38×
ZeroR (clase mayoritaria)	0,566	+2,21	−9,8 %	3,10	1,30×
B&H (comprar y mantener)	0,566	+2,21	−9,8 %	3,10	1,30×
M10 (meta-learner XGBoost)	0,494	−0,60	−16,1 %	−0,50	0,92×
M8 (regla STRATA)	0,442	−0,46	−15,2 %	−0,39	0,94×
M5 (agente solo)	0,366	−3,07	−30,2 %	−1,00	0,70×

Leída de abajo arriba, la tabla es una escalera: cada capa rescata a la anterior. La regla recupera al agente y le recorta a la mitad la máxima caída; el meta-learner sube otro escalón en accuracy; AutoML llega arriba y gana en todas las columnas, también a las dos triviales. El rescate es significativo en los tres casos, contrastado con el McNemar pareado sobre los aciertos diarios frente al agente (McNemar 1947 [62]). Los tres rescatan al agente, y el rescate aguanta el test.

La victoria sobre la trivial pide un matiz. El mismo McNemar de AutoML frente a ZeroR no separa a las dos: no hay potencia en una ventana de doscientos cincuenta días. La ventaja de AutoML sobre el mercado pasivo es real en punto pero nominal en significancia, y tiene una explicación económica: SPY es mayormente beta de mercado, el periodo de evaluación fue alcista, e ir largo capturó esa subida. La Figura 4.4 hace visible la diferencia, y el Sharpe deflactado (López de Prado 2018 [3]; Bailey y López de Prado 2014 [64]) la pone en contexto. El DSR confirma esa lectura: solo el de AutoML se acerca a uno, mientras los de M10 y el agente quedan pegados a cero. AutoML es el único de los modelos cuyo Sharpe sobrevive al ajuste por número de pruebas.




Figura 4.4: Curvas de capital de las seis estrategias sobre SPY (ventana desplegable, $n = 251$ días, un euro inicial). AutoML (línea destacada) supera a las dos referencias triviales en Sharpe (+2,68 frente a +2,21), en máxima caída (−5,5 % frente a −9,8 %) y en capital final (1,38× frente a 1,30×); el agente solo (M5) termina en 0,70×. La ventaja sobre la trivial es nominal (McNemar AutoML vs ZeroR $p = 0,90$). Fuente: `automl_net_returns.json`.

Hay un resultado en riesgo que no alcanza significancia a este nivel. Sobre un único activo, el intervalo de confianza del Δ Sharpe de la regla frente al agente cruza el cero: el rescate de

riesgo de SPY visto en solitario no se distingue de cero. El panel de diez activos, en el capítulo siguiente, da la prueba dura de ese rescate en riesgo.

4.3. Qué rescata STRATA

Ya vimos que sobre SPY el rescate sale por un solo canal, el del régimen (Sección 4.1). Queda una pregunta distinta: ¿usa de verdad el aprendiz las señales de STRATA, o gana por otro lado? La ablación lo responde. Al quitar PSA y GSO de las características, la accuracy de AutoML baja (Tabla 4.5): aunque PSA y GSO casi no disparen como reglas, sus *scores* continuos informan al modelo. Las características de Shapley (Lundberg y Lee 2017 [68]) lo confirman, y aquí etiquetamos cada cuota con su modelo y su ventana porque no son el mismo objeto. Sobre el ensemble M10 ($n = 251$), la cuota de las features de STRATA es 0,71. Sobre el *leader* de AutoML ($n = 401$, otro modelo y otra ventana), es 0,565 por árbol y 0,564 por permutación. Las dos cuotas superan la mitad y colocan los detectores por delante de las características del propio agente.

Tabla 4.5: Ablación de detectores sobre SPY (ventana desplegable, $n = 251$). El conjunto canónico usa las veintidós características; “sin PSA+GSO” deja solo el canal de régimen entre los detectores. AutoML degrada al quitar PSA+GSO, prueba de que usa sus *scores*. Fuente: `automl_ablation_detectors.json`, `detector_ablation_panel.json`.

Conjunto de características	Accuracy AutoML	Accuracy M10
ALL22 (canónico)	0,574	0,494
sin PSA+GSO	0,550	0,514

La objeción más natural es que los umbrales se eligieran para que el resultado saliera bien. El barrido completo lo descarta (Figura 4.5). La accuracy de M8 frente al umbral RAM es plana en una meseta a partir del valor canónico, sin saltos; la del meta-learner frente a su umbral de decisión también es plana en torno a 0,50. El resultado no cuelga de un punto afortunado del espacio de hiperparámetros: descansa sobre una región estable, lo contrario de un ajuste fino al periodo de evaluación. Esta meseta es nuestra mejor defensa frente a la sospecha de sobreajuste.




Figura 4.5: Sensibilidad de la accuracy al umbral de decisión sobre SPY: M8 frente a τ del detector RAM y M10 frente a su umbral de probabilidad. Las dos curvas son planas en una meseta alrededor del valor canónico (marcado), señal de robustez y no de ajuste a un punto. Fuente: `psa_gso_threshold_sensitivity.json`.

Sobre SPY el mecanismo es transparente y el agente, solo, pierde con holgura. La intervención por régimen lo corrige de forma significativa, la derivada aprendida supera a la trivial en

este punto apoyándose en las señales de STRATA, y todo descansa sobre una meseta robusta de umbrales. A nivel de un único activo, sin embargo, la corrección de riesgo no alcanza significancia y la victoria sobre la trivial es nominal. Queda la pregunta que ordena el resto del trabajo: ¿se sostiene el rescate fuera de SPY? El panel de diez activos es el siguiente paso.

Capítulo 5

¿Se generaliza? El panel de diez activos

En SPY STRATA rescató al agente, pero el riesgo dejó una pregunta abierta. Sobre un único activo el intervalo de confianza del Δ Sharpe del rescate cruzaba el cero: la corrección apuntaba en la dirección buena, mas no llegaba a separarse del cero en solitario. Un activo enseña la mecánica y no prueba nada. La prueba dura vive en el panel: diez activos (SPY, QQQ, XLF, DIA, XLK, XLE, ROKU, SMCI, MARA, UNG), elegidos por su naturaleza para cubrir distintos grados de *leverage effect*. Sobre ellos repetimos toda la cadena de SPY, agregamos los resultados y buscamos el patrón que ordena el rescate. Al apilar el panel, el rescate de riesgo que en un activo no alcanzaba significancia la alcanza.

5.1. Rescate agregado: pooled, equivalencia, complementariedad

El problema que vimos en SPY no es de SPY. A través del panel el agente pierde y acierta menos de la mitad de las direcciones con regularidad: queda por debajo de 0,5 en siete de los diez activos, y allí donde lo supera lo hace por poco y con un Sharpe pobre. El agente solo no es una estrategia, es el punto de partida que STRATA tiene que corregir.

5.1.1. La compuerta de régimen y la activación de detectores

Los tres detectores no se encienden por igual en cada activo. RAM domina en todas partes, igual que en SPY: es el canal que lee el régimen y el que carga con el rescate. PSA y GSO disparan poco, porque el agente mantiene posiciones casi constantes y sus *scores* de cambio y de tamaño rara vez cruzan los umbrales de calibración. La Tabla 5.1 recoge la tasa de intervención por activo y la compuerta de régimen. El gate RAM es la lectura que importa: en los días en que RAM dispara, seguir el signo del régimen bate a seguir al agente en **seis de los diez** activos. La intervención no se reparte al azar. Su tasa crece con la discrepancia entre la apuesta del agente y el signo del régimen, y esa relación es casi recta (Figura 5.1).

La compuerta de régimen que vimos en SPY (Sección 4.1) gobierna también el panel. Que la actividad de la regla escale con la discrepancia confirma que la intervención está dirigida: actúa donde el agente y el mercado se contradicen y permanece inactiva donde coinciden.

Tabla 5.1: Activación de RAM y compuerta de régimen por activo (OOS completo del panel). “Tasa interv.” es la fracción de días en que RAM dispara; “discrepancia” es la fracción de días en que la apuesta del agente choca con el signo del régimen; “gate RAM” indica si, en los días de disparo, seguir el régimen bate a seguir al agente. PSA y GSO disparan de forma marginal en todo el panel. Fuente: `spy_panel_gate_descriptive.json`, `mechanism_panel.json`.

Activo	Tasa interv. (RAM)	Discrepancia agente↔régimen	Gate RAM
SPY	0,302	0,601	régimen > agente
QQQ	0,197	0,526	régimen > agente
XLF	0,549	0,720	régimen > agente
DIA	0,343	0,603	agente > régimen
XLK	0,095	0,372	agente > régimen
XLE	0,596	0,781	régimen > agente
ROKU	0,710	0,823	régimen > agente
SMCI	0,018	0,120	régimen > agente
MARA	0,415	0,666	agente > régimen
UNG	0,078	0,169	agente > régimen




Figura 5.1: Compuerta de régimen sobre el panel: tasa de intervención de RAM frente a la discrepancia media entre la apuesta del agente y el signo del régimen, un punto por activo. La relación es casi recta (Pearson $r = 0,93$, $p < 0,001$): cuanto más se aleja el agente del estado del mercado, con más frecuencia actúa la regla. Fuente: `spy_panel_gate_descriptive.json`.

5.1.2. Accuracy por activo: dónde se bate a la trivial

La Tabla 5.2 cruza los diez activos con las seis estrategias en accuracy direccional. La primera lectura es contundente: la mejor derivada de STRATA mejora al agente en los **diez de diez** activos, con una mejora media de accuracy de +0,086. No hay ningún activo en el que supervisar al agente lo empeore. Qué estrategia gana cambia de un activo a otro, coherente con la idea de dos capas: en unos manda la regla, en otros el aprendiz, según la naturaleza del activo.

Tabla 5.2: Accuracy direccional por activo y estrategia (ventana desplegable, `signal_lag = 1`). En negrita, la mejor derivada de STRATA (M8/M10/AutoML) cuando supera a las dos referencias triviales (ZeroR y B&H) en ese activo. ZeroR y B&H comparten valor salvo cuando difieren. Fuente: `automl_runs/panel_mm25_inclGBM-XGB-SE_AUC_emb1_NO-150_step21_kfold_seed42.json`.

Activo	M5	M8	M10	AutoML	ZeroR	B&H
SPY	0,366	0,442	0,494	0,574	0,566	0,566
QQQ	0,418	0,486	0,522	0,534	0,590	0,590
XLFF	0,429	0,502	0,526	0,510	0,538	0,538
DIA	0,440	0,484	0,468	0,520	0,552	0,556
XLK	0,510	0,470	0,542	0,590	0,641	0,641
XLE	0,448	0,528	0,508	0,532	0,565	0,565
ROKU	0,444	0,528	0,508	0,544	0,548	0,548
SMCI	0,484	0,496	0,552	0,472	0,516	0,484
MARA	0,528	0,528	0,532	0,544	0,532	0,468
UNG	0,510	0,502	0,518	0,482	0,449	0,486

En cuatro activos una derivada de STRATA supera en punto a las dos referencias triviales a la vez: SPY y MARA por AutoML, SMCI y UNG por M10 (Tabla 5.2, celdas en negrita). En los seis restantes la trivial aguanta; en índices muy direccionales como XLK la clase mayoritaria del pasado se va por encima de 0,64 y ninguna derivada se le acerca.

Estas victorias son reales en punto, y son nominales. La ventana desplegable tiene del orden de doscientos cincuenta días por activo, y la estrategia ganadora cambia de un activo a otro, de modo que se eligen a posteriori. **Ninguna bate a ZeroR con significancia:** el McNemar pareado de AutoML frente a ZeroR sobre SPY da $p = 0,90$, sin potencia para separarlos. El punto es parte del valor; el límite es que no sobrevive a un test. La Figura 5.2 hace visible el mapa completo: el color mide la distancia a la trivial, y solo cuatro celdas de derivada se tiñen del lado bueno.

STRATA rescata al agente en los diez activos, y en cuatro la derivada le gana en punto a las dos referencias triviales, sobre todo en los de *leverage* débil o invertido. La ventaja sobre la trivial es nominal, no significativa, y la ganadora no es la misma en todas partes. La prueba que sí sobrevive a un test vive en el riesgo, no en la accuracy frente a la trivial.

5.1.3. Pooled-10: el rescate en riesgo

La salida es agregar. Apilamos los días de los diez activos (*pooled-10*, $n = 2493$ días) y medimos el Δ Sharpe pareado frente a M5 con un *bootstrap* estacionario (Politis y Romano



Figura 5.2: Mapa de calor de la accuracy direccional por activo (filas) y estrategia (columnas), centrado en 0,5: el color mide la distancia a una referencia trivial. Verde marca accuracy por encima de la trivial del activo, rojo por debajo. La mejor derivada de STRATA supera a las dos triviales solo en SPY, SMCI, MARA y UNG; en los demás la trivial aguanta. Victorias nominales ($n \approx 250$, a posteriori). Fuente: `automl_runs/panel_mm25_inclGBM-XGB-SE_AUC_emb1_N0-150_step21_kfold_seed42.json`.

1994 [63]). Para que la dependencia temporal no infle la confianza no remuestreamos días sueltos: tomamos tramos con un inicio al azar y una longitud variable, de media $\sqrt{n}$ por la regla heurística habitual para series de este tamaño, así los días vecinos siguen juntos. La Tabla 5.3 reúne las tres estrategias supervisadas.

Las tres rescatan al agente en riesgo, y las tres excluyen el cero con su intervalo simple (Tabla 5.3): tanto la regla como los dos aprendices dejan un ΔSharpe positivo cuyo límite inferior queda por encima de cero. Esa es la afirmación que el caso SPY no podía sostener en solitario: agregado el panel, el rescate de riesgo es estadísticamente distinguible de cero.

Tabla 5.3: Rescate en riesgo agregado (*pooled-10*, $n = 2493$ días): ΔSharpe de cada estrategia supervisada frente al agente M5, con intervalo de confianza al 95 % por *bootstrap* estacionario de bloque medio $\sqrt{n}$ (Politis y Romano 1994). La columna de Bonferroni aplica la cota inferior corregida por $m = 3$ comparaciones (López de Prado 2018): un ΔSharpe pasa si su cota inferior corregida supera cero. M10 y AutoML pasan; M8 no. Fuente: `bullbear_confirmatory.json` (bloque POOLED10).

Estrategia	ΔSharpe	IC_{95}	Cota inf. Bonferroni	¿Pasa?
M8 (regla)	+0,60	[0,05, 1,22]	-0,047	no
M10 (meta-learner)	+1,12	[0,39, 1,84]	+0,258	sí
AutoML (H2O)	+1,08	[0,40, 1,85]	+0,261	sí

La corrección por multiplicidad mete un matiz. Comparamos tres estrategias contra el mismo agente, así que el intervalo de cada una debe corregirse por las $m = 3$ pruebas para no inflar la confianza (López de Prado 2018 [3]). Bajo la cota de Bonferroni, M10 y AutoML siguen pasando; la regla M8 cae justo por debajo de cero y no pasa. La regla rescata el riesgo en punto y con intervalo simple, pero su ventaja no sobrevive a la corrección por número de pruebas; los aprendices sí. La Figura 5.3 lo dibuja: M8 toca el cero bajo Bonferroni mientras

M10 y AutoML se mantienen del lado bueno.




Figura 5.3: Diagrama de bosque del Δ Sharpe *pooled-10* frente al agente M5, con intervalo al 95 % (*bootstrap* estacionario, Politis y Romano 1994) y cota inferior corregida por Bonferroni ($m = 3$). La línea vertical marca el cero. Los tres intervalos simples excluyen el cero; bajo Bonferroni, M10 y AutoML se mantienen positivos y M8 toca el cero (cota inferior $-0,047$). Fuente: `bullbear_confirmatory.json` (bloque POOLED10).

Una cautela sobre el agregado. El *pooled* apila los días de los diez activos como si fueran independientes, y no lo son: la correlación cruzada entre índices es alta, con SPY y QQQ por encima de 0,9. Eso reduce el tamaño de muestra efectivo por debajo del nominal y deja el intervalo algo optimista. El bloque medio $\sqrt{n}$ del *bootstrap* amortigua parte del efecto, porque remuestrea bloques contiguos en lugar de días sueltos, pero el intervalo *pooled* debe leerse con esa cautela. Aun así, el rescate de la regla excluye el cero en el intervalo simple, y los aprendices lo hacen también bajo Bonferroni.

La Figura 5.4 traslada el riesgo a la economía, una curva de capital por activo con la ganadora destacada. En cuatro activos una derivada de STRATA bate al pasivo en Sharpe: SPY, SMCI, MARA y UNG. La lectura razonada separa dos casos. En SMCI, MARA y UNG el pasivo pierde o ronda el cero, y la derivada saca un Sharpe positivo claro yendo defensiva en el momento bueno: ahí la ventaja parece valor direccional, porque no viene de estar largo en una subida. En SPY la cosa es distinta. El periodo fue alcista y SPY es mayormente beta de mercado, así que el Sharpe positivo refleja sobre todo la exposición al índice más que una dirección acertada. Distinguir las dos cosas exige un contraste que no hacemos aquí; queda como lectura, no como afirmación.

5.1.4. Equivalencia: el aprendiz redescubre STRATA y bate a la regla

Si el aprendiz mejora a la regla, la pregunta es de qué se está alimentando. La respuesta es que se apoya en los detectores de STRATA. Las cuotas de Shapley (Lundberg y Lee 2017 [68]) miden cuánto del juicio del aprendiz descansa en cada bloque de características; la cuota de las features de STRATA supera la mitad en los **diez de diez** activos, con una media de 0,66. El aprendiz no inventa una señal nueva: redescubre los detectores que diseñamos a mano y los pondera por encima de las características del propio agente.

Que se apoye en STRATA no quiere decir que solo replique la regla. El contraste lo da el TOST de Schuirmann (1987) [67]. Al revés que un test de superioridad, parte de que las dos estrategias son distintas y solo concede equivalencia si la evidencia de parecido es fuerte: fijado




Figura 5.4: Curvas de capital por activo (un euro inicial), con la mejor derivada de STRATA destacada frente a las referencias. En cuatro activos una derivada bate al pasivo en Sharpe: SPY, SMCI, MARA y UNG. En SMCI/MARA/UNG el pasivo pierde o ronda el cero y la derivada saca Sharpe positivo yendo defensiva (lectura de valor direccional); en SPY la ventaja es sobre todo beta de mercado en un periodo alcista. Lectura sin contraste asociado. Fuente: `automl_net_returns.json`.

un margen δ , exigimos rechazar por los dos lados a la vez, y basta que un lado no rechace para que no haya equivalencia. La Tabla 5.4 lo aplica al aprendiz frente a la regla M8. En accuracy no hay equivalencia, y el desempate va para el aprendiz: tanto M10 como AutoML superan a la regla con un intervalo al 90 % por encima de cero. En Sharpe el TOST es no concluyente: aprendiz y regla son indistinguibles en riesgo, ninguno domina al otro. El mecanismo de la diferencia es claro. La regla M8 es una compuerta fija sobre el régimen; el aprendiz modela interacciones no lineales entre régimen y agente que la regla no alcanza, y de ahí saca el punto extra de accuracy.

Tabla 5.4: TOST del aprendiz frente a la regla M8 (Schuirmann 1987) y cuota de Shapley de las features de STRATA por activo (Lundberg y Lee 2017). En accuracy el aprendiz supera a la regla (intervalo al 90 % por encima de cero); en Sharpe el test es no concluyente (indistinguibles). La cuota SHAP de STRATA supera 0,5 en los diez activos. Fuente: TOST de `equivalence_tost.json`; cuota SHAP de `decision_automl_prep.json`.

Comparación	Δ accuracy (IC ₉₀)	TOST Sharpe	Cuota SHAP STRATA
M10 vs M8	+0,021 [+0,001, +0,039]	no concluyente	> 0,5 en 10/10 (media 0,66)
AutoML vs M8	+0,034 [+0,010, +0,056]	no concluyente	

El aprendiz deja, entonces, dos hechos atados con su test. Se apoya en STRATA, con cuota SHAP mayoritaria en los diez activos, lo que descarta que gane por otro lado. Y bate modestamente a la regla en accuracy sin distinguirse de ella en riesgo. El reparto de funciones queda fijado: la regla protege el riesgo y el aprendiz afina la dirección, ambos sobre las mismas señales. La Tabla 5.5 y la Figura 5.6 cierran ese reparto sobre el panel.

5.1.5. Complementariedad: bull, bear y diferencia en diferencias

Un rescate que solo funcionara en mercado alcista no serviría de mucho, porque el régimen peligroso es el bajista. Partimos el panel por régimen y medimos el rescate en cada mitad con el McNemar pooled de la estrategia superior frente al agente, corrigiendo por Holm las




Figura 5.5: Diagrama 2×2 del TOST del aprendiz frente a la regla M8, ejes accuracy (horizontal) y Sharpe (vertical). Las regiones marcan superioridad, equivalencia y no concluyencia. M10 y AutoML caen en superioridad en accuracy y en no concluyencia en Sharpe: el aprendiz afina la dirección sobre la regla y empata en riesgo. Fuente: `equivalence_tost.json`.

Tabla 5.5: Atribución por capa sobre el panel de diez activos. La regla (M8) aporta el rescate de riesgo y la totalidad de su P&L de rescate viene del canal de régimen (RAM); nunca lidera en accuracy. El aprendiz (M10/AutoML) aporta el rescate de accuracy y no lidera el riesgo en exclusiva. Δ Sharpe pooled frente al agente, IC_{95} por bootstrap estacionario. Fuente: `bullbear_confirmatory.json` (P00LED10), `spy_intervention_anatomy.json`.

	Regla (M8)	Aprendiz (M10/AutoML)
Eje que rescata	riesgo	accuracy
Δ Sharpe pooled vs M5	+0,60 [0,05, 1,22]	+1,12 / +1,08
P&L de rescate (SPY)	+0,312 (100 % RAM)	—
Lidera en accuracy	0/10	10/10
Significancia accuracy (McNemar)	al borde	significativa




Figura 5.6: Reparto de funciones entre las dos capas. A la izquierda, atribución del P&L de rescate por detector sobre SPY: el canal de régimen (RAM) concentra el 100 %, PSA y GSO aportan cero. A la derecha, evolución diaria del rescate de la regla (riesgo, Δ Sharpe acumulado) frente al del aprendiz (accuracy, aciertos acumulados sobre el agente): cada serie sube por un eje distinto. Fuente: `spy_intervention_anatomy.json`, `bullbear_confirmatory.json`.

comparaciones múltiples (Holm 1979 [66]). El rescate aparece en los dos regímenes (Tabla 5.6). En mercado alcista los dos aprendices rescatan de forma significativa y la regla M8 queda al borde; en mercado bajista los tres pasan, con la regla ya holgadamente dentro. El rescate no es de un solo régimen: sobrevive en los dos.

Tabla 5.6: Rescate por régimen (McNemar pooled de la estrategia superior frente a M5, p corregido por Holm 1979) y complementariedad de los aprendices (DiD). El rescate es significativo en alcista y en bajista. El DiD contrasta el $\Delta\Delta\text{Sharpe}$ entre aprendices y regímenes: M10 rescata más en alcista, AutoML más en bajista. Fuente: `bullbear_confirmatory.json`, `regime_did_learners.json`.

	M8	M10	AutoML
McNemar alcista (Holm p)	0,099	0,0076	0,0092
McNemar bajista (Holm p)	0,0092	0,0268	0,0017
DiD complementariedad: $\Delta\Delta\text{Sharpe}$ pooled = +1,37, IC_{95} [0,20, 2,60], $p = 0,008$			

Los dos aprendices no rescatan igual en cada régimen, y eso abre una vía. M10 protege más en alcista, AutoML más en bajista. Para contrastar si ese reparto es real y no ruido construimos un test de diferencia en diferencias, pre-registrado antes de mirar resultados: comparamos la diferencia de ΔSharpe entre los dos aprendices entre los dos regímenes, de modo que cualquier efecto común a ambos se cancela y queda solo la complementariedad. El $\Delta\Delta\text{Sharpe}$ pooled excluye el cero (Tabla 5.6): la complementariedad por régimen es significativa sobre el panel. La Figura 5.7 la dibuja: AutoML cubre el régimen peligroso, M10 el favorable.




Figura 5.7: Complementariedad de los aprendices por régimen: ΔSharpe de M10 y de AutoML frente al agente, en alcista y en bajista. M10 rescata más en alcista, AutoML más en bajista; el contraste de diferencia en diferencias del reparto da $\Delta\Delta\text{Sharpe} = +1,37$, IC_{95} [0,20, 2,60], $p = 0,008$ (pooled; no significativo en SPY solo). Fuente: `regime_did_learners.json`.

Queda la falsación que pre-registramos, y el panel la resuelve. A nivel de SPY solo, en régimen bajista la regla M8 se invierte: sobre los cincuenta días bajistas de SPY su ΔSharpe es $-1,49$, es decir, ahí la regla daña en vez de rescatar. Es exactamente el tipo de fragilidad que un activo único puede esconder o magnificar con cincuenta observaciones. La agregación del panel la resuelve: sobre los diez activos el rescate por régimen es significativo en bajista, y la complementariedad DiD también lo es solo en *pooled*, no en SPY aislado. El fenómeno es de panel, no de un activo, y por eso la prueba vive en la agregación.

Agregado el panel, el rescate deja de ser una anécdota de SPY. El ΔSharpe *pooled-10* excluye el cero para los tres modelos y dos de ellos sobreviven a Bonferroni, así que el rescate de riesgo es significativo; en accuracy el aprendiz mejora al agente en los diez activos y bate modestamente a la regla, con cuota SHAP mayoritaria. Y los dos aprendices se complementan

por régimen. Queda el porqué del reparto por activo: por qué unos se rescatan por régimen y otros por el aprendiz. La respuesta está en la naturaleza del activo.

5.2. El patrón: ley del leverage y clustering

La sección anterior deja un hecho sin explicar: qué canal rescata cada activo cambia de uno a otro. La propiedad que ordena el rescate del aprendiz resulta ser el *leverage effect*, y un clustering sin etiquetas recupera los mismos grupos que esa propiedad dibuja. Sobre diez activos esto es un patrón, no un teorema.

5.2.1. La ley del *leverage*

El rescate del aprendiz en accuracy escala con el *leverage effect* del activo. Medimos el rescate como la mejora de accuracy del mejor aprendiz sobre el agente, $\text{máx}(\text{M10}, \text{AutoML}) - \text{M5}$, y la naturaleza del activo con la correlación de Black,

$$\text{leverage_corr} = \text{corr}(r_t, \text{RV}_{t+1}^{21} - \text{RV}_t^{21}),$$

entre el retorno de hoy y el cambio de la volatilidad realizada a veintiún días (Black 1976 [24]; Christie 1982 [25]). Es negativa cuando una caída eleva la volatilidad de mañana, la firma del *leverage* estándar.

Las dos magnitudes corren juntas: a más *leverage* negativo, más rescate del aprendiz (Tabla 5.7, Figura 5.8). La correlación es fuerte y la tendencia es significativa al nivel $\alpha = 0,10$ que el proyecto fijó de antemano. Nueve de los diez activos la siguen; ROKU es la única excepción, con *leverage* casi nulo y un rescate alto. Partido el panel en dos, los activos de *leverage* fuerte reciben un rescate medio mayor que los de *leverage* débil. El mecanismo es el de la Sección 5.1.3: cuando el régimen es direccional (*leverage* estándar) la regla ya disciplina el riesgo y al aprendiz le queda margen para afinar la dirección; cuando el régimen no informa el signo, el aprendiz rescata por otra vía y la ganancia se estrecha.

Con $n = 10$ no afirmamos $p < 0,05$ ni robustez *leave-one-out*: la correlación es fuerte, pero el test con diez puntos es poco potente, y por eso la presentamos como tendencia al $\alpha = 0,10$, no como ley exacta. Una segunda cautela es de dirección. La naturaleza del activo ordena el rescate del *aprendiz*, pero no predice el valor de la *regla*: ninguna propiedad de la naturaleza (*crisis_mean*, *leverage* o sesgo del agente) correlaciona con el rescate de la regla a ningún nivel razonable (todas con $p > 0,14$). El *crisis_mean* es descriptivo, no ley. La única ley del rescate es la del *leverage* sobre el aprendiz.

5.2.2. Clustering: la naturaleza dibuja los grupos

La ley del *leverage* es una recta. Queda ver si esa misma estructura aparece cuando no le decimos al algoritmo qué buscar. Sí aparece: agrupar los diez activos por su naturaleza recupera los mismos bloques que el rescate dibuja, sin ver ni una métrica de rescate. Describimos cada activo por cinco rasgos de naturaleza (*leverage*, retorno medio en Crisis, fracción de días en Crisis, volatilidad OOS y sesgo direccional del agente) y lo agrupamos con cuatro métodos:

Tabla 5.7: Ley del *leverage*: correlación de Black y rescate del aprendiz por activo (panel de diez), ordenados por *leverage* creciente. Rescate = $\max(\text{M10}, \text{AutoML}) - \text{M5}$ en accuracy. Nueve de los diez siguen la tendencia (a más *leverage* negativo, más rescate); ROKU es la excepción. Sobre los diez: Pearson $r = -0,56$ ($p = 0,093$), Spearman $\rho = -0,59$ ($p = 0,074$); tendencia significativa al $\alpha = 0,10$ pre-registrado. Fuente: `leverage_low_panel10.json`.

Activo	<code>leverage_corr</code>	Rescate aprendiz
DIA	-0,112	0,080
SPY	-0,110	0,207
QQQ	-0,092	0,116
XLF	-0,091	0,097
XLE	-0,089	0,085
XLK	-0,086	0,080
MARA	-0,059	0,016
SMCI	-0,004	0,068
ROKU	+0,003	0,100 (excepción)
UNG	+0,041	0,008
<i>leverage</i> fuerte (media)		0,097
<i>leverage</i> débil (media)		0,059




Figura 5.8: Rescate del aprendiz en accuracy frente al *leverage* del activo, sobre los diez. Cada punto es un activo; el eje horizontal es la correlación de Black $\text{corr}(r_t, \text{RV}_{t+1}^{21} - \text{RV}_t^{21})$, el vertical el rescate $\max(\text{M10}, \text{AutoML}) - \text{M5}$. La recta de regresión baja con el *leverage*: a más *leverage* negativo, más rescate (Pearson $r = -0,56$, $p = 0,093$; tendencia significativa al $\alpha = 0,10$ pre-registrado). Nueve de los diez la siguen; ROKU, señalado, es la excepción. Fuente: `leverage_low_panel10.json`.

k -medias (MacQueen 1967 [71]; Lloyd 1982 [77]), enlace de Ward (Ward 1963 [72]), mezcla gaussiana (Dempster *et al.* 1977 [31]) y clustering espectral (Ng *et al.* 2002 [73]).

Los cuatro coinciden en una partición unánime y bien separada (Tabla 5.8): con tres grupos, el índice de Rand ajustado entre cualquier par de métodos vale uno (Hubert y Arabie 1985 [75]). Cada grupo trae asociado un canal de rescate distinto: los índices de *leverage* fuerte (SPY, QQQ, XLF, DIA, XLK, XLE), donde el mejor canal es AutoML; los de *leverage* invertido (SMCI, UNG), donde el mejor canal es M10; y los volátiles (ROKU, MARA), donde de nuevo gana AutoML.

El cierre lo da la geometría. Al proyectar la naturaleza de los diez sobre sus dos primeras componentes principales, el primer eje recupera casi exactamente el *leverage*: la correlación entre la primera componente y `leverage_corr` es $r = 0,84$ (Figura 5.9). Sin etiquetas de rescate, el clustering ordena los activos por el mismo eje que la ley de la Sección 5.2.1: el *leverage* es el eje que separa la naturaleza de los activos, y también el que decide qué canal rescata a cada uno. La Figura 5.10 lo aterriza en dos casos trabajados, XLE rescatado por el régimen y MARA por la vía del *leverage* invertido.

Una cautela, la misma del principio. Esto es exploratorio: con diez activos el clustering describe, no confirma. El cluster predice el *tipo* de canal que rescata cada grupo, no el modelo exacto que ganará por activo: qué derivada concreta lidera puede cambiar dentro de un mismo grupo, y eso no es predecible con $n = 10$. La estructura es robusta como dibujo; no la presentamos como regla de asignación.

Tabla 5.8: Clustering de la naturaleza de los diez activos (cinco rasgos: *leverage*, retorno medio en Crisis, fracción en Crisis, volatilidad OOS, sesgo del agente). Arriba, calidad por método con $K = 3$: silueta y Rand ajustado frente a k -medias. Abajo, perfil de cada cluster (*leverage* medio) y su mejor canal de rescate. Consenso unánime entre los cuatro métodos (Rand = 1,0). Fuente: `cluster_panel10.json`.

Método ($K = 3$)	Silueta	Rand vs k -medias
k -medias	0,55	1,0
Ward	0,55	1,0
Mezcla gaussiana	0,55	1,0
Espectral	0,55	1,0
<i>Perfil de cluster (naturaleza media y mejor canal)</i>		
Cluster	<i>leverage</i> medio	Mejor canal
C0 índices (SPY, QQQ, XLF, DIA, XLK, XLE)	−0,097	AutoML
C1 <i>leverage</i> invertido (SMCI, UNG)	+0,018	M10
C2 volátiles (ROKU, MARA)	−0,028	AutoML

El reparto de funciones tiene una causa. La regla protege el riesgo a través del régimen, el aprendiz gana accuracy modelando interacciones no lineales que la regla fija no alcanza, y la naturaleza del activo decide cuál de los dos pesa más. El *leverage* ordena el rescate del aprendiz (tendencia significativa al $\alpha = 0,10$) y el clustering recupera los mismos grupos sin etiquetas (Rand = 1,0), con el *leverage* como primer eje ($r = 0,84$). Sobre diez activos esto es un patrón fuerte, no un teorema, y ese límite abre la sección siguiente.




Figura 5.9: Proyección de la naturaleza de los diez activos sobre sus dos primeras componentes principales. Cada punto es un activo, coloreado por su cluster ($K = 3$, partición unánime de los cuatro métodos, Rand = 1,0). El primer eje recupera el *leverage* ($r = 0,84$ entre PC1 y *leverage_corr*): el clustering ordena los activos, sin etiquetas de rescate, por el mismo eje que la ley del *leverage*. La leyenda marca el mejor canal de cada grupo (C0/C2 AutoML, C1 M10). Fuente: `cluster_panel10.json`, `mechanism_panel.json`.




Figura 5.10: Dos casos trabajados, uno por canal. A la izquierda, XLE (*leverage* fuerte): el régimen es direccional y la regla rescata el riesgo del agente. A la derecha, MARA (*leverage* invertido): el régimen no informa el signo y el aprendiz rescata por la vía del sesgo del agente cruzado con el régimen. Cada panel muestra la dirección del agente, la del supervisor que rescata y el régimen vigente. Fuente: `cluster_panel10.json`, `mechanism_panel.json`.

5.3. Qué no sobrevive a un test

Cinco resultados del capítulo viven por debajo del listón de la significancia. La Tabla 5.9 los reúne con su contraste y su veredicto. Dos pesan más que el resto: la victoria sobre la trivial es nominal, y la protección de riesgo de la regla no sobrevive a Bonferroni. La regla, además, se invierte en SPY-bajista, una falsación que pre-registramos y que la agregación del panel resuelve.

Tabla 5.9: Resumen de los resultados que no alcanzan significancia plena, con su contraste y su veredicto. Cada fila enlaza una afirmación del capítulo con el test que la mide y con el JSON del que sale la cifra. La columna de veredicto distingue lo nominal de lo falsado y de lo exploratorio. Fuentes: `automl_runs/panel_mm25_inclGBM-XGB-SE_AUC_emb1_N0-150_step21_kfold_seed42.json`, `leverage_low_panel10.json`, `bullbear_confirmatory.json` (POOLED10), `cluster_panel10.json`.

Afirmación	Test y cifra	Veredicto
Una derivada bate a la trivial en accuracy	McNemar AutoML vs ZorroR sobre SPY, $p = 0,902$	Nominal ($n \approx 250$, a posteriori)
El rescate en accuracy escala con el <i>leverage</i>	Pearson $r = -0,56$, $p = 0,093$; Spearman $\rho = -0,59$, $p = 0,074$ (diez activos)	Tendencia al $\alpha = 0,10$; no $p < 0,05$ ni <i>leave-one-out</i>
La regla M8 rescata el riesgo agregado	$\Delta\text{Sharpe } pooled +0,60$, cota inferior de Bonferroni ($m = 3$) = $-0,047$	No sobrevive a la corrección múltiple
La regla M8 rescata el riesgo en SPY-bajista	$\Delta\text{Sharpe} = -1,49$ ($n = 50$)	Falsación pre-registrada, resuelta por el panel
La naturaleza define grupos de activos	Consenso de cuatro métodos, Rand = 1,0 (diez activos)	Exploratorio, no predictivo por activo

Dos cautelas estadísticas atraviesan estos cinco límites. La primera es la ventana corta: con $n \approx 250$ días, la significancia plena frente a la trivial está fuera de alcance por potencia, no por ausencia de señal. La segunda afecta al *pooled*, ya descontada en la Sección 5.1.3: el tamaño efectivo de la muestra es menor que el nominal y el intervalo queda algo optimista. Aun así, el ΔSharpe de M10 y AutoML excluye el cero con holgura, mientras la regla vive en el filo y queda fuera de lo que sobrevive a Bonferroni.

El panel cierra la pregunta con la que abrió: lo que en SPY no alcanzaba significancia en solitario la alcanza al agregar.

Capítulo 6

Conclusiones

El panel de diez activos cerró la pregunta que SPY dejó abierta: el rescate no es una anécdota de un índice, sobrevive a la agregación y se ordena por una propiedad del activo. El balance es claro: supervisar al agente con detectores estadísticos clásicos aporta un valor que sobrevive a un test, y ese valor vive en el rescate y en la interpretabilidad.

Ese valor tiene una jerarquía. STRATA rescata al agente en dirección y en riesgo, con significancia pareada. El aprendiz se apoya en sus señales y le saca un par de puntos de acierto a la regla. El apalancamiento del activo decide qué canal hace el rescate. Batir a la referencia trivial o generar alfa sobre el mercado queda como valor en punto o como línea futura.

6.1. Veredicto en tres niveles

La hipótesis pedía tres cosas a la vez: que el rescate sobreviva a un test, que se lea por dentro, y que su valor resida en las señales clásicas y no en la potencia del aprendiz. Las contrastamos por separado.

Nivel estadístico. En acierto direccional, el McNemar pareado frente al agente confirma el rescate de los tres supervisores sobre SPY, y aguanta partido por régimen en los tramos alcistas y bajistas del panel (Secciones 4.2 y 5.1). En riesgo, el resultado duro vive en la agregación: apilados los diez activos, el Δ Sharpe frente al agente excluye el cero para los tres supervisores. La grieta tiene nombre y la dejamos a la vista. Bajo corrección de Bonferroni, el rescate de riesgo lo sostienen el meta-learner y AutoML, mientras la regla cae justo por debajo del cero. La protección de riesgo de la regla es real con el intervalo simple y se desvanece al ajustar por número de pruebas.

Nivel mecánico. El rescate se lee detector a detector. Sobre SPY actúa un solo canal, el del régimen: RAM concentra todo el P&L de rescate y los otros dos detectores quedan inertes como reglas (Sección 4.3). En el panel la evidencia apunta igual, seguir el régimen bate a seguir al agente en la mayoría de los activos, y la intervención crece con la discrepancia entre la apuesta del agente y el estado del mercado. Las dos capas hacen trabajos disjuntos: la regla aporta el rescate de riesgo, los aprendices mejoran el acierto, y la ablación confirma que el aprendiz se apoya de verdad en STRATA, porque su acierto cae al quitar los detectores.

Nivel de universalidad. El enunciado mezclaba dos cosas que conviene separar: la atribución, que el valor del aprendiz venga de las señales de STRATA, y la equivalencia, que

un meta-learner libre no bata a la regla. La atribución se confirma sin ambigüedad: la cuota de Shapley de los detectores supera la mitad en los diez activos, y su ablación degrada al aprendiz (Sección 5.1). El criterio de fracaso, fijado de antemano, no se cumple. La equivalencia se refuta en su letra: el aprendiz supera a la regla en acierto por un par de puntos, montándose sobre las mismas señales para modelar las interacciones no lineales entre régimen y agente que una regla fija no alcanza, y empata en riesgo. La cláusula sustantiva, la atribución, se confirma; la indirecta, la equivalencia, se refuta a favor del aprendiz.

Veredicto. El rescate sobrevive a un test pareado en dirección y en riesgo, se lee por dentro y reside en las señales clásicas que un aprendiz potente redescubre y solo afina. La hipótesis se sostiene, con dos márgenes medidos: la regla rescata el riesgo pero no aguanta Bonferroni, y el aprendiz mejora a la regla en acierto sin distinguirse en riesgo. Falta un listón, la ventaja sobre la trivial no llega a significativa, compatible con un límite de muestra antes que con un fallo del mecanismo.

6.2. La ley del leverage

El rescate no es uniforme, y una sola propiedad ordena su intensidad: cuanto más fuerte es el *leverage effect* de un activo, más rescata el aprendiz en acierto (Sección 5.2). Lo llamamos tendencia, significativa al nivel $\alpha = 0,10$ que fijamos por adelantado, sólida sobre diez activos pero sin potencia para afirmar más. El agrupamiento de los activos por su naturaleza de mercado dibuja la misma estructura sin ver una sola métrica de rescate, y su primer eje recupera casi exactamente el apalancamiento. La naturaleza define un eje, ese eje es el *leverage*, y el *leverage* decide qué canal rescata cada activo: el régimen en los índices de apalancamiento fuerte, el aprendiz en los volátiles de apalancamiento débil. El patrón ordena el rescate del aprendiz, pero no el de la regla, y queda como hipótesis para trabajos futuros.

6.3. Aportaciones

La aportación central es metodológica: un protocolo de supervisión estadística sobre un agente opaco que es interpretable, calibrado por completo antes de mirar la evaluación, y contrastado con tests pareados y sus intervalos de confianza. Cada decisión de diseño se justifica por mecanismo o por literatura, cada cifra se traza a su fichero de origen, y la causalidad es estricta, con dos ventanas que nunca se mezclan. Pre-registramos las condiciones de fracaso: la regla se invierte en SPY-bajista, una falsación anotada por adelantado que la agregación del panel resuelve (Sección 5.3). La aportación empírica es doble: la demostración de que una capa de supervisión clásica rescata a un agente perdedor en acierto y en riesgo, y la ley que liga el apalancamiento del activo con el canal que lo rescata. Una prueba el resultado, la otra lo organiza.

6.4. Limitaciones

La limitación principal es el tamaño de la muestra. El agente solo existe en el periodo posterior al corte de conocimiento del modelo de lenguaje, lo que acota la evaluación a unos

doscientos cincuenta días por activo y deja la significancia plena fuera de alcance frente a una referencia exigente. Por eso la ventaja en acierto sobre la trivial es nominal, y el rescate de riesgo es significativo en el agregado de los diez activos pero no por activo individual. El alcance se estrecha donde el *leverage effect* es débil, porque ahí el régimen pierde su contenido direccional. Las dos regularidades de patrón viven al borde de su contraste, la ley del leverage como tendencia y el clustering como descripción exploratoria. El panel reúne estos límites con su contraste y su veredicto (Sección 5.3). El estudio se ciñe a un único agente y a una única ventana fuera de muestra, de modo que la generalización a otros agentes, universos y periodos queda por establecer.

6.5. Líneas futuras

Cada límite ancla una continuación. La vía directa para llevar la ventaja nominal en acierto a significancia plena es una muestra mayor, en horizonte temporal o en número de activos, sin réplicas sintéticas que inflarían la potencia. La complementariedad por régimen que documentamos sugiere un ensemble enrutado por régimen, que elija el supervisor según el estado del mercado. Repetir el esquema sobre otros agentes, otros modelos de lenguaje y otros mercados separaría lo propio de STRATA de lo propio de este agente, y pondría a prueba si la ley del leverage aguanta fuera del panel. Los modos de intervención intermedios, que atenúan la posición en lugar de sustituirla, quedan por explorar. El paso a producción tiene su camino: la regla opera desde el primer día, con sus umbrales fijados en calibración, sin reentrenamiento ni ventana de arranque. Los aprendices piden su ventana de calentamiento y un mantenimiento recurrente, y AutoML añade un coste de gobernanza, porque su modelo líder cambia en cada reentrenamiento y vigilar una pieza estable resulta más sencillo que auditar un objeto distinto cada vez. Y queda una línea más ambiciosa: en algunos activos una derivada de STRATA supera al pasivo en Sharpe yendo defensiva en el momento correcto (Sección 5.3), una señal nominal y leída a posteriori que marca un punto de partida para construir, con un contraste pre-registrado y una muestra que dé potencia, una estrategia que genere alfa direccional. Hasta superar ese contraste, el listón del trabajo sigue siendo el agente, no el mercado.

6.6. Cierre

Supervisar estadísticamente a un agente de lenguaje que pierde dinero recupera su acierto direccional y disciplina su riesgo, con evidencia que sobrevive a un test pareado, por un mecanismo que se puede leer por dentro y con su frontera de aplicabilidad delimitada. El valor probado es el rescate y la interpretabilidad; batir al mercado nunca fue el objetivo. STRATA vuelve fiable, dentro de sus límites medidos, a un agente que por sí solo no lo era.

Bibliografía

- [1] Alan Milligan. *Navigating the New Frontier: Effective Guardrail Implementations for LLMs in Financial Services*. LinkedIn. Literatura gris; recuperado en junio de 2026. 2024. URL: <https://www.linkedin.com/pulse/navigating-new-frontier-effective-guardrail-llms-alan-milligan-vdqre>.
- [2] Alejandro Lopez-Lira. «Can Large Language Models Trade? Testing Financial Theories with LLM Agents in Market Simulations». En: *arXiv preprint arXiv:2504.10789* (2025).
- [3] Marcos López de Prado. *Advances in Financial Machine Learning*. Hoboken, NJ: Wiley, 2018.
- [4] Yijia Xiao et al. «TradingAgents: Multi-Agents LLM Financial Trading Framework». En: *arXiv preprint arXiv:2412.20138* (2024). DOI: 10.48550/arXiv.2412.20138.
- [5] Ashish Vaswani et al. «Attention Is All You Need». En: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc., 2017, págs. 5998-6008.
- [6] Shunyu Yao et al. «ReAct: Synergizing Reasoning and Acting in Language Models». En: *International Conference on Learning Representations (ICLR)*. arXiv:2210.03629. 2023.
- [7] Lei Wang et al. «A Survey on Large Language Model Based Autonomous Agents». En: *Frontiers of Computer Science* 18.6 (2024), pág. 186345. DOI: 10.1007/s11704-024-40231-1.
- [8] Hongyang Yang, Xiao-Yang Liu y Christina Dan Wang. «FinGPT: Open-Source Financial Large Language Models». En: *arXiv preprint arXiv:2306.06031* (2023). FinLLM Workshop @ IJCAI 2023. DOI: 10.48550/arXiv.2306.06031.
- [9] Tianjiao Zhao et al. «AlphaAgents: Large Language Model based Multi-Agents for Equity Portfolio Constructions». En: *arXiv preprint arXiv:2508.11152* (2025).
- [10] Yoo Yeon Sung et al. «GRACE: A Granular Benchmark for Evaluating Model Calibration against Human Calibration». En: *arXiv preprint arXiv:2502.19684* (2025).
- [11] Mehul Damani et al. «Beyond Binary Rewards: Training LMs to Reason About Their Uncertainty». En: *arXiv preprint arXiv:2507.16806* (2025).
- [12] Zeping Li et al. «Behavioral Consistency Validation for LLM Agents: An Analysis of Trading-Style Switching through Stock-Market Simulation». En: *arXiv preprint arXiv:2602.07023* (2026). DOI: 10.48550/arXiv.2602.07023.

- [13] Lewen Yan et al. «TradeTrap: Are LLM-based Trading Agents Truly Reliable and Faithful?» En: *arXiv preprint arXiv:2512.02261* (2025). DOI: 10.48550/arXiv.2512.02261.
- [14] Changlun Li et al. «Will LLMs be Professional at Fund Investment? DeepFund: A Live Arena Perspective». En: *arXiv preprint arXiv:2503.18313* (2025). NeurIPS 2025 (poster). DOI: 10.48550/arXiv.2503.18313.
- [15] Mostapha Benhenda. «Look-Ahead-Bench: a Standardized Benchmark of Look-ahead Bias in Point-in-Time LLMs for Finance». En: *arXiv preprint arXiv:2601.13770* (2026). DOI: 10.48550/arXiv.2601.13770.
- [16] Virat Singh. *AI Hedge Fund: An AI-powered hedge fund team*. Repositorio de software, GitHub. <https://github.com/virattt/ai-hedge-fund>. 2024.
- [17] Varun Chandola, Arindam Banerjee y Vipin Kumar. «Anomaly detection: A survey». En: *ACM Computing Surveys* 41.3 (2009), págs. 1-58. DOI: 10.1145/1541880.1541882.
- [18] Haoyu Wang, Christopher M. Poskitt y Jun Sun. «AgentSpec: Customizable Runtime Enforcement for Safe and Reliable LLM Agents». En: *Proceedings of the IEEE/ACM International Conference on Software Engineering (ICSE)*. arXiv:2503.18666. 2026. DOI: 10.48550/arXiv.2503.18666.
- [19] Niclas Flehmig, Mary Ann Lundteigen y Shen Yin. «Perspectives on a Reliability Monitoring Framework for Agentic AI Systems». En: *arXiv preprint arXiv:2511.09178* (2025). DOI: 10.48550/arXiv.2511.09178.
- [20] James D. Hamilton. «A new approach to the economic analysis of nonstationary time series and the business cycle». En: *Econometrica* 57.2 (1989), págs. 357-384.
- [21] Andrew Ang y Geert Bekaert. «International asset allocation with regime shifts». En: *The Review of Financial Studies* 15.4 (2002), págs. 1137-1187. DOI: 10.1093/rfs/15.4.1137.
- [22] Massimo Guidolin y Allan Timmermann. «Asset allocation under multivariate regime switching». En: *Journal of Economic Dynamics and Control* 31.11 (2007), págs. 3503-3544.
- [23] Alan Moreira y Tyler Muir. «Volatility-managed portfolios». En: *The Journal of Finance* 72.4 (2017), págs. 1611-1644.
- [24] Fischer Black. «Studies of stock price volatility changes». En: *Proceedings of the 1976 Meetings of the American Statistical Association, Business and Economic Statistics Section*. 1976, págs. 177-181.
- [25] Andrew A. Christie. «The stochastic behavior of common stock variances: Value, leverage and interest rate effects». En: *Journal of Financial Economics* 10.4 (1982), págs. 407-432.
- [26] Rama Cont. «Empirical properties of asset returns: stylized facts and statistical issues». En: *Quantitative Finance* 1.2 (2001), págs. 223-236. DOI: 10.1080/713665670.
- [27] Lawrence R. Rabiner. «A tutorial on hidden Markov models and selected applications in speech recognition». En: *Proceedings of the IEEE* 77.2 (1989), págs. 257-286.

- [28] Olivier Cappé, Eric Moulines y Tobias Rydén. *Inference in Hidden Markov Models*. Springer Series in Statistics. New York: Springer, 2005. ISBN: 9780387402642. DOI: 10.1007/0-387-28982-8.
- [29] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006. ISBN: 9780387310732.
- [30] Leonard E. Baum et al. «A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains». En: *The Annals of Mathematical Statistics* 41.1 (1970), págs. 164-171.
- [31] Arthur P. Dempster, Nan M. Laird y Donald B. Rubin. «Maximum likelihood from incomplete data via the EM algorithm». En: *Journal of the Royal Statistical Society: Series B* 39.1 (1977), págs. 1-38. DOI: 10.1111/j.2517-6161.1977.tb01600.x.
- [32] Andrew J. Viterbi. «Error bounds for convolutional codes and an asymptotically optimum decoding algorithm». En: *IEEE Transactions on Information Theory* 13.2 (1967), págs. 260-269.
- [33] James D. Hamilton. *Time Series Analysis*. Princeton, NJ: Princeton University Press, 1994. ISBN: 9780691042893.
- [34] Ruey S. Tsay. *Analysis of Financial Time Series*. 3.^a ed. Wiley Series in Probability and Statistics. Hoboken, NJ: Wiley, 2010. ISBN: 9780470414354. DOI: 10.1002/9780470644560.
- [35] Peter J. Brockwell y Richard A. Davis. *Time Series: Theory and Methods*. 2.^a ed. Springer Series in Statistics. New York: Springer-Verlag, 1991. ISBN: 9780387974293.
- [36] Robert F. Engle. «Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation». En: *Econometrica* 50.4 (1982), págs. 987-1007.
- [37] Tim Bollerslev. «Generalized autoregressive conditional heteroskedasticity». En: *Journal of Econometrics* 31.3 (1986), págs. 307-327.
- [38] Robert F. Engle y Tim Bollerslev. «Modelling the persistence of conditional variances». En: *Econometric Reviews* 5.1 (1986), págs. 1-50. DOI: 10.1080/07474938608800095.
- [39] Daniel B. Nelson. «Stationarity and persistence in the GARCH(1,1) model». En: *Econometric Theory* 6.3 (1990), págs. 318-334. DOI: 10.1017/S0266466600005296.
- [40] Tim Bollerslev. «A conditionally heteroskedastic time series model for speculative prices and rates of return». En: *The Review of Economics and Statistics* 69.3 (1987), págs. 542-547.
- [41] Christian Francq y Jean-Michel Zakoïan. *GARCH Models: Structure, Statistical Inference and Financial Applications*. 2.^a ed. Chichester: Wiley, 2019. ISBN: 9781119313571. DOI: 10.1002/9781119313472.
- [42] Ryan P. Adams y David J. C. MacKay. «Bayesian online changepoint detection». En: *arXiv preprint arXiv:0710.3742* (2007).
- [43] Paul Fearnhead. «Exact and efficient Bayesian inference for multiple changepoint problems». En: *Statistics and Computing* 16.2 (2006), págs. 203-213.

- [44] Jushan Bai y Pierre Perron. «Estimating and testing linear models with multiple structural changes». En: *Econometrica* 66.1 (1998), págs. 47-78. DOI: 10.2307/2998540.
- [45] Jushan Bai y Pierre Perron. «Computation and analysis of multiple structural change models». En: *Journal of Applied Econometrics* 18.1 (2003), págs. 1-22. DOI: 10.1002/jae.659.
- [46] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2.^a ed. Springer Series in Statistics. New York: Springer, 2009. ISBN: 9780387848570. DOI: 10.1007/978-0-387-84858-7.
- [47] Jerome H. Friedman. «Greedy function approximation: A gradient boosting machine». En: *The Annals of Statistics* 29.5 (2001), págs. 1189-1232. DOI: 10.1214/aos/1013203451.
- [48] Tianqi Chen y Carlos Guestrin. «XGBoost: A scalable tree boosting system». En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, págs. 785-794. DOI: 10.1145/2939672.2939785.
- [49] Leo Breiman. «Bagging predictors». En: *Machine Learning* 24.2 (1996), págs. 123-140. DOI: 10.1007/BF00058655.
- [50] David H. Wolpert. «Stacked generalization». En: *Neural Networks* 5.2 (1992), págs. 241-259. DOI: 10.1016/S0893-6080(05)80023-1.
- [51] Mark J. van der Laan, Eric C. Polley y Alan E. Hubbard. «Super Learner». En: *Statistical Applications in Genetics and Molecular Biology* 6.1 (2007), Article 25. DOI: 10.2202/1544-6115.1309.
- [52] Erin LeDell y Sebastien Poirier. «H2O AutoML: Scalable Automatic Machine Learning». En: *Proceedings of the 7th ICML Workshop on Automated Machine Learning (AutoML)*. 2020. URL: https://www.automl.org/wp-content/uploads/2020/07/AutoML_2020_paper_61.pdf.
- [53] James A. Hanley y Barbara J. McNeil. «The meaning and use of the area under a receiver operating characteristic (ROC) curve». En: *Radiology* 143.1 (1982), págs. 29-36. DOI: 10.1148/radiology.143.1.7063747.
- [54] Tom Fawcett. «An introduction to ROC analysis». En: *Pattern Recognition Letters* 27.8 (2006), págs. 861-874. DOI: 10.1016/j.patrec.2005.10.010.
- [55] William F. Sharpe. «Mutual fund performance». En: *The Journal of Business* 39.1 (1966), págs. 119-138. DOI: 10.1086/294846.
- [56] William F. Sharpe. «The Sharpe ratio». En: *The Journal of Portfolio Management* 21.1 (1994), págs. 49-58.
- [57] Malik Magdon-Ismail et al. «On the maximum drawdown of a Brownian motion». En: *Journal of Applied Probability* 41.1 (2004), págs. 147-161. DOI: 10.1239/jap/1077134674.
- [58] Terry W. Young. *Calmar ratio: A smoother tool*. *Futures*, vol. 20, no. 12, p. 40. Revista profesional sin revisión por pares; sin DOI. 1991.

- [59] Leonard J. Tashman. «Out-of-sample tests of forecasting accuracy: an analysis and review». En: *International Journal of Forecasting* 16.4 (2000), págs. 437-450. DOI: 10.1016/S0169-2070(00)00065-0.
- [60] Christoph Bergmeir, Rob J. Hyndman y Bonsoo Koo. «A note on the validity of cross-validation for evaluating autoregressive time series prediction». En: *Computational Statistics & Data Analysis* 120 (2018), págs. 70-83. DOI: 10.1016/j.csda.2017.11.003.
- [61] William J. Conover. *Practical Nonparametric Statistics*. 3.^a ed. New York: Wiley, 1999.
- [62] Quinn McNemar. «Note on the sampling error of the difference between correlated proportions or percentages». En: *Psychometrika* 12.2 (1947), págs. 153-157.
- [63] Dimitris N. Politis y Joseph P. Romano. «The stationary bootstrap». En: *Journal of the American Statistical Association* 89.428 (1994), págs. 1303-1313.
- [64] David H. Bailey y Marcos López de Prado. «The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality». En: *The Journal of Portfolio Management* 40.5 (2014), págs. 94-107.
- [65] Carlo Emilio Bonferroni. *Teoria statistica delle classi e calcolo delle probabilità*. Inf. téc. R. Istituto Superiore di Scienze Economiche e Commerciali di Firenze, 1936, págs. 3-62.
- [66] Sture Holm. «A simple sequentially rejective multiple test procedure». En: *Scandinavian Journal of Statistics* 6.2 (1979), págs. 65-70.
- [67] Donald J. Schuirmann. «A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability». En: *Journal of Pharmacokinetics and Biopharmaceutics* 15.6 (1987), págs. 657-680.
- [68] Scott M. Lundberg y Su-In Lee. «A unified approach to interpreting model predictions». En: *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. Curran Associates, Inc., 2017, págs. 4766-4777. URL: <https://papers.nips.cc/paper/7062-a-unified-approach-to-interpreting-model-predictions>.
- [69] Scott M. Lundberg et al. «From local explanations to global understanding with explainable AI for trees». En: *Nature Machine Intelligence* 2.1 (2020), págs. 56-67. DOI: 10.1038/s42256-019-0138-9.
- [70] Leo Breiman. «Random forests». En: *Machine Learning* 45.1 (2001), págs. 5-32. DOI: 10.1023/A:1010933404324.
- [71] James B. MacQueen. «Some methods for classification and analysis of multivariate observations». En: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. Vol. 1. Berkeley, CA: University of California Press, 1967, págs. 281-297.
- [72] Joe H. Ward. «Hierarchical grouping to optimize an objective function». En: *Journal of the American Statistical Association* 58.301 (1963), págs. 236-244. DOI: 10.1080/01621459.1963.10500845.
- [73] Andrew Y. Ng, Michael I. Jordan y Yair Weiss. «On spectral clustering: Analysis and an algorithm». En: *Advances in Neural Information Processing Systems 14 (NIPS 2001)*. MIT Press, 2002, págs. 849-856.

- [74] Gideon Schwarz. «Estimating the dimension of a model». En: *The Annals of Statistics* 6.2 (1978), págs. 461-464. DOI: 10.1214/aos/1176344136.
- [75] Lawrence Hubert y Phipps Arabie. «Comparing partitions». En: *Journal of Classification* 2.1 (1985), págs. 193-218. DOI: 10.1007/BF01908075.
- [76] Ian T. Jolliffe. *Principal Component Analysis*. 2.^a ed. Springer Series in Statistics. New York: Springer, 2002. ISBN: 9780387954424.
- [77] Stuart P. Lloyd. «Least squares quantization in PCM». En: *IEEE Transactions on Information Theory* 28.2 (1982), págs. 129-137. DOI: 10.1109/TIT.1982.1056489.

Apéndice A

Demostraciones

Este anexo reúne las demostraciones y los desarrollos de los resultados enunciados en el capítulo 3. Cada sección recoge la prueba o la derivación de un resultado, indicado al comienzo por su enunciado y su label en el cuerpo de la memoria.

A.1. Recursión forward del HMM

Desarrollo de la Proposición 3.1 (Recursión forward), Sección 3.1.4.

Demostración. La inicialización es inmediata: $\alpha_1(k) = \mathbb{P}(x_1, z_1 = k) = \mathbb{P}(z_1 = k) \mathbb{P}(x_1 \mid z_1 = k) = \pi_k b_k(x_1)$, usando (*) en el segundo factor.

Para el paso recursivo partimos de la definición e introducimos el estado anterior z_t marginalizando sobre sus K valores posibles:

$$\alpha_{t+1}(j) = \mathbb{P}(x_{1:t+1}, z_{t+1} = j) = \sum_{k=1}^K \mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j).$$

Descomponemos cada sumando separando la última observación x_{t+1} del resto mediante la regla del producto,

$$\mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j) = \mathbb{P}(x_{t+1} \mid x_{1:t}, z_t = k, z_{t+1} = j) \mathbb{P}(x_{1:t}, z_t = k, z_{t+1} = j).$$

Por la independencia condicional de las emisiones (*), la observación x_{t+1} depende solo de su propio estado $z_{t+1} = j$, de modo que el primer factor es

$$\mathbb{P}(x_{t+1} \mid x_{1:t}, z_t = k, z_{t+1} = j) = \mathbb{P}(x_{t+1} \mid z_{t+1} = j) = b_j(x_{t+1}).$$

El segundo factor se descompone a su vez aislando la transición $z_t = k \rightarrow z_{t+1} = j$:

$$\mathbb{P}(x_{1:t}, z_t = k, z_{t+1} = j) = \mathbb{P}(z_{t+1} = j \mid x_{1:t}, z_t = k) \mathbb{P}(x_{1:t}, z_t = k).$$

La Markovianidad de la cadena, junto con la independencia condicional de las emisiones (*), hace que, fijado z_t , el estado z_{t+1} sea independiente de $x_{1:t}$ y de los estados anteriores (es la d-separación en el grafo del modelo); por tanto $\mathbb{P}(z_{t+1} = j \mid x_{1:t}, z_t = k) = A_{kj}$. El factor

restante es, por definición, $\alpha_t(k)$. Reuniendo los tres trozos,

$$\mathbb{P}(x_{1:t+1}, z_t = k, z_{t+1} = j) = b_j(x_{t+1}) A_{kj} \alpha_t(k),$$

y al sumar en k el factor $b_j(x_{t+1})$ no depende del índice de la suma y sale fuera:

$$\alpha_{t+1}(j) = b_j(x_{t+1}) \sum_{k=1}^K \alpha_t(k) A_{kj},$$

que es lo que se quería probar. $\square$

A.2. Filtrado y causalidad del HMM

Desarrollo de la Proposición 3.2 (Filtrado a partir del forward) y del Corolario 3.3 (Causalidad del filtrado), Sección 3.1.4.

Filtrado. Por la definición de probabilidad condicional y la de α_t ,

$$\gamma_t^f(k) = \mathbb{P}(z_t = k \mid x_{1:t}) = \frac{\mathbb{P}(x_{1:t}, z_t = k)}{\mathbb{P}(x_{1:t})} = \frac{\alpha_t(k)}{\sum_{j=1}^K \alpha_t(j)},$$

donde en el denominador se ha usado $\mathbb{P}(x_{1:t}) = \sum_j \mathbb{P}(x_{1:t}, z_t = j) = \sum_j \alpha_t(j)$. $\square$

Causalidad. Por la Proposición 3.2, γ_t^f se expresa a través de $\{\alpha_t(j)\}_{j=1}^K$. La inicialización $\alpha_1(k) = \pi_k b_k(x_1)$ depende solo de x_1 y, por la recursión de la Proposición 3.1, cada $\alpha_t(j)$ se obtiene de $\alpha_{t-1}(\cdot)$ y de x_t . Por inducción sobre t , $\alpha_t(j)$ es función de $x_{1:t}$, luego también lo es γ_t^f . $\square$

A.3. Fórmulas de actualización del paso M de Baum-Welch

Desarrollo de las reestimaciones del paso M del algoritmo de Baum-Welch, Sección 3.1.4. La distribución inicial y la matriz de transición se actualizan como frecuencias esperadas,

$$\hat{\pi}_k = \mathbb{P}(z_1 = k \mid x_{1:T}), \quad \hat{A}_{ij} = \frac{\sum_{t=1}^{T-1} \mathbb{P}(z_t = i, z_{t+1} = j \mid x_{1:T})}{\sum_{t=1}^{T-1} \mathbb{P}(z_t = i \mid x_{1:T})},$$

y las medias y covarianzas de cada régimen, como promedios ponderados por el posterior del estado,

$$\hat{\mu}_k = \frac{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T}) x_t}{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T})}, \quad \hat{\Sigma}_k = \frac{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T}) (x_t - \hat{\mu}_k)(x_t - \hat{\mu}_k)^\top}{\sum_{t=1}^T \mathbb{P}(z_t = k \mid x_{1:T})},$$

donde la media $\hat{\mu}_k$ que interviene en $\hat{\Sigma}_k$ es la ya reestimada en esa misma iteración.

A.4. Recursión de Viterbi

Desarrollo del algoritmo de Viterbi, Sección 3.1.4. Si $\delta_t(j) = \max_{z_{1:t-1}} \mathbb{P}(z_{1:t-1}, z_t = j, x_{1:t} \mid \lambda)$ es la probabilidad de la mejor trayectoria que termina en el estado j en el instante t , la recursión es

$$\delta_{t+1}(j) = b_j(x_{t+1}) \max_{1 \leq k \leq K} \delta_t(k) A_{kj}, \quad \delta_1(k) = \pi_k b_k(x_1),$$

y la trayectoria óptima se recupera memorizando en cada paso el estado k que alcanza el máximo y recorriéndolos hacia atrás desde T .

A.5. Monotonía del algoritmo EM

Demostración del Lema 3.4 (Monotonía de EM), Sección 3.1.4.

Demostración. Para cualquier parámetro θ descomponemos la log-verosimilitud observada tomando esperanza sobre $z_{1:T}$ con la ley del paso E, $\mathbb{P}(\cdot \mid x_{1:T}, \lambda)$, en la identidad $\log \mathbb{P}(x_{1:T} \mid \theta) = \log \mathbb{P}(x_{1:T}, z_{1:T} \mid \theta) - \log \mathbb{P}(z_{1:T} \mid x_{1:T}, \theta)$, cuyo miembro izquierdo no depende de $z_{1:T}$:

$$\log \mathbb{P}(x_{1:T} \mid \theta) = Q(\theta \mid \lambda) - H(\theta \mid \lambda),$$

con $Q(\theta \mid \lambda) = \mathbb{E}_{z|x,\lambda}[\log \mathbb{P}(x_{1:T}, z_{1:T} \mid \theta)]$ y $H(\theta \mid \lambda) = \mathbb{E}_{z|x,\lambda}[\log \mathbb{P}(z_{1:T} \mid x_{1:T}, \theta)]$. El paso M elige $\lambda' = \arg \max_{\theta} Q(\theta \mid \lambda)$, luego $Q(\lambda' \mid \lambda) \geq Q(\lambda \mid \lambda)$. Por la desigualdad de Gibbs (un caso de la de Jensen),

$$H(\lambda \mid \lambda) - H(\lambda' \mid \lambda) = \text{KL}(\mathbb{P}(\cdot \mid x_{1:T}, \lambda) \parallel \mathbb{P}(\cdot \mid x_{1:T}, \lambda')) \geq 0.$$

Restando ambas descomposiciones,

$$\log \mathbb{P}(x_{1:T} \mid \lambda') - \log \mathbb{P}(x_{1:T} \mid \lambda) = \underbrace{Q(\lambda' \mid \lambda) - Q(\lambda \mid \lambda)}_{\geq 0} + \underbrace{H(\lambda \mid \lambda) - H(\lambda' \mid \lambda)}_{\geq 0} \geq 0. \quad \square$$

A.6. Estacionariedad y varianza incondicional del GARCH(1, 1)

Demostración del Teorema 3.5 (Estacionariedad en covarianza del GARCH(1, 1)), Sección 3.1.5.

Demostración. Supongamos primero que existe una solución estacionaria en covarianza, lo que significa, en particular, que $\text{Var}(\epsilon_t)$ es finita y no depende de t ; la llamamos $\bar{\sigma}^2 := \text{Var}(\epsilon_t)$. Calculamos la varianza incondicional de ϵ_t por la ley de la varianza total, usando que $\mathbb{E}[\epsilon_t] = 0$ (pues $\mathbb{E}[\epsilon_t] = \mathbb{E}[\sigma_t] \mathbb{E}[\eta_t] = 0$, al ser σ_t función del pasado e independiente de η_t , y $\mathbb{E}[\eta_t] = 0$):

$$\text{Var}(\epsilon_t) = \mathbb{E}[\epsilon_t^2] = \mathbb{E}[\mathbb{E}[\epsilon_t^2 \mid \mathcal{F}_{t-1}]],$$

donde $\mathcal{F}_{t-1}$ es la información hasta $t - 1$. Como σ_t es función de $\mathcal{F}_{t-1}$ y η_t es independiente

de $\mathcal{F}_{t-1}$ con $\mathbb{E}[\eta_t^2] = \text{Var}(\eta_t) = 1$,

$$\mathbb{E}[\epsilon_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2 \mathbb{E}[\eta_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2,$$

de donde $\mathbb{E}[\epsilon_t^2] = \mathbb{E}[\sigma_t^2]$. La misma identidad aplicada en $t-1$ da $\mathbb{E}[\epsilon_{t-1}^2] = \mathbb{E}[\sigma_{t-1}^2]$. Tomamos ahora esperanzas en la recursión (3.1):

$$\mathbb{E}[\sigma_t^2] = \omega + \alpha \mathbb{E}[\epsilon_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2] = \omega + \alpha \mathbb{E}[\sigma_{t-1}^2] + \beta \mathbb{E}[\sigma_{t-1}^2].$$

Por estacionariedad, $\mathbb{E}[\sigma_t^2] = \mathbb{E}[\sigma_{t-1}^2] =: m$, constante en el tiempo. Sustituyendo,

$$m = \omega + (\alpha + \beta) m \iff m(1 - \alpha - \beta) = \omega.$$

Como $\omega > 0$ y $m = \mathbb{E}[\sigma_t^2] = \text{Var}(\epsilon_t) > 0$ es finita, el factor $1 - \alpha - \beta$ ha de ser estrictamente positivo, es decir, $\alpha + \beta < 1$, y entonces

$$\text{Var}(\epsilon_t) = m = \frac{\omega}{1 - \alpha - \beta}.$$

Esto prueba la necesidad de la condición y la fórmula de la varianza.

Recíprocamente, supongamos $\alpha + \beta < 1$ y construyamos una solución estacionaria. Reescribiendo $\alpha \epsilon_{s-1}^2 + \beta \sigma_{s-1}^2 = (\alpha \eta_{s-1}^2 + \beta) \sigma_{s-1}^2$ e iterando la recursión (3.1) hacia atrás n pasos,

$$\sigma_t^2 = \omega \sum_{i=0}^{n-1} \prod_{l=1}^i (\alpha \eta_{t-l}^2 + \beta) + \left(\prod_{l=1}^n (\alpha \eta_{t-l}^2 + \beta) \right) \sigma_{t-n}^2.$$

En lugar de suponer la solución dada, la *construimos* como la serie

$$\sigma_t^2 := \omega \sum_{i=0}^{\infty} \prod_{l=1}^i (\alpha \eta_{t-l}^2 + \beta),$$

y comprobamos que está bien definida. Los η_{t-l} son i.i.d. con $\mathbb{E}[\alpha \eta_{t-l}^2 + \beta] = \alpha + \beta$ y los factores de cada producto son independientes, de modo que el término i -ésimo tiene esperanza $\omega (\alpha + \beta)^i$. Como todos los sumandos son no negativos, el teorema de convergencia monótona permite intercambiar esperanza y suma:

$$\mathbb{E}[\sigma_t^2] = \omega \sum_{i=0}^{\infty} (\alpha + \beta)^i = \frac{\omega}{1 - \alpha - \beta} < \infty,$$

y la serie geométrica converge por ser $\alpha + \beta < 1$. La serie que define σ_t^2 converge así en L^1 (y casi seguramente), tiene esperanza finita y constante, y por construirse con las mismas variables i.i.d. desplazadas en el tiempo su ley no depende de t ; además satisface la recursión (3.1). El término residual de la iteración finita, $\left(\prod_{l=1}^n (\alpha \eta_{t-l}^2 + \beta) \right) \sigma_{t-n}^2$, tiene esperanza $(\alpha + \beta)^n \mathbb{E}[\sigma_{t-n}^2] \rightarrow 0$, lo que confirma que la serie es el límite de las iteraciones.

Queda ver que $\epsilon_t = \sigma_t \eta_t$ es estacionario en covarianza, esto es, que su media, su varianza y sus autocovarianzas no dependen de t . La media es $\mathbb{E}[\epsilon_t] = \mathbb{E}[\sigma_t] \mathbb{E}[\eta_t] = 0$, y la varianza, $\mathbb{E}[\epsilon_t^2] = \mathbb{E}[\sigma_t^2] = \omega / (1 - \alpha - \beta)$, es finita y constante. Para las autocovarianzas, fijado $h \geq 1$,

como η_t es independiente de $\mathcal{F}_{t-1}$ con $\mathbb{E}[\eta_t] = 0$ y ϵ_{t-h} es $\mathcal{F}_{t-1}$ -medible,

$$\mathbb{E}[\epsilon_t \epsilon_{t-h}] = \mathbb{E}[\epsilon_{t-h} \mathbb{E}[\epsilon_t \mid \mathcal{F}_{t-1}]] = 0, \quad \text{ya que } \mathbb{E}[\epsilon_t \mid \mathcal{F}_{t-1}] = \sigma_t \mathbb{E}[\eta_t] = 0.$$

Media nula, varianza finita constante y autocovarianzas nulas: el proceso es estacionario en covarianza, lo que cierra la equivalencia [39, 41]. $\square$

A.7. Verosimilitud condicional del GARCH(1, 1)- t

Derivación de la log-verosimilitud condicional, Sección 3.1.5. Sea f_ν la densidad de la t de Student estandarizada de ν grados de libertad. Condicionada a la información hasta $t-1$, la innovación $\epsilon_t = \sigma_t \eta_t$ tiene densidad $\frac{1}{\sigma_t} f_\nu(\epsilon_t/\sigma_t)$, ya que es un cambio de escala de η_t por el factor σ_t , que es conocido en $t-1$. La log-verosimilitud condicional de la muestra $\epsilon_{1:T}$, dado un valor inicial σ_1^2 , es la suma de las contribuciones diarias

$$\ell(\theta) = \sum_{t=1}^T \left[\log f_\nu\left(\frac{\epsilon_t}{\sigma_t}\right) - \log \sigma_t \right],$$

donde cada σ_t se obtiene recorriendo la recursión (3.1) con los parámetros θ en evaluación. El término $-\log \sigma_t$ es el jacobiano del cambio de variable de η_t a ϵ_t .

A.8. Recursión de Adams–MacKay del BOCPD

Demostración de la Proposición 3.6 (Recursión de Adams–MacKay), Sección 3.1.6.

Demostración. Partimos de la conjunta del instante t e introducimos la run-length anterior marginalizando sobre sus valores posibles:

$$\mathbb{P}(r_t, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_t, r_{t-1}, x_{1:t}).$$

Cada sumando se descompone separando la nueva observación x_t del pasado $x_{1:t-1}$ mediante la regla del producto,

$$\mathbb{P}(r_t, r_{t-1}, x_{1:t}) = \mathbb{P}(r_t \mid r_{t-1}, x_{1:t-1}) \mathbb{P}(x_t \mid r_t, r_{t-1}, x_{1:t-1}) \mathbb{P}(r_{t-1}, x_{1:t-1}).$$

El primer factor es la dinámica de la run-length, que por construcción del modelo solo depende de r_{t-1} : dado un tramo de longitud r_{t-1} , en el paso siguiente o bien hay cambio, y entonces $r_t = 0$ con probabilidad $H(r_{t-1} + 1)$, o bien no lo hay, y entonces $r_t = r_{t-1} + 1$ con probabilidad $1 - H(r_{t-1} + 1)$. Es decir,

$$\mathbb{P}(r_t \mid r_{t-1}, x_{1:t-1}) = \begin{cases} H(r_{t-1} + 1), & r_t = 0, \\ 1 - H(r_{t-1} + 1), & r_t = r_{t-1} + 1, \\ 0, & \text{en otro caso.} \end{cases}$$

El segundo factor es la predictiva del dato nuevo dentro del tramo: condicionada a r_{t-1} , y por la independencia entre segmentos, la observación x_t depende solo de las r_{t-1} observaciones del tramo en curso, lo que da $\pi_{\text{pred}}^{(r_{t-1})}$. El tercer factor es la conjunta del paso anterior, ya disponible. En ambos mensajes interviene esta misma predictiva $\pi_{\text{pred}}^{(r_{t-1})}$ porque x_t se evalúa contra el segmento en curso, de longitud r_{t-1} : el reinicio se materializa en la run-length siguiente, $r_t = 0$, no en la pertenencia de x_t , que todavía corresponde a ese segmento.

Como la transición de la run-length concentra toda su masa en dos destinos, la marginalización sobre r_{t-1} se reparte en dos casos. Si $r_t = r_{t-1} + 1 > 0$, solo contribuye el valor concreto $r_{t-1} = r_t - 1$ (no hay otra forma de llegar a esa run-length sin reinicio), de donde

$$\mathbb{P}(r_t = r_{t-1} + 1, x_{1:t}) = \mathbb{P}(r_{t-1}, x_{1:t-1}) (1 - H(r_{t-1} + 1)) \pi_{\text{pred}}^{(r_{t-1})},$$

que es el mensaje de crecimiento. Si $r_t = 0$, contribuyen *todos* los valores de r_{t-1} , pues desde cualquier longitud puede producirse un reinicio, y la suma da

$$\mathbb{P}(r_t = 0, x_{1:t}) = \sum_{r_{t-1}} \mathbb{P}(r_{t-1}, x_{1:t-1}) H(r_{t-1} + 1) \pi_{\text{pred}}^{(r_{t-1})},$$

que es el mensaje de reinicio. Finalmente, la posterior se obtiene de la conjunta dividiendo por la verosimilitud marginal del dato, $\mathbb{P}(x_{1:t}) = \sum_r \mathbb{P}(r_t = r, x_{1:t})$, lo que da la normalización del enunciado. $\square$

A.9. Pseudo-residuos del boosting logístico

Demostración de la Proposición 3.11 (Pseudo-residuos del boosting logístico), Sección 3.2.3.

Demostración. Con $p = \sigma(F)$ se tiene $dp/dF = p(1 - p)$. La contribución de un dato a la pérdida es $L = -y \log p - (1 - y) \log(1 - p)$, de donde

$$\frac{\partial L}{\partial p} = -\frac{y}{p} + \frac{1 - y}{1 - p} = \frac{p - y}{p(1 - p)}.$$

Por la regla de la cadena, $\partial L / \partial F = (\partial L / \partial p) p(1 - p) = p - y$, y el pseudo-residuo es su opuesto, $y - p$ [47]. $\square$

A.10. Pesos óptimos y ganancia de una división en XGBoost

Demostración de la Proposición 3.12 (Pesos óptimos y ganancia de una división), Sección 3.2.4.

Demostración. La expansión de Taylor de segundo orden de la pérdida y el descarte del término constante $l(y_i, \hat{y}_i^{(t-1)})$ dan

$$\tilde{\mathcal{L}}^{(t)} = \sum_{i=1}^n [g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t(\mathbf{x}_i)^2] + \Omega(f_t).$$

Como $f_t(\mathbf{x}_i) = w_j$ para todo $i \in I_j$, se agrupa por hoja,

$$\tilde{\mathcal{L}}^{(t)} = \sum_{j=1}^T \left[G_j w_j + \frac{1}{2}(H_j + \lambda) w_j^2 \right] + \gamma T.$$

Para la pérdida logística, la Proposición 3.11 da $g_i = p_i - y_i$ y un cálculo análogo $h_i = p_i(1 - p_i) \geq 0$, luego $H_j + \lambda > 0$ y cada sumando es una parábola convexa en w_j . Su mínimo está en $w_j^* = -G_j/(H_j + \lambda)$, con valor $-\frac{1}{2}G_j^2/(H_j + \lambda)$; sumando sobre las hojas se obtiene $\tilde{\mathcal{L}}^*(q)$. La ganancia de una división es la diferencia entre el objetivo de la hoja madre y el de los dos hijos, que arroja la expresión del enunciado [48]. $\square$